

Стюарт Рассел, Питер Норвиг

Искусственный интеллект: современный подход, 2-е изд.

Часть V. Неопределенные знания и рассуждения в условиях неопределенности

Содержание

Часть V. Неопределенные знания и рассуждения в условиях неопределенности	1
Глава 13. Неопределенность	1
Глава 14. Вероятностные рассуждения	40
Глава 15. Вероятностные рассуждения во времени	97
Глава 16. Принятие простых решений	157
Глава 17. Принятие сложных решений	195

Часть V. Неопределенные знания и рассуждения в условиях неопределенности

Неопределенность 622 Вероятностные рассуждения 660 Вероятностные рассуждения во времени 718 Принятие простых решений 778 Принятие сложных решений 815

Глава 13. Неопределенность

13 Неопределенность В данной главе показано, как должен действовать агент в условиях недостающей информации.

13.1. Действия в условиях неопределенности Логические агенты, описанные в частях III и IV, пользовались базами знаний, эпистемологический вклад которых состоял в том, что содержащиеся в них высказывания были истинными, ложными или неизвестными. Если агенту известно достаточно фактов о его среде, соответствующий логический подход позволяет ему формировать планы, которые гарантированно будут работать. Такая организация функционирования агента является очень удобной. К сожалению, *tir* агенты почти никогда не имеют доступа ко всем необходимым сведениям о своей среде. Поэтому агенты должны действовать в условиях неопределенности. Например, агент в мире вампуса, описанный в главе 7, имеет датчики, которые сообщают ему только локальную информацию; основная часть мира не является для него непосредственно наблюдаемой. Агент в мире вампуса часто оказывается в такой ситуации, что не имеет возможности определить, какой из двух квадратов содержит яму. Если эти

квадраты находятся на пути к золоту, то агенту может потребоваться испытать судьбу и войти наугад в один из этих двух квадратов.

Реальный мир намного сложнее по сравнению с миром вампуса. Логический агент не всегда имеет возможность составить полное и правильное описание того, как будут осуществляться его действия. Предположим, например, что агент-водитель такси желает отвести пассажира в аэропорт, чтобы тот успел на самолет, и составляет план A90, в котором предусматривается выезд из дома за 90 минут до вылета самолета и вождение на приемлемой скорости. Но даже если аэропорт находится от дома на расстоянии примерно 15 миль, агент все равно не сможет со всей определенностью сделать вывод, что "план A90 позволит нам прибыть в аэропорт вовремя". Вместо этого он приходит к более слабому заключению: "План A90 позволит нам прибыть в аэропорт вовремя, если только в моем автомобиле не возникнет неисправность или не закончится топливо, и я не попаду в аварию, и не будет аварий на мосту, и самолет не вылетит раньше времени, и...". Ни одно из этих условий нельзя довести до логического вывода, поэтому невозможно сформировать логическим путем заключение о том, что реализация плана будет успешной. Это — один из примеров проблемы спецификации, которая упоминалась в главе 10.

Если логический агент не сможет сделать заключение о том, какая именно конкретная стратегия позволяет ему достичь цели, то не сможет действовать. Условное планирование позволяет до некоторой степени преодолеть неопределенность, но только если агент сможет получать требуемую информацию с помощью действий, предусматривающих применение датчиков, и только если количество различных непредвиденных ситуаций не слишком велико. Еще одно возможное решение состоит в том, чтобы наделить агента простой, но, возможно, неправильной теорией мира, которая позволит ему составить план; можно надеяться на то, что подобные планы чаще всего будут выполнимыми, но если происходящие события будут противоречить теории агента, возникнут проблемы. Более того, даже сам выбор компромисса между точностью и полезностью этой рабочей теории агента, по-видимому, потребует формирования рассуждений о неопределенности. В конечном итоге ни один чисто логический агент не сможет прийти к выводу, что план A90 — именно то, что следует делать.

Тем не менее предположим, что план A90 действительно представляет собой правильное руководство к действию. Что подразумевается под этим утверждением? Как было описано в главе 2, под этим подразумевается, что из всех планов, которые могут быть выполнены, только план A90, по всей видимости, позволит максимизировать показатели производительности агента при наличии всей той информации о своей среде, которую имеет агент. Показатели производительности включают своевременную доставку пассажира в аэропорт к указанному рейсу, предотвращение продолжительного, непродуктивного ожидания в аэропорту и

избавление от необходимости дополнительно оплачивать проезд по скоростным участкам шоссе.

Информация, которой обладает агент, не позволяет гарантировать получение ни одного из этих результатов выполнения плана A90, но может обеспечить достижение некоторой степени уверенности в том, что эти результаты будут достигнуты. Другие планы, такие как A120, способны повысить степень уверенности агента в том, что он доставит пассажира в аэропорт вовремя, но вместе с тем повысят вероятность продолжительного ожидания, ^ Таким образом, выбор правильной стратегии — рационального решения — зависит и от относительной важности различных целей, и от вероятности того (от степени уверенности в том), что они могут быть достигнуты. Эти идеи будут уточнены в оставшейся части данного раздела в целях подготовки к разработке общих теорий проведения рассуждений в условиях неопределенности и принятия рациональных решений, которые будут представлены в этой и последующих главах.

Учет наличия неопределенных знаний В этом разделе характер неопределенных знаний рассматривается более подробно. Для иллюстрации связанных с этим понятий будет использоваться простой пример из области диагностики. Диагностика (проводимая при обследовании пациента, при ремонте автомобиля или в других областях) представляет собой задачу, в которой почти всегда приходится сталкиваться с неопределенностью. Попробуем записать правила для диагностики заболеваний зубов с использованием логики первого порядка, чтобы можно было ознакомиться с тем, какие трудности возникают при осуществлении логического подхода. Рассмотрим следующее правило:

$$Vp \text{ Symptom}(p, \text{Toothache}) \Rightarrow \text{Disease}(p, \text{Cavity})$$

Проблема состоит в том, что это правило является неверным. Не все пациенты с зубной болью имеют в зубе дупло; у некоторых из них встречается заболевание десен, нарыв или одна из нескольких других проблем:

$$Vp \text{ Symptom}(p, \text{Toothache}) \Rightarrow \text{Disease}(p, \text{Cavity}) \vee \text{Disease}(p, \text{GumDisease}) \vee \text{Disease}(p, \text{Abscess}) \dots$$

К сожалению, для того чтобы сделать это правило истинным, мы вынуждены ввести в него почти бесконечный список возможных причин. Еще одна попытка может состоять в том, чтобы это правило было преобразовано в причинное правило:

$$Vp \text{ Disease}(p, \text{Cavity}) \Rightarrow \text{Symptom}(p, \text{Toothache})$$
 Но и это правило нельзя назвать верным; не все зубы, в которых имеется дупло, вызывают боль. Единственный способ откорректировать данное правило состоит в том, чтобы сделать его логически исчерпывающим: дополнить левую сторону описаниями всех обстоятельств, которые должны иметь место для того, чтобы дупло вызывало

зубную боль. Но даже в этом случае с целью правильной диагностики необходимо также учитывать вероятность того, что наличие зубной боли у пациента и наличие дупла в зубе могут быть не связаны.

Таким образом, попытка использовать логику первого порядка для представления знаний в таких проблемных областях, как медицинская диагностика, оканчивается неудачей по трем основным причинам, описанным ниже.

- $\wedge$ Экономия усилий. Для формирования полного множества антецедентов или консеквентов, необходимого для составления правила, не имеющего исключений, требуется слишком много работы, а само применение таких правил является слишком сложным.
- $\wedge$ Отсутствие теоретических знаний. Медицинская наука не имеет полной теории для данной проблемной области.
- $\wedge$ Отсутствие практических знаний. Даже если известны все правила, может оставаться неопределенность в отношении диагноза данного конкретного пациента, поскольку все необходимые обследования не были или не могли быть выполнены.

Связь между зубной болью и наличием дупла не является просто логическим следствием, действующим в обоих направлениях. Такая ситуация типична не только для данной области медицинской диагностики, но и для большинства других областей, в которых требуется формирование суждений об определенных ситуациях: юриспруденция, экономика, проектирование, ремонт автомобилей, садоводство, датирование ископаемых находок и т.д. Знания агента в лучшем случае позволяют сформировать относящиеся к делу высказывания только с определенной $\wedge$ степенью уверенности (degree of belief). Основным применяемым нами инструментальным средством для учета степеней уверенности будет $\wedge$ теория вероятностей, в которой каждому высказыванию присваивается числовое значение степени уверенности от 0 до 1. (Некоторые альтернативные методы формирования рассуждений в условиях неопределенности описаны в разделе 14.7.) $\wedge$ Вероятности предоставляют способ суммарного учета неопределенности, возникающей по причинам экономии усилий и отсутствия знаний. Мы не можем знать со всей уверенностью, что беспокоит данного конкретного пациента, но можем быть уверенны-

ми в том, что, скажем, в 80 случаях из 100 (т.е. с вероятностью 0,8) у пациента в зубе имеется дупло, если он испытывает зубную боль. Это означает, что из числа всех ситуаций, неотличимых от текущей ситуации в рамках тех знаний, которыми обладает агент, пациент в 80% этих ситуаций должен иметь дупло в зубе. Такая уверенность может быть основана на статистических данных (о том, что у 80% пациентов с зубной болью, наблюдавшихся до сих пор, было обнаружено дупло в зубе), или на основе некоторых общих правил, или с использованием определенной комбинации сведений, полученных из разных источников. В этих 80% дана сводная информация обо всех случаях, в которых присутствовали все факторы, необходимые

для того, чтобы дупло вызывало зубную боль, и о других случаях, в которых у пациента были и дупло, и зубная боль, но эти два обстоятельства оказались несвязанными. Эти недостающие 20% подытоживают все другие возможные причины зубной боли, для подтверждения или отрицания которых мы либо затратили слишком мало усилий, либо не имели достаточно знаний.

Присваивание вероятности 0 данному конкретному высказыванию соответствует безусловной уверенности в том, что это высказывание ложно, а присваивание вероятности 1 соответствует безусловной уверенности, что высказывание истинно. Значения вероятности между 0 и 1 соответствуют промежуточным степеням уверенности в истинности высказывания. В действительности само высказывание может быть либо истинным, либо ложным независимо от этого. Важно отметить, что степень уверенности отличается от степени истинности. Вероятность 0,8 не означает "истинно на 80%", а просто указывает на 80%-ную степень уверенности, т.е. на довольно обоснованные ожидания. Таким образом, теория вероятностей вносит такой же онтологический вклад, как и логика, т.е. позволяет указать, являются ли некоторые факты действительными в этом мире. Степени истинности, в отличие от степеней уверенности, являются предметом нечеткой логики, которая рассматривается в разделе 14.7.

В логике такое высказывание, как "У пациента в зубе имеется дупло", является истинным или ложным в зависимости от интерпретации и от мира; оно истинно именно тогда, когда имеет место факт, на который оно ссылается. С другой стороны, в теории вероятностей такое высказывание, как "Вероятность того, что у данного пациент в зубе имеется дупло, равна 0,8", касается степени уверенности агента, а не относится непосредственно к самому миру. Эта степень уверенности зависит от результатов восприятия, полученных агентом до сих пор. Сами результаты восприятия представляют собой ¹ свидетельство, на котором основаны вероятностные утверждения. Например, предположим, что агент вытянул карту из растасованной колоды. Прежде чем посмотреть на эту карту, агент может присвоить значение вероятности $1/52$ такому событию, что карта окажется тузом пик, а после взгляда на вынутую из колоды карту соответствующая вероятность для того же высказывания примет значение 0 или 1. Таким образом, присваивание значения вероятности некоторому высказыванию аналогично утверждению о том, что данное конкретное логическое высказывание (или его отрицание) следует из базы знаний, а не о том, является ли оно истинным или ложным. Разумеется, оценка того, следует ли высказывание из базы знаний, может изменяться по мере добавления в базу знаний новых высказываний; и, по аналогии с этим, вероятности могут изменяться после получения дополнительных свидетельств¹.

¹ Эта ситуация полностью отличается от той, в которой некоторое высказывание становится истинным или ложным по мере того, как изменяется мир. Для учета

изменений в мире с помощью вероятностей требуются механизмы такого же рода (ситуации, интервалы и события), которые использовались в главе 10 для логических представлений. Эти механизмы рассматриваются в главе 15.

Поэтому во всех вероятностных утверждениях должно быть указано свидетельство, с учетом которого оценивалась данная вероятность. По мере получения агентом новых результатов восприятия его вероятностные оценки обновляются таким образом, чтобы в них отражались новые свидетельства. Вероятности, оцениваемые до получения свидетельства, называются априорными, или безусловными, вероятностями, а вероятности, оцениваемые после получения свидетельства, называются апостериорными, или условными, вероятностями. В большинстве случаев агент должен получать определенные свидетельства из результатов своих восприятий; после этого ему необходимо вычислять апостериорные вероятности результатов, которые его интересуют.

Неопределенность и рациональные решения Из-за наличия неопределенности способ принятия решений агентом изменяется коренным образом. В обычных условиях логический агент ставит перед собой цель и выполняет любой план, который гарантирует ее достижение. Действие в этом плане может быть выбрано или отвергнуто с учетом того, способствует ли оно достижению цели, независимо от наличия или отсутствия каких-либо иных действий, способствующих ее достижению. А если в ситуацию вмешивается неопределенность, такой подход становится неосуществимым. Снова рассмотрим план прибытия в аэропорт, A90. Предположим, что этот план имеет 95%-ные шансы на успех. Означает ли это, что решение по выбору данного плана является рациональным? Не обязательно: могут существовать другие планы, такие как A120, с большими вероятностями успеха.

Если для пассажира жизненно важно успеть на самолет, то стоит рискнуть тем, что ему придется дольше ждать в аэропорту. А что можно сказать о плане A110, который предусматривает заблаговременный выезд из дома за 24 часа до отправления самолета? В большинстве обстоятельств это — не лучший выбор, поскольку он предусматривает невыносимо долгое ожидание, даже несмотря на то, что почти полностью гарантирует своевременное прибытие в аэропорт.

Чтобы иметь возможность выбирать среди подобных вариантов, агент должен вначале получить информацию о $\wedge$ предпочтениях между различными возможными $\wedge$ результатами разных планов. Каждый конкретный результат представляет собой полностью определенное состояние, включая такие факторы, как своевременное прибытие агента и продолжительность ожидания в аэропорту. Для представления и формирования рассуждений с учетом предпочтений мы будем использовать $\wedge$ теорию полезности. (Термин "полезность" имеет англоязычный эквивалент "utility", который в данном контексте обозначает "свойство быть полезным", а не электростанцию или предприятие, предоставляющее

коммунальные услуги.) Теория полезности указывает, что каждое состояние имеет определенную степень полезности (или просто полезность) для агента и что агент предпочитает состояние с более высокой полезностью.

Полезность состояния является относительной для агента, предпочтения которого должна описывать функция полезности. Например, функции вознаграждения для игр, описанные в главе 6, представляют собой функции полезности. Полезность состояния, в котором белые могут победить в ходе какой-то шахматной партии, безусловно, высока для агента, играющего белыми, но низка для агента, играющего черными. Еще один пример состоит в том, что некоторые игроки (включая авторов этой книги) будут счастливы, сыграв вничью против чемпиона мира, а о других игроках (включая бывшего чемпиона мира) этого сказать нельзя. При этом не учитываются личные вкусы или предпочтения: читатель может подумать, что агент, который предпочитает шоколадным чипсам мороженое "Халапеньо" с добавлением компонентов жевательной резинки, — странный или даже бестолковый тип, но не сможет утверждать, что этот агент нерационален. В функции полезности может быть даже учтена польза от альтруистического поведения просто путем включения оценки благополучия других как одного из факторов, которые вносят вклад в полезность для самого агента.

Предпочтения, будучи выраженными в виде полезности, комбинируются с вероятностями в общей теории рациональных решений, называемой $\wedge$ теорией решений, следующим образом:

Теория решений = Теория вероятностей + Теория полезности
Фундаментальная идея теории решений состоит в том, что $\forall$ любой агент является рациональным тогда и только тогда, когда он выбирает действие, позволяющее достичь наибольшей ожидаемой полезности, усредненной по всем возможным результатам данного действия. Это — так называемый принцип максимальной ожидаемой полезности (Maximum Expected Utility — MEU). Мы наблюдали этот принцип в действии в главе 6, когда кратко рассматривали оптимальные решения в нардах, а ниже будет показано, что это — действительно полностью общий принцип.

Проект агента, действующего в соответствии с теорией решений
Набросок структуры агента, который использует теорию решений для выбора действий, приведен в листинге 13.1. На некотором уровне абстракции этот агент идентичен логическому агенту, описанному в главе 7. Основное различие состоит в том, что знания о текущем состоянии агента, действующего в соответствии с теорией решений, являются неопределенными; $\wedge$ доверительное состояние этого агента является представлением вероятностей всех возможных фактических состояний мира. Со временем агент накапливает больше свидетельств и его доверительное состояние изменяется. На основании своего доверительного состояния агент может

делать вероятностные предсказания результатов действий и поэтому выбирать действие с наивысшей ожидаемой полезностью. В настоящей и следующей главах изложение в основном сосредоточивается на задаче представления и вычисления с решения конкретных задач представления и обновления доверительного состояния, а также задач предсказания обстановки в среде. В главе 16 более подробно рассматривается теория полезности, а в главе 17 разрабатываются алгоритмы, применяемые для принятия сложных решений.

Листинг 13.1. Агент, действующий на основании теории решений, который выбирает рациональные действия. Этапы работы этого алгоритма подробно описываются в следующих пяти главах

```
function DT-Agent (percept) returns действие
  static:
    belief_state, доверительное состояние - вероятностные убеждения, касающиеся
    текущего состояния мира
  action, действие агента
```

обновить доверительное состояние `belief_state` с учетом действия `action` и восприятия `percept` вычислить результирующие вероятности для действий `actions` на основании описаний действий `action` и текущего доверительного состояния `belief_state` выбрать действие `action` с наивысшей ожидаемой полезностью с учетом вероятностей результатов и информации о полезности `return action`

13.2. Основная вероятностная система обозначений

Теперь, после определения общей инфраструктуры для рационального агента, нам потребуется формальный язык для представления и формирования рассуждений с неопределенными знаниями. Любая система обозначений, применяемая для описания степеней уверенности, должна предоставлять возможность решать две основные проблемы: отражать характер высказываний, которым присваиваются оценки степени уверенности, и показывать зависимость степени уверенности от опыта агента. В представленной здесь версии теории вероятностей используется одно из расширений пропозициональной логики, которое распространяется на высказывания в этой логике. Зависимость от опыта отражается в синтаксическом различии между априорными вероятностными утверждениями, которые применяются до получения каких-либо свидетельств, и условными вероятностными утверждениями, которые явно включают соответствующие свидетельства.

Высказывания

Оценки степеней уверенности всегда применяются к высказываниям — утверждениям о том, что имеет место то-то и то-то. До сих пор в этой книге рассматривались два формальных языка, применяемых для составления высказываний, — пропозициональная логика и логика первого порядка. В теории вероятностей, как правило, используется язык, немного более выразительный, чем пропозициональная логика. Этот язык описан в данном разделе. (В разделе 14.6 обсуждаются способы, позволяющие предписывать оценки степеней уверенности утверждениям в логике первого порядка.) Основным элементом этого языка является $\wedge$ случайная переменная, которая может рассматриваться как ссылающаяся

на некоторую "часть" мира, "состояние" которого первоначально неизвестно. Например, утверждение Cavity может касаться того, имеется ли у пациента дупло в нижнем левом зубе мудрости. Случайные переменные играют роль, аналогичную той, которую выполняют переменные CSP в задачах удовлетворения ограничений и пропозициональные символы в пропозициональной логике. Мы будем всегда записывать имена случайных переменных с прописной буквы. (Тем не менее для представления любой неизвестной случайной переменной все еще используются однобуквенные имена в виде строчных букв, например $P(a) = 1 - P(-ia)$.) Каждая случайная переменная имеет $\wedge$ область определения значений, которые она может принимать. Например, область определения переменной Cavity может

представлять собой $\langle \text{true}, \text{false} \rangle$. (Для имен значений используются прописные буквы.) В этом высказывании простейшего вида утверждается, что случайная переменная имеет конкретное значение, взятое из ее области определения. Например, Cavity = true может представлять высказывание, что у пациента действительно имеется дупло в левом нижнем зубе мудрости.

Как и в случае переменных CSP, случайные переменные обычно подразделяются на три описанных ниже вида, в зависимости от типа области определения. • $\wedge$ Булевы случайные переменные, такие как Cavity, имеют область определения $\langle \text{true}, \text{false} \rangle$. Мы часто будем сокращенно записывать высказывание, подобное Cavity = true, в виде имени этой переменной, записанного со строчной буквы, cavity. Аналогичным образом, высказывание Cavity = false будет сокращенно записываться как $\neg \text{cavity}$. • $\wedge$ Дискретные случайные переменные, которые включают булевы случайные переменные как частный случай и принимают значения из счетной области определения. Например, областью определения погоды Weather может быть $\langle \text{sunny}, \text{rainy}, \text{cloudy}, \text{snow} \rangle$. Значения в области определения должны быть взаимно исключительными и исчерпывающими. Если не возникает путаница, мы будем, например, использовать snow как сокращение для высказывания Weather = snow. • $\wedge$ Непрерывные случайные переменные принимают свои значения из области действительных чисел. Эта область определения может представлять собой всю ось действительных чисел или некоторое ее подмножество, такое как интервал $[0, 1]$. Например, в высказывании $X = 4.02$ утверждается, что случайная переменная X имеет точное значение 4.02. Высказывания, касающиеся непрерывных случайных переменных, могут также представлять собой неравенства, такие как $X < 4.02$.

За небольшими исключениями, мы будем в основном сосредотачиваться на дискретном случае.

Элементарные высказывания, такие как Cavity = true и Toothache = false, могут комбинироваться для формирования сложных высказываний с использованием всех стандартных логических связок. Например, Cavity = true $\wedge$ Toothache = false представляет собой высказывание, которому может быть предписана определенная

степень уверенности (неуверенности). Как было указано в предыдущем абзаце, это высказывание может быть также записано как $cavity \wedge \neg toothache$.

Атомарные события Для понимания основ теории вероятностей полезно ознакомиться с понятием атомарного события. Атомарное событие представляет собой полную спецификацию состояния мира, в отношении которого знания агента являются неопределенными. Оно может рассматриваться как некоторое присваивание конкретных значений. Читатель мог бы предположить, что эту область определения следует записывать как множество: {true, false}. Но авторы записывают ее в виде кортежа, поскольку в дальнейшем это позволит упростить наложение упорядоченности на значения.

Для всех переменных, из которых состоит этот мир. Например, если мир пациента состоит только из булевых переменных *Cavity* и *Toothache*, то существует всего лишь четыре разных атомарных события³; одним из таких событий является высказывание *Cavity*-false $\wedge$ *Toothache*-true.

Атомарные события имеют некоторые важные свойства, описанные ниже.

- Они являются взаимно исключающими — фактически может иметь место, самое большее, одно такое событие. Например, не могут одновременно происходить такие события, как *cavity* $\wedge$ *toothache* и *cavity* $\wedge$ $\neg$ *toothache*.
- Множество всех возможных атомарных событий является исчерпывающим — должно иметь место по меньшей мере одно из этих событий. Это означает, что дизъюнкция всех атомарных событий логически эквивалентна true.
- Из любого конкретного атомарного события следует истинность или ложность каждого высказывания, либо простого, либо сложного. В этом можно убедиться, используя стандартные определения семантики для логических связок (см. главу 7). Например, из атомарного события *cavity* $\wedge$ $\neg$ *toothache* следует истинность высказывания *cavity* и ложность высказывания *cavity* $\Rightarrow$ *toothache*.
- Любое высказывание логически эквивалентно дизъюнкции всех атомарных событий, из которых следует истинность этого высказывания. Например, высказывание *cavity* эквивалентно дизъюнкции атомарных событий *cavity* $\wedge$ *toothache* и *cavity* $\wedge$ $\neg$ *toothache*.

В упр. 13.4 предлагается доказать некоторые из этих свойств.

Априорная вероятность $\wedge$ Безусловная, или априорная, вероятность, связанная с высказыванием *a*, представляет собой степень уверенности, относящуюся к этому высказыванию в отсутствии любой другой информации; она записывается как $P(a)$. Например, если априорная вероятность того, что у пациента в зубе имеется дупло, равна 0,1, то можно записать следующее:

$P(Cavity = true) = 0.1$ или $P\{cavity\} = 0.1$ Важно помнить, что вероятность $P(a)$ может использоваться, только если нет другой информации. Как только становится известной какая-то новая информация, мы должны проводить рассуждения с

условной вероятностью высказывания a , в которой учитывается эта новая информация. Условные вероятности рассматриваются в следующем разделе.

Иногда приходится вести речь о вероятностях всех возможных значений случайной переменной. В этом случае используется такое выражение, как $P(\text{Weather})$, которое обозначает вектор значений для вероятностей каждого отдельного состояния. Во многих стандартных определениях теории вероятностей в качестве примитивных рассматриваются атомарные события, известные также под названием элементов выборки, а случайная переменная задается как функция, принимающая атомарное событие в качестве параметра и возвращающая значение из соответствующей области определения. Возможно, что такой подход является более общим, но вместе с тем он менее понятен интуитивно.

ния погоды. Таким образом, вместо того, чтобы записывать следующие четыре уравнения:

$P(\text{Weather} = \text{sunny}) = 0.7$ $P(\text{Weather} = \text{rain}) = 0.2$ $P(\text{Weather} = \text{cloudy}) = 0.08$ $P(\text{Weather} = \text{snow}) = 0.02$ можно просто применить такую запись:

$P(\text{Weather}) = (0.7, 0.2, 0.08, 0.02)$ В этом выражении определено $\wedge$ распределение априорных вероятностей для случайной переменной Weather .

Кроме того, такие выражения, как $P(\text{Weather}, \text{Cavity})$, могут использоваться для обозначения вероятностей всех комбинаций значений множества случайных переменных⁴. В этом случае выражение $P(\text{Weather}, \text{Cavity})$ можно представить с помощью таблицы вероятностей с размерами 4×2 . Такая таблица называется $\wedge$ совместным распределением вероятностей переменных Weather и Cavity .

Иногда возникает необходимость рассматривать полное множество случайных переменных, используемых для описания мира. Совместное распределение вероятностей, которое охватывает указанное полное множество, называется $\wedge$ полным совместным распределением вероятностей. Например, если мир состоит только из переменных Cavity , Toothache и Weather , то полное совместное распределение определяется следующим выражением:

$P(\text{Cavity}, \text{Toothache}, \text{Weather})$ Это совместное распределение может быть представлено в виде таблицы с размерами $2 \times 2 \times 4$, имеющей 16 элементов. Полное совместное распределение вероятностей задает вероятность каждого атомарного события и поэтому представляет собой полную спецификацию неопределенности знаний некоего лица о рассматриваемом мире. Как будет показано в разделе 13.4, с помощью полного совместного распределения можно получить ответ на любой запрос, касающийся вероятностных знаний.

Для непрерывных переменных возможность записать все распределение в виде таблицы просто исключена, поскольку количество значений бесконечно велико.

Вместо этого обычно определяется вероятность, которую принимает случайная переменная при некотором значении x , в виде параметризованной функции от x .

Например, допустим, что случайная переменная X обозначает прогноз максимальной температуры воздуха на завтра в Беркли. В таком случае следующее высказывание:

$P(X = x) = 1/10 [18, 26]$ (x) выражает уверенность в том, что значение X распределено равномерно между 18 и 26 градусами Цельсия. (Некоторые полезные непрерывные распределения описаны в приложении А.) Вероятностные распределения для непрерывных переменных называются $\wedge$ функциями плотности вероятностей. Функции плотности отличаются по смыслу от дискретных распределений. Например, с использованием распределения температур, 4 Общее правило применения этого обозначения состоит в том, что распределение охватывает все значения переменных, имена которых записаны с прописной буквы. Таким образом, выражение $P(\text{Weather, cavity})$ — это четырехэлементный вектор вероятностей для конъюнкции каждого высказывания о состоянии погоды с высказыванием Cavitytrue .

приведенного выше, можно найти, что $P(X = 20.5) = 1/10 [18, 26] 20.5 = 0.125/C$.

Это не означает, что имеется 12,5% шансов на то, что завтра максимальная температура будет точно равна 20,5 градуса; вероятность того, что это произойдет, разумеется, равна нулю. Формальный смысл приведенного выше выражения состоит в том, что вероятность пребывания значений температуры в небольшом регионе вокруг 20,5 градуса равна в этих пределах значению 0,125, деленному на ширину региона в градусах Цельсия: $\lim_{dx \rightarrow 0} P(20.5 < X < 20.5 + dx) / dx = 0.125/C$. Некоторые авторы используют разные символы для дискретных распределений и функций плотности, а авторы данной книги в обоих случаях используют обозначение P , поскольку путаница возникает редко и уравнения для обоих случаев обычно одинаковы. Следует учитывать, что вероятности обозначаются безразмерными числами, а функции плотности измеряются с помощью некоторой единицы, в данном примере в качестве такой единицы применяется единица измерения, обратная градусам Цельсия.

Условная вероятность После того как агент получает определенное свидетельство, касающееся ранее неизвестных случайных переменных, составляющих рассматриваемую проблемную область, априорные вероятности становятся больше не применимыми. Вместо этого должны использоваться $\wedge$ условные, или $\wedge$ апостериорные, вероятности. При этом используется обозначение $P(a|b)$, где a и b — любые высказывания. Это обозначение читается как "вероятность a , при условии, что все, что нам известно, — это b ". Например, следующее выражение:

$P(\text{cavity}|\text{toothache}) = 0.8$ показывает, что если наблюдается пациент, имеющий зубную боль, и еще не получена какая-либо иная информация, то вероятность наличия у этого пациента дупла в зубе составляет 0,8. Априорная вероятность, такая как $P(\text{cavity})$, может рассматриваться как частный случай условной вероятности, $P(\text{cavity} | \cdot)$, где условием вероятности является отсутствие свидетельства.

Условные вероятности могут быть определены в терминах безусловных вероятностей. Таким определяющим уравнением является следующее, которое остается истинным, если $P(b) > 0$:

Это уравнение может быть также записано следующим образом и в таком виде называется $\wedge$ правилом произведения:

$P(a \wedge b) = P(a|b)P(b)$ По-видимому, правило произведения запомнить проще; оно основано на таком факте: для того чтобы a и b были истинными, необходимо, чтобы b было истинным, а оператор $|$ имеет наименьший возможный приоритет, поэтому выражение $P(a \wedge b | c \vee d)$ означает $P((a \wedge b) | (c \vee d))$.

а также необходимо, чтобы a было истинным, если дано b . Такое же утверждение можно выразить иначе:

$P(a \wedge b) = P(b|a)P(a)$ В некоторых случаях проще формировать рассуждения в терминах априорных вероятностей конъюнкций, но чаще всего мы в качестве своего основного инструмента для вероятностного логического вывода будем использовать условные вероятности.

Кроме того, для условных распределений может использоваться обозначение P .

Выражение $P(X|Y)$ задает значения выражения $P(X=x_i | Y=y_j)$ для каждой возможной комбинации i, j . В качестве примера того, что с помощью векторного обозначения можно добиться сокращения размеров формул, рассмотрим, как применяется правило произведения к каждому случаю, когда высказывания a и b , соответственно, подтверждают конкретные значения переменных X и Y . При этом будут получены следующие уравнения:

$P(X = x_1 \wedge Y = y_1) = P(X = x_1 | Y = y_1)P(Y = y_1)$ $P(X = x_1 \wedge Y = y_2) = P(X = x_1 | Y = y_2)P(Y = y_2)$ Все эти уравнения можно объединить в такое единственное уравнение:

$P(X, Y) = P(X|Y)P(Y)$ Следует учитывать, что это уравнение обозначает множество уравнений, которые связывают между собой соответствующие отдельные записи в таблицах распределения вероятностей, а не выражает матричное умножение этих таблиц.

Было бы соблазнительно, но неправильно рассматривать условные вероятности как логические следствия с оценкой неопределенности. Например, высказывание $P(a|b) = 0.8$ нельзя интерпретировать в том смысле, что "если b истинно, из этого

следует вывод, что вероятность $P(a)$ равна 0,8". Такая интерпретация была бы неправильной в двух отношениях: во-первых, $P(a)$ всегда обозначает априорную вероятность a , но не апостериорную вероятность, полученную с учетом некоторого свидетельства; во-вторых, само утверждение $P(a \mid b) = 0.8$ непосредственно относится к делу, только если b — единственное доступное свидетельство. Как только становится доступной дополнительная информация c , степень уверенности в истинности a становится равной $P(a \mid b \text{ и } c)$, а это значение может быть почти не связанным со значением $P(a \mid b)$. Например, в высказывании c может быть непосредственно указано, является ли a истинным или ложным. Если врач обследует пациента, который жалуется на зубную боль, и обнаруживает дупло, то получает дополнительное свидетельство $cavity$ и составляет логический вывод (тривиальный), что $P(cavity \mid toothache \text{ и } cavity) = 1.0$.

Истоки ПОНЯТИЯ ВЕРОЯТНОСТИ По поводу того, каковы истоки и значения вероятностных числовых оценок, существуют разные взгляды, и между сторонниками этих взглядов ведутся нескончаемые споры. [^] Фреквентистская (от слова frequency — частота) позиция состоит в том, что эти числовые оценки могут быть основаны только на экспериментах: если мы обследуем 100 человек и обнаружим, что у 10 из них в зубах имеется дупло, то лишь в этом случае можем утверждать, что веро-

ятность наличия дупла примерно равна 0,1. Согласно этим взглядам, утверждение "вероятность дупла равна 0,1" означает, что 0.1 — это доля соответствующих пациентов, которая будет наблюдаться в пределе при обследовании выборки, состоящей из бесконечного количества людей. А любая конечная выборка позволяет оценить истинную долю, а также рассчитать, насколько точной, по-видимому, является эта оценка.

Согласно [^] объективистским взглядам, вероятности — это реальные аспекты универсума (связанные с тем, что в поведении объектов наблюдаются определенные закономерности), а не просто описания степени уверенности наблюдателя. Например, тот факт, что подлинная монета падает решкой вверх с вероятностью 0,5, отражает закономерности падения самой монеты. С точки зрения сторонников этих взглядов, фреквентистские измерения представляют собой попытки проведения наблюдений за реализацией таких закономерностей. Большинство физиков согласны с тем, что квантовые феномены, наблюдаемые в микроскопических масштабах, объективно являются вероятностными, а неопределенность в макроскопических масштабах (например, при подбрасывании монеты) обычно обусловлена незнанием начальных условий и, скорее всего, не согласуется с этими взглядами о реализации каких-то закономерностей.

Сторонники [^] субъективистских взглядов описывают вероятности как способ описания уверенности агента, а не как проявления, имеющие какуюто внешнюю

физическую значимость. Именно это позволяет врачу или аналитику оперировать с числами, например, чтобы иметь возможность утверждать:

"По моему мнению, ожидаемая вероятность наличия дупла составляет около 0,1". Кроме того, для выявления вероятностных оценок, применяемых людьми, было разработано несколько более надежных методов, таких как системы регистрации ставок, описанные на с. 637.

В конце концов, даже строго фреквентистская позиция требует субъективного анализа, поэтому с точки зрения практики различия между взглядами сторонников этих трех направлений, по-видимому, не имеют большого значения. То, что нельзя обойтись без субъективного подхода, иллюстрирует проблема $\wedge$ референтного класса (reference class). Предположим, что некий врач, сторонник фреквентистских взглядов, желает знать, каковы шансы того, что некоторый пациент имеет данное конкретное заболевание. Этот врач хочет рассмотреть сведения о других пациентах, которые обладают аналогичными характеристиками по важным показателям (возраст, симптомы и, возможно, пол), и определить, какая часть из них имеет это заболевание. Такая задача может быть решена, но если врач станет рассматривать все, что известно о пациенте (вес с точностью до грамма, цвет волос, девичья фамилия матери и т.д.), результатом станет то, что не найдется больше пациентов, имеющих точно такие же характеристики, и поэтому нельзя будет определить референтный класс, в котором можно было бы собрать экспериментальные данные.

Это — одна из неразрешимых проблем в философии науки.

В принципе безразличия Лапласа [887] утверждается, что высказывания, которые являются синтаксически "симметричными" по отношению к данному свидетельству, должны рассматриваться как равновероятные. Были предложены различные уточнения этого принципа, а кульминацией этих усилий ста-

ла попытка Карнапа и других ученых разработать строгую индуктивную логику, позволяющую правильно вычислять вероятность любого высказывания на основании результатов любой коллекции наблюдений. В настоящее время считается, что никакой уникальной индуктивной логики не существует; вместо этого любая подобная логика опирается на субъективное априорное распределение вероятностей, субъективность которой уменьшается по мере накопления все большего и большего количества наблюдений.

13.3. Аксиомы ВЕРОЯТНОСТЕЙ До сих пор в этой главе был определен синтаксис для высказываний, а также для априорных и условных вероятностных утверждений об этих высказываниях. Теперь необходимо определить своего рода семантику для вероятностных утверждений.

Начнем с базовых аксиом, которые служат для определения шкалы вероятностей и ее конечных точек, как описано ниже.

1. Все вероятности находятся в пределах от 0 до 1; для любого высказывания a справедливо следующее:

$0 < P(a) < 1$ 2. Безусловно истинные (т.е. выполнимые) высказывания имеют вероятность 1, а безусловно ложные (т.е. невыполнимые) высказывания имеют вероятность 0:

$P(\text{true}) = 1$ $P(\text{false}) = 0$ Кроме того, требуется аксиома, которая соединяет вероятности логически взаимосвязанных высказываний. Такую аксиому можно проще всего составить, определив вероятность дизъюнкции, как показано ниже.

3. Вероятность дизъюнкции задается следующей формулой:

$P(a \vee b) = P(a) + P(b) - P(a \wedge b)$ Это правило можно легко запомнить, отметив, что те случаи, когда высказывание a является истинным, вместе с теми случаями, когда b является истинным, безусловно, охватывают все те случаи, когда истинно высказывание $a \vee b$; но в сумме двух множеств случаев их пересечение встречается дважды, поэтому необходимо вычесть $P(a \wedge b)$.

Эти три аксиомы часто называют $\wedge$ аксиомами Колмогорова в честь советского математика Андрея Колмогорова, который показал, как построить остальную часть теории вероятностей на этом простом фундаменте. Обратите внимание на то, что в этих аксиомах речь идет только об априорных вероятностях, а не об условных; это связано с тем, что последние уже были определены в терминах первых в уравнении 13.1.

Использование аксиом вероятностей Из этих основных аксиом можно вывести целый ряд полезных фактов.

Например, знакомое правило отрицания следует из подстановки $\neg a$ вместо b в аксиому 3, что приводит к получению следующего выражения:

$P(a \vee \neg a) = P(a) + P(\neg a) - P(a \wedge \neg a)$ $P(\text{true}) = P(a) + P(\neg a) - 0 = P(a) + P(\neg a)$ $P(\neg a) = 1 - P(a)$ (согласно аксиоме 2) (согласно алгебраическому определению) Третья строка этого логического вывода сама является полезным фактом и может быть распространена с данного булева случая на общий дискретный случай.

Допустим, что дискретная переменная D имеет область определения $\{d_1, \dots, d_n\}$. Тогда можно легко показать (упр. 13.2), что справедлива следующая формула: $\sum_{i=1}^n P(D=d_i) = 1$ Это означает, что любое вероятностное распределение по одной переменной должно в сумме составлять 1. Справедливо также утверждение, что любое совместное распределение вероятностей по любому множеству переменных

должно в сумме составлять 1; в этом можно убедиться, создав одну мегапеременную, областью определения которой является перекрестное произведение областей определения первоначальных переменных.

Напомним, что любое высказывание a эквивалентно дизъюнкции всех атомарных событий, в которых a является истинным; назовем эту дизъюнкцию множеством событий $e(a)$. Напомним также, что атомарные события являются взаимно исключающими, поэтому вероятность любой конъюнкции атомарных событий равна нулю, согласно аксиоме 2. Таким образом, из аксиомы 3 можно вывести следующее простое соотношение: $P(a) = \sum_{e \in e(a)} P(e)$ вероятность любого высказывания равна сумме вероятностей атомарных событий, в которых оно является истинным; т.е. вывести такое уравнение:

$P(a) = \sum_{e \in e(a)} P(e)$ A3.2) Это уравнение предоставляет простой метод вычисления вероятности любого высказывания при наличии полного совместного распределения, которое задает вероятности всех атомарных событий (см. раздел 13.4.) В следующих разделах будут выведены дополнительные правила для манипулирования вероятностями. Но вначале исследуем теоретические основы самих этих аксиом.

Теоретическое обоснование аксиом вероятностей Аксиомы вероятностей могут рассматриваться как ограничивающие множество вероятностных убеждений, которых может придерживаться некоторый агент. Такой подход в определенной степени подобен логическому подходу, согласно которому, 5 Для непрерывных переменных эта сумма заменяется интегралом: $\int P(x) dx = 1$.

например, логический агент не может одновременно быть уверенным в истинности высказываний $A, B, \neg(A \wedge B)$. Тем не менее в вероятностном подходе возникает дополнительное усложнение. В логическом случае семантическое определение конъюнкции означает, что, по меньшей мере, одно из трех только что упомянутых убеждений должно быть ложным в этом мире, поэтому для любого агента неразумно было бы сохранять уверенность в истинности этих трех высказываний. Но в случае вероятностей, с другой стороны, утверждения относятся не непосредственно к самому миру, а к собственному состоянию знаний агента. В таком случае, почему агент не мог бы иметь приведенное ниже множество убеждений, которое явно нарушает аксиому 3?

$P(a) = 0.4 \quad P(a \wedge b) = 0.0 \quad P(b) = 0.3 \quad P(a \vee b) = 0.8$ A3.3) Такого рода вопрос был предметом жаростных дебатов, продолжавшихся в течение нескольких десятилетий, между теми, кто отстаивал допустимость использования вероятностей как единственной обоснованной формы оценки степеней уверенности, и теми, кто отстаивал альтернативные подходы. В данном разделе мы приведем один довод в

пользу аксиом вероятностей, впервые сформулированный в 1931 году в работах Бруно де Финетти (Bruno de Finetti).

Ключом к этому доводу де Финетти является связь между степенью уверенности и действиями. Идея состоит в том, что если агент имеет некоторую степень уверенности в истинности высказывания a , то агент должен быть способен сформулировать оценку того, в какой степени он безразличен к ставке за или против высказывания a . Рассмотрим эту ситуацию как игру между двумя агентами: агент 1 утверждает "моя степень уверенности в истинности события a равна 0,4". Затем агент 2 вправе выбрать, будет ли он делать ставку за или против высказывания a , применяя суммы, которые совместимы с заявленной степенью уверенности. Это означает, что агент 2 может решить сделать ставку на то, что событие a произойдет, поставив 4 доллара против 6 долларов агента 1. С другой стороны, агент 2 может поставить 6 долларов против 4, что A не произойдет⁷. Если степень уверенности агента не точно отражает состояние мира, можно вполне рассчитывать на то, что в долговременной перспективе он будет проигрывать деньги агенту-противнику, убеждения которого более точно отражают состояние мира.

Но де Финетти доказал гораздо более сильное утверждение: $c^A =$ если агент руководствуется множеством степеней уверенности, которое нарушает аксиомы теории вероятностей, то существует такая комбинация ставок агента 2, которая гарантирует, что агент 1 будет терять деньги при каждой ставке. Поэтому, если вы придерживаетесь той идеи, что агент должен стремиться "ставить свои деньги на те события, вероятности которых выше", то должны также признать, что иррационально иметь такие убеждения, которые нарушают аксиомы вероятностей.

⁷ Можно было бы возразить, что предпочтения агента применительно к балансам разных ставок являются таковыми, что возможность потерять 1 доллар не уравнивается равной возможностью выиграть 1 доллар. Один из возможных ответов на это возражение состоит в том, что суммы ставок должны быть достаточно малыми для того, чтобы можно было избежать данной проблемы. Анализ, проведенный Сэведжем [1354], позволяет полностью исключить из рассмотрения эту проблему.

На первый взгляд может показаться, что эта игра со ставками довольно надумана.

Например, что было бы, если один из агентов отказался бы делать ставки?

Закончился бы на этом спор? Ответ на данный вопрос состоит в том, что эта игра со ставками представляет собой абстрактную модель для ситуации принятия решений, в которую любой агент неизбежно вовлечен в любой момент своего существования.

Каждое действие (включая бездействие) — это своего рода ставка, а каждый результат может рассматриваться как положительное или отрицательное

вознаграждение за эту ставку. Отказ делать ставку аналогичен решению предоставить все естественному течению событий.

Мы не будем доказывать представленную выше теорему де Финетти, а приведем один пример. Предположим, что агент 1 руководствуется множеством степеней уверенности, приведенным в уравнении 13.3. В табл. 13.1 показано, что если агент 2 решит делать ставки 4 доллара на событие a , 3 доллара — на событие b и 2 доллара на событие $\neg(a \vee b)$, то агент 1 будет всегда терять деньги, независимо от результатов a и b .

Таблица 13.1. Пример того, что при наличии у агента 1 несогласованных убеждений агент 2 получает возможности составить множество ставок, которое гарантирует потери для агента 1, независимо от результатов a и b . Агент 1 Высказывание $a \wedge b$ $a \wedge \neg b$ $\neg a \wedge b$ $\neg a \wedge \neg b$ Степень уверенности 0.4 0.3 0.8 Ставка $a \wedge b$ -1 $a \wedge \neg b$ -1 $\neg a \wedge b$ 3 $\neg a \wedge \neg b$ -7 Сумма ставки 4-6 3-7 2-8 $a \wedge b$ -6 -7 -11 b Результат для Агента 1 $a \wedge b$ -6 -1 $\neg a \wedge b$ -3 -7 -1 $\neg b$ $\neg a \wedge b$ -8 -1 $\neg b$ пользу применения вероятностей были выдвинуты и другие весомые философские аргументы; к числу наиболее широко известных из них относятся сформулированные Коксом [304] и Карнапом [225]. Но мир таков, каким он является, и практические свидетельства иногда становятся более весомыми, чем доказательства. Успех систем формирования рассуждений, основанных на теории вероятностей, оказался гораздо более привлекательным стимулом, который вызвал пересмотр многих взглядов. В следующем разделе будет показано, как описанные выше аксиомы могут быть применены для составления логических выводов.

13.4. Логический вывод с использованием полных совместных распределений В данном разделе будет описан простой метод $\wedge$ вероятностного вывода, т.е. вычисления апостериорных вероятностей для высказываний, заданных в виде запросов, на основании наблюдаемых свидетельств. Мы будем использовать полное совместное распределение как своего рода "базу знаний", из которой могут быть выведе-

дены ответы на все вопросы. В ходе этого мы также представим несколько полезных методов манипулирования уравнениями, в которых учитываются вероятности.

Начнем с очень простого примера — с описания проблемной области, состоящей только из трех булевых переменных, Toothache, Cavity и Catch (неприятные ощущения от захвата зуба стальными клещами дантиста все еще свежи в памяти автора). Полное совместное распределение представляет собой таблицу с размерами $2 \times 2 \times 2$ (табл. 13.2).

Таблица 13.2. Полное совместное распределение для мира Toothache, Cavity, Catch $ca \vee i \vee ty \neg i \neg cavity \neg catch$ 0.108 0.016 toothache $\neg i \neg cavity \neg catch$ 0.012 0.064 catch 0.072 0.144 $\neg i \neg cavity \neg catch$ 0.008 0.576 Обратите внимание на то, что вероятности в этом совместном распределении в сумме составляют 1, как и требуется согласно

аксиомам вероятностей. Следует также отметить, что уравнение 13.2 предоставляет нам прямой способ вычисления вероятности любого высказывания, простого или сложного: мы должны определить те атомарные события, в которых данное высказывание является истинным, и сложить их вероятности. Например, имеется шесть атомарных событий, в которых истинным является высказывание $cavity \vee toothache$:

$P\{cavity \vee toothache\} = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$ Одна из задач, которая встречается особенно часто, состоит в том, чтобы извлечь из подобной таблицы распределение вероятностей по некоторому подмножеству переменных или по одной переменной. Например, складывая элементы первого ряда табл. 13.2, получим безусловную, или $\wedge$ маргинальную, вероятность события $cavity$.

$P(cavity) = 0.108 + 0.012 + 0.072 + 0.008 = 0.2$ Такой процесс называется $\wedge$ маргинализацией, или исключением из суммы, поскольку из суммы вероятностей исключаются прочие переменные, кроме $Cavity$.

Можно записать следующее общее правило маргинализации для любых множеств переменных Y и Z :

$P(Y) = \sum_z P(Y, z)$ А3.4) z Это означает, что распределение вероятностей по Y может быть получено путем исключения из суммы вероятностей всех прочих переменных, относящихся к любому совместному распределению вероятностей, содержащему Y . В одном из вариантов этого правила учитываются условные вероятности, а не совместные вероятности с использованием правила произведения:

8 Эта вероятность получила такое название, поскольку страховщики имеют общую привычку записывать суммы наблюдаемых частот событий на полях (margin) таблиц страхования.

$P(Y) = \sum_z P(Y|z)P(z)$ А3.5) z Это правило называется правилом $\wedge$ обусловливания. Как оказалось, правила маргинализации и обусловливания являются очень полезными правилами для всех видов логических выводов, в которых применяются вероятностные выражения.

В большинстве случаев нас будет интересовать задача вычисления условных вероятностей некоторых переменных при наличии свидетельств, касающихся других переменных. Условные вероятности можно найти, вначале воспользовавшись уравнением 13.1 для получения выражения в терминах безусловных вероятностей, а затем рассчитав это выражение на основании полного совместного распределения.

Например, можно вычислить вероятность наличия дупла после получения свидетельства о том, что пациент страдает от зубной боли, следующим образом: .

$P(\text{cavity} \mid \text{toothache}) = \frac{P(\text{cavity, toothache})}{P(\text{toothache})} = \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} = \frac{0.12}{0.2} = 0.6$
 $P(\neg \text{cavity} \mid \text{toothache}) = \frac{P(\neg \text{cavity, toothache})}{P(\text{toothache})} = \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} = \frac{0.08}{0.2} = 0.4$
 Обратите внимание на то, что в этих двух примерах вычисления вероятности терм $1/P(\text{toothache})$ остается постоянным, независимо от того, какое значение Cavity вычисляется. Фактически этот терм может рассматриваться как константа ^нормализации для распределения $P(\text{Cavity} \mid \text{toothache})$, гарантирующая, что полученные вероятности в сумме составят 1. Во всех главах этой книги, где речь идет о вероятностях, для обозначения подобных констант будем использовать символ a .

С помощью такого обозначения можно записать два приведенных выше уравнения в виде одного:

$P(\text{Cavity} \mid \text{toothache}) = a \cdot P(\text{Cavity, toothache}) = a [P(\text{Cavity, toothache, catch}) + P(\text{Cavity, toothache, -ncatch})]$
 $= a [0.108 + 0.012 + 0.016 + 0.064] = a \cdot 0.2 = 0.6$
 Как оказалось, нормализация является полезным сокращением во многих вероятностных вычислениях.

На основании приведенного выше примера можно составить общую процедуру вероятностного вывода. Мы будем придерживаться того случая, в котором запрос касается только одной переменной. Кроме того, потребуются некоторые обозначения: допустим, что X — переменная запроса (в данном примере Cavity), E — множество переменных свидетельства (в данном примере к нему относится только Toothache); e — наблюдаемые значения этих переменных; Y — оставшиеся ненаблюдаемые переменные (в данном примере таковой является только Catch).

Запросом является $P(X \mid e)$, и ответ на него может быть вычислен следующим образом:

$P(X \mid e) = \frac{P(X, e)}{P(e)} = \frac{\sum_y P(X, e, y)}{\sum_y P(e, y)}$ (3.6) где суммирование осуществляется по всем возможным значениям y (т.е. по всем возможным комбинациям значений ненаблюдаемых переменных Y). Обратите внимание на то, что переменные X , E и Y , вместе взятые, составляют полное множество переменных для данной проблемной области, поэтому $P(X, e, y)$ представляет собой подмножество вероятностей из полного совместного распределения. Алгоритм вычисления ответа на запрос приведен в листинге 13.2. В этом алгоритме проверяются в циклах значения X и значения Y для перебора всех возможных атомарных событий с фиксированными значениями e , складываются их вероятности из таблицы совместного распределения, после чего результаты нормализуются.

Листинг 13.2. Алгоритм вероятностного вывода путем перебора всех элементов в таблице полного совместного распределения

```
function Enumerate-Joint-Ask( $X, e, P$ )
```

returns распределение по X inputs: X , переменная запроса e , наблюдаемые значения переменных E P , совместное распределение по переменным $\{X\} \cup E \cup Y$ /* Y - скрытые переменные */ $Q(X) \leftarrow$ распределение по X , первоначально пустое for each значение x_i переменной X do $Q(x_i) \leftarrow$ Enumerate-Joint($x_i, e, Y, [], P$) return Normalize($Q(X)$) function Enumerate-Joint($x, e, vars, values, P$) returns действительное число if Empty?(vars) then return $P(x, e, values)$ $Y \leftarrow$ First(vars) return Y Enumerate-Joint($x, e, \text{Rest}(vars), [y \setminus values], P$) При наличии полного совместного распределения, с которым можно было бы работать, алгоритм Enumerate-Joint-Ask становится полным алгоритмом получения ответов на вероятностные запросы, касающиеся дискретных переменных. Но этот алгоритм недостаточно хорошо масштабируется, поскольку при наличии проблемной области, которая описана n булевыми переменными, он требует входной таблицы с размером $O(2^n)$, а обработка этой таблицы занимает время $O(2^n)$. В реальных задачах может потребоваться рассмотреть сотни или тысячи случайных переменных, а не только три. Попытка определить огромные количества требуемых вероятностей быстро становится полностью неосуществимой, поскольку может быть даже не накоплено достаточного количества экспериментальных данных, которые требуются для того, чтобы отдельно оценить каждую из записей этой таблицы.

По этим причинам полное совместное распределение вероятностей в табличной форме нельзя считать практически применимым инструментальным средством для создания систем формирования рассуждений (хотя в исторических заметках в конце данной главы упоминается одно реальное приложение, основанное на этом методе).

Вместо этого данный подход следует рассматривать как теоретическую основу, на которой могут быть созданы более эффективные подходы. В оставшейся части данной главы представлены некоторые основные идеи, которые потребуются для подготовки к разработке реально осуществимых систем, описанных в главе 14.

13.5. Независимость Расширим полное совместное распределение, приведенное в табл. 13.2, введя четвертую переменную, Weather. После этого полное совместное распределение, состоящее из 32 элементов (поскольку переменная Weather имеет четыре значения), принимает вид $P(\text{Toothache}, \text{Catch}, \text{Cavity}, \text{Weather})$. Оно содержит четыре варианта таблицы, показанной в табл. 13.2, по одному на каждый вид погоды. Напрашивается резонный вопрос о том, какую связь имеют эти варианты друг с другом и с первоначальной таблицей, состоящей из трех переменных.

Например, как связаны друг с другом высказывания $P(\text{toothache}, \text{catch}, \text{cavity}, \text{Weather} = \text{cloudy})$ и $P(\text{toothache}, \text{catch}, \text{cavity})$? Один из способов получения ответа на этот вопрос состоит в использовании правила произведения:

$P\{\text{toothache, catch, cavity, Weather} = \text{cloudy}\} = P\{\text{Weather} = \text{cloudy} \mid \text{toothache, catch, cavity}\} P\{\text{toothache, catch, cavity}\}$ Но человек, не верящий в существование колдунов, не может себе представить, что чьи-то проблемы с зубами могут влиять на погоду. Поэтому кажется резонным следующее утверждение:

$P\{\text{Weather} = \text{cloudy} \mid \text{toothache, catch, cavity}\} = P\{\text{Weather} = \text{cloudy}\}$ А3.7) На основании этого можно вывести следующее:

$P\{\text{toothache, catch, cavity, Weather} = \text{cloudy}\} = P\{\text{Weather} = \text{cloudy}\} P\{\text{toothache, catch, cavity}\}$ Аналогичное уравнение существует для каждого элемента в распределении $P\{\text{Toothache, Catch, Cavity, Weather}\}$. В действительности можно записать такое общее уравнение:

$P\{\text{Toothache, Catch, Cavity, Weather}\} = P\{\text{Toothache, Catch, Cavity}\} P\{\text{Weather}\}$ Таким образом, 32-элементная таблица для четырех переменных может быть сконструирована из одной 8-элементной таблицы и одной 4-элементной. Такая декомпозиция показана схематически на рис. 13.1, а.

Свойство вероятностей, используемое при составлении уравнения 13.7, называется $\wedge$ независимостью (а также маргинальной независимостью и абсолютной независимостью). В частности, погода независима от чьих-то проблем с зубами.

Независимость между высказываниями α и β может быть показана следующим образом:

$$P(\alpha \mid \beta) = P(\alpha) \text{ или } P(\beta \mid \alpha) = P(\beta) \text{ или } P(\alpha \wedge \beta) = P(\alpha)P(\beta) \text{ А3.8)}$$

Cavity Toothache Catch Weather Coin] Coinn декомпонуется на декомпонуется на Coin Coinn а) б) Рис. 13.1. Два примера факторизации большого совместного распределения на меньшие распределения с использованием свойства абсолютной независимости: независимы друг от друга погода и проблемы с зубами (а); независимы друг от друга броски монеты (б) Все эти формы записи являются эквивалентными (упр. 13.7). Свойство независимости между переменными x и y можно сформулировать следующим образом (все эти формы записи также эквивалентны):

$P(X \mid Y) = P(X)$ или $P(Y \mid X) = P(Y)$ или $P(X, Y) = P(X)P(Y)$ Утверждения о независимости обычно основаны на знаниях о проблемной области. Как показывает приведенный выше пример, эти утверждения позволяют существенно уменьшить объем информации, необходимой для описания полного совместного распределения. Если все множество переменных может быть разделено на независимые подмножества, то полное совместное распределение может быть факторизовано на отдельные совместные распределения, заданные на этих подмножествах. Например, совместное распределение результатов n независимых бросков монеты, $p(C_1, \dots, C_n)$, может быть представлено как произведение n распределений $P(C_i)$ с одной

переменной. Например, с точки зрения практики очень благоприятным фактором является независимость данных зубоврачебного дела и метеорологии, поскольку в противном случае для занятия зубоврачебным делом потребовались бы глубокие знания в области метеорологии, и наоборот.

Поэтому утверждения о независимости, если они имеются, позволяют сократить размеры представления проблемной области и уменьшить сложность проблемы вывода. К сожалению, чистое разделение целых множеств переменных по признаку независимости встречается редко. Если между двумя переменными существует хоть какая-то связь, пусть даже косвенная, свойство независимости перестает соблюдаться. Кроме того, даже независимые подмножества могут оказаться чрезвычайно большими, например, в области стоматологии могут встретиться десятки заболеваний и сотни симптомов, причем все они взаимосвязаны друг с другом. Чтобы справиться с такими проблемами, мы должны иметь более тонкие методы, чем прямолинейная концепция независимости.

13.6. Правило Байеса и его использование На с. 632 определено правило произведения и указано, что оно может быть записано в двух следующих формах благодаря коммутативности конъюнкции:

$P(a \wedge b) = P(a|b)P(b)$ $P(a \wedge b) = P(b|a)P(a)$ Приравняв две правые части стороны и разделив их на $P(a)$, получим такое уравнение:

$P(a|b)P(b)P(b|a) = j^{\wedge}$ А3.9) Это уравнение известно под названием $\wedge$ правила Байеса (а также закона Байеса, или теоремы Байеса)9. Это простое уравнение лежит в основе всех современных систем искусственного интеллекта для вероятностного вывода. Более общий случай многозначных переменных может быть записан в системе обозначений P следующим образом:

$P(X|Y)P(Y)P(Y|X) = P(U)$ Это уравнение также следует рассматривать как представляющее множество уравнений, в каждом из которых рассматриваются конкретные значения переменных. Время от времени нам также придется использовать более общую версию, которая обусловлена некоторым фоновым свидетельством e :

$P(X|Y,e)P(Y|e)P(Y|X,e) = P(U|e)$ А3.10) Применение правила Байеса: простой случай На первый взгляд правило Байеса не кажется очень полезным. В нем требуются три термина (одна условная вероятность и две безусловных вероятности) только для вычисления одной условной вероятности.

Но правило Байеса находит очень широкое практическое применение, поскольку во многих случаях имеются хорошие оценки вероятностей для этих трех терминов и нужно вычислить четвертый. В такой задаче, как медицинская диагностика, часто известны условные вероятности причинных связей и требуется определить диагноз.

Врач знает, что такое заболевание, как менингит, очень часто вызывает у пациента симптом, характеризующийся снижением подвижности шеи; предположим, что этот симптом наблюдается в 50% случаев. Кроме того, врачу известны некоторые безусловные факты: априорная вероятность того, что некоторый пациент имеет менингит, равна $1/50\,000$, а априорная вероятность того, что некоторый пациент имеет неподвижную шею, равна $1/2$. Предположив, что s — высказывание, согласно которому пациент имеет неподвижную шею, m — высказывание, что пациент имеет менингит, получим следующее:

9 Согласно правилу 1, приведенному на странице 1 книги *The Elements of Style* (Основы стилистики) Шранка и Уайта, в англоязычном эквиваленте этого термина следует применять форму родительного падежа Bayes's, а не Bayes'. Однако чаще используется последняя форма.

$P(s|m) = 0.5$ $P(m) = 1/50\,000$ $P(s) = 1/2$ $P(s|m)P(m) = 0.5 \times 1/50\,000$ $P(m|s) = \frac{P(s|m)P(m)}{P(s)} = \frac{0.5 \times 1/50\,000}{1/2} = 0.0002$ Итак, следует предполагать, что 1 из 5 000 пациентов с неподвижной шеей имеет менингит. Следует отметить, что даже если неподвижная шея является весьма надежным показателем наличия менингита (с вероятностью 0,5), сама вероятность наличия менингита у пациента остается низкой. Это связано с тем, что априорная вероятность наличия симптома неподвижной шеи намного выше по сравнению с вероятностью менингита.

В разделе 13.4 показан процесс, с помощью которого можно избежать необходимости оценки вероятности свидетельства (в данном случае $P(s)$), вместо этого вычислив апостериорную вероятность для каждого значения переменной запроса (в данном случае t и j), а затем нормализовав результаты. Тот же процесс можно применить при использовании правила Байеса. Таким образом, мы имеем:

$P(M|s) = \frac{P(s|m)P(m)}{P(s)}$ Итак, чтобы воспользоваться этим подходом, необходимо вместо $p(s)$ вычислить значение $P(s|m)$. Осуществление такого подхода требует определенных затрат; иногда эти затраты не столь велики, а иногда становятся довольно значительными. Общая форма правила Байеса с нормализацией является таковой:

$P(Y|X) = \frac{P(X|Y)F(Y)}{\sum_j P(X|j)F(j)}$ (3.11) где a — константа нормализации, необходимая для того, чтобы записи в распределении $P(Y|X)$ в сумме составляли 1.

Один из очевидных вопросов, касающихся правила Байеса, состоит в том, почему может оказаться доступной условная вероятность, реализуемая в одном направлении, но не в другом. В проблемной области лечения менингита, возможно, врач знает, что из симптома неподвижной шеи следует наличие менингита в 1 из 5000 случаев; это означает, что врач имеет количественную информацию в диагностическом направлении, от симптомов к причинам. Для такого врача не требуется использование правила Байеса. К сожалению, с[^] = диагностические

знания часто встречаются намного реже по сравнению с причинными знаниями. Если внезапно возникает эпидемия менингита, то безусловная вероятность менингита, $P(t)$, повышается. Врач, который вывел диагностическую вероятность $P(m|s)$ непосредственно из статистических наблюдений за пациентами перед эпидемией, не будет иметь представления о том, как обновить это значение, а врач, который вычисляет $p(m|s)$ из других трех значений, обнаружит, что значение $P(t|s)$ должно увеличиваться пропорционально $P(t)$. Еще более важно то, что причинная информация $p(s|m)$ остается незатронутой данной эпидемией, поскольку она просто показывает, в чем выражается действие менингита. Использование такого рода прямых причинных знаний, или знаний, основанных на модели, позволяет достичь надежности, которая крайне важна при создании вероятностных систем, применимых в реальном мире.

Использование правила Байеса: комбинирование свидетельств Как было показано выше, правило Байеса может применяться для получения ответов на вероятностные запросы, в которых учтено условие, составляющее одно из свидетельств, например неподвижная шея. В частности, было показано, что вероятностная информация часто доступна в форме $P(\text{effect} | \text{cause})$ (где effect — результат, а cause — причина). А что произойдет, если свидетельств два или больше?

Например, какой вывод может сделать зубной врач, если его стальной инструмент захватил больной зуб пациента, причинив еще большие страдания? Если известно полное совместное распределение (табл. 13.2), можно сразу же прочитать ответ:

$P(\text{Cavity} | \text{toothache} \wedge \text{catch}) = a <0.108, 0.016> = <0.871, 0.129>$ Но нам уже известно, что такой подход не масштабируется на большее количество переменных.

Тогда можно попытаться воспользоваться правилом Байеса для переформулировки этой задачи:

$P(\text{Cavity} | \text{toothache} \wedge \text{catch}) = a P(\text{toothache} \wedge \text{catch} | \text{Cavity}) P(\text{Cavity})$ A3.12) Для того чтобы можно было найти ответ запрос в такой формулировке, необходимо знать условные вероятности конъюнкции $\text{toothache} \wedge \text{catch}$ для каждого значения Cavity . Такая задача может быть осуществима, если речь идет только о двух переменных свидетельства, но этот подход снова становится источником затруднений при его применении в больших масштабах. Если имеется p возможных переменных свидетельства (рентгеновское обследование, диета, гигиена полости рта и т.д.), то количество возможных комбинаций наблюдаемых значений, для которых необходимо будет знать условные вероятности, составит 2^p . С таким же успехом можно было бы снова вернуться к использованию полного совместного распределения. Именно по этой причине исследователи после первых попыток отказались от применения теории вероятностей и обратились к приближенным

методам комбинирования свидетельств, в которых требуется использовать меньше чисел для получения ответов, хотя сами эти ответы не всегда бывают правильными.

Вместо того чтобы следовать по такому пути, мы должны найти некоторые дополнительные утверждения о рассматриваемой проблемной области, которые позволят упростить применяемые выражения. Понятие независимости, приведенное в разделе 13.5, дает ключ к этому решению, но требует уточнения. Было бы прекрасно, если бы переменные Toothache и Catch были независимыми, но они таковыми не являются: если зубной врач захватывает зуб своим инструментом, то он делает это, вероятно, потому, что в этом зубе есть дупло, а это действие, вероятно, в свою очередь вызывает боль. Но эти переменные независимы, если речь идет о наличии или отсутствии дупла. Причиной каждого из соответствующих действий было дупло, но ни одно из них не оказывает непосредственного влияния на другое: зубная боль зависит от состояния нервов в зубе, а точность наложения инструмента зависит от навыков зубного врача¹⁰, к которым зубная боль не имеет отношения.

Математически это свойство записывается следующим образом:

Предполагается, что пациент и зубной врач — это разные люди.

$P(\text{toothache} \wedge \text{catch} | \text{Cavity}) = P(\text{toothache} | \text{Cavity}) P(\text{catch} | \text{Cavity})$ A3.13) В данном уравнении выражена "условная независимость переменных toothache и catch, если дана вероятность Cavity. Соответствующее выражение можно вставить в уравнение 13.12 для определения вероятности наличия дупла:

$P(\text{Cavity} | \text{toothache} \wedge \text{catch}) = \alpha P(\text{toothache} | \text{Cavity}) P(\text{catch} | \text{Cavity}) P(\text{Cavity})$ Теперь требования к наличию информации становятся такими же, как и при вероятностном выводе с использованием каждого свидетельства отдельно: необходимо знать априорную вероятность $P(\text{Cavity})$ для переменной запроса и условную вероятность каждого результата, если дана его причина.

Общее определение условной независимости двух переменных X и Y , если дана третья переменная Z , выражается следующей формулой:

$P(X, Y | Z) = P(X | Z) P(Y | Z)$ Например, в проблемной области стоматологии представляется вполне резонным применение утверждения об условной независимости переменных Toothache и Catch, если дана вероятность Cavity.

$P(\text{Toothache}, \text{Catch} | \text{Cavity}) = P(\text{Toothache} | \text{Cavity}) P(\text{Catch} | \text{Cavity})$ A3.14) Обратите внимание на то, что это утверждение немного строже по сравнению с уравнением 13.13, в котором сформулировано утверждение о независимости только для конкретных значений Toothache и Catch. А при использовании свойства абсолютной независимости, сформулированного в уравнении 13.8, могут также применяться следующие эквивалентные формы:

$P(X \setminus Y, Z) = P(X \setminus Z)$ и $P(Y \setminus X, Z) = P(Y \setminus Z)$ В разделе 13.5 показано, что утверждения с описанием свойств абсолютной независимости позволяют выполнять декомпозицию полного совместного распределения на гораздо более мелкие распределения. Как оказалось, аналогичную декомпозицию позволяют выполнять утверждения об условной независимости. Например, с помощью утверждения, приведенного в уравнении 13.14, декомпозицию можно вывести следующим образом:

$P(\text{Toothache}, \text{Catch}, \text{Cavity}) = P(\text{Toothache}, \text{Catch} \setminus \text{Cavity}) P(\text{Cavity})$ (по правилу произведения) $= P(\text{Toothache} \setminus \text{Cavity}) P(\text{Catch} \setminus \text{Cavity}) P(\text{Cavity})$ (согласно уравнению 13.14) Таким образом, первоначальная крупная таблица декомпонована на три меньшие таблицы. В исходной таблице было семь независимых чисел $B \times B - 1$, поскольку эти числа должны в сумме составлять 1). Меньшие таблицы содержат пять независимых чисел $B \times B - 1$ для каждого распределения условных вероятностей и 21-Гдля распределения априорной вероятности Cavity). Такое достижение на первый взгляд может показаться не очень значительным, но дело в том, что для симптомов, являющихся условно независимыми, если дана вероятность Cavity , размер представления растет как $O(n)$, а не $O(B^3)$. Таким об-

разом, C° утверждения об условной независимости могут обеспечивать масштабирование вероятностных систем; более того, такие утверждения могут быть подкреплены данными намного проще по сравнению с утверждениями об абсолютной независимости. С концептуальной точки зрения переменная $\text{Cavity} \wedge$ разделяет переменные Toothache и Catch , поскольку наличие дупла является прямой причиной и зубной боли, и наложения инструмента на зуб. Разработка методов декомпозиции крупных вероятностных областей определения на слабо связанные подмножества с помощью свойства условной независимости стало одним из наиболее важных достижений в новейшей истории искусственного интеллекта.

Приведенный выше пример из области стоматологии может служить проявлением часто встречающейся ситуации, в которой одна причина непосредственно влияет на целый ряд результатов, причем все эти результаты являются условно независимыми, если дана эта причина. Полное совместное распределение может быть записано следующим образом:

$F(\text{Cause}, \text{Effect}_1, \dots, \text{Effect}_n) = P(\text{Cause}) \prod_i P(\text{Effect}_i \setminus \text{Cause})$ Указанное распределение вероятностей называется $\wedge$ наивной байесовской моделью. Такая модель называется "наивной", поскольку часто используется (как упрощающее допущение) в тех случаях, когда переменные "результата" не являются условно независимыми, если дана переменная причины. (Наивную байесовскую модель иногда называют байесовским классификатором, а это не совсем корректное применение термина побудило настоящих специалистов в области байесовских моделей называть ее не наивной, а $\wedge$ идиотской байесовской моделью.) На практике наивные байесовские

системы могут действовать удивительно успешно, даже если предположение о независимости не является истинным. В главе 20 описаны методы изучения наивных байесовских распределений поданным наблюдений.

13.7. Еще одно возвращение в мир вампуса Теперь мы можем применить многие идеи, изложенные в этой главе, для решения задач в мире вампуса, требующих использования вероятностных рассуждений (полное описание мира вампуса приведено в главе 7). Неопределенность в мире вампуса возникает из-за того, что датчики агента сообщают только частичную, локальную информацию об этом мире. Например, на рис. 13.2 показана ситуация, в которой каждый из трех достижимых квадратов ([1,3], [2,2] и [3,1]) может содержать яму. Чисто логический вывод не позволяет прийти к каким-либо заключениям о том, какой квадрат с наибольшей вероятностью окажется безопасным, поэтому логический агент может быть вынужден выбирать среди них случайным образом. В этом разделе будет показано, что вероятностный агент может действовать гораздо успешнее, чем логический агент.

а) б) Рис. 13.2. Пример из мира вампуса: после обнаружения ветерка и в квадрате [1,2], и в квадрате [2,1] агент заходит в тупик — больше нет такого квадрата, который он мог бы обследовать без опасений (а); разделение квадратов на категории Known (Известные), Fringe (Периферийные) и Other (Другие) для формирования запроса (Query), касающегося квадрата [1,3] (б).

Наша цель будет состоять в том, чтобы вычислить вероятность наличия ямы в каждом из этих трех квадратов. (В данном конкретном примере игнорируется наличие вампуса и золота.) Относящиеся к этой задаче свойства мира вампуса состоят в том, что, во-первых, яма становится причиной возникновения ветерка во всех соседних квадратах, и, во-вторых, каждый квадрат, отличный от [1,1], содержит яму с вероятностью 0,2. Первый этап состоит в определении множества необходимых случайных переменных, как показано ниже. • Как и в случае пропозициональной логики, требуется по одной булевой переменной p_{ij} для каждого квадрата, которая принимает истинное значение тогда и только тогда, когда квадрат $[i, j]$ действительно содержит яму. • Требуются также булевы переменные B_{ij} принимающие истинное значение тогда и только тогда, когда в квадрате $[i, j]$ чувствуется ветерок; мы предусматриваем эти переменные только для наблюдаемых квадратов, в данном случае [1,1], [1,2] и [2,1].

Следующий этап состоит в определении полного совместного распределения $P\{P_{11}, \dots, P_{44}, B_{11}, B_{12}, B_{21}\}$. Применяя правило произведения, получаем следующее: $P(P_{11}, \dots, P_{44}, B_{11}, B_{12}, B_{21}) = P(B_{11}, B_{12}, B_{21} | P_{11}, \dots, P_{44}) P(P_{11}, \dots, P_{44})$ Эта декомпозиция позволяет очень легко определить, какими должны быть значения совместной вероятности. Первый терм представляет собой условную вероятность некоторой

конфигурации данных о наличии ветерка, если дана конфигурация расположения ям; он принимает значение 1, если в квадратах, соседних с ямами, чувствуется ветерок, в противном случае принимает значение 0. Вторым термом яв-

ляется априорная вероятность конфигурации расположения ям. Каждый квадрат может содержать яму с вероятностью 0,2, независимо от других квадратов, поэтому имеет место следующее:

$P(P_{i,j}, \dots, P_{4,4}) = \prod P(P_{i,j})$ A3.15) $i,j=1,4$ Для конфигурации с p ямами это значение равно $0.2^p \cdot 0.8^{16-p}$.

В ситуации, показанной на рис. 13.2, а, свидетельство состоит из наблюдаемого ветерка (или его отсутствия) в каждом посещенном квадрате, в сочетании с тем фактом, что каждый такой квадрат не содержит ямы. Эти факты можно сокращенно представить как $b = \langle b_1, \dots, b_4 \rangle$ и $known = \langle p_1, \dots, p_4 \rangle$. Мы заинтересованы в получении ответов на такие запросы, как $P(P_1 > 3 \mid known, b)$: насколько велика вероятность того, что квадрат [1,3] содержит яму, если даны результаты всех наблюдений, сделанных до сих пор?

Для получения ответа на этот запрос можно воспользоваться стандартным подходом, основанном на уравнении 13.6 и реализованном в алгоритме EnumerateJoint-Ask, а именно просуммировать элементы из таблицы полного совместного распределения. Допустим, что Unknown (Неизвестное) — составная переменная, которая состоит из переменных j if j для квадратов, отличных от квадратов Known и квадрата запроса [1,3]. В таком случае с помощью уравнения 13.6 получаем следующее:

$P(P_{1,3} \mid known, b) = \sum P(P_{1,3}, unknown, known, b)$ Полное совместное распределение вероятностей уже было задано, поэтому задача решена, точнее, осталось только выполнить вычисления. Количество неизвестных квадратов равно 12, поэтому требуемая сумма состоит из $2^{12} = 4096$ термов. Вообще говоря, количество термов в этой сумме растет экспоненциально в зависимости от количества квадратов.

Но интуиция подсказывает, что здесь есть какое-то упущение. Безусловно, напрашивается вопрос, не являются ли другие квадраты не относящимися к делу? Ведь содержимое квадрата [4,4] не влияет на то, имеется ли яма в квадрате [1,3]!

И действительно, эта догадка является правильной. Пользуясь ею, предположим, что Fringe — переменные (отличные от переменной запроса), которые описывают свойства квадратов, соседних по отношению к посещенным квадратам; в данном случае таковыми являются только [2,2] и [3,1]. Кроме того, допустим, что Other — это переменные, которые относятся к другим неизвестным квадратам; в данном случае количество других квадратов равно 10, как показано на рис. 13.2, б.

Ключевая идея состоит в том, что данные о наблюдаемом ветерке являются условно независимыми от других переменных, если даны условные переменные, переменные периферии и переменная запроса. После этой догадки остается лишь, так сказать, дело техники — выполнить несколько алгебраических операций.

Чтобы воспользоваться этой идеей, необходимо преобразовать формулу запроса в такую форму, в которой данные о наличии ветерка становятся условно зависимыми от всех других переменных, а затем упростить полученное выражение с использованием утверждения об условной независимости, как показано ниже.

$P(P_i, 31 \text{ known}, b) = a \cup P(b \setminus P_i, 3, \text{known}, \text{unknown}) P(P_i, i, \text{known}, \text{unknown})$ (согласно unknown правилу произведения) $= a \cup \cup P(b \setminus \text{known}, P_i, 3 / \text{fringe}, \text{other}) P(P_i, 3, \text{known}, \text{fringe}, \text{other}) \text{fringe other} = a \cup \cup P(b \setminus \text{known}, P_i, 3, \text{fringe}) "P(P_i, 3, \text{known}, \text{fringe}, \text{other}) \text{fringe other}$ В этом преобразовании на конечном этапе используется утверждение об условной независимости. Теперь первый терм в выражении не зависит от других переменных, поэтому можно переместить операцию суммирования внутрь выражения, следующим образом:

$P(P_i, r1 \text{ known}, b) = a \cup P(b \setminus \text{known}, P_i, 3 / \text{fringe}) \cup^{\wedge} P(P_i, 3 / \text{known}, \text{fringe}, \text{other}) \text{fringe other}$ Согласно утверждению о независимости, соответствующему приведенному в уравнении 13.15, терм априорной вероятности может быть факторизован, после чего все эти термы могут быть переупорядочены следующим образом:

$P(P_i, 31 \text{ known}, b) = a \cup^{\wedge} P(b \setminus \text{known}, P_i, 3, \text{fringe})^{\wedge} P(P_i / 3) P(\text{known}) P(\text{fringe}) P(\text{other}) \text{fringe other} = a P(\text{known}) "P(P_i \text{ tz}) \cup P(b \setminus \text{known}, P_i, 3 / \text{fringe}) P(\text{fringe}) \cup P(\text{other}) \text{fringe other} = a * P(P_i, 3) / P(b \setminus \text{known}, P_i, 3, \text{fringe}) P(\text{fringe}) \text{fringe}$ В этом преобразовании на последнем этапе постоянный терм $P(\text{known})$ вводится в нормализующую константу и используется тот факт, что выражение $\sum_{\text{other}} P(\text{other}) = 1$ Теперь в сумме по периферийным переменным $r_2, 2$ и R_{31} осталось только четыре термина. Использование свойств независимости и условной независимости позволило полностью исключить из рассмотрения другие квадраты. Обратите внимание на то, что выражение $P(b \setminus \text{known}, P_i, 3, \text{fringe})$ равно 1, если периферия совместима с данными наблюдений о наличии ветерка, а в противном случае равно 0.

Поэтому для получения каждого значения P_{13} проводится суммирование по логическим моделям для периферийных переменных, которые согласованы с известными фактами (это можно сравнить с тем, как осуществлялся перебор моделей на

рис. 7.4). Эти модели и связанные с ними априорные вероятности, $P(\text{fringe})$, показаны на рис. 13.3. Итак, получаем следующие значения:

$P(P_i, 3 \setminus \text{known}, b) = a_1 < 0.2 @ .04 + 0.16 + 0.16 >, 0.8 @ .04 + 0.16 > \ll < 0.31, 0.69 > \text{ OK и OK}$
т.

2.1 в ок 3,1 1.2 В ок 1,1 ок щ 2,1 в ок Ъв ОК 1,1 ..ок Щ 2,1 в ОК 1-2 В ОК 1,1 ок ш 2,1 в ОК 3,1 1>2В ок 1,1 ОК т 2,1 в _ОК 0,2x0,2 = 0,04 0,2x0,8 = 0,16 0,8x0,2 = 0,16 0,2x0,2 = 0,04 0,2x0,8 = 0,16 а) б) Рис. 13.3. Согласованные модели для периферийных переменных $P_{2,2}$ и $P_{3,i}$, показывающие значение P (fringe) для каждой модели: три модели с $P_i, z = \text{true}$, где показаны две или три ямы (а); две модели с $P_{1/3} = f a 1 s e$, где показаны одна или две ямы (б) Это означает, что квадрат [1,3] (а также квадрат [3,1], поскольку для него могут быть выполнены подобные вычисления) содержит яму с вероятностью приблизительно 31%. Аналогичное вычисление, которое авторы рекомендуют выполнить читателю, показывает, что квадрат [2,2] содержит яму с вероятностью приблизительно 86%.

Агент в мире вампуса определенно должен избегать квадрата [2,2]!

В данном разделе наглядно продемонстрировано, что даже такие задачи, которые внешне кажутся очень сложными, могут быть точно сформулированы в терминах теории вероятностей и решены с использованием простых алгоритмов. Для получения эффективных решений могут применяться соотношения, определяющие свойства независимости и условной независимости, которые позволяют упростить требуемые операции суммирования. Эти соотношения часто соответствуют нашему интуитивному пониманию того, как следует выполнять декомпозицию задачи.

В следующей главе будут разработаны формальные представления для таких соотношений, а также алгоритмы, оперирующие с соответствующими представлениями и позволяющие эффективно осуществлять вероятностный вывод.

13.8. Резюме В данной главе было показано, что понятие вероятности лежит в основе правильных способов формирования рассуждений о неопределенности. • Неопределенность возникает и по причине экономии усилий, и из-за отсутствия знаний. Неопределенности нельзя избежать в сложных, динамичных или труднодоступных мирах. • Наличие неопределенности означает, что многие упрощения, возможные в дедуктивном логическом выводе, становятся больше не допустимыми. • В оценках вероятности выражается неспособность агента прийти к определенному решению, касающемуся истинности высказывания. Вероятности являются выражением степени уверенности агента.

К основным типам вероятностных утверждений относятся утверждения, касающиеся априорных вероятностей и условных вероятностей простых и сложных высказываний.

Полное совместное распределение вероятностей задает вероятность каждого полного присваивания значений случайным переменным. Это распределение обычно слишком велико для того, чтобы его можно было создать или использовать в явной форме.

Аксиомы вероятностей регламентируют возможные присваивания вероятностей высказываниям. Агент, не учитывающий в своих действиях эти аксиомы, ведет себя в некоторых обстоятельствах нерационально.

Если полное совместное распределение доступно, оно может использоваться для получения ответов на запросы путем суммирования элементов с данными об атомарных событиях, соответствующих высказываниям запроса.

Наличие свойства абсолютной независимости между подмножествами случайных переменных позволяет факторизовать полное совместное распределение на меньшие совместные распределения. Это дает возможность значительно уменьшить сложность, но редко встречается на практике.

Правило Байеса позволяет вычислять неизвестные вероятности из известных условных вероятностей, обычно в причинном направлении. При наличии многочисленных свидетельств применение правила Байеса, как правило, приводит к возникновению таких же проблем масштабирования, которые возникают при использовании полного совместного распределения.

Свойство условной независимости, вызванное наличием прямых причинных связей в рассматриваемой проблемной области, может обеспечить факторизацию полного совместного распределения на меньшие условные распределения. В наивной байесовской модели предполагается наличие условной независимости всех переменных действия, если задана одна переменная причины; размеры этой модели увеличиваются линейно, в зависимости от количества результатов.

Агент в мире вампуса может рассчитывать вероятности ненаблюдаемых объектов мира и использовать их для принятия лучших решений по сравнению с теми, которые принимает простой логический агент.

Библиографические и исторические заметки Игры с элементами случайного выбора известны, по меньшей мере, с 300 года до н.э., но математический анализ случайных чисел и вероятностей стал проводиться гораздо позднее. Некоторые работы, выполненные индийским математиком Махавиракарьей (Mahaviracarya), датированы примерно IX веком. В Европе первые попытки проведения такого анализа начались только в эпоху итальянского Возрождения, приблизительно с 1500 года. Первый значимый систематический анализ был проведен Джироламо Кардано примерно в 1565 году, но его работы оставались неопубликованными до 1663 года. В это время открытие Блезом Паскалем систематического способа вычисления вероятностей (о котором он сообщил в переписке с

Пьером Ферма в 1654 году) впервые привело к утверждению теории вероятностей как математической дисциплины. Первым опубликованным учебником по теории

вероятностей была книга Гюйгенса *De Ratiociniis in Ludo Aleae* [712]. Кроме того, Паскаль ввел понятие условной вероятности, которое описано в учебнике Гюйгенса.

Преподобный Томас Байес (1702-1761 гг.) сформулировал правило формирования рассуждений об условных вероятностях, которое было названо в его честь. Работы Байеса были опубликованы только после его смерти [88]. Колмогоров в своей работе [826] (которая вышла вначале на немецком языке, в 1933 году) впервые представил теория вероятностей в виде строго аксиоматической инфраструктуры. В дальнейшем Реньи [1282] сформулировал аксиоматическое представление, в котором в качестве примитивного понятия используется условная, а не абсолютная вероятность.

Паскаль использовал вероятность в таких вычислениях, которые требовали не только ее объективной интерпретации, как свойства мира, основанного на симметрии или относительных частотах событий, но и субъективной интерпретации, основанной на оценке степени уверенности. Первая интерпретация обнаруживается в проведенном Паскалем анализе вероятностей в играх с элементами случайности, а последняя — в знаменитых доводах "Спора с Паскалем", касающихся возможного существования Бога. Однако Паскаль недостаточно четко учитывал различие между этими двумя интерпретациями. Указанное различие было впервые наглядно подчеркнуто Джеймсом Бернулли (1705-1782 гг.).

Лейбниц ввел "классическое" понятие вероятности как доли перечислимых, равновероятных случаев, которое использовалось также Бернулли, но полностью проанализировано Лапласом (1749-1827 гг.). Это понятие является противоречивым из-за наличия частотной и субъективной интерпретации. События могут рассматриваться как равновероятные либо из-за наличия естественной, физической симметрии между ними, либо просто из-за того, что мы не обладаем достаточными знаниями, которые позволили бы считать одно событие более вероятным, чем другое.

Подход, предусматривающий использование последних, субъективных соображений, оправдывающих допустимость присваивания равных вероятностей, известен под названием принципа безразличия [792].

Споры между приверженцами объективного и субъективного подходов обострились в XX столетии. Колмогоров [827], Р.А. Фишер [473] и Ричард фон Мизес [1544] были сторонниками относительной частотной интерпретации. Приведенная в работе Карла Поппера [1228] (которая была вначале выпущена на немецком языке, в 1934 году) интерпретация "проявлений закономерностей" позволяет проследить истоки формирования относительных частот вплоть до основополагающих законов физической симметрии. Франк Рамсей [1265], Бруно де Финетти [342], Р.Т. Кокс [304], Леонард Сэведж [1354] и Ричард Джеффри [727] интерпретировали вероятности как

степени уверенности конкретных лиц. Проводимый ими анализ степеней уверенности был тесно связан с полезностями и с поведением, а именно в этом направлении анализа оценивалась готовность субъекта делать те или иные ставки.

Рудольф Карнап, последовав за Лейбницем и Лапласом, предложил субъективную интерпретацию вероятности другого рода — не как определенной степени уверенности конкретного лица, а как степень уверенности, которую должна иметь идеализированная личность в отношении истинности конкретного высказывания а, если дан конкретный ряд свидетельств е. Карнап попытался продвинуться дальше Лейбница или Лапласа, сформулировав понятие степени $\wedge$ подтверждения математически

точно, как логического отношения между а и е. Исследования этого отношения имели своей целью создание математической дисциплины, которая была названа $\wedge$ индуктивной логикой по аналогии с обычной дедуктивной логикой [224], [225].

Карнап не смог далеко расширить свою индуктивную логику за пределы пропозиционального случая, а Хилари Патнем [1247] показала, что некоторые фундаментальные сложности послужили бы препятствием при создании строгих расширений языков, способных выражать арифметические соотношения.

С попыткой создать индуктивную логику тесно связана проблема референтных классов. Подход, предусматривающий выбор "наиболее конкретного" референтного класса с достаточными размерами, был формально предложен Рейхенбахом [1273].

Были сделаны различные попытки сформулировать более сложные подходы для предотвращения некоторых очевидных ошибок, связанных с использованием правила Рейхенбаха (к наиболее известным из них относятся работы Генри Кайберга [873], [874]), но такие подходы остаются в определенной степени лишенными теоретического фундамента. В опубликованной в дальнейшем работе [54] методы Карнапа распространены на теорию первого порядка, что позволило избежать многих сложностей, связанных с применением прямолинейного метода референтных классов.

Байесовские вероятностные рассуждения использовались в искусственном интеллекте начиная с 1960-х годов, особенно в области медицинской диагностики. Эти методы применялись не только для составления диагноза на основании доступных свидетельств, но и для выбора дополнительных вопросов и тестов с использованием теории информационного значения (раздел 16.6), если доступные свидетельства не позволяли прийти к окончательному выводу [583], [584]. Одна из систем превзошла людей-экспертов в области диагностики острых брюшных заболеваний [340]. Но такие ранние байесовские системы были подвержены многочисленным недостаткам.

Поскольку в этих системах отсутствовали какие-либо теоретические модели диагностируемых ими условий, они были чувствительными к нерепрезентативным данным, встречающимся в тех ситуациях, когда доступны были лишь небольшие выборки [341]. Еще более важным недостатком было то, что в этих системах не применялись лаконичные формальные средства (подобные тем, которые будут описаны в главе 14) для представления и использования информации об условной независимости, поэтому эксплуатация этих систем требовала накопления, хранения и обработки таблиц с вероятностными данными, достигающих колоссальных размеров. Из-за этих сложностей вероятностные методы решения задач в условиях неопределенности не вызывали интереса исследователей в области искусственного интеллекта в период 1970-х середины 1980-х годов. Достижения в этой области, появившиеся в конце 1980-х годов, которые изменили эту ситуацию, описаны в следующей главе.

Наивное байесовское представление для совместных распределений широко исследовалось в литературе по распознаванию образов с 1950-х годов [421]. Кроме того, такой способ представления использовался в области выборки текста, часто не совсем продуманно, начиная с [984]. Вероятностные основы этого метода, который дополнительно описан в упр. 13.18, были сформулированы в работе Робертсона и Спарка Джонса [1297]. Домингос и Паццани [402] объяснили причины поразительного успеха наивных байесовских рассуждений даже в тех проблемных областях, где они явно нарушали предположения о независимости.

По теории вероятностей есть много хороших вводных учебников, включая [254] и [1310]. Морис де Грот [378] подготовил объединенное введение в проблематику вероятностей и статистики с байесовской точки зрения, а также выпустил более расширенный учебник [377]. В учебнике Ричарда Хемминга [608] дано математически сложное введение в теорию вероятностей с точки зрения интерпретации проявления закономерностей, основанной на физической симметрии. В [605] и [606] описана ранняя история развития понятия вероятности. Бернштейн [114] составил увлекательный популярный отчет об истории понятия риска.

Упражнения 13.1. Докажите на основании основных принципов, что $P(A \setminus B | A) = 1$.

13.2. С использованием аксиом вероятностей докажите, что любое распределение вероятностей дискретной случайной переменной должно в сумме составлять 1.

13.3. Было бы рациональным для агента придерживаться трех убеждений — $P(A) = 0.4$, $P(B) = 0.3$ и $P(A \vee B) = 0.5$? Если это так, то какой диапазон вероятностей был бы рациональным для агента применительно к A и B ? Составьте таблицу, подобную приведенной в табл. 13.1, и покажите, подтверждает ли она ваши доводы в

отношении рациональности. Затем составьте еще одну версию этой таблицы, в которой $P(A \vee B) = 0.7$.

Объясните, почему рационально иметь уверенность в наличии этой вероятности, даже несмотря на то, что таблица показывает один случай, который соответствует проигрышу, и три случая, в которых достигается ничья. (Подсказка.

Какие обязательства взял на себя агент 1 применительно к вероятности каждого из четырех случаев, в частности, того случая, когда имеет место проигрыш?) 13.4. Этот вопрос касается свойств атомарных событий, как описано на с. 629. а) Докажите, что дизъюнкция всех возможных атомарных событий логически эквивалентна значению true. (Подсказка. Используйте доказательство по индукции, которое распространяется на произвольное количество случайных переменных.) б) Докажите, что любое высказывание логически эквивалентно дизъюнкции атомарных событий, из которых следует истинность этого высказывания.

13.5. Рассмотрите проблемную область, в которой речь идет о раздаче в покере на руки по 5 карт из стандартной колоды в 52 карты, на основе предположения, что раздача проводится честно. а) Каково количество атомарных событий в совместном распределении вероятностей (т.е. каково количество различных раздач по 5 карт)? б) Какова вероятность каждого атомарного события? в) Какова вероятность получения королевского флеша стрит? Четырех королей?

13.6. Исходя из полного совместного распределения, приведенного в табл. 13.2, вычислите следующее: а) $P\{\text{toothache}\}$ б) $P(C \wedge \neg \text{ty})$

в) $P\{\text{Toothache} \setminus \text{cavity}\}$ г) $P(\text{Cavity} | \text{toothache} \vee \text{catch})$ 13.7. Покажите, что три формы описания свойства независимости, приведенные в уравнении 13.8, являются эквивалентными.

13.8. После ежегодного медицинского осмотра некоторого пациента у врача есть плохая новость и хорошая новость. Плохая новость состоит в том, что оказалась положительной проверка на наличие серьезного заболевания и что точность результатов проверки составляет 99% (это означает, что вероятность получения положительного результата проверки, если пациент имеет это заболевание, равна 0,99, и такова же вероятность получения отрицательных результатов проверки, если пациент не имеет этого заболевания). Хорошая новость состоит в том, что это заболевание — редкое и поражает только 1 из 10 000 людей того возраста, в котором находится пациент. Почему новость, что это заболевание редкое, названа хорошей? Каковы шансы на то, что пациент действительно имеет данное заболевание?

13.9. Очень часто бывает полезно рассмотреть результаты некоторых конкретных высказываний в контексте определенного общего фоновое свидетельства, которое

остаётся неизменным, а не действовать в условиях полного отсутствия информации. В приведенных ниже вопросах предлагается доказать более общие версии правила произведения и правила Байеса применительно к некоторому фоновому свидетельству e . а) Докажите версию общего правила произведения с условными вероятностями:

$P(X, Y|e) = P(X|Y, e) P(Y|e)$ б) Докажите версию правила Байеса из уравнения 13.10 с условными вероятностями.

13.10. Покажите, что утверждение $P(A, B|C) = P(A|C) P(B|C)$ эквивалентно любому из следующих утверждений:

$P(A|B, C) = P(A|C)$ и $P(B|A, C) = P(B|C)$ 13.11. Допустим, что вам вручили мешок, содержащий p подлинных монет, и сообщили, что $l-1$ из этих монет являются нормальными, такими, что с одной стороны имеется орел, с другой — решка, а одна монета — фальшивая, и с обеих ее сторон имеется орел. а) Предположим, что вы открыли мешок, случайным образом выбрали монету, не пытаясь определить ее свойства, подбросили ее, после чего выпал орел. Какова (условная) вероятность того, что выбранная вами монета является фальшивой? б) Предположим, что вы продолжаете подбрасывать монету всего k раз после того, как ее выбрали, и обнаруживаете k выпадений орла. Какова теперь условная вероятность того, что вы выбрали фальшивую монету? в) Предположим, что вы хотите принять решение в отношении того, является ли выбранная монета фальшивой, подбросив ее k раз. Процедура

принятия решения возвращает FAKE (Фальшивая), если все k бросков приводят к выпадению орла, а в противном случае возвращает NORMAL (Нормальная). Какова (безусловная) вероятность того, что эта процедура допускает ошибку?

13.12. В этом упражнении предлагается выполнить вычисление коэффициента нормализации для примера с менингитом. Вначале выберите подходящее значение для $P(S|-iM)$ и примените его для вычисления ненормализованных значений $p(m|S)$ и $p(-m|S)$ (т.е. игнорируя терм $P(S)$ в выражении правила Байеса). Теперь нормализуйте эти значения таким образом, чтобы они в сумме составляли 1.

13.13. В этом упражнении исследуется то, как влияют соотношения, касающиеся условной независимости на количество информации, требуемой для вероятностных вычислений. а) Предположим, что необходимо рассчитать значение $P(h \in e_2)$, а информация об условной независимости отсутствует. Какие из следующих множеств чисел являются достаточными для такого вычисления?

1. $P(E_1|E_2), P(Y), P(E_1|Y), P(E_2|Y)$ 2. $T?(E_1|E_2), T?(H), T?(E_1|E_2 \wedge H)$ 3. $T?(H), V(E_1 \setminus H), V(E_2 \setminus H)$ б) Предположим, известно, что $P(E_1 \setminus Y, E_2) = P(E_2 | Y)$ для всех значений Y, E_1, E_2 . Какое из этих трех множеств значений теперь будет достаточным?

13.14. Допустим, что X, Y, Z — булевы случайные переменные. Обозначьте восемь элементов в совместном распределении $v\{x, Y, Z\}$ буквами алфавита от a до h . Выразите утверждение, что X и Y являются условно независимыми, если дано Z , в виде множества уравнений, связывающих элементы от a до h . Сколько среди них избыточных уравнений?

13.15. (Адаптировано из [1191].) Предположим, что вы — свидетель ночного наезда на пешехода в Афинах с участием такси, виновник которого уехал с места происшествия. Все такси в Афинах покрашены в синий или зеленый цвет.

Вы поклялись под присягой, что такси было синим, а результаты широких экспериментов показывают, что в условиях плохого освещения надежность распознавания синего и зеленого цветов составляет 75%. Возможно ли рассчитать наиболее вероятный цвет этого такси? (Подсказка. Тщательно проведите различие между высказыванием, что такси — синего цвета, и высказыванием, что оно внешне казалось синим.) А что можно сказать, получив информацию о том, что в Афинах 9 из 10 такси имеют зеленый цвет?

13.16. (Адаптировано из [1191].) Три заключенных, A , B и C , заперты в своих камерах. Всем известно, что один из них завтра будет казнен, а другие помилованы.

Но только губернатор знает, кто именно будет казнен. Заключенный A просит охранника об одолжении: "Пожалуйста, узнайте у губернатора, кто будет казнен, а затем передайте сообщение одному из моих друзей, B или C , чтобы он знал, что утром будет помилован". Охранник соглашается, а после возвращения говорит заключенному A , что передал сообщение о помиловании заключенному B .

Каковы шансы заключенного A на то, что он будет казнен, при наличии этой информации? (Ответьте на этот вопрос с помощью математики, а не энергичной жестикуляции.) 13.17. Напишите общий алгоритм получения ответов на запросы в форме $P(\text{Cause} | e)$ с использованием наивного байесовского распределения. Вы должны исходить из предположения, что свидетельство e может присваивать значения любому подмножеству переменных результата.

13.18. Категоризацией текста называется задача присваивания данному конкретному документу одной из фиксированного множества категорий на основе анализа содержащегося в нем текста. Для решения этой задачи часто используются наивные байесовские модели. В этих моделях переменной запроса является категория документа, а в качестве переменных "результата" рассматривается наличие или отсутствие каждого слова из языка документа; основное предположение состоит в том, что слова в документах встречаются независимо друг от друга, а их частоты определяются категорией документа. а) Объясните точно, как можно сформировать такую модель, получив в качестве "обучающих данных"

множество документов, которые были распределены по категориям. б) Объясните точно, как следует определять категорию нового документа. в) Является ли указанное предположение о независимости обоснованным?

Обсудите этот вопрос. 13.19. В проведенном в данной главе анализе мира вампуса использовался тот факт, что каждый квадрат содержит яму с вероятностью 0,2, независимо от содержимого других квадратов. Вместо этого примите предположение, что точно $N/5$ ям разбросаны равномерно случайным образом среди N квадратов, отличных от $[1,1]$. Остаются ли переменные $P_i \# j$ и $P_k < 1$ все еще независимыми? Каково теперь совместное распределение P ($P_1 \# 1, \dots, P_4/4$) ? Снова проведите вычисления вероятностей наличия ям в квадратах $[1,3]$ и $[2,2]$.

Глава 14. Вероятностные рассуждения

14 Вероятностные рассуждения В этой главе описано, как составлять сетевые модели для формирования рассуждений в условиях неопределенности в соответствии с законами теории вероятностей.

В главе 13 рассматривались синтаксис и семантика теории вероятностей. В ней отмечалась важность связей, определяющих независимость и условную независимость высказываний, для упрощения вероятностных представлений о мире.

В данной главе описан систематический способ явного представления таких связей в форме байесовских сетей. В ней будут определены синтаксис и семантика этих сетей и показано, как они могут использоваться для представления неопределенных знаний естественным и эффективным способом. Затем в этой главе будет продемонстрировано, что вероятностный вывод, хотя и не осуществимый с помощью вычислительных методов в наихудшем случае, может эффективно выполняться во многих практических ситуациях. Кроме того, будет описан целый ряд алгоритмов приближенного вероятностного вывода, которые часто могут применяться в тех случаях, когда точный вероятностный вывод неосуществим. В этой главе будут также представлены способы, с помощью которых теория вероятностей может быть применена к мирам с объектами и отношениями, т.е. к представлениям первого порядка, в отличие от пропозициональных представлений.

Наконец, в данной главе приведен обзор альтернативных подходов к формированию рассуждений в условиях неопределенности.

14.1. Представление знаний в неопределенной ПРОБЛЕМНОЙ ОБЛАСТИ В главе 13 было показано, что полное совместное распределение вероятностей позволяет отвечать на любые вопросы о рассматриваемой проблемной области, но может приобретать по мере увеличения количества переменных настолько большие

размеры, что вычисления становятся невозможными. Более того, сам способ задания вероятностей для атомарных событий является довольно неестественным и может оказаться весьма затруднительным при отсутствии большого объема данных, на основании которых накапливаются статистические оценки.

Кроме того, в предыдущей главе было показано, что связи, определяющие независимость и условную независимость между переменными, позволяют намного сократить количество вероятностей, которые должны быть заданы в целях определения полного совместного распределения. В настоящем разделе показана структура данных, называемая¹ байесовской сетью, которая позволяет представить связи между переменными и составить краткую спецификацию любого полного совместного распределения вероятностей.

Байесовская сеть — это ориентированный граф, в котором каждая вершина помечена количественной вероятностной информацией. Полная спецификация такой сети описана ниже.

1. Вершинами сети является множество случайных переменных. Переменные могут быть дискретными или непрерывными.
2. Вершины соединяются попарно ориентированными ребрами, или ребрами со стрелками; ребра образуют множество ребер. Если стрелка направлена от вершины X к вершине Y , то вершина X называется родительской вершиной вершины Y .
3. Каждая вершина x_i характеризуется распределением условных вероятностей $P(X_i \mid \text{Parents}\{X_i\})$, которое количественно оценивает влияние родительских вершин на эту вершину.
4. Граф не имеет циклов, состоящих из ориентированных ребер (и поэтому является ориентированным ациклическим графом (Directed Acyclic Graph — DAG)).

Топология сети (множество вершин и ребер) показывает отношения, определяющие условную независимость, которые проявляются в данной проблемной области, в том смысле, который вскоре будет точно сформулирован. Интуитивный смысл стрелки в правильно составленной сети обычно состоит в том, что вершина X оказывает непосредственное влияние на вершину Y . Для специалиста в проблемной области задача определения того, какие непосредственные влияния существуют в этой проблемной области, обычно является довольно легкой; действительно, она намного легче по сравнению с фактическим определением самих вероятностей.

После того как составлена топология байесовской сети, остается только указать распределение условных вероятностей для каждой переменной с учетом ее родительских переменных. В данной главе будет показано, что применение этой топологии и распределений условных вероятностей вполне позволяет (неявно) задать полное совместное распределение для всех переменных.

1 Такое название применяется наиболее часто, но для обозначения этой структуры данных предусмотрено также много других названий, в том числе сеть доверия (belief network), вероятностная сеть (probabilistic network), причинная сеть (causal network) и схема знаний (knowledge map).

В статистике термином графическая модель (graphical model) обозначается немного более широкий класс структур данных, который включает байесовские сети. Еще одно расширение байесовских сетей, называемое сетью принятия решений (decision network), или диаграммой влияния (influence diagram), рассматривается в главе 16.

Еще раз вернемся к простому миру, описанному в главе 13, который состоит из переменных Toothache, Cavity, Catch и Weather. В этой главе было показано, что переменная Weather не зависит от других переменных; более того, было продемонстрировано, что переменные Toothache и Catch являются условно независимыми, если задана переменная Cavity. Эти отношения представлены в виде структуры байесовской сети, показанной на рис. 14.1. Формально условная независимость переменных Toothache и Catch, если задана переменная Cavity, обозначается отсутствием связи между Toothache и Catch. Интуитивно можно понять, что в сети представлен такой факт— Cavity является непосредственной причиной Toothache и Catch, тогда как между Toothache и Catch не существует прямой причинной связи.

С[^]ШШЫ[^] (Cavity) Toothache) (Catch Рис. 14.1. Простая байесовская сеть, в которой переменная Weather независима от трех других переменных, а переменные Toothache и Catch являются условно независимыми, если задана переменная Cavity. Теперь рассмотрим следующий пример, который является немного более сложным. Житель пригорода установил в своем доме новую систему тревожной сигнализации для обнаружения взлома. Она довольно надежно обнаруживает взлом, но иногда также реагирует на небольшие землетрясения. (Этим примером мы обязаны Джуди Перлу, который живет в Лос-Анджелесе, поэтому проявляет острый интерес к землетрясениям.) У этого человека есть два соседа, Джон и Мэри, которые обещали звонить ему на работу, услышав тревожный сигнал. Джон всегда звонит, услышав тревожный сигнал, но иногда путает с ним телефонный звонок в доме соседа и в этих случаях также звонит. Мэри любит слушать довольно громкую музыку и поэтому иногда вообще пропускает тревожный сигнал. Получив факты о том, кто из этих соседей звонил или не звонил, необходимо оценить вероятность взлома.

Байесовская сеть для этой проблемной области приведена на рис. 14.2.

На время отвлечемся от распределения условных вероятностей, показанных на этом рисунке, и сосредоточимся на топологии сети. В случае сети определения взлома топология показывает, что взлом и землетрясения непосредственно влияют на вероятность появления тревожного сигнала, а звонки Джона и Мэри зависят только

от тревожного сигнала. Поэтому сеть подтверждает наши предположения, что соседи самостоятельно не обнаруживают какие-либо попытки взлома, не замечают незначительных землетрясений и не совещаются друг с другом перед звонками.

Обратите внимание на то, что в этой сети нет вершин, соответствующих тем ситуациям, в которых Мэри в настоящее время слушала бы громкую музыку или звонил бы телефон и сбивал с толку Джона. Эти факторы подытожены в показателях неопределенности, связанных с ребрами, направленными от вершины Alarm к вершинам JohnCalls и MaryCalls. Такая структура сети служит примером проявления в действии не только экономии усилий, но и недостатка знаний, поскольку потребовалось бы слишком много работы, чтобы узнать, по какой причине эти факторы могут оказаться более или менее вероятными в каждом конкретном случае; к тому же все равно отсутствует приемлемый способ получения релевантной информации. Вероятности, показанные на рисунке, фактически подытоживают потенциально бесконечное множество обстоятельств, которые либо могут вызвать нарушения при выработке тревожного сигнала (высокая влажность, отказ сети электропитания, разрядка аккумулятора, обрыв проводов,дохлая мышь, застрявшая внутри звонка, и т.д.), либо станут причиной того, что Джон или Мэри не смогут о нем сообщить (из-за того, что выйдут на обед, отправятся в отпуск, на время оглохнут, не расслышат сигнал в шуме пролетающего вертолета и т.д.). Но именно благодаря использованию приближенных оценок маленький агент получает возможность узнавать, что происходит в большом мире, по крайней мере, приблизительно. Степень приближения к истине может быть повышена по мере введения дополнительной релевантной информации.

Earthquake B E t t P(Л) 0,95 0,94 0,29 0,001 ML 0,002 A t f P(W 0,7 0,01 Рис. 14.2. Типичная байесовская сеть, на которой показаны и топология, и таблицы условных вероятностей (Conditional Probability Table — CPT). В таблицах CPT буквами в, Е, А, J и м обозначены следующие события: Burglary (Взлом), Earthquake (Землетрясение), Alarm (Тревожный сигнал), JohnCa 11 s (Звонки Джона) и MaryCa 11 s (Звонки Мэри) Теперь обратимся к распределениям условных вероятностей, показанным на рис. 14.2. На этом рисунке каждое распределение представлено в виде ^.таблицы условных вероятностей, или сокращенно CPT (Conditional Probability Table). (Такая форма таблицы может использоваться для дискретных переменных; другие представления, включая те, которые подходят для непрерывных переменных, описаны в разделе 14.2.) Каждая строка в таблице CPT содержит условную вероятность каждого значения вершины для ^ обуславливающего случая (conditioning case), определяющего условную вероятность. Обуславливающий случай представляет собой одну из возможных комбинаций значений родительских вершин (в принципе его можно

рассматривать как миниатюрное атомарное событие). Каждая строка должна в сумме составлять 1, поскольку элементы этой строки представляют собой исчерпывающее множество случаев для данной переменной. А если речь идет о булевых переменных, то после определения вероятности истинного значения, скажем p , вероятность ложного значения должна быть равна $1-p$, поэтому в таблицах CPT второе число часто не указывают, как и на рис. 14.2. Вообще говоря, любая таблица для булевой переменной с k булевыми родительскими переменными содержит 2^k независимо определяемых вероятностей. Таблица для вершины без родительских вершин имеет только одну строку, представляющую априорные вероятности каждого возможного значения соответствующей переменной.

14.2. Семантика байесовских сетей В предыдущем разделе описано, какой должна быть байесовская сеть, но не указано, что означает эта сеть. Существуют два способа, позволяющих понять семантику байесовских сетей. Первый из них состоит в том, что сеть следует считать одним из представлений совместного распределения вероятностей, а второй — в том, что она должна рассматриваться как описание совокупности утверждений об условной независимости. Эти две трактовки являются эквивалентными, но первая оказалась более полезной при определении способа составления сетей, а вторая — более применимой при проектировании процедур вероятностного вывода.

Представление полного совместного распределения Любая байесовская сеть представляет собой полное описание рассматриваемой проблемной области. Каждый элемент в полном совместном распределении вероятностей (которое ниже будет сокращенно именоваться "совместным распределением") может быть рассчитан на основании информации, представленной в этой сети.

Универсальным элементом в совместном распределении является вероятность конъюнкции конкретных присваиваний значений каждой переменной, такой как $P(X_1=x_1 \wedge \dots \wedge X_n=x_n)$. В качестве сокращенного обозначения для такой конъюнкции будет использоваться выражение $P(x_1, \dots, x_n)$. Значение этого элемента задается следующей формулой: $P(x_1, \dots, x_n) = \prod_i P(x_i | \text{parents}(X_i))$ A4.1 где $\text{parents}(X_i)$ обозначает конкретные значения переменных в множестве вершин $\text{Parents}(X_i)$. Поэтому каждый элемент в совместном распределении представлен в виде произведения соответствующих элементов в таблицах условных вероятностей (Conditional Probability Table — CPT) байесовской сети. Таким образом, таблицы CPT обеспечивают декомпонованное представление совместного распределения.

Для иллюстрации описанных выше понятий рассчитаем вероятность того, что прозвучал тревожный сигнал, но не произошли ни взлом, ни землетрясение, а позвонили и Мэри, и Джон. Мы будем использовать однобуквенные имена для этих переменных (см. рис. 14.2):

$P(j \text{ л т л л -иь л -ie}) = P(j|a)P(m|a)P(a|-ib \text{ л -ie}) P(-ib) P(-ie) = 0.90 \times 0.70 \times 0.001 \times 0.999 \times 0.998 = 0.00062$ В разделе 13.4 было описано, как можно использовать полное совместное распределение для получения ответа на любой запрос о данной проблемной области.

А если байесовская сеть служит представлением совместного распределения, то может также применяться для получения ответа на любой запрос путем суммирования соответствующих элементов совместного распределения. В разделе 14.4 показано, как найти ответ с помощью такого способа, а также описаны методы, которые являются гораздо более эффективными.

Метод составления байесовских сетей В уравнении 14.1 показано, что означает данная конкретная байесовская сеть.

Но это уравнение не позволяет определить, как следует составлять байесовскую сеть таким образом, чтобы результирующее совместное распределение служило адекватным представлением данной проблемной области. Тем не менее в этом разделе будет показано, что из уравнения 14.1 следуют определенные отношения условной независимости, которые могут использоваться инженером по знаниям в качестве руководящих указаний при составлении топологии сети. Вначале перезапишем это совместное распределение в терминах условных вероятностей с использованием правила произведения (см. главу 13):

$P(X_1, \dots, X_n) = P(x_n | x_{n-1}, \dots, X_1) P(x_{n-1} | \dots, X_1)$ Затем повторим этот процесс, приводя каждую конъюнктивную вероятность к условной вероятности и меньшей конъюнкции. В конечном итоге будет получено одно большое произведение:

$P(X_1, \dots, X_n) = P(x_n | x_{n-1}, \dots, X_1) P(x_{n-1} | x_{n-2}, \dots, X_1) \dots P(X_2 | X_1) P(X_1)$ Это тождество справедливо для любого множества случайных переменных и называется $\wedge$ цепным правилом (chain rule). Сравнивая его с уравнением 14.1, можно обнаружить, что данная спецификация совместного распределения эквивалентна общему утверждению, что для каждой переменной X_i в сети верно следующее:

$P(X_i | X_1, \dots, X_{i-1}) = P(X_i | \text{Parents}(X_i))$ A4.2) при условии, что $\text{Parents}(X_i) \subseteq \{X_1, \dots, X_{i-1}\}$. Это последнее условие можно выполнить, разметив вершины графа в любом порядке, совместимом с частичным упорядочением, неявно заданным в структуре графа.

Фактически уравнение 14.2 свидетельствует о том, что байесовская сеть служит правильным представлением проблемной области, только если каждая вершина в ней условно независима от ее предшественников в конкретном упорядочении вершин, после того как заданы ее родительские вершины. Поэтому, для того чтобы составить байесовскую сеть с правильной структурой для рассматриваемой проблемной области, необходимо выбрать для каждой вершины родительские

вершины так, чтобы соблюдалось это свойство. Интуитивно ясно, что множество родительских

вершин вершины X_i должно включать все такие вершины из множества $X_{1..n}$, X^A , которые $s^A =$ непосредственно влияют на x_L . Например, предположим, что мы полностью составили сеть, показанную на рис. 14.2, и осталось только выбрать родительские вершины для MaryCalls. Безусловно, на вершину MaryCalls оказывает влияние то, произошло ли событие Burglary или Earthquake, но это — не непосредственное влияние. Очевидно, что наши знания в этой проблемной области говорят о том, что эти события влияют на поведение Мэри, касающееся звонков, только через свое воздействие на тревожный сигнал. Кроме того, если речь идет о наличии тревожного сигнала, то звонок Джона не влияет на звонок Мэри.

Формально говоря, составляя эту сеть, мы уверены в том, что справедливо следующее утверждение об условной независимости:

$$P(\text{MaryCalls} \setminus \text{JohnCalls}, \text{Alarm}, \text{Earthquake}, \text{Burglary}) = P(\text{MaryCalls} \mid \text{Alarm})$$

Компактность сети и упорядочение вершин Байесовская сеть не только является полным и избыточным представлением проблемной области, но часто оказывается намного более компактной по сравнению с полным совместным распределением. Именно благодаря этому свойству байесовские сети становятся применимыми для представления проблемных областей со многими переменными. Компактность байесовских сетей является примером очень общего свойства $\wedge$ локально структурированных систем (называемых также $\wedge$ разреженными системами). В локально структурированной системе каждый субкомпонент непосредственно взаимодействует только с ограниченным количеством других компонентов независимо от общего количества компонентов. Локальная структура обычно ассоциируется с линейным, а не с экспоненциальным ростом сложности. В случае байесовских сетей резонно предположить, что в большинстве проблемных областей на каждую случайную переменную оказывают непосредственное влияние самое большее k других переменных, где k — некоторая константа. Если для простоты предположить, что в сети представлено p булевых переменных, то количество информации, необходимое для задания каждой таблицы условных вероятностей, будет составлять не больше 2^k чисел, а полная сеть может быть определена с помощью $l \cdot 2^k$ чисел. В отличие от этого, совместное распределение содержит 2^p чисел. В качестве конкретного примера предположим, что имеется $l=30$ вершин, а каждая из них имеет пять родительских вершин ($k=5$). В таком случае для соответствующей байесовской сети потребуется 960 чисел, а для полного совместного распределения — больше миллиарда.

Существуют и такие проблемные области, в которых на каждую переменную могут оказывать непосредственное влияние все другие переменные, поэтому соответствующая сеть является полносвязной. В таком случае для задания таблиц

условных вероятностей требуется такое же количество информации, как и для задания совместного распределения. Но есть и такие проблемные области, в которых существуют незначительные зависимости, тем не менее, обязательно требующие включения в сеть путем добавления нового ребра. Но если эти зависимости выражены очень слабо, то может не иметь смысла дополнительно повышать сложность сети ради небольшого выигрыша в точности. Например, можно было бы раскритиковать структуру нашей сети определения взлома на том основании, что если бы было землетря-

сение, то Джон и Мэри не позвонили бы, даже услышав тревожный сигнал, поскольку посчитали бы, что его причиной является землетрясение. Решение вопроса о том, следует ли вводить связи от Earthquake к JohnCalls и MaryCalls (и таким образом увеличивать размеры таблиц), зависит от результатов сравнения важности получения более точных вероятностей с затратами на указание дополнительной информации.

Составление локально структурированной байесовской сети даже в локально структурированной проблемной области представляет собой нетривиальную задачу.

Для этого требуется не только знать, что на каждую переменную непосредственно влияют лишь несколько других переменных, но и убедиться в том, что топология сети действительно отражает эти непосредственные влияния, представленные с помощью соответствующего множества родительских вершин. В связи с тем, как организована сама процедура составления сети, "непосредственно влияющие" вершины должны быть введены в сеть первыми, если они затем станут родительскими вершинами тех вершин, на которые влияют. Поэтому <Ж* правильный порядок, в котором следует вводить вершины, состоит в том, что вначале необходимо вводить вершины "коренных причин", затем вершины переменных, на которые они влияют, и т.д. до тех пор, пока не будут достигнуты "листовые вершины", которые не оказывают непосредственного причинного влияния на другие переменные.

А что произойдет, если будет выбран порядок, который окажется неправильным?

Еще раз рассмотрим пример со взломом. Предположим, что мы решили вводить вершины в порядке MaryCalls, JohnCalls, Alarm, Burglary, Earthquake.

В таком случае будет получена немного более сложная сеть, показанная на рис. 14.3, а. При этом процесс введения вершин происходит, как описано ниже. а) б) Рис. 14.3. Пример того, что структура сети зависит от порядка введения вершин. В каждой из сетей, показанных на этом рисунке, вершины вводились в порядке сверху вниз • Введение вершины MaryCalls — родительские вершины отсутствуют. • Введение

вершины JohnCalls — если звонит Мэри, это, по-видимому, означает, что раздался тревожный сигнал, а вероятность такого события, очевид-

но, будет выше, если позвонит также и Джон. Поэтому для вершины JohnCalls необходимо использовать в качестве родительской вершину MaryCalls. • Введение вершины Alarm— безусловно, если позвонили оба соседа, вероятность того, что раздался тревожный сигнал, больше, чем лишь при одном звонке или вообще без звонков, поэтому в качестве родительских необходимо включить обе вершины, и MaryCalls, и JohnCalls. • Введение вершины Burglary— если известно состояние тревожного сигнала, то звонок от Джона или Мэри может дать жильцу охраняемого дома информацию о том, что звонил его телефон или Мэри слушала музыку, но не о взломе:

$P(\text{Burglary} \setminus \text{Alarm}, \text{JohnCalls}, \text{MaryCalls}) = P(\text{Burglary} \setminus \text{Alarm})$ Поэтому для использования в качестве родительской вершины требуется только Alarm. • Введение вершины Earthquake — если раздался тревожный сигнал, то возможно также, что было землетрясение (эта тревожная сигнализация является к тому же своего рода детектором землетрясения). Но известно, что если был взлом, то тревожный сигнал объясняется именно этим, а вероятность землетрясения должна быть лишь ненамного выше нормальной. Поэтому в качестве родительских вершин для этой вершины необходимо иметь и Alarm, и Burglary.

Результирующая сеть имеет на два ребра больше по сравнению с первоначальной сетью, показанной на рис. 14.2, а также требует указания трех дополнительных вероятностей. Но что еще хуже, некоторые из ее связей представляют надуманные отношения, которые требуют формирования сложных и неестественных суждений о вероятностях, таких как оценки вероятности Earthquake, если даны Burglary и Alarm. Такой феномен является весьма распространенным и связан с различием между причинными и диагностическими моделями, которые были представлены в главе 8. Если мы попытаемся построить диагностическую модель со связями от симптомов к причинам (как, например, от MaryCalls к Alarm или от Alarm к Burglary), то в конечном итоге будем вынуждены задавать дополнительные зависимости между причинами, которые во всем остальном являются независимыми (а часто даже между отдельно возникающими симптомами), <Ж* Если же мы будем придерживаться причинной модели, то в конечном итоге нам придется задавать меньше чисел и сами эти числа, скорее всего, можно будет легче определить. Например, Тверский и Канеман [1523] для проблемной области медицинской диагностики показали, что опытные врачи предпочитают составлять вероятностные суждения для причинных, а не диагностических правил.

На рис. 14.3, б показано еще худшее упорядочение вершин: MaryCalls, JohnCalls, Earthquake, Burglary, Alarm. Для этой сети требуется задать 31 отдельную вероятность — точно такое же количество, как и при использовании полного совместного

распределения. Однако важно понять, что любая из этих трех сетей может представлять точно такое же совместное распределение, как и другие.

Просто в последних двух версиях не удалось успешно выявить все отношения условной независимости и поэтому вместо них пришлось ввести много ненужных чисел.

Отношения условной независимости в байесовских сетях В предыдущем разделе была определена "числовая" семантика для байесовских сетей в терминах представления полного совместного распределения, как в уравнении 14.1.

Используя эту семантику для вывода метода составления байесовских сетей, мы пришли к заключению, что вершина является условно независимой от ее предшественников, если заданы ее родительские вершины. Как оказалось, можно также двигаться в другом направлении. Мы можем начать с "топологической" семантики, которая задает отношения условной независимости, закодированные в структуре графа, а из этой информации вывести "числовую" семантику. Топологическая семантика задается любой из приведенных ниже спецификаций, которые являются эквивалентными².

1. Вершина является условно независимой от вершин, не являющихся ее $\wedge$ потомками, если даны ее родительские вершины. Например, на рис. 14.2 вершина JohnCalls независима от Burglary и Earthquake, если дано значение Alarm.

2. Вершина является условно независимой от всех других вершин в сети, если даны ее родительские вершины, дочерние вершины и родительские вершины дочерних вершин, т.е. дано ее $\wedge$ марковское покрытие (Markov blanket).

Например, вершина Burglary независима от JohnCalls и MaryCalls, если даны Alarm и Earthquake.

Примеры применения этих спецификаций показаны на рис. 14.4. На основании приведенных утверждений об условной независимости и таблиц CPT можно реконструировать полное совместное распределение; таким образом, "числовая" семантика и "топологическая" семантика являются эквивалентными.

14.3. Эффективное представление распределений условных вероятностей Даже если максимальное количество родительских вершин невелико, для заполнения таблицы CPT, относящейся к некоторой вершине, необходимо будет задать вплоть до $O(V^k)$ чисел, а также, возможно, потребуется значительный опыт оценки всех возможных обуславливающих случаев. К тому же на практике иногда встречается наихудшая ситуация, в которой связь между родительскими вершинами и дочерней вершиной является полностью произвольной. Обычно такие отношения можно описать с помощью $\wedge$ канонического распределения, которое соответствует некоторому стандартному образцу. В таких случаях всю таблицу можно задать,

указав тип распределения и, возможно, введя несколько параметров, что намного проще по сравнению с определением экспоненциального количества параметров.

2 Существует также общий топологический критерий, называемый d-отделением, для принятия решения о том, является ли множество вершин X независимым от другого множества Y , если задано третье множество Z . Этот критерий является довольно сложным и не требуется для разработки алгоритмов, приведенных в данной главе, поэтому мы его не описываем. Подробные сведения об этом критерии можно найти в [1191] или [1328], а в [1384] описан более интуитивно понятный метод проверки выполнения условий d-отделения.

а) б) Рис. 14.4. Примеры использования спецификаций топологической семантики: вершина X является условно независимой от вершин, не являющихся ее потомками (например, от вершин Z_{jj}), если даны ее родительские вершины (вершины U_i , показанные в затененной области) (а); вершина X является условно независимой от всех других вершин в сети, если дано ее марковское покрытие (затененная область) (б) С другой стороны, примером простейшей ситуации является наличие $\wedge$ детерминированных вершин. Детерминированная вершина характеризуется тем, что ее значение точно определяется значениями ее родительских вершин, без какой-либо неопределенности. Отношение между вершинами может быть логическим, например, отношение между родительскими вершинами Canadian, US, Mexican и дочерней вершиной NorthAmerican состоит в том, что значение дочерней вершины представляет собой дизъюнкцию значений родительских вершин. Такое отношение может также быть числовым, например, если значениями родительских вершин являются цены на конкретную модель автомобиля у нескольких дилеров, а значением дочерней вершины является цена, которую в конечном итоге заплатит охотник за низкими ценами, то значением дочерней вершины является минимальное из значений родительских вершин. Если же значениями родительских вершин являются притоки воды (через реки, ключи, росу) в озеро и оттоки воды (через реки, испарения, дренаж) из озера, а значением дочерней вершины является изменение уровня воды в озере, то значение дочерней вершины представляет собой общую разницу между родительскими вершинами с притоком и родительскими вершинами с оттоком.

Неопределенные отношения можно также часто охарактеризовать с использованием так называемых "зашумленных" логических отношений. Стандартным примером является отношение $\wedge$ зашумленного OR, которое представляет собой обобщение логического отношения OR. В пропозициональной логике можно составить утверждение, что высказывание Fever (Жар) является истинным тогда и только тогда, когда истинны высказывания Cold (Простуда), Flu (Грипп) или Malaria (Малярия). Модель зашумленного OR позволяет учитывать неопределенность знаний в отношении способности каждой из родительских

вершин вызывать присваивание истинного значения дочерней вершине, поскольку причинная связь между родительской и дочерней вершинами может быть заблокирована и поэтому иногда

пациент бывает простужен, но у него не обнаруживается жар. В этой модели приняты два предположения. Во-первых, в ней предполагается, что учтены все возможные причины. (Это — не такое строгое требование, как кажется на первый взгляд, поскольку всегда есть возможность ввести так называемую $\wedge$ вершину утечки (leak node), которая покрывает "прочие причины".) Во-вторых, предполагается, что блокирование каждой родительской вершины не зависит от блокирования любых других родительских вершин, например, та причина, которая блокирует возникновение жара под влиянием действия вершины Malaria, не зависит от тех причин, которые блокируют возникновение жара под действием вершины Flu. С учетом этих предположений значение вершины Fever является ложным тогда и только тогда, когда заблокированы все ее родительские вершины, имеющие истинное значение, а вероятность такой ситуации представляет собой произведение вероятностей блокировки каждой родительской вершины. Предположим, что такие отдельные вероятности блокировки выражаются следующим образом:

$P(\neg \text{if ever } \setminus \text{cold}, -1 \text{ flu}, \neg \text{jnalaria}) = 0.6$ $P(\neg \text{ifever } \setminus \text{-tCold, flu, } -\wedge \text{malaria}) = 0.2$ $P(\neg \text{nf ever } \setminus \neg \setminus \text{Cold}, -n \text{ flu, malaria}) = 0.1$ В таком случае появляется возможность составить всю таблицу CPT на основании этой информации и предположений модели зашумленного OR. Пример вычисления значений соответствующих элементов показан в табл. 14.1.

Таблица 14.1. Пример вычисления значений таблицы CPT Cold F F F T T T T Flu F F T T F F T T Malaria F T F T F T F T P(Fever) 0.0 0.9 0.8 0.98 0.4 0.94 0.88 0.988 P(-iFever) 1.0 0.1 0.2 0.02 = 0.2x0.1 0.6 0.06 = 0.6 x 0.1 0.12 = 0.6 x 0.2 0.012 = 0.6 x 0..

Вообще говоря, зашумленные логические отношения, в которых некоторая переменная зависит от k родительских переменных, могут быть описаны с использованием $O(k)$ параметров вместо $O(2^k)$ параметров, которые требуются для полной таблицы условных вероятностей. Благодаря этому задачи присваивания значений и обучения намного упрощаются. Например, распределения зашумленного OR и зашумленного MAX успешно использовались в сети CPCS [1232] для моделирования отношений между заболеваниями и симптомами в диагностике внутренних органов.

При наличии 448 вершин и 906 связей в этой сети потребовалось только 8254 значения вместо 133 931 430 значений для сети с полными таблицами CPT.

Байесовские сети с непрерывными переменными Для решения многих реальных задач требуется учитывать непрерывные количества, такие как уровень, масса, температура и сумма денежных средств; в действи-

тельности большая часть такого научного направления, как статистика, посвящена исследованию случайных переменных, области определения которых являются непрерывными. По определению непрерывные переменные имеют бесконечное количество возможных значений, поэтому невозможно явно задать условные вероятности для каждого значения. Один из возможных способов обработки непрерывных переменных состоит в избавлении от них с помощью ^ дискретизации, т.е. разделения всех возможных значений на постоянное множество интервалов. Например, температуры могут быть разделены на интервалы ($< 0^{\circ}\text{C}$), $@^{\circ}\text{C} - 100^{\circ}\text{C}$) и ($> 100^{\circ}\text{C}$).

Иногда дискретизация становится вполне адекватным решением, но часто приводит к значительной потере точности и появлению очень больших таблиц СРТ. Еще одно решение состоит в определении стандартных семейств функций плотности вероятностей (см. приложение А), которые задаются с помощью конечного количества ^ параметров. Например, гауссово (или нормальное) распределение $N(\mu, \sigma^2)$ (x) имеет в качестве параметров среднее μ и дисперсию σ^2 .

Сеть, в которой имеются и дискретные, и непрерывные переменные, называется ^ гибридной байесовской сетью. Для составления гибридной сети необходимо определить два новых типа распределений: условное распределение для непрерывной переменной, если даны дискретные или непрерывные родительские переменные, и условное распределение для дискретной переменной, если даны непрерывные родительские переменные. Рассмотрим простой пример, приведенный на рис. 14.5, в котором клиент покупает какие-то фрукты в зависимости от их стоимости, которая, в свою очередь, зависит от размера урожая и от того, применяется ли правительственная программа субсидий. Переменная Cost (Стоимость) является непрерывной и имеет непрерывные и дискретные родительские переменные; переменная Buys (Покупает) является дискретной и имеет непрерывную родительскую переменную.

(Subsidy (Harvest $\rightarrow$ Cost) $\rightarrow$ Buys) Рис. 14.5. Простая сеть с дискретными переменными (^Subsidy — субсидия) и Buys — покупает) и непрерывными переменными (^Harvest — урожай и Cost — стоимость) Для переменной Cost необходимо задать распределение $P(\text{Cost} | \text{Harvest}, \text{Subsidy})$. Это дискретное родительское значение учитывается с помощью явного перечисления, т.е. определения и значения $P(\text{Cost} | \text{Harvest}, \text{subsidy})$, и значения $P(\text{Cost} | \text{Harvest}, \text{^subsidy})$. Чтобы учесть переменную Harvest, требуется определить, как распределение по стоимости зависит от непрерывного значения h переменной Harvest. Иными словами, необходимо определить параметры распределения стоимости как функции от h . Наиболее часто применяемым вариантом является ^ линейное гауссово распределение, в котором дочерняя переменная имеет

гауссового распределение со средним $j\mu$, изменяющимся линейно в зависимости от значения родительской переменной, и с постоянным среднеквадратичным отклонением σ . Необходимо иметь два распределения, одно для $subsidy$, а другое для $-subsidy$, с разными параметрами:

$P(c|h, subsidy) = N(ath + bt, at^2)$ (с) $P(c|h, -subsidy) = N(ath + bt, af^2)$ (с) $CTt \text{ фл1 } 1(c - (ath+bt) \text{ If } c - (afh+bf) \text{ Gt} \lfloor 2n$ Итак, в данном примере условное распределение для переменной $Cost$ было задано путем обозначения его как линейного гауссового распределения и предоставления параметров at , bt , at , af , bf и af . Эти два отношения показаны на рис. 14.6, а и б. Обратите внимание на то, что в каждом случае наклон кривых является отрицательным, поскольку цена уменьшается по мере увеличения поставок. (Безусловно, из предположения о линейности следует, что цена в некоторый момент станет отрицательной; линейная модель является приемлемой, только если объем урожая ограничен каким-то узким диапазоном.) На рис. 14.6, в показано распределение $P(c|h)$, усредненное по двум возможным значениям $Subsidy$, в предположении, что каждое из этих двух значений имеет априорную вероятность 0,5. Данный пример показывает, что даже с помощью очень простых моделей могут быть представлены весьма интересные распределения.

$P(c|h, subsidy) 0,4$ Harvest h $P(c|h, subsidy) \text{ Л } 0,4 \text{ л } 0,3 \text{ | } 0,2 \text{ | } 0,1 \text{ | } Cost \text{ с б) } P(c|h) \text{ Harvest } h \text{ Cost с в) Рис. 14.6. Графики отношений. На графиках а) и б) показаны распределения вероятностей по значению стоимости Cost как функции от объема урожая Harvest, при условии, что переменная Subsidy имеет соответственно истинное и ложное значения. На графике в) показано распределение }^{Cost / Harvest}, полученное путем суммирования по двум случаям, связанным с субсидией (предоставление и не предоставление) Линейное гауссово условное распределение обладает некоторыми особыми свойствами. Сеть, содержащая только непрерывные переменные с линейными гауссовыми распределениями, имеет совместное распределение, представляющее собой многомерное гауссово распределение по всем переменным³ (упр. 14.5).$

3 Из этого следует, что вероятностный вывод в линейных гауссовых сетях в наихудшем случае требует $O(n^3)$ времени независимо от топологии сети. В разделе 14.4 будет показано, что вероятностный вывод в сетях с дискретными переменными является NP-трудным.

нескольких измерениях, которая имеет пик в районе среднего значения, в p измерениях, и уменьшается по всем направлениям.) Если в сеть введены дискретные переменные (при условии, что ни одна дискретная переменная не является дочерней применительно к непрерывной переменной), то сеть определяет $\wedge$ условное гауссово распределение, или распределение CG (conditional Gaussian): если дано любое присваивание дискретным переменным, то распределение по непрерывным переменным становится многомерным гауссовым распределением.

Теперь обратимся к распределениям для дискретных переменных с непрерывными родительскими переменными. Например, рассмотрим вершину Buys на рис. 14.5. Представляется обоснованным предположение, что клиент сделает покупку, если стоимость является низкой, и не сделает покупку, если она высока, а также, что вероятность покупки изменяется плавно в некотором промежуточном регионе.

Другими словами, условное распределение напоминает "мягкую" пороговую функцию. Один из способов определения мягких пороговых функций состоит в использовании интеграла стандартного нормального распределения:

$\Phi(x) = \int_{-\infty}^x \phi(t) dt$ В таком случае вероятность события Buys, если дано значение Cost, может выражаться следующей формулой:

$P(\text{buys} \mid \text{Cost}=c) = \Phi((c-\mu)/\sigma)$ которая означает, что пороговое значение стоимости обнаруживается в районе μ , ширина порогового региона пропорциональна σ , а вероятность покупки уменьшается по мере возрастания стоимости.

Такое распределение вероятностей называется $\wedge$ пробит-распределением (probit distribution) и показано на рис. 14.7, а. Возможность применения распределения с такой формой может быть обосновано тем, что соответствующий процесс принятия решения имеет твердый порог, но точное расположение этого порогового значения подвержено воздействию случайного гауссового шума. Альтернативным по отношению к пробит-распределению является $\wedge$ логит-распределение (logit distribution), в котором для формирования мягкого порога используется $\wedge$ сигмоидальная функция (sigmoid function): $P(\text{buys} \mid \text{Cost}=c) = \frac{1}{1 + \exp(-\frac{c-\mu}{\sigma})}$ Это распределение показано на рис. 14.7, б. Два распределения внешне выглядят одинаковыми, но фактически логит-распределения имеют более длинные "хвосты". Пробит-распределения часто лучше подходят в реальных ситуациях, а логит-распределения иногда проще поддаются математической обработке.

Последние широко используются в нейронных сетях (глава 20). И пробиты логитраспределения могут быть обобщены для учета многочисленных непрерывных родительских значений путем применения линейной комбинации родительских значений. Расширения для случая многомерных дискретных дочерних значений рассматриваются в упр. 14.6.

6 8 10 12 Стоимость с Стоимость с а) б) Рис. 14.7. Примеры других распределений: пробит-распределение для вероятности события Buys, если дано значение Cost, которое характеризуется значениями $\mu = 6$. 0 и $\sigma = 1.0$ (а); логитраспределение с такими же параметрами (б) 14.4. Точный ВЕРОЯТНОСТНЫЙ ВЫВОД В БАЙЕСОВСКИХ СЕТЯХ Основной задачей для любой системы вероятностного вывода является вычисление распределения апостериорных вероятностей для множества переменных запроса, если дано некоторое наблюдаемое $\wedge$ событие, т.е. если выполнено некоторое присваивание значений множеству переменных

свидетельства. Мы будем использовать систему обозначений, введенную в главе 13: X обозначает переменную запроса; E — множество переменных свидетельства, $E_1, \dots, E_n$; e — конкретное наблюдаемое событие; Y обозначает переменные, отличные от переменных свидетельства, $Y_1, \dots, Y_n$ (иногда называемые скрытыми переменными). Таким образом, полное множество переменных определяется выражением $X = \{X_i\}_{i \in \mathcal{U}}$. В типичном запросе⁴ содержится просьба определить распределение апостериорных вероятностей $P(X|e)$.

В сети с описанием взлома может наблюдаться событие, в котором $\text{JohnCalls} = \text{true}$ и $\text{MaryCalls} = \text{true}$. В таком случае можно ввести следующий запрос, скажем, для определения вероятности того, что произошел взлом:

$P(\text{Burglary} | \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true}) = \langle 0.284, 0.716 \rangle$ В этом разделе рассматриваются точные алгоритмы вычисления апостериорных вероятностей и приводятся сведения о сложности такой задачи. Как оказалось, в общем случае эта задача неразрешима, поэтому в разделе 14.5 рассматриваются методы приближенного вероятностного вывода.

⁴ Предполагается, что переменная запроса не относится к числу переменных свидетельства; если бы она была таковой, то в распределении апостериорных вероятностей для X была бы присвоена вероятность 1 этому наблюдаемому значению. Кроме того, для упрощения предполагается, что запрос касается только единственной переменной. Приведенные здесь алгоритмы могут быть легко дополнены для обработки запросов, касающихся нескольких переменных.

Вероятностный вывод с помощью перебора Как говорилось в главе 13, любую условную вероятность можно вычислить, суммируя элементы из полного совместного распределения. Более конкретно следует указать, что ответ на запрос $P(X|e)$ можно получить с использованием уравнения 13.6, которое мы повторяем здесь для удобства:

$P(x|e) = \frac{1}{Z} P(X, e) = \frac{1}{Z} \sum_y P(X, e, y)$ Итак, любая байесовская сеть создает исчерпывающее представление полного совместного распределения. А именно, в уравнении 14.1 показано, что термы $P(x, e, y)$ в совместном распределении можно записать в виде произведений условных вероятностей, взятых из сети. Поэтому Z на любой запрос можно найти ответ с помощью байесовской сети, вычисляя суммы произведений условных вероятностей из этой сети.

В листинге 13.2 был приведен алгоритм Enumerate-Joint-Ask, обеспечивающий вероятностный вывод путем перебора элементов полного совместного распределения, который принимает на входе полное совместное распределение P и выполняет в нем поиск значений. Этот алгоритм несложно модифицировать так, чтобы он принимал на входе байесовскую сеть $\mathcal{B}$ и "отыскивал" элементы

совместного распределения, умножая соответствующие элементы таблиц CPT, взятые из сети Ьп.

Рассмотрим запрос $P(\text{Burglary} \mid \text{JohnCalls} = \text{true}, \text{MaryCalls} = \text{true})$.

Скрытыми переменными для этого запроса являются Earthquake и Alarm.

Из уравнения 13.6, используя начальные символы имен переменных для сокращения длины выражений, можно получить следующее5:

$P(B_{j,m}) = \sum_a P(B_{j,m} = a) \sum_{e,t} P(B_{j,m} = a, e, t) \sum_{a'} P(B_{j,m} = a, e, t, a')$ В таком случае выражение в терминах элементов таблицы CPT может быть получено с учетом семантики байесовских сетей (уравнение 14.1). Для упрощения получим соответствующее выражение только для случая Burglary = true:

$P(b_{j,m}) = \sum_a \sum_{e,t} p(b)p(e)p(a|b,e)p(t|a,e)p(m|a)$ Для вычисления этого выражения необходимо сложить четыре терма, каждый из которых вычисляется путем умножения пяти чисел. В наихудшем случае, когда приходится находить сумму почти по всем переменным, сложность этого алгоритма для сети с n булевыми переменными равна $O(2^n)$.

Некоторое упрощение может быть достигнуто на основе следующих простых наблюдений: терм $P(b)$ представляет собой константу и может быть перенесен за пределы выражения, как $\sum_e p(a, e)$, обозначает сумму $p(A=a, E=e)$ по всем возможным значениям e . При этом может возникать неоднозначность, связанная с тем, что $P(e)$ используется для обозначения и $P(E=\text{true})$, и $p(E=e)$, но из контекста должно быть ясно, какой смысл имеет это выражение; в частности, в контексте суммы подразумевается последнее значение.

дела выражений суммирования по a и e , а терм $P(e)$ — перенесен за пределы выражения суммирования по a . Поэтому получаем следующее:

$P(b_{j,m}) = \sum_a P(b) \sum_e P(a|b,e) P(j|a) P(m|a)$ A4.3) e и a Это выражение можно вычислить, последовательно обрабатывая в цикле его переменные и перемножая в ходе этого элементы таблицы CPT. При каждом суммировании необходимо также выполнить цикл по возможным значениям переменной.

Структура этих вычислений показана на рис. 14.8. Используя числа, приведенные на рис. 14.2, получим выражение $P(b_{j,m}) = 0.00059224$. Соответствующее вычисление для $i=b$ приводит к получению выражения 0.0014919 , поэтому имеет место следующее:

$P(B_{j,m}) = 0.00059224, 0.0014919 > \ll 0.284, 0.716 >$ Таким образом, вероятность взлома, при условии, что поступили звонки от обоих соседей, составляет около 28%.

Процесс вычисления выражения, приведенного в уравнении 14.3, показан в виде дерева синтаксического анализа выражения на рис. 14.8. В алгоритме Enumeration-

Ask, приведенном в листинге 14.1, вычисление подобных деревьев осуществляется с использованием рекурсии в глубину. Таким образом, пространственная сложность алгоритма Enumeration-Ask зависит от количества переменных только линейно; по сути этот алгоритм вычисляет суммы по полному совместному распределению, даже не формируя его явно. К сожалению, его временная сложность для сети с p булевыми переменными всегда составляет $O(2^p)$; это лучше по сравнению с оценкой $O(p^2)$ для простого подхода, описанного выше, но все еще довольно велика. В отношении дерева, приведенного на рис. 14.8, необходимо сделать еще одно замечание — в нем явно показаны повторяющиеся подвыражения, вычисляемые с помощью этого алгоритма.

Произведения $P(j|a)P(m|a)$ и $P(j|-a)P(t|-a)$ вычисляются дважды, по одному для каждого значения e . В следующем разделе описан общий метод, позволяющий избежать таких избыточных вычислений.

Листинг 14.1. Алгоритм перебора для получения ответов на запросы в байесовских сетях

```
function Enumeration-Ask( $X, e, bn$ ) returns распределение по  $X$ 
inputs:  $X$ , переменная запроса  $e$ , наблюдаемые значения переменных  $E \setminus p$ , байесовская сеть с переменными  $\{X\} \cup E \cup Y$  /*  $Y$  - скрытые переменные */
 $Q(X) \leftarrow$  распределение по  $X$ , первоначально пустое
for each значение  $x_i$  переменной  $X$  do дополнить  $e$  значением  $x_i$  переменной  $X$ 
 $Q(x_i) \leftarrow \text{Enumerate-All}(\text{Vars}[bn], e)$ 
return Normalize( $Q(X)$ )

function Enumerate-All( $vars, e$ ) returns действительное число
if Empty? $\{vars\}$  then return 1.0
 $Y \leftarrow \text{First}(vars)$  if переменная  $Y$  имеет значение  $y$  в множестве  $e$ 
```

then return $P(y|\text{parents}\{Y\}) \times \text{Enumerate-All}(\text{Rest}(vars), e)$ else return $> P(y|\text{parents}(Y)) \times \text{Enumerate-All}(\text{Rest}(vars), e)$ где e_y представляет собой множество e , дополненное значением $Y = y$

$P(e) = 0,002$ $P(a|b,e) = 0,95$ $P(-b|c,e) = 0,06$ $P(a) = 0,9$ $P(t|a) = 0,7$ Рис. 14.8.

Структура выражения, показанного в уравнении 14.3. Процесс вычисления осуществляется сверху вниз; при этом значения вдоль каждого пути умножаются и суммируются в узлах "+". Обратите внимание на то, что пути для j и m повторяются

Алгоритм устранения переменной

Описанный выше алгоритм перебора можно существенно улучшить, исключив повторные вычисления такого типа, как показано на рис. 14.8. Его идея проста: выполнить вычисление один раз и сохранить результаты для дальнейшего использования. В этом выражается одна из форм динамического программирования.

Существует несколько версий такого подхода; в данной главе будет представлен алгоритм $\wedge$ устранения переменной (variable elimination), который является наиболее простым.

Устранение переменной осуществляется путем вычисления выражений, подобных представленному в уравнении 14.3, в порядке справа налево (т.е. на рис. 14.8 — сверху вниз). Промежуточные результаты сохраняются, а операции суммирования

по каждой переменной выполняются только для тех частей выражения, которые зависят от этой переменной.

Проиллюстрируем этот процесс на примере сети с описанием взлома. Нам необходимо вычислить следующее выражение:

$$P(B|f,j,n) = \frac{1}{Z} P(B) \prod_{e \in E} p(e) \prod_{a \in A} P(a|B,e) \prod_{m \in M} P(m|a)$$

Обратите внимание на то, что каждая часть этого выражения аннотирована именем связанной с ней переменной; эти части называются $\wedge$ факторами. Этапы работы алгоритма устранения переменной описаны ниже.

- Фактор для M , $P(m|a)$, не требует суммирования по M (поскольку значение M уже фиксировано). Мы сохраним эту вероятность при условии, что задано каждое значение a в виде следующего двухэлементного вектора:

$P(m|a)$ $f_M(A) = (P(m|a))$ (Обозначение f m показывает, что для получения f используется m .)

- Аналогичным образом сохраняется фактор для J в виде двухэлементного вектора $f_j(A)$.
- Фактор для A выражается распределением $P(a|B, e)$, которое представляет собой матрицу $f_A(B, E)$ с размерами $2 \times 2 \times 2$.
- Теперь необходимо устранить путем суммирования из произведения этих трех факторов переменную A , что позволит получить матрицу 2×2 , индексы которой пробегают только по B и E . Поместим штрих над A в имени этой матрицы для указания на то, что A устранена путем суммирования: $f_{A'}(B, E) = \sum_a f_A(a|B, e) \times f_j(a) \times f_M(a)$ $a = f_A(a|B, E) \times f_j(a) \times f_M(a) + f_A(-a|B, E) \times f_j(-a) \times f_M(-a)$ Применяемый в этом выражении процесс умножения называется процессом получения $\wedge$ точечного произведения (pointwise product) и будет вскоре описан.
- Обработаем таким же образом переменную K исключим E путем суммирования из произведения $f_E(E)$ и $f_{AJM}(B, E)$: $f_{EAJM}(B) = f_E(e) \times f_{AJM}(B/e) + f_E(-e) \times f_{AJM}(B/-, e)$
- Теперь мы можем вычислить ответ, умножив фактор для B (т.е. $f_B(B) = P(B)$) на накопленную матрицу $f_{e^A}(B)$: $p(B|f,j,n) = \frac{1}{Z} f_B(B) \times f_{EAJM}(B)$

В упр. 14.7, а предлагается проверить, действительно ли данный процесс приводит к получению правильного ответа.

Исследуя приведенную выше последовательность этапов, можно убедиться в том, что требуются две основные вычислительные операции: получение точечного произведения пары факторов и исключение некоторой переменной путем суммирования из произведения факторов.

Точечное произведение — это не результат умножения матриц и не результат поэлементного умножения. Точечное произведение двух факторов, f_1 и f_2 , представляет собой новый фактор f , переменные которого являются объединением переменных из f_1 и f_2 . Предположим, что два фактора имеют общие переменные $Y_1, \dots, Y_k$. В таком случае получим следующее: $f(X_1 \dots X_j, Y_1 \dots Y_k, Z_1 \dots Z_i) = f_1(X_1 \dots X_j, Y_1 \dots Y_k) \times f_2(Y_1 \dots Y_k, Z_1 \dots Z_i)$

Если все переменные являются бинарными, то факторы f_1 и f_2 имеют 2^{d+k} и 2^{k+1} элементов соответственно, а точечное произведение включает 2^{d+k+1} элементов.

Например, если даны два фактора, $f_1 \in \{A, B\}$ и $f_2 \in \{B, C\}$, с распределениями вероятностей, показанными ниже, то точечное произведение $f_1 \times f_2$ задается в табл. 14.2 Как $f_3(A, B, C)$.

Таблица 14.2. Пример произведения факторов

$f_1(A, B)$	$f_2(B, C)$	$f_3(A, B, C)$
0.3	0.7	0.9
0.1	0.2	0.8
0.6	0.4	0.2
0.4	0.6	0.6
0.2	0.8	0.4
0.8	0.2	0.2
0.6	0.4	0.8
0.4	0.6	0.6
0.2	0.8	0.4

Операция исключения некоторой переменной путем суммирования из произведения факторов также является несложной. Единственное затруднение заключается в следующем: в этой операции необходимо учитывать, что любой фактор, который не зависит от переменной, подлежащей исключению путем суммирования, может быть вынесен за пределы выражения суммирования, например, как показано ниже.

$$\sum_e f_e(e) X f_A(A, B, e) X f_j(A) x f_M(A) = f_j(A) x f_M(A) x \sum_e f_e(e) X f_A(A, B, e)$$
 Теперь вычисляется точечное произведение в выражении суммирования и переменная исключается путем суммирования из результирующей матрицы следующим образом: $f_j(A) X f_M(A) X A^T f_e(e) X f_A(A, B, e) = f_j(A) X f_M(A) X f_{A/B}(A, B)$ Обратите внимание на то, что матрицы не умножаются до тех пор, пока не потребуется исключить некоторую переменную путем суммирования из накопленного произведения. В данный момент умножаются только те матрицы, которые включают переменную, подлежащую исключению путем суммирования. Если даны процедуры получения точечного произведения и исключения путем суммирования, то сам алгоритм устранения переменной может быть записан весьма просто, как показано в листинге 14.2.

Листинг 14.2. Алгоритм устранения переменной, предназначенный для получения ответов на запросы в байесовских сетях

```
function Elimination-Ask(X, e, bn) returns
распределение по X
inputs: X, переменная запроса e, свидетельство, определяемое
как некоторое событие bn, байесовская сеть, которая задает совместное
распределение P(X1,...,Xn)
factors ← []
vars ← Reverse(Vars[bn])
for each var in vars
do factors ← [Make-Factor(var, e) | factors]
if переменная var является скрытой then
factors ← Sum-Out(var, factors)
return Normalize(Pointwise-Product(factors))
```

Рассмотрим еще один запрос: $P(\text{JohnCalls} \mid \text{Burglary} = \text{true})$. Как обычно, на первом этапе необходимо записать вложенное выражение суммирования: $\sum_e P(e) \sum_a P(a \mid b, e) P(j \mid a) = \sum_a P(b) > P(e) > P(a \mid b, e) P(j \mid a) > P(a \mid b)$ Если бы мы вычисляли это выражение справа налево, то заметили бы нечто интересное: терм $P(m \mid a)$ равен 1 по определению! Поэтому сразу отпадает необходимость учитывать это выражение; переменная M не имеет отношения к данному запросу. Эту мысль можно выразить иным образом: результат запроса $P(\text{JohnCalls} \mid \text{Burglary} = \text{true})$ не изменится, если из сети вообще будет исключена переменная MaryCalls . Вообще говоря, из сети может быть удалена любая листовая вершина, если она не

относится к переменной запроса или к переменной свидетельства. После ее удаления могут еще оставаться некоторые листовые вершины, которые также могут не относиться к данному запросу. Продолжая указанный процесс, мы в конечном итоге обнаружим, что $s^{\wedge} = k$ запросу не относится любая переменная, которая не является потомком переменной запроса или переменной свидетельства. Поэтому алгоритм устранения переменной позволяет удалять все эти переменные, прежде чем приступить к вычислению ответа на запрос.

Сложность точного вероятностного вывода. Выше было показано, что устранение переменной является более эффективным по сравнению с перебором, поскольку позволяет предотвратить повторяющиеся вычисления (а также обеспечить удаление не относящихся к делу переменных).

Требования процесса устранения переменной к времени и пространству зависят в основном от размера наибольшего фактора, сформированного в процессе работы данного алгоритма. А этот размер, в свою очередь, зависит от порядка устранения переменных и от структуры сети.

Сеть с описанием взлома, приведенная на рис. 14.2, принадлежит к семейству сетей, в которых имеется самое большее один неориентированный путь между любыми двумя вершинами в сети. Такие сети называются $\wedge$ односвязными (singly connected) сетями, или $\wedge$ полидеревьями (polytree), и обладают одним особо привле-

кательным свойством: ej^* временная и пространственная сложность точного вероятностного вывода в полидеревьях линейно зависят от размера сети. В данном случае размер определяется как количество элементов таблиц CPT; если количество родительских вершин каждой вершины ограничено некоторой константой, то сложность также будет зависеть линейно от количества вершин. Эти результаты справедливы для любого упорядочения, совместимого с топологическим упорядочением сети (упр. 14.7).

Для $\wedge$ многосвязных (multiply connected) сетей, подобных приведенной на рис. 14.9, а, процедура устранения переменной в наихудшем случае может иметь экспоненциальную временную и пространственную сложность, даже если количество родительских вершин в расчете на каждую вершину ограничено. В этом нет ничего удивительного, если учесть, что $s^{\wedge} =$ вероятностный вывод в байесовских сетях является NP-трудным, поскольку включает вывод в пропозициональной логике как частный случай. Фактически можно показать (упр. 14.8), что эта задача является настолько трудной, насколько трудна задача вычисления количества выполняющих присваиваний для формулы пропозициональной логики. Это означает, что данная задача является #P-трудной (читается "шарп-P-трудной", или "диз-P-трудной"), т.е. строго труднее, чем NP-полные задачи.

Существует тесная связь между сложностью вероятностного вывода в байесовской сети и сложностью задач удовлетворения ограничений (Constraint Satisfaction Problem — CSP). Как было показано в главе 5, трудность решения дискретной задачи CSP зависит от того, насколько "древовидным" является ее граф ограничений.

Такие показатели, как ширина гипердерева, которые устанавливают пределы сложности решения задачи CSP, могут также применяться непосредственно к байесовским сетям. Более того, существует возможность обобщить алгоритм устранения переменной таким образом, чтобы он позволял находить решения не только в байесовских сетях, но и в задачах CSP.

Алгоритмы кластеризации. Описанный выше алгоритм устранения переменной является простым и эффективным средством получения ответов на отдельные запросы. Если же возникает необходимость вычислить апостериорные вероятности для всех переменных в сети, то этот алгоритм может оказаться менее эффективным. Например, в сети с полидревовидной структурой для этого потребуется выдать $O(n)$ запросов со стоимостью $O(n)$ каждый, что в сумме составляет затраты времени $O(n^2)$. Использование алгоритмов $\wedge$ кластеризации (известных также под названием алгоритмов $\wedge$ дерева соединения-join tree), позволяет сократить это время до $O(n)$. По указанной причине данные алгоритмы широко используются в коммерческих инструментальных средствах на основе байесовских сетей.

Основная идея кластеризации состоит в том, что отдельные узлы в дереве должны быть соединены для формирования кластерных вершин таким образом, чтобы результирующая сеть стала полидеревом. Например, многосвязная сеть, показанная на рис. 14.9, а, может быть преобразована в полидереву путем объединения вершин Sprinkler (Опрыскиватель) и Rain (Дождь) в кластерную вершину, называемую Sprinklers Rain (см. рис. 14.9, б). Эти две булевы вершины заменяются мегавершиной, которая принимает четыре возможных значения: TT, TF, FT и FF. Данная

мегавершина имеет только одну родительскую вершину— булеву переменную Cloudy, поэтому для нее количество обуславливающих случаев равно двум.

$S \ R \ t \ t \ t \ f \ f \ t \ f \ f \ P(W) \ 0,99 \ 0,90 \ 0,90 \ 0,00 \ C \ t \ f \ P(R) \ 0,80 \ 0,20 \ S+R \ t \ t \ t \ f \ f \ f \ P(W) \ 0,99 \ 0,90 \ 0,90 \ 0,00 \ P(Q=0,5 \ (\ Cloudy \ j \ Spr+Rain) \ (WeT \ \ Grass) \ C \ t \ f \ P(S+R=x) \ 1 \ " \ // \ / \ // \ 0,08 \ 0,02 \ 0,72 \ 0,18 \ 0,10 \ 0,40 \ 0,10 \ 0,40$ Рис. 14.9. Пример применения кластеризации: многосвязная сеть с таблицами условных вероятностей (а); кластеризованный эквивалент многосвязной сети (б) После преобразования сети в форму полидерева применяется алгоритм вероятностного вывода специального назначения. По сути этот алгоритм представляет собой одну из форм алгоритма распространения ограничений (см. главу 5), где ограничения обеспечивают согласование соседних кластеров по апостериорной вероятности любых переменных, которые являются в них общими. При наличии тщательно продуманных средств учета этот алгоритм

позволяет вычислять апостериорные вероятности для всех вершин в сети, отличных от вершин свидетельства, за время $O(p)$, где p теперь обозначает размер модифицированной сети. Тем не менее NP-трудность решаемой задачи не исчезает: если сеть требует экспоненциальных затрат времени и пространства при устранении переменной, то экспоненциальные затраты времени и пространства требуются и для построения таблиц CPT в кластеризованной сети.

14.5. Приближенный вероятностный вывод в байесовских сетях Исходя из того, что точный вероятностный вывод в больших многосвязных сетях является неосуществимым, важно предусмотреть методы приближенного вероятностного вывода. В настоящем разделе описаны рандомизированные алгоритмы выборки (называемые также алгоритмами $\wedge$ Монте-Карло), обеспечивающие получение приближенных ответов, точность которых зависит от количества сформированных выборок. В последние годы алгоритмы Монте-Карло нашли широкое распространение в компьютерных науках для получения оценочных значений величин, которые трудно вычислить точно. Например, алгоритм эмуляции отжига, описанный в главе 4, представляет собой метод Монте-Карло для задач оптимизации.

В этом разделе нас интересует применение методов выборки для вычисления апостериорных вероятностей. Здесь описаны два семейства алгоритмов: непосредственная выборка и выборка с помощью цепи Маркова. Два других подхода (вариационные методы и метод циклического распространения) упоминаются в библиографических и исторических заметках, приведенных в конце данной главы.

Методы непосредственной выборки Прimitивной операцией в любом алгоритме выборки является формирование выборок из известного распределения вероятностей. Например, подлинная монета может рассматриваться как случайная переменная $Coin$ со значениями $\langle heads, tails \rangle$ и априорным распределением $P(Coin) = \langle 0.5, 0.5 \rangle$. Операция получения выборки из этого распределения полностью аналогична подбрасыванию монеты: с вероятностью 0,5 эта операция будет возвращать значение $heads$ (орел) и с такой же вероятностью — значение $tails$ (решка). Если имеется источник случайных чисел в диапазоне $[0,1]$, сформировать любые распределения по одной переменной совсем несложно (см. упр. 14.9).

В процессе случайного формирования выборки простейшего типа для байесовских сетей, рассматриваемом в этом разделе, вырабатываются события, не имеющие связанных с ними свидетельств, которые могут быть зарегистрированы в сети. Идея этого метода состоит в том, что выборка должна формироваться последовательно по каждой переменной, в топологическом порядке. Распределение вероятностей, из которого берется выборка значения, обуславливается значениями, уже

присвоенными родительским переменным этой переменной. Соответствующий алгоритм приведен в листинге 14.3. Проиллюстрируем его работу на примере сети, приведенной на рис. 14.9, а, предполагая, что имеет место упорядочение [Cloudy, Sprinkler, Rain, WetGrass], как описано ниже.

Листинг 14.3. Алгоритм формирования выборки, который вырабатывает события на основании байесовской сети `function Prior-Sample(bn) returns событие`, выработанное путем применения операции формирования выборки к априорному распределению, заданному в виде сети `bn` `inputs: bn`, байесовская сеть, задающая совместное распределение $P(X_1, \dots, X_n)$ `x` $\leftarrow$ событие с n элементами `for i = 1 to 21 do` `Xi` $\leftarrow$ случайная выборка из $P(X_i \mid \text{parents}(X_i))$ `return x` 1. Выборка из распределения $P(\text{Cloudy}) = \langle 0.5, 0.5 \rangle$; предположим, что она возвращает `true`.

2. Выборка из распределения $P(\text{Sprinkler} \mid \text{Cloudy}=\text{true}) = \langle 0.1, 0.9 \rangle$; предположим, что она возвращает `false`.

3. Выборка из распределения $P(\text{Rain} \mid \text{Cloudy}=\text{true}) = \langle 0.8, 0.2 \rangle$; предположим, что она возвращает `true`.

4. Выборка из распределения $P(\text{WetGrass} \mid \text{Sprinkler}=\text{false}, \text{Rain}=\text{true}) = \langle 0.9, 0.1 \rangle$; предположим, что она возвращает `true`.

В данном случае алгоритм `Prior-Sample` возвращает событие [`true`, `false`, `true`, `true`].

Можно легко показать, что алгоритм `Prior-Sample` формирует выборки на основе априорного совместного распределения, которое задано рассматриваемой сетью. Прежде всего предположим, что $S_{vs}(x_{1t} \dots, x_n)$ представляет собой вероятность того, что конкретное событие сформировано алгоритмом `Prior-Sample`.

Достаточно лишь проанализировать сам процесс формирования выборки, чтобы убедиться в справедливости следующего соотношения, поскольку каждый этап формирования выборки зависит только от значений родительских переменных: $n \cdot S_{ps}(x_1 \dots, x_n) = \prod_{i=1}^n P(x_i \mid \text{parents}(X_i))$ Это выражение должно показаться читателю весьма знакомым, поскольку оно определяет также вероятность события в соответствии с представлением совместного распределения в байесовской сети, как указано в уравнении 14.1. Поэтому получаем следующее:

$S_{ps}(X_1 \dots, X_n) = P(X_1 \dots, X_n)$ Благодаря такому простому факту задача получения ответов на вопросы с помощью выборок решается очень просто.

В любом алгоритме формирования выборки ответы вычисляются путем подсчета фактически сформированных выборок. Предположим, что общее количество выборок равно N , а также допустим, что $N(x_{1f} \dots, x_n)$ — частота конкретного события $x_{1f} \dots, x_n$. Следует полагать, что эта частота сойдется в пределе к ее ожидаемому значению, соответствующему вероятности сформированной выборки:

$NPS(x_1, \dots, x_n) \approx \frac{1}{N} \sum_{i=1}^N \mathbb{I}(x_i = (x_1, \dots, x_n))$ A4.4) $N \rightarrow \infty$ IV Например, рассмотрим событие, полученное ранее: [true, false, true, true]. Вероятность формирования выборки для этого события такова:

$SPS(\text{true}, \text{false}, \text{true}, \text{true}) = 0.5 \times 0.9 \times 0.8 \times 0.9 = 0.324$ Поэтому следует полагать, что в пределе, при очень больших значениях N , около 32,4% выборок будут относиться к этому событию.

В последующем изложении мы будем использовать знак приближенного равенства ($\sim$) для обозначения соотношения, имеющего именно этот смысл, — что оцениваемая вероятность становится точной при больших пределах количества выборок.

Такая оценка называется $\hat{P}$ согласованной. Например, может быть получена согласованная оценка вероятности любого частично заданного события $x_1, \dots, x_t$, где $t < l$, следующим образом:

$P(x_1, \dots, x_t) \approx \frac{NPS(x_1, \dots, x_t)}{N}$ A4.5) Это означает, что вероятность события можно оценить с помощью деления количества выборок частично заданного события на количество всех событий, получен-

ных в процессе формирования выборок. Например, если на основании сети с описанием опрыскивателя (см. рис. 14.9, а) сформирована 1000 выборок и для 511 из них справедливо выражение $\text{Rain} = \text{true}$, то оценка вероятности дождя, которая записывается как $P(\text{Rain} = \text{true})$, равна 0,511.

Формирование выборок с исключением в байесовских сетях $\hat{P}$ Формирование выборок с исключением представляет собой общий метод получения выборок на основании распределения, для которого трудно получить выборки, если дано распределение, позволяющее легко сформировать выборки. В своей простейшей форме этот метод может использоваться для вычисления условных вероятностей, т.е. для определения вероятностей $P(x|e)$. Алгоритм RejectionSampling приведен в листинге 14.4. Вначале он формирует выборки из априорного распределения, определяемого сетью, а затем исключает все те выборки, которые не соответствуют свидетельству. Наконец, формируется оценка $P(X=x|e)$ путем подсчета того, насколько часто событие $X=x$ встречалось в оставшихся выборках.

Листинг 14.4. Алгоритм формирования выборок с исключением для получения ответов на запросы, если даны свидетельства в байесовской сети

```
function RejectionSampling(X, v, bn, N) returns оценка значения  $P(x|e)$ 
inputs: X, переменная запроса v, свидетельство, определяемое как некоторое событие bn, байесовская сеть N, общее количество выборок, которые должны быть сформированы
local variables: N, вектор результатов подсчетов по X, первоначально равный нулю
for j = 1 to N do
  x ← PriorSample(bn)
  if выборка x согласуется со свидетельством e then
    N[x] ← N[x] + 1, где x
```

представляет собой значение переменной X в множестве x return $\text{Normalize}(N[X])$
 Допустим, что $P(X \setminus e)$ — оцениваемое распределение, которое возвращено алгоритмом. Из определения алгоритма получаем следующее:

$NPS(X, e) \cdot P(x \setminus e) = a \cdot NPS(X, e) = NpS(e)$ С помощью уравнения 14.5 это соотношение может быть преобразовано в следующее: $\frac{P(X, e)}{P(X \setminus e)} \ll p(e) = P(X|e)$ Таким образом, алгоритм формирования выборок с исключением вырабатывает согласованную оценку истинной вероятности.

Продолжая пример, приведенный на рис. 14.9, а, предположим, что необходимо оценить вероятность $P(\text{Rain} \setminus \text{Sprinkler}^{\text{true}})$ с использованием 100 выборок.

Допустим, что из 100 сформированных выборок 73 соответствуют событию

$\text{Sprinkler} = \text{false}$ и исключаются, а для 27 имеет место $\text{Sprinkler} = \text{true}$; из 27 выборок в 8 наблюдается событие $\text{Rain} = \text{true}$, а в 19 — $\text{Rain} = \text{false}$. Поэтому получаем следующее:

$V(\text{Rain} \setminus \text{Sprinkler} = \text{true}) \sim \text{Normalize}(\langle 8, 19 \rangle) = \langle 0.296, 0.704 \rangle$ Правильным ответом является $\langle 0.3, 0.7 \rangle$. В ходе дальнейшего накопления все большего количества выборок эта оценка сходится к правильному ответу.

Среднеквадратичное отклонение ошибки в каждой оценке вероятности будет пропорционально $1/\sqrt{n}$, где n — количество выборок, используемых для получения оценки.

Самым большим недостатком алгоритма формирования выборок с исключением является то, что в нем приходится исключать слишком много выборок! Доля выборок, согласованных со свидетельством e , уменьшается экспоненциально по мере увеличения количества переменных свидетельства, поэтому данная процедура становится неприменимой для решения сложных задач.

Обратите внимание на то, что процесс формирования выборок с исключением весьма напоминает процесс оценки условных вероятностей непосредственно по данным, полученным из реального мира. Например, чтобы оценить вероятность дождя после того, как накануне вечером наблюдался красный закат, $P(\text{Rain} \setminus \text{RedSkyAtNight} = \text{true})$, можно подсчитать, насколько часто наблюдался дождь после красного заката, игнорируя данные о тех вечерах, когда закат не был красным. (Поэтому в данном случае роль алгоритма формирования выборок играет сама природа.) Безусловно, для проведения таких наблюдений может потребоваться много времени, если закат бывает красным очень редко, и в этом состоит недостаток процедуры формирования выборок с исключением.

Оценка веса с учетом правдоподобия В методе $\wedge$ оценки веса с учетом правдоподобия преодолен указанный недостаток метода формирования выборок с исключением благодаря тому, что в нем вырабатываются только события,

согласованные со свидетельством e . Начнем с описания того, как работает алгоритм, затем покажем, что он работает правильно, т.е. вырабатывает согласованные оценки вероятности.

В алгоритме Likelihood-Weighting, приведенном в листинге 14.5, значения для переменных свидетельства E фиксируются и формируются выборки только для оставшихся переменных X и Y . Это позволяет гарантировать, что каждое выработанное событие будет согласованным со свидетельством. Но не все события являются равноправными. Поэтому перед подведением итогов подсчетов в распределении для переменной запроса каждое событие взвешивается с учетом правдоподобия того, что событие согласуется со свидетельством. Такое правдоподобие измеряется с помощью произведения условных вероятностей для каждой переменной свидетельства, если даны ее родительские переменные. Интуитивно ясно, что события, в которых фактическое свидетельство кажется маловероятным, должны получать меньший вес.

Листинг 14.5. Алгоритм оценки веса с учетом правдоподобия, предназначенный для вероятностного вывода в байесовских сетях `function Likelihood-Weighting( $X, e, bn, N$ )` returns оценка значения $P(X|e)$ inputs: X , переменная запроса e , свидетельство, определяемое как некоторое событие

bn , байесовская сеть N , общее количество выборок, которые должны быть сформированы local variables: W , вектор взвешенных результатов подсчетов по X , первоначально равный нулю for $j = 1$ to N do $x, w \leftarrow \text{Weighted-Sample}(bn)$ $W[x] \leftarrow W[x] + w$, где x представляет собой значение переменной X в множестве x return `Normalize( $W[X]$ )` `function Weighted-Sample( $bn, e$ )` returns событие x и вес w $x \leftarrow$ событие с n элементами; $w \leftarrow 1$ for $i = 1$ to $2i$ do if X_i имеет значение x_i in свидетельство e then $w \leftarrow w \cdot P(X_i = x_i | \text{parents}(X_i))$ else $X_i \leftarrow$ случайная выборка из $P(X_i | \text{parents}(X_i))$ return x, w Применим этот алгоритм к сети, показанной на рис. 14.9, а, на примере получения ответа на запрос $P(\text{Rain} \setminus \text{Sprinkler} = \text{true}, \text{WetGrass} = \text{true})$. Этот процесс происходит следующим образом: вначале вес w устанавливается равным 1,0, затем вырабатывается событие, как описано ниже.

1. Выборка из распределения $P(\text{Cloudy}) = \langle 0.5, 0.5 \rangle$; предположим, что она возвращает значение true.

2. `Sprinkler` — переменная доказательства со значением true. Поэтому мы устанавливаем: $w \leftarrow w \cdot P(\text{Sprinkler} = \text{true} | \text{Cloudy} = \text{true}) = 0.1$ 3. Выборка из распределения $P(\text{Rain} \setminus \text{Cloudy} = \text{true}) = \langle 0.8, 0.2 \rangle$; предположим, что она возвращает значение true.

4. `WetGrass` — переменная доказательства со значением true. Поэтому мы устанавливаем: $w \leftarrow w \cdot P(\text{WetGrass} = \text{true} | \text{Sprinkler} = \text{true}, \text{Rain} = \text{true}) = 0.099$ Теперь алгоритм `Weighted-Sample` возвращает событие `[true, true, true, true]` с весом 0,099,

и данные об этом событии подытоживаются с учетом условия $Rain = true$. Этот вес является низким потому, что событие описывает пасмурный день, в который вероятность применения опрыскивателя является весьма небольшой.

Чтобы понять, как работает алгоритм оценки веса с учетом правдоподобия, начнем с изучения сформированного с помощью выборок распределения S^s для функции Weighted-Sample. Напомним, что переменные свидетельства E зафиксированы со значениями e . Обозначим все прочие переменные как Z , иными словами, $z = \{X\}_{u \neq e}$. В алгоритме выборки для каждой переменной из z , если даны ее родительские значения, формируются следующим образом:

$$Sws(z, e) = \prod_{i=1}^n P(z_i | \text{parents}(Z_i)) \quad A4.6$$

Обратите внимание на то, что в число переменных $\text{Parents}(z_L)$ могут входить и скрытые переменные, и переменные свидетельства. В отличие от априорного распределения $P(z)$, в распределении S^s некоторое внимание уделено свидетельству: на значения сформированных выборок для каждой переменной z_i кроме других предков z_i оказывает влияние само свидетельство. С другой стороны, в распределении w^s свидетельству уделяется меньше внимания, чем в истинном апостериорном распределении $P(z | e)$, поскольку в значениях сформированных выборок для каждой переменной z_L игнорируются свидетельства, относящиеся к переменным, которые не являются предками z_L .

Весовое значение правдоподобия w представляет собой разность между фактическим и желаемым распределениями вероятностей сформированных выборок. Такой вес для данной конкретной выборки x , состоящий из значений z и e , является произведением значений правдоподобия каждой переменной свидетельства, если даны ее родительские переменные (причем некоторые или все эти переменные могут находиться среди переменных z_L): $w(z, e) = \prod_{i=1}^n P(e_i | \text{parents}(E_i)) \quad A4.7$ Умножая уравнения 14.6 и 14.7, можно определить, что соотношение для взвешенной вероятности выборки имеет следующую особенно удобную форму, поскольку эти два произведения охватывают все переменные, заданные в сети:

$$1/n \sum Sws(z, e) w(z, e) = \prod_{i=1}^n [P(z_i | \text{parents}(Z_i)) \prod_{j=1}^m P(e_j | \text{parents}(E_j))] = P(z, e) \quad A4.8$$

Это позволяет использовать для вычисления совместной вероятности уравнение 14.1.

Теперь можно легко показать, что оценки весов, полученные с учетом правдоподобия, являются согласованными. Для любого конкретного значения x переменной X оценка апостериорной вероятности может быть рассчитана следующим образом:

$P(x|e) = \frac{1}{Z} \sum_{y \sim a'} \prod_{i=1}^n w(x_i, y_i, e) \quad A4.9$ из алгоритма Likelihood-Weighting $Y \sim a'$ $\prod_{i=1}^n Sws(x_i, y_i, e)$ $w(x_i, y_i, e)$ для больших N 6 Желательно было бы использовать распределение вероятностей сформированных выборок, равное истинному апостериорному

распределению $P(z | e)$, чтобы в расчет принимались все свидетельства. Но такой подход не может быть осуществлен эффективно, поскольку если бы существовала такая возможность, то мы могли бы оценивать желаемую вероятность с любой заданной точностью, применяя полиномиальное количество выборок. Тем не менее можно показать, что существование такой полиномиальной схемы аппроксимации невозможно.

= а' 2. $P(x, y, e)$ согласно уравнению 14.8 $Y = a' P(x, e) = P(x|e)$ Поэтому алгоритм оценки веса с учетом правдоподобия возвращает согласованные оценки.

Поскольку в алгоритме оценки веса с учетом правдоподобия используются все сформированные выборки, он может оказаться гораздо более эффективным по сравнению с алгоритмом формирования выборок с исключением. Тем не менее его недостатком является снижение производительности по мере увеличения количества переменных свидетельства. Это связано с тем, что в таком случае большинство выборок имеет очень низкие веса, поэтому в составе взвешенной оценки доминирует крошечная доля выборок, которые согласуются со свидетельством с правдоподобием, большим бесконечно малого. Эта проблема усугубляется, если переменные свидетельства расположены на последних местах в упорядочении переменных, поскольку в таком случае процесс формирования выборок представляет собой процесс моделирования, имеющий мало сходства с реальностью и имитируемый с помощью свидетельства.

Вероятностный вывод по методу моделирования цепи Маркова В этом разделе описан алгоритм $\wedge$ Монте-Карло с применением цепи Маркова (Markov chain Monte Carlo— MCMC), предназначенный для вероятностного вывода в байесовских сетях. Вначале опишем, какие действия выполняются в этом алгоритме, затем объясним, благодаря чему он работает и почему имеет такое сложное название.

Алгоритм MCMC В отличие от других двух алгоритмов формирования выборок, которые вырабатывают каждое событие с нуля, в алгоритме MCMC каждое событие вырабатывается путем внесения случайного изменения в предыдущее событие. Поэтому сеть целесообразно рассматривать как находящуюся в конкретном текущем состоянии, заданном с помощью присваивания значения каждой переменной. Переход в следующее состояние осуществляется путем случайного формирования выборки значения для одной из переменных X_L , отличных от переменных свидетельства, причем это значение обусловлено текущими значениями переменных в марковском покрытии переменной x_L . (Напомним, что, как было сказано на с. 1, марковское покрытие переменной состоит из ее родительских переменных, дочерних переменных и родительских переменных дочерних переменных.) Поэтому в алгоритме MCMC предусмотрено случайное блуждание по пространству состояний (пространству возможных полных

присваиваний), в котором каждый раз изменяется значение одной переменной, но значения переменных свидетельства остаются зафиксированными.

Рассмотрим запрос $P(\text{Rain} \setminus \text{Sprinkler}^{\text{true}}, \text{WetGrass} = \text{true})$, примененный к сети, которая показана на рис. 14.9, а. Для переменных свидетельства *Sprinkler* и *WetGrass* зафиксированы их наблюдаемые значения, а скрытые переменные *Cloudy* и *Rain* инициализированы случайным образом; допустим, что им присвоены значения *true* и *false* соответственно. Таким образом, начальным

состоянием является $[\text{true}, \text{true}, \text{false}, \text{true}]$. После этого повторно выполняются описанные ниже этапы.

1. Формируется выборка для переменной *Cloudy* с учетом текущих значений переменных марковского покрытия: в данном случае выборка берется из $P(\text{Cloudy} \setminus \text{Sprinkler}^{\text{true}}, \text{Rain} = \text{false})$. (Вскоре мы покажем, как рассчитать это распределение.) Предположим, что результатом является $\text{Cloudy}^{\text{false}}$. В таком случае новым текущим состоянием становится $[\text{false}, \text{true}, \text{false}, \text{true}]$.

2. Формируется выборка для переменной *Rain* с учетом текущих значений переменных марковского покрытия: в данном случае выборка берется из $P(\text{Rain} \setminus \text{Cloudy} = \text{false}, \text{Sprinkler} = \text{true}, \text{WetGrass} = \text{true})$.

Предположим, что эта операция приводит к получению $\text{Rain} = \text{true}$. Новым текущим состоянием становится $[\text{false}, \text{true}, \text{true}, \text{true}]$.

Каждое состояние в пространстве состояний, посещенное в ходе этого процесса, представляет собой выборку, которая вносит свой вклад в оценку вероятности переменной запроса *Rain*. Если в данном процессе посещаются 20 состояний, в которых переменная *Rain* принимает истинное значение, и 60 состояний, в которых переменная *Rain* становится ложной, то ответом на запрос становится $\text{Normalize}(\langle 20, 60 \rangle) = \langle 0.25, 0.75 \rangle$. Полный алгоритм показан в листинге 14.6.

Листинг 14.6. Алгоритм MCMC приближенного вероятностного вывода в байесовских сетях `function MCMC-Ask(X, v, hn, N) returns оценка значения $P(x \setminus e)$ local variables: $N[X]$, вектор результатов подсчетов по X , первоначально равный нулю Z , переменные в сети hn , отличные от переменных свидетельства x , текущее состояние сети, первоначально скопированное из e инициализировать z случайными значениями переменных из Z for $j = 1$ to N do for each Z_i in Z do выполнить выборку значения переменной Z_i в векторе x из $P\{Z_i \setminus mb(Z_i)\}$, если даны значения $MB(Z_i)$ в векторе z $N[x] \leftarrow N[x] + 1$, где x представляет собой значение переменной X в множестве x return $\text{Normalize}(N[X])$ Обоснование правильности работы алгоритма MCMC В этом разделе будет показано, что алгоритм MCMC возвращает согласованные оценки для апостериорных вероятностей. Материал, изложенный в данном разделе, является весьма формальным, но основное утверждение в нем`

несложно: с³ процесс формирования выборок переходит в "динамическое равновесие", в котором в конечном итоге доля времени, проведенного в каждом состоянии, точно пропорциональна апостериорной вероятности этого состояния. Такое замечательное свойство является следствием конкретной "тSk переходной вероятности, с которой данный процесс переходит из од-

ного состояния в другое и которая определена условным распределением, заданным с учетом марковского покрытия переменной, для которой формируется выборка.

Предположим, что $d(x \rightarrow x')$ — вероятность того, что в этом процессе произойдет переход из состояния x в состояние x' . Эта переходная вероятность определяет информационную структуру, заданную на пространстве состояний, которая называется [^] цепью Маркова. (Цепи Маркова играют также важную роль в главах 15 и 17.) Теперь предположим, что мы развернули цепь Маркова на t этапов, и допустим, что $7it(x)$ — вероятность того, что система находится в состоянии x во время t .

Аналогичным образом, допустим, что $nt+1(x')$ — вероятность пребывания системы в состоянии x' во время $t+1$. Если дано значение $7it(x)$, то значение $7it+1(x')$ можно рассчитать путем суммирования по всем состояниям, в которых система может находиться во время t , вероятностей пребывания в этом состоянии, умноженных на вероятности осуществления перехода в состояние x' , следующим образом:

$7it+1(x') = \sum_x 7it(x)g(x \rightarrow x')$ Цепь называется достигшей своего [^] стационарного распределения (stationary distribution), если $nt = nt+1$. Назовем это стационарное распределение π ; итак, его определяющим уравнением является следующее: $\pi(x') = \sum_x \pi(x) d(x \rightarrow x')$ для всех x' A4.9) X При некоторых стандартных допущениях⁷, касающихся распределения вероятностей перехода d , существует одно и только одно распределение π , удовлетворяющее этому уравнению при каждом конкретном значении d .

Уравнение 14.9 можно трактовать как утверждение, что в установившемся режиме ожидаемый "отток" из каждого состояния (т.е. его текущее "население") равен ожидаемому "притоку" из всех других состояний. Один из очевидных способов удовлетворения этого отношения состоит в достижении того, чтобы ожидаемый поток между любыми парами состояний был одинаковым в обоих направлениях.

В этом состоит свойство [^] детализированного равновесия, которое показано ниже.

$7E(x) d(x \rightarrow x') = \pi(x') d(x' \rightarrow x)$ для всех x, x' A4.10) Можно показать, что из этого свойства детализированного равновесия можно вывести свойство стационарности, получив суммы по x в уравнении 14.10. Получаем следующее соотношение:

У $7E(x) \text{ д}(x \rightarrow x') = 2, \text{ я}(x') < \text{ЭГ}(x' \rightarrow x) = \text{те}(x') \text{ У. } <7(x' \rightarrow x) = \wedge(x1$ где возможен последний этап преобразования, поскольку гарантировано выполнение перехода из состояния x' .

7 Цепь Маркова, определяемая значением q , должна быть эргодичной; это означает, что каждое состояние должно быть достижимо из любого другого состояния и не должно быть строго периодических циклов.

Теперь мы покажем, что вероятность перехода $\text{д}(x \rightarrow x')$, определяемая на этапе формирования выборки в алгоритме MCMC-Ask, удовлетворяет уравнению детализированного равновесия со стационарным распределением, равным $P(x|e)$ (истинному апостериорному распределению по скрытым переменным). Мы проведем это доказательство в два этапа. Вначале определим цепь Маркова, в которой формирование выборки по каждой переменной обусловлено текущими значениями всех прочих переменных, и покажем, что это условие соответствует свойству детализированного равновесия. Затем мы просто констатируем, что для байесовских сетей формирование такой условной выборки эквивалентно условному формированию выборки по марковскому покрытию переменной (см. с. 1).

Допустим, что X_i — переменная, для которой должна быть сформирована выборка, и предположим, что $\wedge$ — все скрытые переменные, отличные от X_L . Их значениями в текущем состоянии являются x_L и $x^\wedge$. Если будет выполнена выборка нового значения x_L' для переменной x_i обусловленного всеми прочими переменными, включая переменные свидетельства, то будет получено следующее: $\text{д}(x \rightarrow x^*) = \text{qr}(\text{if } x \sim i \rightarrow (x_i', *i)) = P(x_L' | x_L, e)$ Это выражение для переходной вероятности называется $\wedge$ формирователем выборок Гиббса (Gibbs sampler) и служит основой особенно удобной формы алгоритма MCMC. Теперь мы покажем, что формирователь выборок Гиббса находится в детализированном равновесии с истинной апостериорной вероятностью:

$7E(x) \text{ д}(x \rightarrow x') = P(x|e) P(x_i \cdot |x_L, e) = P(x_L | x^\wedge | v) P(x_i' | x_L, e) = P(x_i | x_L, v) P(x^\wedge | v) P(x_i' | x^\wedge, e)$ (использование цепного правила после первого термина) $= P(x_i | x_L, v) P(x_i', x^\pm | v)$ (использование цепного правила для перехода в обратном направлении) $= 7E(x^*) \text{ д}(x' \rightarrow x)$ Как указано на с. 1, переменная независима от всех других переменных, если дано ее марковское покрытие, поэтому имеет место следующее соотношение:

$P(x_i' | x_L, e) = P(x_i' | \text{mb}(X_L))$ где $\text{mb}(X_L)$ обозначает значения переменных в марковском покрытии $x^\pm$, $\text{mb}\{x^\pm\}$.

Как показано в упр. 14.10, вероятность переменной, если дано ее марковское покрытие, пропорциональна вероятности переменной, если даны ее родительские переменные, умноженной на вероятность каждой дочерней переменной, если даны ее соответствующие родительские переменные:

$P(x_i | \text{mb}(X_i)) = \alpha P(X_i^* | \text{parents}\{X_i\}) \times \prod_j P(y_j^* | \text{parents}(Y_j))$ A4.11) $Y_j \in \text{Children}(X_j)$
 Поэтому для изменения значения каждой переменной x_L необходимо выполнить такое количество операций умножения, которое равно количеству дочерних переменных переменной x_L .

В этом разделе рассматривался только один простой вариант алгоритма МСМС — вариант, основанный на использовании формирователя выборок Гиббса.

В своей наиболее общей форме алгоритм МСМС представляет собой мощный метод вычислений с помощью вероятностных моделей, поэтому было разработано много вариантов этого алгоритма, включая алгоритм эмуляции отжига (см. главу 4), алгоритмы стохастической выполнимости (см. главу 7) и формирователь выборок Метрополиса—Гастингса, рассматриваемый в главе 15.

14.6. Распространение вероятностных методов на представления в логике первого порядка В главе 8 описывалось, какими преимуществами с точки зрения возможностей представления обладает логика первого порядка по сравнению с пропозициональной логикой. В логике первого порядка учитывается существование объектов и отношений между ними, и она позволяет выражать факты о некоторых или обо всех объектах в проблемной области. Это часто приводит к созданию представлений, намного более кратких, чем эквивалентные пропозициональные описания. Теперь отметим, что байесовские сети по существу являются пропозициональными: множество переменных в них является фиксированным и конечным, а каждая переменная имеет постоянную область определения, состоящую из возможных значений. В связи с этим применимость байесовских сетей становится ограниченной. с^3 Если бы можно было найти способ применения теории вероятностей в сочетании с выразительными возможностями представлений в логике первого порядка, то можно было бы рассчитывать на существенное расширение спектра задач, решаемых таким образом.

Основная идея, которая может привести к достижению этой цели, состоит в следующем: в пропозициональном контексте байесовская сеть задает распределения вероятностей по атомарным событиям, каждое из которых определяет значение для каждой переменной в сети. Таким образом, атомарное событие является моделью, или одним из возможных миров, в терминологии пропозициональной логики. А в контексте логики первого порядка модель (с ее интерпретацией) задает область определения объектов, отношения, которые имеют место между этими объектами, и отображения из констант и предикатов базы знаний в объекты и отношения модели. Поэтому с^4 вероятностная база знаний первого порядка должна задавать вероятности для всех возможных моделей первого порядка. Допустим, что с^5 $P(M)$ — вероятность, присвоенная модели m с помощью базы знаний. Для каждого высказывания в логике первого порядка ϕ

вероятность $P(\phi)$ задается обычным образом, путем суммирования по всем возможным мирам, где высказывание ϕ является истинным:

$P(\phi) = \sum_K \mathbb{1}(K \models \phi)$ A4.12) $M:\phi$ является истинным в M До сих пор все, казалось бы, шло хорошо. Тем не менее есть одна проблема: множество моделей первого порядка является бесконечным. Это означает, что, во-первых, суммирование может быть неосуществимым, и, во-вторых, задача определения полного, согласованного распределения на бесконечном множестве миров может оказаться очень трудной.

Поэтому мы должны умерить наши амбиции, по крайней мере, на время. В частности, определим ограниченный язык, для которого интересующими становятся только модели, количество которых является конечным. Для этого можно использовать несколько способов. В этом разделе будут описаны $\wedge$ реляционные вероятностные модели, или RPM (Relational Probability Model), идея которых заимствована из семантических сетей (см. главу 10) и из объектно-реляционных баз данных. Другие подходы обсуждаются в библиографических и исторических заметках в конце настоящей главы.

Модели RPM допускают использование константных символов, которыми именуются объекты. Например, допустим, что Prof Smith— имя профессора, а Jones— имя студента. Каждый объект представляет собой экземпляр некоторого класса; например, Prof Smith относится к классу Professor (Профессор), Jones— к классу Student (Студент). Предполагается, что класс каждого константного символа известен.

Применяемые нами функциональные символы будут подразделяться на два типа.

Функции первого типа, $\wedge$ простые функции, отображают объект не на другой структурированный объект, а на некоторое значение из фиксированной области значений, полностью аналогично случайной переменной. Например, значениями функций Intelligence(Jones) (Интеллект Джонса) и Funding {Prof Smith} (Финансирование профессора Смита) могут быть hi (высокий) или lo (низкий), а значениями функций Success {Jones} (Успех Джонса) и Fame {Prof Smith} (Известность профессора Смита) могут быть true (истинный) или false (ложный). Функциональные символы не должны применяться к таким значениям, как true и false, поэтому вложение простых функций невозможно. Это позволяет исключить один из источников бесконечных ветвлений. Значение простой функции, применяемое к конкретному объекту, может быть наблюдаемым или неизвестным; для нашего представления эти значения будут служить значениями основных случайных переменных⁸.

Допускается также использование $\wedge$ сложных функций, которые отображают объекты на другие объекты. Например, значением функции Advisor {Jones}

(Консультант Джонса) может быть Prof Smith. Каждая сложная функция имеет заданную область определения и диапазон значений, которые являются классами.

Например, областью определения функции Advisor является Student, а диапазоном значений — Professor. Функции применяются только к объектам соответствующего им класса; например, значение консультанта Advisor для Prof Smith не определено. Сложные функции могут вкладываться, например значением выражения DeptHead{ Advisor{Jones}) может быть ProfMoore. На данный момент предполагается, что для всех константных символов значения всех сложных функций известны. Поскольку база знаний является конечной, из этого следует, что каждая цепочка применений сложных функций приводит к получению одного объекта из конечного множества объектов⁹.

8 Эти значения играют роль, во многом аналогичную роли базовых атомарных высказываний, формируемых в процессе пропозиционализации, который описан в разделе 9.1.

9 Это ограничение означает, что не могут использоваться такие сложные функции, как Father и Mother, приводящие к созданию потенциально бесконечных цепочек, которые могли бы оканчиваться формированием неизвестного объекта. Указанное ограничение будет пересмотрено позднее.

Последним необходимым нам элементом является вероятностная информация.

Для каждой простой функции задается множество родительских объектов, так же, как и в байесовских сетях. Родительскими объектами могут быть другие простые функции от того же объекта; например, финансирование (Funding) некоторого профессора (Professor) может зависеть от его известности (Fame). Кроме того, родительские объекты могут быть простыми функциями от связанных объектов, например, успех (Success) студента может зависеть от его интеллекта (Intelligence) и от известности (Fame) консультанта этого студента. По сути подобные высказывания представляют собой утверждения о родительских объектах всех объектов в классе с квантором всеобщности. Таким образом, можно записать следующее:

$\forall x \ x \in \text{Student} \Rightarrow \text{Parents}(\text{Success}(x)) = \{\text{Intelligence}(x), \text{Fame}(\text{Advisor}(x))\}$ (При менее формальном подходе можно нарисовать диаграммы, подобные приведенной на рис. 14.10, а.) Теперь определим распределение условных вероятностей для дочернего объекта, если даны значения его родительских объектов. Например, можно сформулировать следующее утверждение: $\forall x \ x \in \text{Student} \Rightarrow P(\text{Success}(x) = \text{true} \mid \text{Intelligence}(x) = h_i, \text{Fame}(\text{Advisor}(x)) = \text{true}) = 0.95$ U— ProfMoore U— ProfSmith U— Jones Advisor а) б) Рис. 14.10. Примеры диаграмм: модель RPM с описанием двух классов — Professor и Student.

Имеются два профессора и два студента, причем ProfSmith является консультантом обоим студентам (а); байесовская сеть, эквивалентная модели RPM, приведенной на рис. 14.10, а (б) Как и в семантических сетях, распределение условных вероятностей можно закрепить за самим классом так, чтобы его экземпляры наследовали зависимости и условные вероятности от этого класса.

В семантике для языка RPM подразумевается, что каждый константный символ ссылается на отдельный объект; в этом состоит предположение об уникальности имен, описанное в главе 10. С учетом этого определения и ограничений, перечисленных выше, можно показать, что каждая модель RPM вырабатывает фиксированное конечное множество случайных переменных, причем каждая из них является результатом применения простой функции к константному символу. Таким образом, при условии, что родительско-дочерние зависимости являются ациклическими, можно составить эквивалентную байесовскую сеть. Это означает, что модель RPM и

байесовская сеть задают идентичные вероятности для каждого возможного мира.

На рис. 14.10, б показана байесовская сеть, соответствующая модели RPM, приведенной на рис. 14.10, а. Обратите внимание на то, что связи Advisor, имеющиеся в модели RPM, в байесовской сети отсутствуют. Это связано с тем, что такие связи являются фиксированными и известными. Однако они присутствуют в топологии сети неявно, например, объект Success {Jones} имеет в качестве родительского объект Fame {Prof Smith}, поскольку значением функции Advisor {Jones} является Prof Smith. Вообще говоря, отношения, которые имеют место между объектами, определяют характер зависимостей между свойствами этих объектов.

Для повышения выразительной мощности моделей RPM применяется несколько способов. В частности, могут быть разрешены $\wedge$ рекурсивные зависимости между переменными, позволяющие представить несколько типов зависимостей, которые ссылаются сами на себя. Например, предположим, что склонность к питанию всухомятку вызвана фактором McGene. В таком случае для любого x истинность выражения $McGene(x)$ зависит от $McGene\{Father(x)\}$ и $McGene\{Mother(x)\}$, которые, в свою очередь, зависят от $McGene\{Father\{Father(x)\}\}$, $McGene\{Mother\{Father(x)\}\}$, и т.д. Даже несмотря на то, что такие базы знаний соответствуют байесовским сетям с бесконечно большим количеством случайных переменных, иногда решения могут быть получены на основе уравнений с неподвижной точкой (fixed-point equation). Например, равновесное распределение вероятностей для генетического фактора McGene можно рассчитать на основе условной вероятности наследования этого фактора. Еще одно очень важное семейство рекурсивных баз знаний состоит из временных/вероятностных моделей, которые описаны в главе 15. В этих моделях свойства рассматриваемого состояния во время t зависят от свойств этого состояния во время $t-1$ и т.д.

Модели RPM могут быть также расширены, чтобы в них можно было представить "тSk реляционную неопределенность, т.е. неопределенность, касающуюся значений сложных функций. Например, в базе знаний может отсутствовать информация о том, кто является консультантом Джонса, Advisor {Jones). В таком случае Advisor {Jones) становится случайной переменной с возможными значениями Prof Smi th и ProfMoore. Соответствующая сеть показана на рис. 14.11.

Рис. 14.11. Часть байесовской сети, соответствующая одной из моделей RPM, в которой значение Advisor (Jones) неизвестно, но им может быть либо Prof Smith, либо ProfMoore. Выбор студентом консультанта зависит от того, какой объем финансирования имеет каждый профессор. Обратите внимание на то, что теперь успех Джонса, Success (Jones), зависит от известности, Fame, обоих профессоров, хотя тот факт, какой из этих профессоров окажет влияние на успех Джонса, фактически зависит от значения переменной Advisor (Jones)

Модели RPM позволяют также представить такое свойство, как $\wedge$ неопределенность идентичности (identity uncertainty); например, в базе знаний может отсутствовать информация о том, что Mary и ProfSmi th — одно и то же лицо. При наличии свойства неопределенности идентичности количество объектов и высказываний в разных возможных мирах может изменяться. В мире, где Mary и ProfSmi th — одно и то же лицо, количество объектов меньше, чем в том мире, где они считаются разными людьми. В результате этого процесс вероятностного вывода усложняется, но основные принципы, установленные в уравнении 14.12, все еще соблюдаются: вероятность любого высказывания вполне определена и может быть рассчитана. Свойство неопределенности идентичности является особенно важным для роботов и встроенных систем датчиков, которые должны следить за многими объектами. Мы вернемся к описанию этой проблемы в главе 15.

Теперь рассмотрим проблему вероятностного вывода. Очевидно, что такой вывод может осуществляться в эквивалентной байесовской сети при условии, что язык RPM будет ограничен таким образом, чтобы эквивалентная сеть была конечной и имела фиксированную структуру. Такой подход аналогичен способу, с помощью которого логический вывод в логике первого порядка может быть выполнен посредством логического вывода в пропозициональной логике по эквивалентной пропозициональной базе знаний (см. раздел 9.1). Но, как и в случае логического вывода, эквивалентная сеть может оказаться слишком большой для того, чтобы существовала возможность ее построить, не говоря уже о том, чтобы выполнять в ней вычисления.

Кроме того, при этом возникает проблема плотных взаимосвязей (см. упр. 14.12).

Поэтому для вероятностного вывода на основе модели RPM очень полезными являются приближенные алгоритмы, такие как MCMC (см. раздел 14.5).

В ходе применения алгоритма МСМС к байесовской сети, которая эквивалентна простой базе знаний RPM без реляционной неопределенности или неопределенности идентичности, алгоритм формирует выборки из пространства возможных миров, определяемых значениями простых функций, заданных на объектах. Можно легко показать, что такой подход может быть также дополнен с учетом реляционной неопределенности или неопределенности идентичности. В таком случае переход между возможными мирами способен привести к изменению значения простой функции или сложной функции и поэтому вызвать изменение структуры зависимостей.

Кроме того, переходы могут стать причиной изменения отношений идентичности между константными символами. Поэтому создается впечатление, что алгоритм МСМС представляет собой изящный способ осуществления вероятностного вывода на основе весьма выразительных вероятностных баз знаний в логике первого порядка.

Исследования в этой области все еще находятся на ранних этапах, но уже стало очевидно, что вероятностные рассуждения в логике первого порядка позволяют достичь колоссального повышения эффективности применения систем искусственного интеллекта для обработки неопределенной информации. К числу потенциальных приложений относятся машинное зрение, обработка естественного языка, выборка информации и оценка ситуаций. Во всех этих областях множество объектов (и поэтому множество случайных переменных) заранее не известно, поэтому "чисто пропозициональные" методы, такие как байесовские сети, не способны полностью представить ситуацию. Была предпринята попытка расширить возможности таких сетей с помощью метода поиска в пространстве моделей, но подходы, основанные на использовании моделей RPM, обеспечивают формирование рассуждений об указанных видах неопределенности в рамках одной модели.

14.7. Другие подходы к формированию рассуждений Применение вероятности в качестве модели для неопределенности уже очень давно стало доминирующим методом исследований не только в искусственном интеллекте, но и в других науках (например, в физике, генетике и экономике). В 1819 году Пьер Лаплас заявил: "Теория вероятностей есть не что иное, как здравый смысл, который удалось свести к вычислениям", а в 1850 году Джеймс Максвелл сказал, что "истинной логикой для нашего мира является исчисление вероятностей, в котором учитывается та величина вероятности, какой она является или должна быть по оценке рассудительного человека".

Поскольку существует такая долгая традиция в использовании вероятностных методов, может на первый взгляд показаться удивительным, что в искусственном интеллекте рассматривалось много альтернативных подходов, не

предусматривающих применение вероятностей. В ранних экспертных системах 1970-х годов игнорировалась неопределенность и использовались строго логические рассуждения, но вскоре стало очевидно, что такой подход является практически не применимым для большинства проблемных областей реального мира. Поэтому в следующем поколении экспертных систем (особенно в проблемных областях медицины) использовались вероятностные методы. Первые результаты этого оказались многообещающими, но сами эти системы не могли быть развернуты в больших масштабах из-за экспоненциального количества вероятностей, которые требовались в полном совместном распределении (тогда еще не были известны эффективные алгоритмы для байесовских сетей). В результате этого вероятностные подходы в период 1975-1988 гг. перестали привлекать интерес исследователей, и по многим причинам, описанным ниже, был опробован целый ряд альтернативных подходов.

- Один из широко распространенных взглядов состоит в том, что теория вероятностей по сути является числовой, тогда как рассуждения человека, в которых выражаются его оценки, в большей степени имеют "качественный" характер. Безусловно, люди сознательно не выполняют числовые расчеты со степенями уверенности (к тому же люди не осознают те ситуации, в которых они выполняют унификацию, но, по-видимому, обладают способностью формировать логические рассуждения определенного вида). Тем не менее может оказаться, что числовые оценки степеней уверенности определенного рода кодируются непосредственно в виде интенсивностей соединений и параметров активизации нейронов человеческого мозга. Если дело обстоит действительно так, то не стоит удивляться тому, что человеку так трудно сознательно оценить эти интенсивности. Следует также отметить, что механизмы качественного рассуждения могут быть сформированы непосредственно на основе теории вероятностей, поэтому доводы против использования людьми вероятностей, поскольку они "не мыслят с помощью чисел", можно легко опровергнуть. Однако некоторые схемы качественных рассуждений сами по себе оказались весьма привлекательными. Одним из наиболее хорошо исследованных подходов является формирование рассуждений по умолчанию, в котором логические заключения рассматриваются не как "являющиеся предметом уверенности в их истинности до определенной степени", а как "являющиеся предметом уверенности в их

истинности до тех пор, пока не будет обнаружена более весомая причина для того, чтобы предметом уверенности в их истинности не стало нечто иное".

Методы формирования рассуждений по умолчанию рассматривались в главе 10.

- Были также предприняты попытки учета неопределенности с помощью подходов на основе правил. Приверженцы таких подходов надеялись развить успех логических систем на основе правил, но, как было признано в дальнейшем, в каждом правиле,

в котором учитывалась неопределенность, в них приходилось добавлять своего рода "коэффициент подгонки под факты" (fudge factor).

Эти методы разрабатывались в середине 1970-х годов и составили основу большого количества экспертных систем в медицине и других областях. • Еще одна область, которая до сих пор не рассматривалась в этой книге, относится к вопросу о незнании, которое следует отличать от неопределенности.

Рассмотрим задачу с подбрасыванием монеты. Если мы знаем, что монета подлинная, то вполне резонно можем считать, что вероятность выпадения орла равна 0,5. Если же известно, что монета поддельная, но не известно, есть ли на ней два орла или две решки, то по-прежнему единственным разумным решением является принятие гипотезы о вероятности 0,5. Очевидно, что оба эти случая не одинаковы, но теория вероятностей, по-видимому, не позволяет провести между ними различие. В теории Демпстера—Шефера для представления знаний агента о вероятности высказывания используются оценки степени уверенности с интервальными значениями. В литературе обсуждались также другие методы, в которых используются вероятности второго порядка. • Теория вероятностей вносит такой же онтологический вклад в познание действительности, как и логика: в ней утверждается, что в рассматриваемом мире события являются истинными или ложными, даже если агент не может знать со всей определенностью, каковыми являются эти события. Исследователи в области нечеткой логики предложили онтологию, которая допускает неосведомленность (vagueness) — незнание о том, "до какой степени" является истинным некоторое событие. Как будет показано ниже, фактически проблемы неосведомленности и неопределенности являются ортогональными.

В следующих трех подразделах некоторые из этих подходов рассматриваются немного более подробно. В них не даны исчерпывающие формальные сведения, а указаны ссылки на литературу для дальнейшего изучения.

Методы на основе правил для формирования рассуждений в условиях Системы на основе правил стали итогом ранних работ по практическим и интуитивным системам, применяемым для логического вывода. Логические системы в целом и логические системы на основе правил в частности обладают тремя описанными ниже желаемыми свойствами. • $\wedge$ Локальность. В логических системах, если имеется правило в форме $A \Rightarrow B$, можно вывести B при наличии свидетельства A , не учитывая существование каких-либо иных правил. С другой стороны, в вероятностных системах необходимо учитывать все свидетельства, представленные в марковском покрытии.

• $\wedge$ Отделение (detachment). Как только будет найдено логическое доказательство для высказывания v , это высказывание может использоваться без учета того, как оно

было получено. Это означает, что высказывание может быть отделено от его обоснования. С другой стороны, при манипулировании с вероятностями важно учитывать источник свидетельства, который служит обоснованием для рассматриваемой оценки степени уверенности, поскольку это требуется для дальнейшего формирования рассуждений. • "<Эч Истинностная функциональность (truth-functionality). В логике истинность сложных высказываний может быть вычислена на основании значений истинности их компонентов. Вероятностные комбинации не обладают таким свойством, за исключением тех случаев, когда используются сильные глобальные предположения о независимости.

В связи с этим было сделано несколько попыток разработать схемы неопределенных рассуждений, в которых сохранялись бы эти преимущества. При этом идея состояла в том, чтобы закрепить степени уверенности за высказываниями и правилами, а также разработать чисто локальные схемы для комбинирования и распространения таких степеней уверенности. Соответствующие схемы также обладают свойством истинностной функциональности; например, степень уверенности в истинности высказывания $A \vee B$ является функцией от степени уверенности в истинности высказывания A и степени уверенности в истинности высказывания B .

Но перспективы успешного развития систем на основе правил находятся под сомнением в связи с тем, что свойства C^A = локальности, отделения и истинностной функциональности просто не распространяются на неопределенные рассуждения.

Вначале рассмотрим истинностную функциональность. Допустим, что $\#1$ является событием, связанным с тем, что подлинная монета падает орлом вверх, а также предположим, что T_1 — событие, в котором эта монета при том же подбрасывании падает решкой вверх, а H_2 — событие, что та же монета при втором подбрасывании падает орлом вверх. Безусловно, все три события имеют одну и ту же вероятность 0,5, поэтому система с истинностной функциональностью должна присваивать одну и ту же оценку степени уверенности дизъюнкции любых двух из этих событий. Но как показано в табл. 14.3, можно доказать, что вероятность дизъюнкции зависит от самих событий, а не только от их вероятностей.

Таблица 14.3. Значения вероятностей отдельных событий и их дизъюнкций

События	$P(A)$	$P(B)$	$P(A \vee B)$	$P(H_1)$	$P(H_2)$	$P(H_1 \vee H_2)$
A	0.5			0.5		
B		0.5			0.5	
$A \vee B$			1.00			
H_1				0.5		
H_2					0.5	
$H_1 \vee H_2$						0.75

Ситуация становится еще хуже при соединении свидетельств в цепочку логических выводов. В системах с истинностной функциональностью предусмотрены правила в форме $A \rightarrow B$, которые позволяют вычислять степень уверенности в истинности B как функцию от степени уверенности в истинности правила и степени уверенности в истинности A . Могут быть разработаны системы и прямого и обратного логического вывода. Предполагается, что степень уверенности в истинности прави-

ла является постоянной, и это значение обычно определяется инженером по знаниям, например, как $A \rightarrow 0.9$ в.

Рассмотрим ситуацию с влажной травой, показанную на рис. 14.9, а. Если бы нам потребовалось иметь возможность проводить и причинные, и диагностические рассуждения, то нужны были бы два следующих правила:

$Rain \rightarrow WetGrass$ и $WetGrass \rightarrow Rain$ Эти два правила образуют петлю обратной связи: свидетельство в пользу события $Rain$ повышает степень уверенности в истинности события $WetGrass$, что, в свою очередь, еще больше повышает степень уверенности в истинности события $Rain$.

Очевидно, что в системах формирования неопределенных рассуждений приходится отслеживать пути, по которым распространяется свидетельство.

Сложными становятся также межпричинные рассуждения (или исключение из объяснений некоторых причин). Рассмотрим, что произойдет, если имеются следующие два правила:

$Sprinkler \rightarrow WetGrass$ и $WetGrass \rightarrow Rain$ Предположим, мы видим, что опрыскиватель включен. При формировании прямого логического вывода по нашим правилам это свидетельство увеличивает степень уверенности в том, что трава должна быть мокрой, а это, в свою очередь, увеличивает степень уверенности в том, что идет дождь. Но это же нелепо — тот факт, что опрыскиватель включен, полностью объясняет наличие мокрой травы и должен уменьшить степень уверенности в том, что идет дождь! А система с истинностной функциональностью действует таким образом, как будто в ней реализуется также уверенность в том, что применение опрыскивателя вызывает дождь, $Sprinkler \rightarrow Rain$.

С учетом описанных сложностей, можно ли рассчитывать на то, что системы с истинностной функциональностью когда-либо найдут практическое применение?

Ответ состоит в том, что для этого нужно ограничивать решаемые задачи и тщательно конструировать базу правил, чтобы в ней не возникали нежелательные взаимодействия. Наиболее известным примером системы с истинностной функциональностью для неопределенных рассуждений является модель $\wedge$ факторов определенности (certainty factor), которая была разработана для программы медицинской диагностики *Mycin* и широко использовалась в экспертных системах в конце 1970-х и в 1980-х гг.

Почти во всех областях использования факторов определенности предусматривались наборы правил, которые были либо чисто диагностическими (как в программе *Mycin*), либо чисто причинными. Более того, данные свидетельства вводились только в "корнях" мультидерева правил, а большинство деревьев правил были односвязными. Хекерман [639] показал, что при таких обстоятельствах

незначительно модифицированный вариант вероятностного вывода на основе фактора определенности был точно эквивалентен байесовскому вероятностному выводу на полидеревах.

В других обстоятельствах применение факторов определенности из-за переоценки свидетельства приводило к появлению настолько неправильных степеней уверенности, что дальнейшая эксплуатация системы становилась невозможной. По мере увеличения размеров деревьев правил нежелательные взаимодействия правил становятся все более частыми, поэтому практики пришли к выводу, что приходится "поправлять" факторы определенности во многих других правилах после добавле-

ния новых правил. Нет смысла даже останавливаться на том, по каким причинам этот подход больше не рекомендуется.

Представление незнания: теория Демпстера—Шефера Теория $\wedge$ Демпстера—Шефера разработана для того, чтобы можно было учесть различие между неопределенностью (uncertainty) и незнанием (ignorance). Вместо вычисления вероятности высказывания в ней вычисляется вероятность того, что данное свидетельство поддерживает высказывание. Этот показатель измерения степени уверенности называется $\wedge$ доверительной функцией (belief function), которая обозначается как $Bel(X)$.

Вернемся к задаче с подбрасыванием монеты, чтобы рассмотреть пример применения доверительных функций. Предположим, что к вам подходит подозрительный тип и предлагает поспорить на 10 долларов, что его монета упадет орлом вверх после следующего подбрасывания. С учетом того, что эта монета может оказаться либо подлинной, либо фальшивой, какую степень уверенности вы должны назначить тому событию, что она упадет орлом вверх? В теории Демпстера-Шефера утверждается, что у вас пока нет свидетельств в пользу того или иного предположения, поэтому вам следует исходить из предположения, что степень уверенности $Bel(Heads) = 0$ и что $Bel(-nHeads) = 0$. Таким образом, в системах формирования рассуждений на основе теории Демпстера-Шефера принят скептический взгляд на то, что могут подсказывать некоторые интуитивные соображения. А теперь предположим, что вы пригласили эксперта, который освидетельствовал монету и с определенностью 90% заявил, что монета является подлинной (т.е. он на 90% уверен, что $P(Heads) = 0.5$). В таком случае теория Демпстера-Шефера дает оценку $Bel(Heads) = 0.9 \times 0.5 = 0.45$ и, аналогичным образом, $Bel(-^Heads) = 0.45$. Таким образом, все еще остается "зазор" в 10%, который не охватывается этим свидетельством. В "правиле Демпстера" [382] показано, как комбинировать свидетельства для получения новых значений Bel , а в работе Шефера эти вычисления развиты до уровня полной вычислительной модели.

Однако, как и при формировании рассуждений по умолчанию, возникает проблема при соединении степеней уверенности с действиями. При использовании вероятностей теория принятия решений утверждает, что если $P(\text{Heads}) = P(\neg \text{Heads}) = 0.5$, то (при условии, что выигрыш в 10 долларов и проигрыш в 10 долларов рассматриваются как противоположные исходы с равной величиной) механизм формирования рассуждений не отдаст предпочтения одному из действий, в котором предложение сделать ставку отклоняется или принимается. С другой стороны, механизм формирования рассуждений Демпстера-Шефера имеет оценку $\text{Bel}(\neg \text{Heads}) = 0$ и поэтому не видит причин принять ставку, но, кроме того, он имеет и оценку $\text{Bel}(\text{Heads}) = 0$ и поэтому не видит причин, по которым он мог бы отклонить это предложение. Таким образом, на первый взгляд кажется, что механизм формирования рассуждений Демпстера-Шефера приходит к такому же заключению о том, как действовать в данном случае. К сожалению, теория Демпстера-Шефера не позволяет также прийти к определенному решению во многих других случаях, притом что в вероятностном выводе вырабатывается какой-то конкретный вариант. В действительности понятие полезности в модели Демпстера-Шефера еще не достаточно полно исследовано.

Еще в одной интерпретации теории Демпстера-Шефера предусмотрено определение интервала вероятностей, например, интервал для Heads равен $[0, 1]$ до про-

верки монеты экспертом и становится равным $[0.45, 0.55]$ после такой проверки.

Оценка ширины этого интервала может способствовать выработке решения о получении дополнительных свидетельств; в частности, такая оценка говорит о том, что заявление эксперта поможет вам, если вы не знаете, является ли монета подлинной, но уже не поможет, если вы узнали, что монета — подлинная. Однако не существует четких рекомендаций в отношении того, как следует принимать указанные решения, поскольку еще нет четкого понимания того, что означает ширина интервала. При использовании байесовского подхода рассуждения такого рода могут быть сформированы более легко путем исследования вопроса, как изменилась бы степень уверенности некоего лица при получении им дополнительных свидетельств. Например, знание о том, что монета — подлинная, оказало бы значительное влияние на степень уверенности в том, что она упадет орлом вверх, а обнаружение смещения ее центра тяжести оказало бы влияние на степень уверенности в том, что монета — подлинная.

Полная байесовская модель должна была бы включать вероятностные оценки для факторов, подобных этому, что позволило бы нам выражать наше "незнание" в терминах того, как изменялись бы значения степеней уверенности в процессе сбора информации в будущем.

Представление неосведомленности: нечеткие множества и нечеткая логика ^
Теория нечетких множеств — это один из подходов к определению того, насколько хорошо некоторый объект подходит под расплывчатое описание. Например, рассмотрим высказывание: "Нат имеет стройную фигуру". Является ли это высказывание истинным, если Нат имеет рост примерно 180 см? Большинство людей затрудняются при выборе ответа "да" или "нет", предпочитая сказать "скорее всего".

Обратите внимание на то, что этот вопрос не относится к сфере неопределенности знаний о внешнем мире — нам точно известен рост Ната. Проблема состоит в том, что лингвистическое выражение "стройный" не ссылается на четкую классификацию людей по признаку того, насколько стройной является его фигура. По этой причине & теория нечетких множеств вообще не является методом формирования неопределенных рассуждений. Вместо этого в теории нечетких множеств оценка стройности фигуры, Tall, рассматривается как нечеткий предикат и принимается предположение, что истинностное значение высказывания Tall (Nate) — это число от 0 до 1, а не просто значение true или false. Само название "нечеткое множество" исходит из интерпретации предиката как неявно определяющего множество его элементов — множество, не имеющее четких границ.

"<Эч Нечеткая логика — это метод формирования рассуждений с помощью логических выражений, описывающих принадлежность элементов к нечетким множествам. Например, сложное высказывание Tall (Nate) л Heavy(Nate) с оценкой того, насколько стройным является Нат и насколько велик его вес, имеет нечеткое истинностное значение, которое является функцией истинностных значений его компонентов. Ниже приведены стандартные правила оценки нечеткой истинности т сложного высказывания.

$$T(A \text{ л } B) = \min(T(A), T(B)) \quad T(A \vee B) = \max(T(A), T(B)) \quad T(\neg A) = 1 - T(A)$$

Поэтому нечеткая логика представляет собой систему с истинностной функциональностью, а этот факт становится причиной серьезных затруднений. Например, предположим, что $T(\text{Tall (Nate)}) = 0.6$ и $T(\text{Heavy(Nate)}) = 0.4$. В таком случае получаем значение $T(\text{Tall(Nate) л Heavy(Nate)}) = 0.4$, которое кажется обоснованным, но получаем также результат $T'(\text{Tall (Nate) л -nTall (Nate)}) = 0.4$, который таковым не кажется. Безусловно, эта проблема возникает из-за того, что истинностнофункциональный подход не позволяет учитывать корреляции или антикорреляции между компонентами высказываний.

"<Эч Нечеткое управление — это методология создания систем управления, в которых отображение между реальными входными данными и выходными параметрами представлено с помощью нечетких правил. Нечеткое управление оказалось очень успешным в таких коммерческих продуктах, как автоматические

коробки передач, видеокамеры и электрические бритвы. Критики этого подхода утверждают, что такие приложения оказались успешными потому, что в них используются небольшие базы правил, логические выводы не формируют цепочки, а для повышения производительности системы может осуществляться настройка параметров (см., например, [434]). И действительно, тот факт, что правила функционирования этих систем реализованы с помощью нечетких операторов, может не быть ключевым фактором их успеха; секрет состоит в том, чтобы применялся лаконичный и интуитивно понятный способ задания гладко интерполируемой функции с реальными значениями.

Предпринимались также попытки предложить одну из трактовок нечеткой логики в терминах теории вероятностей. Одна из таких идей состоит в том, чтобы такие утверждения, как "Нат — стройный", рассматривались в качестве дискретных наблюдений, сделанных применительно к непрерывной скрытой переменной — фактическому росту, Height, Ната. В такой вероятностной модели определяется вероятность $P(\text{Наблюдатель сообщает, что Нат — стройный} \mid \text{Height})$, возможно, с использованием пробит-распределения (см. с. 674). В таком случае появляется возможность рассчитать апостериорное распределение вероятностей значений роста Ната обычным образом, например, если эта модель входит в состав гибридной байесовской сети. Безусловно, такой подход не относится к категории истинностнофункциональных. Например, следующее условное распределение:

$P(\text{Наблюдатель сообщает, что Нат имеет стройную фигуру и большой вес} \mid \text{Height, Weight})$ допускает взаимодействия роста и веса в обоснованиях наблюдения. Таким образом, некто, имеющий рост примерно 245 см и вес 85 кг, с очень малой вероятностью будет назван "имеющим стройную фигуру и большой вес", даже несмотря на то, что человек, имеющий рост 45 см" рассматривается как "стройный", а вес "85 кг" принято считать "большим".

Нечетким предикатам может быть также дана вероятностная интерпретация в терминах $\wedge$ случайных множеств, т.е. случайных переменных, возможными значениями которых являются множества объектов. Например, Tall — это случайное множество, возможными значениями которого являются множества людей.

Вероятность $P(\text{Tall} = S_i)$, где S_i — некоторое определенное множество людей, представляет собой вероятность того, что именно данное множество будет обозначено некоторым наблюдателем как "характеризующееся стройными фигурами". Таким образом, вероятность того, что "Нат имеет стройную фигуру", представляет собой сумму вероятностей для всех множеств, элементом которых является Нат.

Создается впечатление, что и подход на основе гибридных байесовских сетей, и подход с использованием случайных множеств охватывает многие аспекты

нечеткости, не требуя учета степеней истинности. Тем не менее остается много нерешенных вопросов, касающихся правильного представления лингвистических наблюдений и непрерывных количеств, а этими вопросами пренебрегают большинство исследователей, не относящихся к сообществу специалистов по нечетким представлениям.

14.8. Резюме В этой главе описаны байесовские сети — тщательно разработанное представление для неопределенных знаний. Байесовские сети играют роль, примерно аналогичную той, которую выполняет пропозициональная логика применительно к определенным знаниям.

- Байесовская сеть — это ориентированный ациклический граф, вершины которого соответствуют случайным переменным; с каждой вершиной связано распределение условных вероятностей для этой вершины, если даны ее родительские вершины.
- Байесовские сети лежат в основе удобного способа представления отношений условной независимости в рассматриваемой проблемной области.
- Любая байесовская сеть задает полное совместное распределение; каждый элемент совместного распределения определяется как произведение соответствующих элементов в локальных условных распределениях. Байесовская сеть часто позволяет экспоненциально уменьшить размеры вероятностного представления по сравнению с полным совместным распределением.
- Многие условные распределения могут быть представлены компактно с помощью канонических семейств распределений. Целый ряд канонических распределений используется в гибридных байесовских сетях, которые включают и дискретные, и непрерывные переменные.
- Под вероятностным выводом в байесовских сетях подразумевается вычисление распределения вероятностей множества переменных запроса, если дано множество переменных свидетельства. Алгоритмы точного вероятностного вывода, такие как алгоритм устранения переменной, позволяют вычислять суммы произведений условных вероятностей настолько эффективно, насколько это возможно.
- В полидеревах (односвязных сетях) точный вероятностный вывод требует времени, линейно зависящего от размера сети. А в общем случае проблема такого вывода неразрешима.
- Методы стохастической аппроксимации, такие как оценка веса с учетом правдоподобия и метод Монте-Карло на основе цепи Маркова, позволяют получить приемлемые оценки истинных апостериорных вероятностей в сети и способны справиться с гораздо более крупными сетями по сравнению с точными алгоритмами.

- Теория вероятностей может применяться в сочетании с идеями представления знаний, заимствованными из логики первого порядка, для создания очень мощных систем формирования рассуждений в условиях неопределенности.

Реляционные модели вероятностей (Relational Probability Model — RPM) включают ограничения на средства представления, которые гарантируют получение

полностью определенного распределения вероятностей, которое может быть выражено в виде эквивалентной байесовской сети. • Был предложен целый ряд альтернативных систем для формирования рассуждений в условиях неопределенности. Вообще говоря, истинностно-функциональные системы не очень хорошо подходят для таких рассуждений.

Библиографические и исторические заметки Широкое использование сетей для представления вероятностной информации началось с первых десятилетий XX столетия, когда были опубликованы работы Сьюэлла Райта по вероятностному анализу генетического наследования и показателей развития животных [1622], [1624]. Одна из его сетей показана на обложке данной книги. И.Дж. Гуд [575] в сотрудничестве с Аланом Тьюрингом разработал вероятностные представления и методы байесовского вероятностного вывода, которые могут рассматриваться как предшественники современным байесовским сетям, хотя указанная статья не часто цитируется в данном контексте¹⁰. Та же статья является оригинальным литературным источником с описанием модели зашумленного OR.

Форма представления для задач принятия решений с помощью диаграммы влияния, которая была встроена в представление DAG для случайных переменных, вычислений применялись только методы перебора. Джуди Перл разработал метод передачи сообщений для осуществления вероятностного вывода в древовидных сетях [1186] и ввел понятие полидревовидных сетей [796], а также объяснил важность составления причинных, а не диагностических вероятностных моделей, в противовес системам, основанным на использовании факторов определенности, которые были в моде в то время. Первой экспертной системой, в которой использовались байесовские сети, стала Convince [795], [797]. Многие новейшие медицинские системы включают систему Munin для диагностирования нейромускульных нарушений [27] и систему Pathfinder для выявления патологий [640]. Одними из наиболее широко используемых систем на основе байесовских сетей оказались модули диагностики и восстановления (например, модуль Printer Wizard) в операционной системе Microsoft Windows [178] и Office Assistant в пакете Microsoft Office [685].

Перл [1189] разработал алгоритм кластеризации для точного вероятностного вывода в байесовских сетях общего вида, используя метод преобразования в ориентированное полидерево кластеров, в котором для достижения согласованности по переменным, разделяемым между кластерами, использовалась передача сообщений.

¹⁰ И. Дж. Гуд был главным статистиком в группе Тьюринга, занимавшейся раскрытием шифров во время Второй мировой войны. В книге 2 001: A Space Odyssey [264] выражена благодарность Гуду и Минскому за их вклад в тот научный прорыв, который привел к разработке компьютера HAL 9000.

Аналогичный подход, разработанный статистиками Дэвидом Шпигельхальтером и Штеффеном Лауритценом [895], [1449], основан на преобразовании в неориентированную сеть (Маркова). Этот подход реализован в системе Hugin, которая представляет собой эффективное и широко применяемое инструментальное средство для формирования рассуждений в условиях неопределенности [27]. Росс Шахтер, работающий в сообществе исследователей диаграмм влияния, разработал точный метод, который основан на сокращении сети, управляемом целями, с использованием преобразований, сохраняющих апостериорную вероятность [1383].

Метод устранения переменных, описанный в данной главе, ближе всего по замыслу к методу Шахтера, на основе которого разработан алгоритм символического вероятностного вывода (Symbolic Probabilistic Inference— SPI) [1385]. В алгоритме SPI предпринимается попытка оптимизировать вычисление деревьев выражений, подобных приведенному на рис. 14.8. Описанный в данной книге алгоритм больше всего напоминает алгоритм, разработанный Чжангом и Пулом [1643], [1644].

Критерии отсекаания нерелевантных переменных были разработаны Гейгером и др. [530], а также Лауритценом и др. [894]; приведенный в данной книге критерий представляет собой простой частный случай этих критериев. Рина Дехтер [369] показала, что идея устранения переменной по сути идентична $\wedge$ непоследовательному динамическому программированию [117]— алгоритмическому подходу, который может использоваться для решения целого ряда задач вероятностного вывода в байесовских сетях, например поиска наиболее вероятного объяснения для множества наблюдений.

В этом подходе алгоритмы байесовских сетей применяются в сочетании с соответствующими методами решения задач CSP и дается прямая оценка меры сложности точного вывода в терминах ширины гипердерева сети.

Вопрос о включении непрерывных случайных переменных в байесовские сети рассматривался Перлом [1191], а также Шахтером и Кенли [1386]; в этих статьях обсуждаются сети, содержащие только непрерывные переменные с линейными гауссовыми распределениями. Проблема включения дискретных переменных исследовалась Лауритценом и Вермутом [896], а полученные результаты реализованы в системе sHUGIN [1154]. Пробит-распределение впервые было исследовано Финнеем [469], который назвал его сигмоидальным распределением. Это распределение широко использовалось для моделирования феномена дискретного выбора и может быть дополнено, если требуется его применение в тех случаях, когда количество выборов превышает два [318]. В [133] приведено обоснование целесообразности использования логит-распределения в данной научной области.

Купер [291] показал, что общая проблема вероятностного вывода в байесовских сетях без ограничений является NP-трудной, и Пол Дагум и Майк Луби [319] показали, что NP-трудной является соответствующая задача аппроксимации. Одной из серьезных проблем при использовании методов кластеризации и устранения переменной является также пространственная сложность. Применение метода определения условий выбора множества разрыва цикла, который был разработан для задач CSP в главе 5, позволяет исключить необходимость построения экспоненциально больших таблиц. В байесовской сети множеством разрыва цикла является множество вершин, позволяющих после их конкретизации свести оставшиеся вершины к полидереву, которое может быть решено с линейными затратами времени и пространства. Поиск ответа на запрос осуществляется путем суммирования по всем конкретизациям множества разрыва цикла, поэтому общие требования к пространству все

еще остается линейными [1191]. В [323] описан рекурсивный алгоритм обусловливания, который допускает широкий выбор компромиссных методов сокращения затрат пространства/времени.

В настоящее время разработка быстрых алгоритмов аппроксимации для вероятностного вывода в байесовских сетях представляет собой очень активную научную область, которая испытывает положительное влияние со стороны статистики, компьютерных наук и физики. Способ формирования выборок с исключением представляет собой общий метод, давно известный статистикам; он был впервые применен к байесовским сетям Максом Хенрионом [648], который назвал этот метод логическим формированием выборок. Метод взвешивания с учетом правдоподобия, который был разработан Фунгом и Чангом [512], а также Шахтером и Пеотом [1387], представляет собой пример широко известного статистического метода формирования выборок с учетом важности. Результаты крупномасштабного применения метода взвешивания с учетом правдоподобия в области медицинской диагностики опубликованы в [1407]. Ченг и Друздзель [247] описали адаптивную версию метода взвешивания с учетом правдоподобия, которая действует очень успешно, даже если свидетельства имеют крайне низкое априорное правдоподобие.

Развитие алгоритмов Монте-Карло на основе цепи Маркова (Markov chain Monte Carlo — MCMC) началось с создания алгоритма Метрополиса, впервые опубликованного в статье [1036], которая стала также первой публикацией сведений об алгоритме эмуляции отжига (см. главу 4). Формирователь выборок Гиббса был предложен в [535] для вероятностного вывода в неориентированных сетях Маркова.

Применение алгоритма MCMC к байесовским сетям было предложено Перлом [1190].

Статьи, собранные в [554], охватывают широкий диапазон направлений использования алгоритма МСМС, многие из которых были разработаны при создании широко известного пакета Bugs [555].

В этой главе не рассматривались два очень важных семейства методов аппроксимации. Первым из них является семейство методов $\wedge$ вариационной аппроксимации, которые могут использоваться для упрощения сложных вычислений любых типов.

Основная идея состоит в том, что должна быть предложена сокращенная версия первоначальной задачи, с которой легче работать, но которая напоминает первоначальную задачу настолько близко, насколько это возможно. Сокращенная задача описывается с помощью некоторых $\wedge$ вариационных параметров X , которые корректируются с целью минимизации функции расстояния D между оригинальной и сокращенной задачами, часто путем решения системы уравнений $dD/dX=0$. Во многих случаях могут быть получены строгие верхние и нижние границы. Вариационные методы уже давно использовались в статистике [1333]. В статистической физике метод " $\wedge$ поля осредненных величин (mean field) представляет собой особую вариационную аппроксимацию, в которой предполагается, что отдельные переменные, входящие в состав модели, являются полностью независимыми. Эта идея была применена для поиска решений в крупных неориентированных сетях Маркова [1174], [1209].

В [1353] представлены результаты разработки математических основ применения вариационных методов к байесовским сетям и получения точных аппроксимаций нижней границы для сигмоидальных сетей с использованием методов поля осредненных величин. Эта методология была дополнена в [720] для получения нижней и верхней границ. Обзор вариационных подходов приведен в [748].

Второе важное семейство алгоритмов аппроксимации основано на алгоритме Перла передачи сообщений в полидереже [1186]. Как указал Перл [1191], этот алгоритм может применяться к сетям общего типа. Иногда результаты оказываются неправильными, или же не удается добиться нормального завершения работы алгоритма, но во многих случаях полученные значения близки к истинным значениям. Так называемый подход с " $\wedge$ распространением оценок степени уверенности (или с циклическим распространением) привлекал мало внимания до тех пор, пока Макэлис и др. [1027] не обнаружили, что передача сообщений в многосвязной байесовской сети полностью аналогична вычислениям, выполняемым в алгоритме $\wedge$ турбодекодирования (turbo decoding) [115], который оказался крупным научным прорывом в области разработки эффективных кодов коррекции ошибок. Из этого следует вывод, что способ циклического распространения быстро и точно работает в очень крупных и тесно связанных сетях, используемых для декодирования, и поэтому может найти более широкое

применение. В [1105] представлены результаты эмпирического исследования областей использования этого алгоритма. В [1630] подробно описаны связи между методом циклического распространения и идеями статистической физики.

Связь между вероятностными методами и языками первого порядка была впервые исследована Карнапом [225]. В [513] и [1373] определен язык, в котором вероятности могут быть объединены с высказываниями первого порядка и для которого моделями являются вероятностные показатели в возможных мирах. В рамках искусственного интеллекта эта идея была разработана Нильссоном для пропозициональной логики [1144] и Халперном для логики первого порядка [607]. Результаты первого обширного исследования проблем представления знаний в таких языках были опубликованы в [51], а в [1577] приведен обзор первых подходов к реализации этих способов представления на основе формирования эквивалентных пропозициональных байесовских сетей. В дальнейшем исследователи пришли к пониманию важности полных баз знаний, т.е. баз знаний, в которых, как и в байесовских сетях, определяется уникальное совместное распределение по всем возможным мирам. Методы осуществления этого были основаны на вероятностных версиях логического программирования [1226], [1352] или на семантических сетях [823].

Реляционные вероятностные модели такого типа, описанные в данной главе, были глубоко исследованы Пфеффером [1210]. В [1179] приведены результаты исследования проблем реляционной неопределенности и неопределенности идентичности в рамках моделей RPM, а также результаты использования вероятностного вывода с помощью алгоритма MCMC.

Как было описано в главе 13, после появления первых вероятностных систем в начале 1970-х годов интерес к ним упал и частично образовался вакуум, который стали заполнять альтернативные методы. Для использования в медицинской экспертной системе Mycin [1406] был разработан подход на основе факторов определенности, который был предназначен как для выработки проектных решений, так и для моделирования субъективных суждений, формируемых в условиях неопределенности.

В сборнике статей Rule-Based Expert Systems [204] приведен полный обзор системы Mycin и других систем, разработанных на ее основе (см. также [1458]). Дэвид Хекерман [639] показал, что в некоторых случаях слегка модифицированная версия на основе вычислений с фактором определенности позволяет получить правильные вероятностные результаты, но в других случаях приводит к серьезной переоценке важности свидетельств. В экспертной системе Prospector [420] используется подход на

основе правил, в котором правила были обоснованы с помощью предположения о глобальной независимости (которое редко оправдывается).

Теория, получившая название теории Демпстера—Шефера, была впервые опубликована в статье Артура Демпстера [382], который предложил обобщение способа представления вероятностей в виде интервальных значений и обосновал правила комбинирования для их использования. После того как в дальнейшем была опубликована работа Гленна Шефера [1388], теория Демпстера-Шефера стала рассматриваться как научный подход, способный конкурировать с вероятностным подходом.

В [1319] приведены результаты анализа связи между теорией Демпстера—Шефера и стандартной теорией вероятностей. Шеной [1401] предложил метод принятия решений с помощью доверительных функций Демпстера-Шефера.

Нечеткие множества были разработаны Лотфи Задэ [1637] в целях устранения широко признанных сложностей при предоставлении точных входных данных для интеллектуальных систем. В [1649] приведено исчерпывающее введение в теорию нечетких множеств; статьи по приложениям нечетких множеств собраны в [1648].

Как уже было указано в данной книге, нечеткую логику часто трактуют неправильно, усматривая в ней прямого конкурента для теории вероятностей, тогда как в этой теории фактически рассматриваются другие вопросы. Для вычислений с учетом неопределенности в нечетких системах была предложена $\wedge$ теория возможностей (possibility theory) [1638], которая имеет много общего с теорией вероятностей.

В [419] предложен исчерпывающий обзор по проблеме связей между теорией возможностей и теорией вероятностей.

Пробуждение в последнее время интереса к вероятностным методам в основном вызвано тем открытием, что байесовские сети являются удобным средством представления и использования информации об условной независимости. Но сторонникам байесовского подхода пришлось бороться за его дальнейшее распространение; некоторое представление о том, какие дебаты они вели со своими противниками, можно получить, ознакомившись с воинственной статьей Питера Чизмена *In Defense of Probability* [242] и с его последующей статьей *An Inquiry into Computer Understanding* [243] (с комментариями). Одним из принципиальных возражений противников байесовского подхода (и последователей логицистского подхода) было то, что числовые вычисления, применяемые в теории вероятностей, не очевидны для интуитивного восприятия и претендуют на наличие нереального уровня точности в наших неопределенных знаниях. Результаты разработки Веллманом качественных вероятностных сетей [1574] привели к созданию чисто качественной абстракции байесовских сетей, в которой используется понятие положительных и отрицательных влияний между переменными. Веллман показал,

что во многих случаях такая информация является достаточной для принятия оптимальных решений и не требует точного указания вероятностных значений. В работе Эднана Дарвича и Мэтта Гинсберга [324] выявлены основные свойства методов обусловливания и комбинирования свидетельств, разработанных в рамках теории вероятностей, и показано, что эти методы могут также применяться при формировании логических рассуждений и рассуждений по умолчанию.

Система диагностики сердечных заболеваний, описанная в данной главе, разработана Лукасом [962]. К другим отраслевым приложениям байесовских сетей относятся выполненные в компании Microsoft работы по выявлению целей пользователя компьютера на основании анализа его действий [685] и по фильтрации нежелательной электронной почты [1344], а также работа Electric Power Research Institute по

контролю над электрическими генераторами [1088] и работа NASA по выводу крайне чувствительной ко времени информации на дисплей в Центре управления полетами в Хьюстоне [684].

Некоторые важные ранние статьи по применению методов формирования рассуждений в условиях неопределенности в искусственном интеллекте собраны в антологиях *Readings in Uncertain Reasoning* [1389] и *Uncertainty in Artificial Intelligence* [768].

Наиболее важной отдельной публикацией, посвященной развитию байесовских сетей, безусловно, является книга *Probabilistic Reasoning in Intelligent Systems* [1191].

Более свежие материалы можно найти в нескольких превосходных книгах, включая [734], [746] и [893]. Новейшие результаты исследований в области вероятностных рассуждений публикуются и в профильных журналах по искусственному интеллекту, таких как *Artificial Intelligence* и *Journal of AI Research*, и в более специализированных журналах, таких как *International Journal of Approximate Reasoning*. Многие статьи по графическим моделям, к которым относятся байесовские сети, публикуются в статистических журналах. Превосходными источниками сведений о современных исследованиях являются труды конференций *Uncertainty in Artificial Intelligence (UAI)*, *Neural Information Processing Systems (NIPS)* и *Artificial Intelligence and Statistics (AISTATS)*.

Упражнения 14.1. Рассмотрите сеть для диагностики автомобиля, показанную на рис. 14.12.

Рис. 14.12. Байесовская сеть, описывающая некоторые характеристики электрической системы и двигателя автомобиля. Каждая переменная является булевой, а значение true указывает на то, что соответствующая подсистема автомобиля находится в рабочем состоянии а) Дополните сеть булевыми

переменными icyWeather (Морозная погода) и StarterMotor (Стартер). б) Приведите приемлемые таблицы условных вероятностей для всех вершин.

в) Сколько независимых значений содержится в совместном распределении вероятностей для восьми булевых вершин, если исходить из предположения, что неизвестны какие-либо отношения условной независимости, которые бы их связывали? г) Какое количество независимых вероятностных значений содержится в таблицах вашей сети? д) Условное распределение для вершины Starts (Запускается) может быть описано как распределение зашумленного AND. Дайте общее определение этого семейства распределений и покажите его связь с распределениями зашумленного OR.

14.2. Допустим, что вы живете рядом с атомной электростанцией, в которой предусмотрена тревожная сигнализация, срабатывающая, если показания датчика температуры превышают некоторое пороговое значение. Датчик измеряет температуру в реакторе. Рассмотрите булевы переменные A (звучит тревожный сигнал), FA (тревожная сигнализация неисправна) и FG (неисправен датчик), а также многозначные вершины G (показания датчика) и t (фактическая температура в реакторе). а) Нарисуйте байесовскую сеть для этой проблемной области с учетом того, что вероятность отказа датчика повышается, если температура в реакторе становится слишком высокой. б) Является ли ваша сеть полидеревом? в) Примите предположение, что есть только два значения фактической и измеряемой температур — нормальная и высокая; вероятность того, что датчик сообщает правильную температуру, равна x , когда он работает, а если не исправен, равна y . Приведите таблицу условных вероятностей, связанную с вершиной G. г) Примите предположение, что тревожная сигнализация действует правильно, при условии, что она не вышла из строя; в последнем случае тревожный сигнал никогда не звучит. Приведите таблицу условных вероятностей, связанную с вершиной A. д) Примите предположение, что тревожная сигнализация и датчик исправны и что тревожный сигнал звучит. Вычислите выражение для вероятности того, что температура в реакторе слишком высока, в терминах различных условных вероятностей в данной сети.

14.3. Два астронома в различных частях Земли провели измерения, m_1 и m_2 , количества звезд, N , в некотором небольшом регионе неба с помощью своих телескопов. Обычно вероятность ошибки e на одну звезду в большую или меньшую сторону при подсчете этого количества не очень велика. Каждый телескоп может также оказаться (с гораздо меньшей вероятностью f) сильно расфокусированным (события F1 и F2), и в этом случае ученый не досчитается трех или большего количества звезд (или, если $i \setminus 7$ меньше 3, вообще не обнаружит ни одной звезды). Рассмотрите эти три сети, показанные на рис. 14.13. а) Какая из этих трех байесовских

сетей может служить правильным (но не обязательно эффективным) представлением приведенной выше информации?

б) Какая из этих сетей является самой лучшей? Объясните, почему. в) Запишите распределение условных вероятностей $P(M_1 \setminus N)$ для случая, где $N \in \{1, 2, 3\}$ и $M \in \{0, 1, 2, 3, 4\}$. Каждая запись в распределении условных вероятностей должна быть представлена как функция от параметров e и/или f . г) Примите предположение, что $M_1=1$ и $M_2=3$. Каково возможное количество звезд, если предполагается, что на значения N не налагаются априорные ограничения? д) Каково наиболее вероятное количество звезд, если даны эти наблюдения? Объясните, как рассчитать эту вероятность, или, если ее невозможно рассчитать, объясните, какая требуется дополнительная информация и как она повлияет на результат.

14.4. Рассмотрите сеть, показанную на рис. 14.13, б; примите предположение, что два телескопа дают идентичные результаты, $N \in \{1, 2, 3\}$ и $M \in \{0, 1, 2, 3, 4\}$, а также, что применяются такие символические таблицы CPT, как описано в упр.

14.3. Используя алгоритм перебора, рассчитайте распределение вероятностей $P(N \setminus M_1=2, M_2=2)$. а) б) в) Рис. 14.13. Три возможные сети для задачи с телескопом

14.5. Рассмотрите семейство линейных гауссовых сетей, которое показано на с. 672. а) Допустим, что в сети с двумя переменными переменная X_1 является родительской по отношению к переменной X_2 , переменная x_1 имеет гауссово распределение априорных вероятностей, а $P(X_2 \setminus x_1)$ — линейное гауссово распределение. Покажите, что совместное распределение $P(X_1, X_2)$ представляет собой многомерное гауссово распределение, и рассчитайте его матрицу ковариации. б) Докажите по индукции, что совместное распределение для линейной гауссовой сети общего вида по переменным $X_1, \dots, X_n$ также является многомерным гауссовым распределением.

14.6. Пробит-распределение, описанное на с. 674, позволяет представить распределение вероятностей для булевой дочерней переменной, если задана одна непрерывная родительская переменная.

а) Как можно расширить это определение, чтобы оно охватывало несколько непрерывных родительских переменных? б) Как оно может быть расширено с учетом многозначной дочерней переменной? Рассмотрите и те случаи, в которых значения дочерней переменной упорядочены (как при выборе во время вождения автомобиля передачи в зависимости от скорости, крутизны подъема, требуемого ускорения и т.д.), и те случаи, в которых они не упорядочены (как при выборе для проезда на работу или автобуса, или электропоезда, или автомобиля).

(Подсказка. Рассмотрите способы распределения возможных значений по двум множествам для имитации булевой переменной.) 14.7. В этом упражнении речь идет об алгоритме устранения переменной, приведенном в листинге 14.2. а) В разделе 14.4 алгоритм устранения переменной применялся к следующему запросу:

$P(\text{Burglary} | \text{JohnCalls}=\text{true}, \text{MaryCalls}=\text{true})$ Проведите указанные вычисления и проверьте правильность ответа. б) Подсчитайте количество выполненных арифметических операций и сравните его с количеством операций, выполняемых в алгоритме перебора. в) Предположим, что сеть имеет форму цепи — последовательности булевых переменных $X_1, \dots, X_n$, где $\text{Parents}(X_i) = \{X_{i-1}\}$ для $i=2, \dots, n$. Какова сложность вычисления выражения $P(X_1 \wedge \dots \wedge X_n = \text{true})$ с использованием алгоритма перебора? С использованием алгоритма устранения переменной? г) Докажите, что сложность применения алгоритма устранения переменной в сети, имеющей форму полидерева, линейно зависит от размера дерева при любом упорядочении переменных, согласованном со структурой сети.

14.8. Проведите исследование сложности точного вывода в байесовских сетях общего вида. а) Докажите, что любую задачу 3-SAT можно свести к задаче точного вывода в байесовской сети, сформированной для представления данной конкретной задачи, и поэтому такой точный вывод является NP-трудным.

(Подсказка. Рассмотрите сеть с одной переменной для каждого пропозиционального символа, с одной для каждого выражения и с одной для конъюнкции выражений.) б) Проблема подсчета количества выполняющих присваиваний для задачи 3-SAT является #P-полной (шарп-, или дизель-P-полной). Покажите, что задача точного вывода является, по меньшей мере, такой же трудной, как эта.

14.9. Рассмотрите задачу формирования случайной выборки из заданного распределения по одной переменной. Вы можете принять предположение, что в вашем распоряжении имеется генератор случайных чисел, который возвращает случайное число с равномерным распределением в интервале от 0 до 1. а) Допустим, что X — дискретная переменная с $P(X=X_j) = p_j$ для $j \in \{1, \dots, k\}$. Кумулятивное распределение (cumulative distribution) X задает вероятность того, что $X \leq x_j$ для каждого возможного j .

Объясните, как рассчитать это кумулятивное распределение за время

$O(k)$ и как получить из него одну выборку X . Может ли последняя операция быть выполнена за время меньше $O(k)$? б) Теперь предположим, что необходимо сформировать N выборок X , где $N \gg k$. Объясните, как выполнить эту операцию с ожидаемым временем прогона в расчете на выборку, которое является постоянным (т.е. независимым от k). в) После этого рассмотрим непрерывную переменную с параметризованным (например, с гауссовым) распределением. Как можно формировать выборки с помощью такого распределения? г) Предположим, что необходимо сформулировать запрос, касающийся непрерывной переменной, и что для вероятностного вывода используется такой алгоритм, как Likelihood Weighting. Как вы модифицировали бы процесс поиска ответов на такие запросы?

14.10. Марковское покрытие переменной определено на с. 669. а) Докажите, что переменная является независимой от всех других переменных в сети, если дано ее марковское покрытие. б) Выведите уравнение 14.11.

14.11. Рассмотрите запрос $P\{\text{Rain} \setminus \text{Sprinkler}=\text{true}, \text{WetGrass}=\text{true}\}$ к байесовской сети, приведенной на рис. 14.9, я, и покажите, как можно получить на него ответ с помощью алгоритма MCMC. а) Какое количество состояний имеет эта цепь Маркова? б) Рассчитайте матрицу переходов Q , содержащую значение $d(y \rightarrow y')$ для всех y, y' . в) Что представляет собой Q^2 , квадрат матрицы переходов? г) А что можно сказать о выражении $(Y^1, \text{ где } l \rightarrow \infty)$? д) Объясните, как следует выполнять вероятностный вывод в байесовских сетях, при условии, что доступно выражение (?). Является ли такой способ вероятностного вывода практически применимым?

14.12. \$t Три футбольные команды, A, B и C, играют друг с другом по одному разу.

Каждый матч проводится между двумя командами и может закончиться для команды выигрышем, ничьей или проигрышем. Каждой команде присвоена постоянная, неизвестная оценка ее класса (целое число в диапазоне от 0 до 3), и результат матча оценивается вероятностной зависимостью от разницы в классе между двумя участвующими командами. а) Сформируйте реляционную вероятностную модель для описания этой проблемной области и предложите реальные числовые значения для всех необходимых распределений вероятностей. б) Сформируйте эквивалентную байесовскую сеть. в) Примите предположение, что в первых двух матчах команда A побеждает B и играет вничью с C. Используя выбранный вами алгоритм точного вывода, вычислите распределение апостериорных вероятностей для результатов третьего матча.

г) Предположим, что в этой футбольной лиге p команд и известны результаты всех матчей, кроме последнего. Как сложность предсказания результатов последней игры зависит от p ? д) Рассмотрите возможность применения алгоритма MCMC для решения этой задачи. Насколько быстро этот алгоритм сходится на практике и насколько хорошо он масштабируется?

Глава 15. Вероятностные рассуждения во времени

15 Вероятностные рассуждения во времени В данной главе предпринимается попытка истолковать настоящее, понять прошлое, а также, возможно, предсказать будущее, даже если пока лишь немного полностью ясно.

Агенты, действующие в неопределенных вариантах среды, должны быть способны следить за текущим состоянием среды; это требование аналогично тому, которое предъявляется к логическим агентам. Указанная задача в значительной степени усложняется из-за наличия частичных и зашумленных результатов восприятия, а также из-за неопределенности в отношении того, как среда изменяется во времени.

В лучшем случае агент будет способен получить только вероятностную оценку текущей ситуации. В этой главе описаны способы представления и алгоритмы вероятностного вывода, благодаря которым такая оценка становится возможной, на основе идей, представленных в главе 14.

Базовый подход описан в разделе 15.1: изменяющийся мир моделируется с использованием случайных переменных, обозначающих каждый аспект состояния мира в каждый момент времени. Отношения между этими переменными описывают, как развивается данное состояние. В разделе 15.2 определены основные задачи вероятностного вывода и описана общая структура алгоритмов вероятностного вывода для временных моделей. Затем рассматриваются три конкретных типа моделей: скрытые марковские модели, фильтры Калмана и динамические байесовские сети (которые включают скрытые марковские модели и фильтры Калмана в качестве частных случаев). Наконец, в разделе 15.6 показано, благодаря чему временные вероятностные модели образуют ядро современных систем распознавания речи.

Центральную роль в создании всех этих моделей играет обучение, но подробное исследование алгоритмов обучения будет отложено до части VI.

15.1. Время и неопределенность В предыдущих главах методы вероятностных рассуждений рассматривались в контексте статических миров, в которых каждая случайная переменная имеет одно фиксированное значение. Например, в ходе ремонта автомобиля предполагается, что неисправный узел остается неисправным на протяжении всего процесса диагностики; наша задача состоит в вероятностном выводе информации о состоянии автомобиля из наблюдаемых свидетельств, которые также остаются фиксированными.

Теперь обратимся к несколько другой задаче — лечение больного диабетом. Как и в случае ремонта автомобиля, в нашем распоряжении имеются факты, такие как последние дозы приема инсулина, рацион питания, результаты измерения количества сахара в крови и другие физические симптомы. Задача состоит в том, чтобы оценить текущее состояние пациента, включая фактический уровень сахара в крови и уровень инсулина. При наличии такой информации врач (или больная) принимает решение о рационе питания больного и дозе инсулина. Но в отличие от случая с ремонтом автомобиля теперь становятся существенными динамические аспекты задачи. Значения уровня сахара в крови и результаты их измерения могут резко изменяться во времени, в зависимости от последнего приема пищи больным и доз инсулина, от интенсивности обмена веществ в организме, времени суток и т.д. Чтобы оценить текущее состояние больного по хронологии накопленных фактов и предсказать результаты терапевтических действий, необходимо моделировать эти изменения.

Точно такие же соображения возникают во многих других контекстах, начиная от слежения за экономической активностью определенного государства по приблизительным и частичным статистическим данным и заканчивая пониманием последовательности слов устной речи по зашумленным и неоднозначным результатам акустических измерений. Возникает вопрос: как можно промоделировать подобные динамические ситуации?

Состояния и наблюдения Основной подход, который будет принят в этой главе, основан на идеях, аналогичных идеям ситуационного исчисления, как описано в главе 10: процесс изменения может рассматриваться как ряд снимков, каждый из которых описывает состояние мира в данный конкретный момент времени. Каждый снимок, или $\wedge$ временной срез, содержит множество случайных переменных, причем одна часть из них является наблюдаемой, а другая — нет. Для упрощения будем предполагать, что в каждом временном срезе является наблюдаемым одно и то же подмножество переменных (хотя такое требование не является строго необходимым во всем последующем изложении). Мы будем использовать x_t для обозначения множества ненаблюдаемых переменных состояния во время t и E_t для обозначения множества наблюдаемых переменных свидетельства. Результаты наблюдения во время t представляют собой множество $E_t = e_t$, соответствующее некоторому множеству значений e_t .

Рассмотрим следующий крайне упрощенный пример. Предположим, что на каком-то секретном подземном объекте служит охранник, который никогда не выходит наружу. Он хочет знать, идет ли сегодня дождь, но единственный доступ к информации из внешнего мира охранник получает только по утрам, когда видит директора, пришедшего с зонтиком или без зонтика. Таким образом, в каждые сутки t

множество E_t включает единственную переменную свидетельства U_t (которая показывает, несет ли директор зонтик), а множество x_t содержит единственную переменную состояния R_t (которая показывает, идет ли дождь). Другие задачи могут быть связаны с использованием более крупных множеств переменных. В частности, в примере с больным диабетом могут использоваться такие переменные свидетельства, как результаты измерения уровня сахара в крови $\text{MeasuredBloodSugar}_t$ и частоты пульса PulseRate_t , а также переменные состояния¹, такие как фактический уровень сахара в крови BloodSugar_t и содержимое желудка StomachContent_t .

Интервал между временными срезами также зависит от задачи. При контроле состояния больного диабетом подходящим интервалом может оказаться час, а не сутки. В этой главе в основном предполагается использование фиксированных конечных интервалов; это означает, что точки во времени, соответствующие временным срезам, могут быть обозначены целыми числами. Кроме того,

предполагается, что последовательность состояний начинается в момент времени $t=0$; к тому же по некоторым причинам, не имеющим особого значения, предполагается, что свидетельства начинают появляться в момент времени $t=1$, а не $t=0$. Таким образом, мир задачи с зонтиком может быть представлен переменными состояния $i_0, i_1, i_2, \dots$ и переменными свидетельства $U_1, U_2, \dots$. Для обозначения последовательности целых чисел от a до b (включительно) будет использоваться запись $a:b$, а для обозначения соответствующего ряда переменных от x_a до x_b — запись $x_a:b$. Например, $i_1:3$ соответствует переменным i_1, i_2, i_3 .

Стационарные процессы и марковское предположение После того как выбраны множества переменных состояния и переменных свидетельства для данной конкретной задачи, на следующем этапе необходимо определить зависимости между этими переменными. Мы будем следовать процедуре, описанной в главе 14, размещая переменные в некотором порядке и отвечая на вопросы об условной независимости переменных-преемников, если дано некоторое множество родительских переменных. Одним из очевидных вариантов является упорядочение переменных в их естественной временной последовательности, поскольку причина обычно предшествует результату, а мы предпочитаем вводить переменные в причинной последовательности.

Однако при таком подходе сразу же возникает одно препятствие: множество переменных является неограниченным, поскольку включает переменные состояния и переменные свидетельства для каждого временного среза. Такая ситуация фактически порождает две проблемы: во-первых, нам может потребоваться задать неограниченное количество таблиц условных вероятностей, по одной для каждой переменной в каждом срезе, во-вторых, каждая переменная может быть связана с неограниченным количеством родительских переменных.

Первая проблема разрешима на основании предположения, что изменения в состоянии мира вызваны $\wedge$ стационарным процессом, т.е. процессом изменения, подчиняющимся таким законам, которые сами не изменяются во времени. (Не следует 1 Обратите внимание на то, что `BloodSugart` и `MeasuredBloodSugart` представляют собой разные переменные; это позволяет отличить зашумленные результаты измерений от фактических данных.

путать стационарные процессы со статическими — в статическом процессе не изменяется само состояние.) Поэтому в мире задачи с зонтиком условная вероятность того, что директор придет с зонтиком, $P(U_t | \text{Parents}(U_t))$, является одинаковой для всех значений t . Таким образом, если принято предположение о стационарности, то необходимо задавать условные распределения только для переменных, относящихся к некоторому "репрезентативному" временному срезу.

Вторая проблема, касающаяся того, что приходится иметь дело с таким количеством родительских переменных, которое в принципе может стать бесконечным, решается благодаря принятию так называемого $\wedge$ марковского предположения, или предположения о марковости, которое заключается в том, что текущее состояние зависит лишь от конечной истории предыдущих состояний. Процессы, соответствующие этому предположению, были впервые глубоко исследованы российским ученым-статистиком Андреем Марковым и называются $\wedge$ марковскими процессами, или марковскими цепями. Существует несколько разновидностей таких процессов; простейшим из них является $\wedge$ марковский процесс первого порядка, в котором текущее состояние зависит только от предыдущего состояния и не зависит от какихлибо более ранних состояний. Иными словами, состояние — это информация, которая требуется для того, чтобы сделать прогноз о будущем независимым от прошлого, если дано это состояние. С использованием принятой в этой главе системы обозначений соответствующее утверждение об условной независимости позволяет сформулировать для всех t следующее соотношение:

$P(X_t | X_{0:t-1}) = P(X_t | X_{t-1})$ A5.1) Таким образом, в марковском процессе первого порядка законы, описывающие, как состояние развивается во времени, полностью представлены в условном распределении $P(X_t | X_{t-1})$, которое мы будем называть моделью перехода для процессов первого порядка². Моделью перехода для марковского процесса второго порядка является условное распределение $P(x_t | x_{t-2}, x_{t-1})$. Структуры байесовских сетей, соответствующие марковским процессам первого и второго порядка, приведены на рис. 15.1.

Рис. 15.1. Структуры байесовских сетей: байесовская сеть, соответствующая марковскому процессу первого порядка с состоянием, определяемым переменными X_t (а); марковский процесс второго порядка (б) Кроме ограничения количества родительских переменных, относящихся к переменным состояния x_t , необходимо ограничить количество родительских переменных, относящихся к переменным свидетельства E_t . Как правило, в данной главе 2 Модель перехода представляет собой вероятностный аналог булевых схем обновления, описанных в главе 7, и аксиом состояния-преемника, представленных в главе 10.

предполагается, что переменные свидетельства во время t зависят только от текущего состояния:

$P(E_t | X_{0:t}, E_{0:t-1}) = P(E_t | X_t)$ A5.2) Условное распределение $p(E_t | x_t)$ называется $\wedge$ моделью восприятия (или иногда моделью наблюдения), поскольку оно показывает, как фактическое состояние мира влияет на "результаты восприятия", т.е. на переменные свидетельства.

Обратите внимание на то, каково направление зависимости: "стрелки" идут от состояния к значениям результатов восприятия, поскольку именно состояние мира

вынуждает результаты восприятия приобретать данные конкретные значения. Например, в мире задачи с зонтиком дождь вынуждает директора прийти с зонтиком. (Разумеется, процесс вероятностного вывода проходит в другом направлении; одним из преимуществ байесовских сетей является то, что они позволяют провести различие между направлением моделируемых зависимостей и направлением вероятностного вывода.) Кроме модели перехода и модели восприятия, необходимо определить $P(x_0)$ — распределение априорных вероятностей состояний во время 0. Эти три распределения, в сочетании с предположениями об условной независимости, приведенными в уравнениях 15.1 и 15.2, позволяют получить спецификацию полного совместного распределения по всем переменным. Для любого конечного значения t получаем следующее:

$P(X_0, X_i, X_t, E_i, E_t) = P(X_0) \prod_i P(X_i | X_{i-1}) \prod_i P(E_i | X_i)$ Предположения о независимости соответствуют очень простой структуре байесовской сети, описывающей всю систему. На рис. 15.2 показана структура сети для примера с зонтиком, включая условные распределения для модели перехода и модели восприятия.

Рис. 15.2. Структура байесовской сети и распределения условных вероятностей, которые описывают мир задачи с зонтиком. Моделью перехода служит $P(R_{i+1} | R_i)$, а моделью восприятия является $P(U_{i+1} | R_{i+1})$. В структуре, показанной на этом рисунке, предполагается использование марковского процесса первого порядка, поскольку считается, что вероятность дождя зависит только от того, был ли дождь в предыдущие сутки. Является ли такое предположение обоснованным, зависит от самой проблемной области. Марковское предположение первого порядка указывает, что переменные состояния содержат всю

информацию, необходимую для описания распределения вероятностей для следующего временного среза. Иногда такое предположение полностью соответствует истине; например, если некоторая частица совершает случайное блуждание вдоль оси x , изменяя свою позицию на величину ± 1 в каждый интервал времени, то применение в качестве состояния координаты x позволяет определить марковский процесс первого порядка. Иногда такое предположение является лишь приблизительным, как и в случае предсказания дождя лишь на основании того, был ли дождь в предыдущие сутки. Как описано ниже, существуют два возможных метода корректировки, если такое приближение оказывается слишком неточным.

1. Повышение порядка модели марковского процесса. Например, можно перейти к использованию модели второго порядка, введя переменную R_{i+2} в качестве родительской по отношению к R_{i+1} , что позволит получить немного более точные предсказания (например, в Пало-Альто дождь очень редко идет больше двух дней подряд).

2. Расширение множества переменных состояния. Например, можно ввести переменную с обозначением времени года $Season_t$, чтобы иметь возможность включить хронологические данные о дождливых временах года, или ввести переменные для температуры $Temperature^t$ влажности $Humidity^t$ и атмосферного давления $Pressure^t$ чтобы иметь возможность использовать физическую модель условий, способствующих возникновению дождя.

В упр. 15.1 предлагается показать, что первое решение (увеличение порядка модели) можно всегда переформулировать как расширение множества переменных состояния, при сохранении фиксированного порядка. Следует отметить, что введение дополнительных переменных состояния может увеличить прогностическую мощь системы, но вместе с тем повысить требования к прогнозированию, поскольку при этом придется также прогнозировать значения новых переменных. Поэтому обычно исследователи стараются найти "самодостаточное" множество переменных, а это фактически означает, что прежде всего они стремятся понять "физику" моделируемого процесса. Очевидно, что требования к точному моделированию процесса можно ослабить, если есть возможность ввести новые результаты восприятия (например, результаты измерения температуры и атмосферного давления), которые непосредственно предоставляют информацию о новых переменных состояния.

Рассмотрим, например, задачу слежения за роботом, блуждающим случайным образом на плоскости $X-Y$. Можно было бы предложить, что достаточно воспользоваться таким множеством переменных состояния, как положение и скорость, — ведь для вычисления нового положения можно просто использовать законы Ньютона, а скорость будет изменяться непредсказуемо. Но если робот получает питание электрической энергией от аккумулятора, то разрядка аккумулятора будет оказывать систематическое влияние на изменение скорости. А поскольку само это влияние зависит от того, сколько электроэнергии было израсходовано во всех предыдущих маневрах, то свойство принадлежности марковской цепи к модели определенного порядка (или просто марковость) нарушается. Марковость цепи можно восстановить, включив уровень зарядки аккумулятора $Battery_t$ в состав переменных состояния, которые входят в множество x_t . Это позволит лучше предсказывать движения робота, но, в свою очередь, потребует создания модели для предсказания значе-

ния $Battery_t$ на основании значения $Battery_{t-1}$ и скорости. В некоторых случаях такое моделирование может быть выполнено достаточно надежно, а повышения точности можно будет добиться, введя для измерения уровня заряда аккумулятора новый датчик.

15.2. Вероятностный вывод во временных моделях После определения структуры универсальной временной модели мы получаем возможность сформулировать

основные задачи вероятностного вывода, которые должны быть решены с помощью этой модели, как описано ниже.

- $\wedge$ Фильтрация, или $\wedge$ текущий контроль. В этом состоит задача вычисления $\wedge$ доверительного состояния — распределения апостериорных вероятностей переменных, относящихся к текущему состоянию, при наличии всех полученных к данному моменту свидетельств. Это означает, что требуется вычислить значение $p(X_t | e_{1:t})$, при условии, что фактические свидетельства поступают в виде непрерывного потока, начиная со времени $t=1$. В примере с зонтиком это может означать вычисление вероятности дождя сегодня, если даны все результаты наблюдений о носителе зонтика, полученные до сих пор.

А фильтрацией называется та операция, которую должен выполнять рациональный агент в ходе слежения за текущим состоянием так, чтобы иметь возможность принимать рациональные решения (см. главу 17). Как оказалось, почти идентичные расчеты должны осуществляться в процессе определения правдоподобия последовательности свидетельств, $P(e_{1:t})$.

- $\wedge$ Предсказание. В этом состоит задача вычисления распределения апостериорных вероятностей значений переменных в будущем состоянии, если даны все свидетельства, полученные к данному моменту. Это означает, что может потребоваться вычислить $P(x_{t+k} | e_{1:t})$ для некоторого $k > 0$. В примере с зонтиком такое вычисление может сводиться к определению вероятности дождя через три дня от нынешнего, если даны все результаты наблюдений за носителем зонтика, полученные до сих пор. Предсказание является полезным для оценки возможных стратегий.
- $\wedge$ Сглаживание, или $\wedge$ ретроспективный анализ. В этом состоит задача вычисления распределения апостериорных вероятностей значений переменных, относящихся к прошлому состоянию, если даны все свидетельства вплоть до нынешнего состояния. Это означает, что может потребоваться вычислить значение $P(x_k | e_{1:t})$ для некоторого k , такого, что $0 < k < t$. В примере с зонтиком это может означать вероятность того, что дождь шел в прошлую среду, если даны все результаты наблюдений за носителем зонтика, полученные до сих пор. Ретроспективный анализ обеспечивает лучшую оценку информации о состоянии, которая была доступна к тому времени (поскольку включает больше свидетельств).
- Наиболее правдоподобное объяснение. Если дан ряд результатов наблюдений, то может потребоваться найти последовательность состояний, которые с наибольшей вероятностью стали причиной получения результатов

наблюдений. Это означает, что может потребоваться вычислить значение $\arg\max_x P(x_{1:t} | e_{1:t})$. Например, если директор приходил с зонтиком в каждый из первых трех дней, а на четвертый пришел без зонтика, то наиболее вероятным объяснением становится наличие дождя в первые три дня и отсутствие в четвертый. Алгоритмы решения такой задачи являются полезными во многих приложениях, включая распознавание речи (целью которого является поиск наиболее вероятной

последовательности слов, если дан ряд звуков) и реконструкцию цепочек битов, передаваемых по зашумленному каналу.

Кроме этих задач, необходимы методы для создания с помощью обучения моделей перехода и моделей восприятия на основании наблюдений. Так же как и в случае статических байесовских сетей, обучение в динамических байесовских сетях может осуществляться в виде получения побочного результата от вероятностного вывода.

Вероятностный вывод предоставляет оценку того, какие переходы между состояниями фактически происходили и какие состояния привели к получению данных результатов восприятия, а эти оценки могут использоваться для обновления моделей. Обновленные модели предоставляют новые оценки, и в этом процессе происходят итерации до тех пор, пока все вычисления не сходятся. Весь этот процесс представляет собой пример применения алгоритма "ожидания—максимизации", или алгоритма EM (Expectation-Maximization) (см. раздел 20.3). Важно отметить, что для обучения требуется вероятностный вывод с полным сглаживанием, а не с фильтрацией, поскольку он предоставляет лучшие оценки состояний процесса. Обучение с фильтрацией может не позволить добиться правильной сходимости; рассмотрим, например, задачу обучения раскрытию убийств: чтобы узнать из наблюдаемых переменных с помощью вероятностного вывода, что скорее всего произошло на месте убийства, всегда требуется ретроспективный анализ.

Алгоритмы для решения четырех задач вероятностного вывода, перечисленных в начале данного раздела, можно прежде всего описать на общем уровне, независимо от конкретного типа применяемой модели. Усовершенствования этих алгоритмов, относящиеся к каждой модели, будут описаны в соответствующих разделах.

Фильтрация и предсказание Начнем с фильтрации. Мы покажем, что эту задачу можно решить простым рекурсивным способом: если есть результаты фильтрации вплоть до момента t , можно легко вычислить результат для $t+1$ из нового свидетельства e_{t+1} . Это означает, что для некоторой функции f имеет место следующее:

$P(X_{t+i}|e_{1:t+i}) = f(e_{t+i}/P(X_t|e_{1:t}))$ Такой процесс часто называют $\wedge$ рекурсивной оценкой. Соответствующее вычисление может рассматриваться как фактически состоящее из двух частей: прежде всего распределение вероятностей для текущего состояния проектируется вперед от t к $t+1$, затем оно обновляется с использованием нового свидетельства e_{t+1} . Такое двухэтапное протекание процесса можно выразить формально весьма просто:

$P(X_{t+i} | e_{1:t+i}) = P(X_{t+i} | e_{1:t} / e_{t+i})$ (Разделение свидетельства) = $a P(e_{t+i} | X_{t+i}, e_{1:t}) P(X_{t+i} | e_{1:t})$ (Применение правила Байеса) = $a P(e_{t+i} | x_{t+i}) P(X_{t+i} | e_{1:t})$ (Преобразование в соответствии со свойством марковости свидетельства)

Здесь и далее в данной главе a представляет собой нормализующую константу, используемую для того, чтобы вероятности в сумме составляли 1. Второй терм, $P(x_{t+1} | e_{1:t})$, представляет одношаговое предсказание следующего состояния, а первый терм обновляет его новым свидетельством; обратите внимание на то, что значение $P(e_{t+1} | x_{t+1})$ можно получить непосредственно из модели восприятия.

Теперь определим одношаговое предсказание для текущего состояния путем обусловливания вероятностей значений переменных для текущего состояния x_t :

$$P(x_{t+1} | e_{1:t+1}) = a P(e_{t+1} | x_{t+1}) \cdot P(x_{t+1} | x_t, e_{1:t}) P(x_t | e_{1:t}) \quad x_t = a P(e_{t+1} | x_{t+1}) \cdot p(x_{t+1} | x_t) P(x_t | e_{1:t}) \quad x_t \quad (\text{Преобразование в соответствии со свойством марковости}) \quad A5.3)$$

В операциях суммирования первым множителем является модель перехода, а вторым — распределение вероятностей для текущего состояния. Поэтому получена требуемая рекурсивная формулировка. Отфильтрованная оценка $P(x_t | e_{1:t})$ может рассматриваться как "сообщение" $f_{1:t}$, которое распространяется в прямом направлении вдоль последовательности состояний, будучи модифицируемым при каждом переходе и обновляемым при получении каждого нового результата наблюдения.

Этот процесс можно представить следующим образом: $f_{t+1} = \text{os Forward}(f_t, e_{t+1})$ где функция Forward реализует обновление, описанное в уравнении 15.3.

Если все переменные состояния являются дискретными, то затраты времени на каждое обновление остаются постоянными (т.е. независимыми от t) и потребность в пространстве также остается постоянной. (Соответствующие постоянные показатели временной и пространственной сложности, безусловно, зависят от размера пространства состояний и от конкретного типа используемой временной модели.) CF3 Требования ко времени и пространству для обновления должны быть постоянными, если агент с ограниченной памятью обязан следить за распределением вероятностей для текущего состояния на протяжении неограниченной последовательности наблюдений.

Проиллюстрируем процесс фильтрации, состоящий из двух этапов, на простом примере с зонтиком (см. рис. 15.2). Предполагается, что охранник обладает с определенной степенью уверенности сведениями о распределении априорных вероятностей дождя в день 0, непосредственно до того, как началась данная последовательность наблюдений. Предположим, что данным распределением является $P(R_0) = \langle 0.5, 0.5 \rangle$.

Теперь обрабатываем результаты двух наблюдений, как показано ниже. • В день 1 директор пришел с зонтиком, поэтому $ig = \text{true}$. Результаты предсказания перехода от $t=0$ к $t=1$ состоят в следующем:

$$P(r_1) = \sum_i P(i | r_0) P(r_0) \quad r_0 = \langle 0.7, 0.3 \rangle \times 0.5 + \langle 0.3, 0.7 \rangle \times 0.5 = \langle 0.5, 0.5 \rangle$$

а их обновление с помощью свидетельства, полученного для $t = 1$, является таковым: $p(fli|ui) = a p(ui|J?i)P(J?i) = a <0.9, 0.2 \times 0.5, 0.5> = a <0.45/0.1> \ll <0.818, 0.182>$ • В день 2 директор также пришел с зонтиком, поэтому $U2=true$. Результаты предсказания перехода от $t=1$ к $t=2$ являются следующими:

$P(*2|ui) = \int P(J?2|ri)P(n|ui) r1 = <0.7, 0.3> \times 0.818 + <0.3, 0.7> \times 0.182 \ll <0.627, 0.373>$ а обновление их с помощью свидетельства для $t=2$ позволяет получить следующее:

$V(R2 \setminus u1, u2) = a P(u2| \#2) P(B?2|zi) = a <0.9, 0.2 \times 0.627, 0.373> = a <0.565, 0.075> \ll <0.883, 0.117>$ Интуитивно ясно, что вероятность дождя от дня 1 ко дню 2 повышается, поскольку дождь продолжается. В упр. 15.2, а предлагается исследовать такую тенденцию дальше.

Задача предсказания может рассматриваться просто как фильтрация без добавления новых свидетельств. В действительности процесс фильтрации уже включает одношаговое предсказание, и поэтому можно легко вывести следующую формулу рекурсивного вычисления для предсказания состояния в момент времени $t+k+1$ на основании предсказания для $t+k$ \ $P(X_{t+k+1}|e_{1:t}) = \wedge P(X_{t+k+1}|x_{t+k})P(x_{t+k}|e_{1:t})$ A5.4) $x_t + k$ Естественно, что в этом вычислении участвует только модель перехода, а не модель восприятия.

Интересно рассмотреть, что произойдет при попытке предсказывать все дальше и дальше в будущее. Как показано в упр. 15.2, б, прогнозируемое распределение для дождя сходится к фиксированной точке $<0.5, 0.5>$, после чего продолжает оставаться неизменным. Это — так называемое стационарное распределение для марковского процесса, определяемого с помощью модели перехода (см. также с. 1). О свойствах таких распределений и о продолжительности смешивания (грубо говоря, о затратах времени, необходимых для достижения фиксированной точки) известно очень многое. С точки зрения практики эти знания сводятся к печальному выводу, что любая попытка предсказать фактическое состояние для количества этапов, составляющего не больше чем небольшую часть количества, соответствующего продолжительности смешивания, обречена на неудачу. Чем более неопределенной является модель перехода, тем короче будет продолжительность смешивания и тем более туманным становится будущее.

Рекурсия в прямом направлении может использоваться не только для фильтрации и предсказания, но и для вычисления правдоподобия последовательности свидетельств, $P(e_{1:t})$. Такое значение может оказаться применимым, если потребуется сравнить различные временн/е модели, которые способны вырабатывать одну и ту

же последовательность свидетельств; например, в разделе 15.6 сравниваются различные слова, при произношении которых может создаваться одна и та же последовательность звуков. Для такой рекурсии используется сообщение о

правдоподобия $P(x_t, e_{1:t})$. Несложно показать, что справедливо следующее соотношение: $P(x_t, e_{1:t}) = \text{Forward}(P(x_t, e_{1:t}))$. После вычисления $P(x_t, e_{1:t})$ получим фактическое значение правдоподобия, исключая путем суммирования значение x_t :

$P(x_t, e_{1:t}) = P(e_{1:t}) = \sum_{x_t} P(x_t, e_{1:t})$ A5.5) Сглаживание Как было указано выше, сглаживание — это процесс вычисления распределения вероятностей значений переменных в прошлых состояниях при наличии свидетельств вплоть до нынешнего состояния, иными словами, $P(x_k | e_{1:t})$ для $k < t$ (рис. 15.3.) Такие вычисления наиболее удобно разбить на две части: применительно к свидетельствам вплоть до момента времени k и к свидетельствам от $k+1$ до t :

$P(x_k | e_{1:t}) = P(x_k | e_{1:k}, e_{k+1:t}) = P(x_k | e_{1:k}) P(e_{k+1:t} | x_k | e_{1:k})$ (Применение правила Байеса) $= P(x_k | e_{1:k}) P(e_{k+1:t} | x_k)$ (Применение правила условной независимости) $= \alpha f_{1:k} b_{k+1:t}$ A5.6) где используется сообщение $b_{k+1:t} = P(e_{k+1:t} | x_k)$, определяемое как "обратное", по аналогии с прямым сообщением $f_{1:k}$. Прямое сообщение $f_{1:k}$ может быть вычислено путем фильтрации в прямом направлении от 1 до k в соответствии с уравнением 15.3. Как оказалось, обратное сообщение $b_{k+1:t}$ может быть вычислено с помощью рекурсивного процесса, который осуществляется в обратном направлении от t :

$P(e_{k+1:t} | x_k) = \sum_{x_{k+1}} P(e_{k+1:t} | x_k, x_{k+1}) P(x_{k+1} | x_k)$ (Обусловливание по x_{k+1}) $= \sum_{x_{k+1}} P(e_{k+1:t} | x_{k+1}) P(x_{k+1} | x_k)$ (Применение правила условной независимости) $= \sum_{x_{k+1}} P(e_{k+1:t}, e_{k+2:t} | x_{k+1}) P(x_{k+1} | x_k)$ A5.7) $= \sum_{x_{k+1}} P(e_{k+1:t} | x_{k+1}) P(e_{k+2:t} | x_{k+1}) P(x_{k+1} | x_k)$

где последний этап преобразования следует из свойства условной независимости e_{k+1} и $e_{k+2:t}$, если дано x_{k+1} . Из трех множителей в этой операции суммирования первый и третий можно получить непосредственно с помощью модели, а второй представляет собой "рекурсивный вызов". С использованием обозначения для сообщений получим следующее: $b_{k+1:t} = \text{Backward}(b_{k+2:t} | e_{k+1:t})$ где функция Backward осуществляет обновление, описанное в уравнении 15.7. Как и при рекурсии в прямом направлении, время и пространство, требуемые для каждого обновления, являются постоянными и поэтому независимыми от t .

Рис. 15.3. Процесс сглаживания, в котором вычисляется $P(x_k | e_{1:t})$, распределение апостериорных вероятностей значений переменных в состоянии, наблюдавшемся в какой-то прошлый момент времени k , если дана полная последовательность наблюдений от 1 до t . Теперь становится вполне очевидно, что оба термина, приведенные в уравнении 15.6, можно вычислить с помощью рекурсий по времени, одна из которых проходит в прямом направлении от 1 до k и в которой используется уравнение фильтрации 15.3, а другая проходит в обратном направлении от t до $k+1$ и в ней используется уравнение 15.7. Следует отметить, что этап обратной рекурсии инициализируется с помощью выражения $b_{t+1:t} = P(e_{t+1:t} | x_t) = 1$, где 1 — вектор из

единиц (поскольку $e_{t+1:t}$ — пустая последовательность, вероятность наблюдения равна 1).

Итак, применим этот алгоритм к примеру с зонтиком и вычислим сглаженную оценку вероятности дождя в момент времени $t=1$ по данным наблюдений за появлением директора с зонтиком в дни 1 и 2. Согласно уравнению 15.6, это значение определяется следующим образом:

$P(u_1|u_{1:2}) = \alpha P(u_1|u_2) P(u_2|t_{f1})$ A5.8) Как нам уже известно, первый терм равен $\langle 0.818, 0.182 \rangle$, согласно результатам применения процесса прямой фильтрации, описанного выше. Второй терм можно вычислить, применив обратную рекурсию по уравнению 15.7:

$P(u_2|R_1) = \frac{1}{Z} P(u_2|R_2) P(R_2) P(R_2|J_1) = \frac{0.9 \times 1 \times \langle 0.7, 0.3 \rangle \times \langle 0.69, 0.41 \rangle + 0.2 \times 1 \times \langle 0.3, 0.7 \rangle}{0.883} = \langle 0.69, 0.41 \rangle$ Подставляя эти значения в уравнение 15.8, можно найти, что сглаженная оценка вероятности дождя в день 1 такова:

$P(K_1|u_{1:2}) = \text{OC} \langle 0.818, 0.182 \rangle \times \langle 0.69, 0.41 \rangle = \langle 0.883, 0.117 \rangle$

Таким образом, в данном случае сглаженная оценка выше, чем отфильтрованная оценка $\langle 0.818 \rangle$. Это связано с тем, что появление директора с зонтиком в день 2 повышает вероятность того, что в день 2 шел дождь; в свою очередь, поскольку дожди обычно являются затяжными, это приводит к повышению вероятности дождя и в день 1.

И для прямой, и для обратной рекурсии требуется постоянное количество времени в расчете на каждый этап; поэтому временная сложность сглаживания по отношению к свидетельству $e_{1:t}$ составляет $O(t)$. Этим выражением определяется также сложность сглаживания в конкретном интервале времени k . А если требуется провести сглаживание всей последовательности, то один из очевидных методов состоит в выполнении всего процесса сглаживания по одному разу для каждого интервала времени, в котором должно быть выполнено сглаживание. Такой подход приводит к получению временной сложности $O(t^2)$. Но в лучшем подходе можно было бы использовать очень простое приложение динамического программирования, чтобы свести сложность к величине $O(t)$. Один из намеков на то, как это сделать, можно найти в приведенном выше анализе примера с зонтиком, где была показана возможность повторного использования результатов прямой фильтрации. Ключом к созданию алгоритма с линейными затратами времени является регистрация результатов прямой фильтрации по всей последовательности. В таком случае можно выполнить обратную рекурсию от t вплоть до 1, вычисляя сглаженную оценку для каждого этапа k из вычисленного обратного сообщения $b_{k+1:t}$ и хранимого прямого сообщения $f_{1:k}$. Этот алгоритм, обоснованно названный $\wedge$ прямым—обратным алгоритмом (forward—backward algorithm), показан в листинге 15.1.

Листинг 15.1. Прямой—обратный алгоритм для вычисления апостериорных вероятностей последовательности состояний при наличии последовательности наблюдений. Операторы Forward и Backward определены в уравнениях 15.3 и 15.7

```
function Forward-Backward(ev,prior) returns вектор распределений вероятностей
inputs: ev, вектор значений свидетельств для этапов 1,...,t prior, распределение
априорных вероятностей в начальном состоянии, P(X0) local variables: fv, вектор
прямых сообщений для этапов 0,...,t b, представление обратного сообщения,
первоначально состоящее из одних единиц, 1 sv, вектор сглаженных оценок для
этапов 1,...,t
fv[0] ← prior
for i=1 to t do fv[i] ← Forward(fv[i-1],ev[i])
for i=t downto 1 do sv[i] ← Normalize (fv[i]xb)
b ← Backward (b, ev[i] )
return sv
```

Внимательный читатель должен был заметить, что структура байесовской сети, показанной на рис. 15.3, представляет собой полидерево, согласно терминологии главы 14. Это означает, что непосредственное применение алгоритма кластеризации также приводит к созданию алгоритма с линейными затратами времени, который

вычисляет сглаженные оценки для всей последовательности. Итак, вполне понятно, что прямой—обратный алгоритм фактически представляет собой частный случай алгоритма распространения в полидереве, используемого в сочетании с методами кластеризации (хотя эти два алгоритма были разработаны независимо).

Прямой—обратный алгоритм лежит в основе вычислительных методов, применяемых во многих таких приложениях, где приходится иметь дело с последовательностями зашумленных результатов наблюдений, начиная от распознавания речи и заканчивая слежением за самолетами с помощью радара. Как было описано выше, с точки зрения практики он имеет два недостатка. Первым из них является пространственная сложность, которая может оказаться слишком высокой применительно к приложениям, где пространство состояний велико, а последовательности имеют большую длину. В нем используется пространство $O(|f|t)$, где $|f|$ — размер представления прямого сообщения. Такую потребность в пространстве можно уменьшить до $O(|f| \log t)$ с помощью соответствующего увеличения временной сложности на коэффициент $\log t$, как показано в упр. 15.3. В некоторых случаях (см. раздел 15.3) может использоваться алгоритм с постоянными потребностями в пространстве, но без лишних затрат времени.

Вторым недостатком этого несложного алгоритма является то, что он требует модификации для использования в оперативных приложениях, где сглаженные оценки должны вычисляться для более ранних временных срезов по мере того, как к концу последовательности непрерывно добавляются новые наблюдения. Наиболее часто возникает требование по обеспечению $\wedge$ сглаживания с постоянным запаздыванием, при котором необходимо вычислять сглаженную оценку $P(X_{t-d} | e_{1:t})$ для постоянного значения d . Это означает, что сглаживание выполняется для временного среза, отстоящего на d этапов от текущего времени t ;

по мере возрастания t сглаживание не должно отставать. Безусловно, что прямой— обратный алгоритм можно вызывать на выполнение применительно к данным d -этапного "окна" по мере добавления результатов каждого нового наблюдения, но такой подход, по-видимому, является неэффективным. В разделе 15.3 будет показано, что сглаживание с постоянным запаздыванием в некоторых случаях может выполняться за постоянное время в расчете на каждое обновление, независимо от запаздывания d .

Поиск наиболее вероятной последовательности Предположим, что [true, true, false, true, true] — последовательность истинностных значений с результатами наблюдений за появлением директора с зонтиком, которые проводил охранник в течение первых пяти дней своей работы. Какая последовательность состояний погоды может стать наиболее вероятным объяснением для этих данных? Означает ли отсутствие зонтика в день 3, что не было дождя или директор забыл его взять? А если в день 3 не было дождя, то, возможно, дождь не шел и в день 4 (поскольку погода обычно является устойчивой), однако директор захватил с собой зонтик просто на всякий случай. В целом существуют 25 возможных последовательностей состояний погоды, которые могут быть приняты в качестве объяснения. Но есть ли способ найти наиболее вероятную из этих последовательностей, не перебирая их все?

Один из подходов, который может быть опробован, состоит в использовании следующей процедуры с линейными затратами времени: с помощью алгоритма

сглаживания найти распределения апостериорных вероятностей погоды на каждом временном интервале; после этого составить последовательность, используя на каждом этапе наиболее вероятное состояние погоды, соответствующее этим апостериорным вероятностям. Но такой подход должен вызвать у читателя сомнения, поскольку апостериорные вероятности, вычисленные с помощью сглаживания, представляют собой распределения вероятностей для отдельных временных интервалов, тогда как, чтобы найти наиболее вероятную последовательность, необходимо рассматривать совместные вероятности по всем временным интервалам. Соответствующие результаты фактически могут оказаться довольно различными (см. упр. 15.4).

Тем не менее алгоритм поиска наиболее вероятной последовательности с линейными затратами времени существует, но чтобы его найти, необходимо продумать все обстоятельства немного более тщательно. Алгоритм должен быть основан на том же свойстве марковости (неизменности порядка марковской цепи), которое позволило создать эффективные алгоритмы фильтрации и сглаживания. Проще всего можно подойти к решению этой задачи, рассматривая каждую последовательность как путь в графе, узлами которого являются возможные состояния на каждом временном интервале. Такой граф показан для мира задачи с

зонтиком на рис. 15.4, а. Теперь рассмотрим задачу поиска наиболее вероятного пути через этот граф, где значение правдоподобия любого пути представляет собой произведение вероятностей перехода вдоль этого пути и вероятностей конкретных наблюдений в каждом состоянии.

В частности, сосредоточимся на тех путях, которые достигают состояния $Rain_5 = \text{true}$. Ввиду наличия свойства марковости можно прийти к заключению, что наиболее вероятный путь к состоянию $Rain_5 = \text{true}$ состоит из наиболее вероятного пути к некоторому состоянию, достигнутому во время 4, за которым следует переход в состояние $Rain_5 = \text{true}$, а состоянием во время 4, которое станет частью пути к состоянию $Rain_5 = \text{true}$, является именно то состояние, которое максимизирует значение правдоподобия этого пути. Иными словами, $\exists$ существует рекурсивная связь между наиболее вероятными путями в каждое состояние x_{t+1} и наиболее вероятными путями в каждое состояние x_t . Эту связь можно записать в виде уравнения, соединяющего вероятности путей, следующим образом: $\max_{x_1, \dots, x_t} P(x_1, \dots, x_t, x_{t+1} | e_{1:t+1}) = P(e_{t+1} | x_{t+1}) \max_{x_t} P(x_{t+1} | x_t) \max_{x_1, \dots, x_{t-1}} P(x_1, \dots, x_{t-1}, x_t | e_{1:t})$ (15.9) Уравнение 15.9 идентично уравнению фильтрации 15.3, за исключением описанных ниже отличий.

1. Прямое сообщение $f_{1:t} = P(x_t | e_{1:t})$ заменяется следующим сообщением, т.е. вероятностями наиболее правдоподобного пути в каждое состояние x_t : $m_{1:t} = \max_{x_1, \dots, x_t} P(x_1, \dots, x_t | e_{1:t})$ 2. Суммирование по переменным x_t в уравнении 15.3 заменяется максимизацией по переменным x_t в уравнении 15.9.

Таким образом, алгоритм вычисления наиболее вероятной последовательности аналогичен алгоритму фильтрации: он проходит в прямом направлении вдоль последовательности, вычисляя сообщение m на каждом временном интервале с помощью уравнения 15.9. Ход этих вычислений показан на рис. 15.4, б. В конечном итоге этот алгоритм позволяет получить вероятность наиболее правдоподобной последовательности, достигающей каждого из заключительных состояний. Поэтому с его помощью можно легко выбрать последовательность, которая является наиболее правдоподобной среди всех прочих (соответствующие ей состояния обозначены на рисунке жирными контурами). Для того чтобы иметь возможность определить фактически наблюдаемую последовательность, а не просто вычислить ее вероятность, в этом алгоритме необходимо также сопровождать указатели от каждого состояния обратно к наилучшему состоянию, приведшему к нему (эти указатели показаны на рисунке жирными стрелками); соответствующую последовательность можно найти, проследовав по указателям в обратном направлении от наилучшего заключительного состояния.

Rairi\ Rain^ Rain* RairiA Rain* true false true false true false Umbrellat true false . 4 0,8182 0,5155 0,1818 0,0491 0,0361 0,1237 true false true J 0,0334 0,0173 P Й true false true

0,0210 1 0,0024 Рис. 15.4. Пример применения алгоритма Витерби: возможные последовательности состояний для переменной Raint могут рассматриваться как пути через граф возможных состояний на каждом временном интервале (состояния обозначены прямоугольниками для предотвращения путаницы с узлами в байесовской сети) (а); результаты применения алгоритма Витерби к последовательности наблюдений за появлением директора с зонтиком, /"true, true, false, true, true7 (б). Для каждого значения t показано значение сообщения $m1:t$, которое представляет собой вероятность наилучшей последовательности, достигающей каждого состояния во время t . Кроме того, для каждого состояния ведущая в него жирная стрелка показывает его наилучшего преемника, согласно оценке, представляющей собой произведение вероятности предшествующей последовательности и вероятности перехода. Наиболее вероятную последовательность можно определить, проходя по жирным стрелкам в обратном направлении от наиболее вероятного состояния в интервале времени Шг: 5 Только что описанный алгоритм называется $\wedge$ алгоритмом Витерби в честь его разработчика. Временная сложность этого алгоритма, как и алгоритма фильтрации, линейно зависит от t , от длины последовательности. Но в отличие от алгоритма фильтрации его потребность в пространстве также линейно зависит от t . Это связано с тем, что в алгоритме Витерби необходимо следить за указателями, которые обозначают наилучшую последовательность, ведущую к каждому состоянию.

15.3. Скрытые марковские модели В предыдущем разделе были разработаны алгоритмы формирования временных вероятностных рассуждений с использованием общей инфраструктуры, которая была независимой от конкретной формы моделей перехода и моделей восприятия.

В этом и следующих двух разделах будут описаны более конкретные модели и приложения, которые иллюстрируют мощь этих простых алгоритмов, а в некоторых случаях допускают дополнительные усовершенствования.

Начнем с описания $\wedge$ скрытой марковской модели, или сокращенно HMM (Hidden Markov Model). Любая модель HMM — это временная вероятностная модель, в которой состояние процесса описано с помощью единственной дискретной случайной переменной. Возможными значениями этой переменной являются возможные состояния мира. Поэтому пример с зонтиком, описанный в предыдущем разделе, представляет собой одну из моделей HMM, поскольку в нем применяется лишь единственная переменная состояния, Raint. Во временную модель могут быть введены дополнительные переменные состояния без выхода за пределы инфраструктуры HMM, но только путем комбинирования всех переменных состояния в единственную "мегапеременную", значениями которой являются все возможные кортежи значений отдельных переменных состояния. В данном разделе будет показано, что благодаря такой жестко регламентированной структуре

моделей НММ появляется возможность создавать очень простые и элегантные матричные реализации всех основных алгоритмов³. В разделе 15.6 показано, как модели НММ используются для распознавания речи.

Упрощенные матричные алгоритмы При использовании единственной, дискретной переменной состояния x_t можно определить более сжатую форму представлений модели перехода, модели восприятия, а также прямых и обратных сообщений. Предположим, что переменная состояния x_t имеет значения, обозначенные целыми числами $1, \dots, S$, где S — количество возможных состояний. В таком случае модель перехода $P(x_t | x_{t-1})$ преобразуется в матрицу T с размерами $S \times S$, где $T_{ij} = P(x_t = j | x_{t-1} = i)$. Таким образом, T^i представляет собой вероятность перехода из состояния i в состояние j . Например, матрица перехода для мира задачи с зонтиком выглядит следующим образом:

0.7 0.3 $T = P(x_t | x_{t-1}) = \begin{pmatrix} 0.3 & 0.7 \end{pmatrix}$ Переведем также в матричную форму модель восприятия. В данном случае, поскольку известно, что значение переменной свидетельства E_t равно, скажем, e_t , необходимо использовать только ту часть модели, в которой определена вероятность появления значения e_t . Для каждого временного интервала t мы составим диагональную матрицу O_t , диагональные элементы которой задаются значениями 3 Читателю, не знакомому с основными операциями над векторами и матрицами, может потребоваться обратиться к приложению А, прежде чем продолжать чтение данного раздела.

$P\{e_t | x_t = i\}$, а остальные элементы равны 0. Например, в мире задачи с зонтиком в день 1 было получено значение $untrue$, поэтому, согласно рис. 15.2, имеет место следующее:

0.9 0 $\alpha^i = \begin{pmatrix} 0 & 0.2 \end{pmatrix}$ Теперь, если для представления прямых и обратных сообщений будут использоваться векторы столбцов, то все вычисления преобразуются в простые матрично-векторные операции. Прямое уравнение 15.3 принимает следующий вид: $f_t^T + l = O_t^T \alpha + l$ $T f_t^T A5.10$) а обратное уравнение 15.7 становится следующим: $b_j^T + i_t = T O_k + l$ $b_k + 2:t A5.11$) Как показывают эти уравнения, временная сложность прямого—обратного алгоритма (см. листинг 15.1), применяемого к последовательности с длиной t , равна $O(S^2t)$, поскольку на каждом этапе требуется умножить вектор с S элементами на матрицу $S \times S$. Потребность в пространстве измеряется величиной $O(S^2t)$, так как при проходе в прямом направлении необходимо сохранить в памяти t векторов с размером S .

Такая матричная формулировка не только становится изящным описанием алгоритмов фильтрации и сглаживания для моделей НММ, но и открывает возможности для создания улучшенных алгоритмов. Первым из таких алгоритмов является простой вариант прямого—обратного алгоритма, который обеспечивает выполнение сглаживания за счет использования постоянного пространства,

независимо от длины последовательности. Идея этого алгоритма состоит в том, что для выполнения сглаживания в любом конкретном временном срезе требуется одновременное присутствие в памяти и прямого, и обратного сообщений, $f_{1:k}$ и $b_{k+1:t}$, согласно уравнению 15.6. В прямом—обратном алгоритме это достигается за счет хранения значений f , вычисленных во время прохода в прямом направлении, для того, чтобы они были доступными во время прохода в обратном направлении. Еще один способ достижения этой цели состоит в использовании одного прохода, в котором и значение f , и значение b распространяются в одном и том же направлении. Например, можно добиться распространения "прямого" сообщения f в обратном направлении, преобразовав уравнение 15.10 таким образом, чтобы оно действовало в другом направлении, как показано ниже. $f_{l:t} = O_f(TV_1 \circ \Gamma_1 f_{l:t} + I$ Этот модифицированный алгоритм сглаживания действует так, что в нем вначале осуществляется стандартный проход в прямом направлении для вычисления значения $f_{t:t}$ (при этом все промежуточные результаты уничтожаются), после чего выполняется проход в обратном направлении для совместного вычисления и b , и f , а затем эти значения используются для вычисления сглаженной оценки для каждого интервала.

Поскольку требуется только одна копия каждого сообщения, потребности в памяти являются постоянными (т.е. независимыми от t , длины последовательности). Тем не менее этот алгоритм имеет одно существенное ограничение — в нем требуется, чтобы матрица перехода была обратимой, а модель восприятия не имела нулей, иными словами, чтобы каждое наблюдение было возможным в любом состоянии.

Матричная формулировка открывает возможности усовершенствования еще в одном направлении — в области создания методов оперативного сглаживания с постоянным запаздыванием. Тот факт, что сглаживание может быть выполнено за счет постоянных затрат пространства, наводит на мысль, что может существовать эффективный рекурсивный алгоритм для оперативного сглаживания, т.е. алгоритм, временная сложность которого остается независимой от величины запаздывания.

Предположим, что запаздывание равно d ; это означает, что сглаживание проводится во временном срезе f_{t-d} , притом что текущее время равно t . Согласно уравнению 15.6, для среза $t-d$ необходимо рассчитать значение следующего выражения:

$O_S f_{l:t-d} b_{t-d+1:t}$ В таком случае после поступления новых результатов наблюдения необходимо будет вычислить следующее выражение для среза $t-d+1$:

$O_S f_{l:t-d+1} b_{t-d+2:t} + I$ Как можно выполнить эту операцию инкрементно? Прежде всего, можно вычислить $f_{i:t-d+i}$ из $f_{i:t-d}$ с использованием стандартного процесса фильтрации, в соответствии с уравнением 15.3.

Инкрементное вычисление обратного сообщения является более сложным, поскольку не существует простого соотношения между старым обратным сообщением $bt_{d+i:t}$ и новым обратным сообщением $bt_{d+2:t+i}$. Вместо этого рассмотрим соотношение между старым обратным сообщением $bt_{d+1:t}$ и обратным сообщением в начале последовательности, $bt_{+1:t}$. Для этого `draw` применим уравнение 15.11, чтобы получить следующее уравнение:

$(t \text{ Л } bt_{-d+1:t} \text{ riTOi } Vi=t-d+1 \text{ J } bt_{+1:t} = Bt_{-d+1:t} \text{ 1 A5.12})$ где матрица $Bt_{d+1:t}$ является произведением последовательности матриц O и t .

Матрицу v можно рассматривать как "оператор преобразования", который преобразует более позднее обратное сообщение в более раннее. Аналогичное уравнение остается справедливым для новых обратных сообщений, сформированных после поступления результатов следующего наблюдения:

$(t+i \text{ Л } btd_{+2:t+i} - \text{п } TOi \text{ Vi}=t-d+2 \text{ J } Bt_{-d+2:t} + \text{I } 1 \text{ A5.13})$ Исследуя выражения для произведений в уравнениях 15.12 и 15.13, можно определить, что их связывает между собой простое соотношение, — чтобы получить второе произведение, достаточно "разделить" первое произведение на первый элемент TO_{t-d+1} и умножить на новый последний элемент TO_{t+i} . Поэтому на языке алгебры матриц можно представить следующее простое соотношение между старой и новой матрицами v :

$$Bt_{-d+2:t+i} = Ot_{-d+1} T Bt_{-d+1:t} TO_{t+i} \text{ A5.14}$$

Это уравнение предоставляет способ вычисления инкрементного обновления для матрицы v , которая, в свою очередь (в силу уравнения 15.13), позволяет вычислить новое обратное сообщение $bt_{d+2:t+i}$. Полный алгоритм, в котором предусматривается хранение и обновление значений f и v , показан в листинге 15.2.

Листинг 15.2. Алгоритм сглаживания с постоянным временным запаздыванием на d этапов, реализованный как оперативный алгоритм, который выводит новую сглаженную оценку после получения данных наблюдения, относящихся к новому временному интервалу `function Fixed-Lag-Smoothing (et, hmiri, d) returns` распределение по X_{t-d} `inputs: et/` текущее свидетельство для временного интервала t `hmm,` скрытая марковская модель с матрицей переходов T с размерами 5×5 `d,` величина запаздывания при сглаживании `static: t,` текущее время, первоначально равно 1 `f,` распределение вероятностей (прямое сообщение $P(X_t|e_{1:t})$)# первоначально `Prior[hmm]` `B,` матрица d -этапного обратного преобразования, первоначально матрица идентичного преобразования `?Vd:t/` двухсторонний список свидетельств от $t-d$ до t , первоначально пустой `local variables: Ot-d/Ot/` диагональные матрицы, содержащие информацию модели восприятия `добавить et к концу списка et-d:t` `Ot <—` диагональная матрица, содержащая $P(et|X_t)$ `if fc>d then f <— Forward (f, et)` удалить $et-d-i$ с начала списка `et-d:t` `Ot-d <—` диагональная матрица, содержащая

$P(\text{et-d} \mid -X_t\text{-d}) \quad B \leftarrow O_t\text{-d}_1 T_1 B T O_t \text{ else } B \leftarrow B T O_t \quad t \leftarrow t+1 \text{ if } f_c > d \text{ then return}$
 $\text{Normalize}(f_x B I) \text{ else return пустое значение}$

15.4. Фильтры Калмана Представьте себе, что вы внимательно следите за маленькой птицей, летящей через плотную листву джунглей в сумраке: вы замечаете краткие промежуточные этапы движения и пытаетесь угадать, где сейчас находится птица и где она появится в следующий раз, чтобы ее не потерять. Или вообразите себя на месте оператора радара во Второй мировой войне, который напряженно вглядывается в крошечный, блуждающий блик, появляющийся на экране через каждые 10 секунд. А если вернуться в прошлое еще дальше, вообразите, что вы, как Кеплер, пытаетесь реконструировать орбиты движения планет из совокупности крайне неточных угловых измерений, полученных через нерегулярные и неточно измеренные интервалы времени. Во всех этих случаях осуществляется попытка оценить показатели состояния физической системы (например, положение и скорость) на основе зашумленных результатов на-

блюдений во времени. Эту задачу можно сформулировать как вероятностный логический вывод во временной вероятностной модели, где модель перехода описывает физические основы движения, а модель восприятия описывает процесс измерения.

В данном разделе рассматриваются специальные формы представления и алгоритмы вероятностного вывода, которые были разработаны для решения задач такого рода; описанный здесь метод называется [^] калмановской фильтрацией в честь его разработчика Рудольфа Э. Калмана.

Очевидно, что для определения состояния этой системы требуется несколько непрерывных переменных. Например, траектория полета птицы может быть задана с помощью данных о положении (x, Y, Z) и скорости $(\dot{x}, \dot{Y}, \dot{Z})$ в каждый момент времени. Необходимо также иметь соответствующие плотности условных вероятностей для представления модели перехода и модели восприятия; как и в главе 14, в данной главе будут использоваться линейные гауссовы распределения. Это означает, что следующее состояние x_{t+1} должно представлять собой линейную функцию от текущего состояния X_t с добавлением какого-то гауссова шума, а такое предположение, как оказалось, является весьма оправданным на практике. Рассмотрим, например, координату X птицы, игнорируя на данный момент все другие координаты. Допустим, что интервал между наблюдениями равен A , и предположим, что птица летит с постоянной скоростью; в таком случае данные об обновлении ее положения определяются с помощью следующего уравнения:

$$X_{t+A} = X_t + X \cdot A$$
 Если мы введем в него гауссов шум, то получим линейную гауссову модель перехода: $p(x_{t+A} = x_t + A \mid X_t = x_t, f_t = x_t) = \mathcal{N}(x_{t+A} \mid x_t + A, \sigma^2)$ Структура байесовской сети для системы с переменными, описывающими положение X_t и скорость $\dot{X}_t$, показана на рис. 15.5. Обратите внимание на то, что это — весьма специфичная форма линейной гауссовой модели; общая форма этой модели будет

описана ниже в этом разделе; она охватывает колоссальный спектр приложений, выходящий за пределы простых примеров моделирования движений, приведенных в первом абзаце данного раздела. Читателю может потребоваться обратиться к приложению А для ознакомления с некоторыми математическими свойствами гауссовых распределений; для наших непосредственных целей наиболее важным из них является то, что $\hat{\cdot}$ многомерное гауссово распределение для d переменных задается d -элементным средним $\bar{x}$ и матрицей ковариации X с размерами $d \times d$.

Обновление гауссовых распределений В главе 14 было описано ключевое свойство семейства линейных гауссовых распределений: при стандартных операциях в байесовской сети оно остается замкнутым. В этом разделе данное утверждение будет уточнено в контексте фильтрации с помощью временной вероятностной модели. Ниже перечислены требуемые свойства, соответствующие процессу двухэтапного вычисления результатов фильтрации с помощью уравнения 15.3.

1. Если текущее распределение $P(x_t | e_{1:t})$ является гауссовым, а модель перехода $P(x_{t+1}|x_t)$ — линейной гауссовой, то распределение, прогнозируемое

на один этап вперед, которое задается с помощью следующего уравнения, также представляет собой гауссово распределение:

$P(x_{t+1}|e_{1:t}) = \int P(x_{t+1}|x_t)P(x_t|e_{1:t}) dx_t$ A5.15) © © Рис. 15.5. Структура байесовской сети для линейной динамической системы с переменными, определяющими положение x_t , скорость $\dot{x}_t$ и результаты измерения позиции z_t 2. Если прогнозируемое распределение $P(x_{t+1} | e_{1:t})$ является гауссовым, а модель восприятия $P(e_{t+1} | x_{t+1})$ — линейной гауссовой, то после обусловливания вероятности на основании нового свидетельства следующее обновленное распределение также является гауссовым:

$P(x_{t+1}|e_{1:t+1}) = \int P(e_{t+1}|x_{t+1}) P(x_{t+1}|e_{1:t}) dx_{t+1}$ A5.16) Таким образом, оператор Forward для калмановской фильтрации принимает на входе гауссово прямое сообщение $f_{1:t}$, заданное с помощью среднего $\bar{x}_t$ и матрицы ковариации Z_t , и вырабатывает новое многомерное гауссово прямое сообщение $f_{1:t+1}$, заданное с помощью среднего $\bar{x}_{t+1}$ и матрицы ковариации Z_{t+1} . Итак, начиная с гауссова априорного сообщения $f_{1:0} = P(x_0) = N(\bar{x}_0, I, o)$ и проводя фильтрацию с помощью линейной гауссовой модели, мы можем получить гауссово распределение вероятностей состояний для любых временн $\bar{x}$ срезов.

Очевидно, что этот научный результат является привлекательным и изящным, но почему он имеет такое важное значение? Причина этого состоит в том, что за исключением нескольких частных случаев, подобных рассматриваемому, $\hat{\cdot}$ в процессе фильтрации с помощью непрерывных или гибридных (как дискретных, так и непрерывных) сетей вырабатываются распределения вероятностей состояний, размеры представления которых растут во времени без ограничения. Это

утверждение нелегко доказать, но в упр. 15.5 показано, что в простых примерах так и происходит.

Простой одномерный пример Как было указано выше, оператор Forward для фильтра Калмана отображает одно гауссово распределение на другое, новое гауссово распределение. Применение

этого оператора сводится к вычислению новых значений среднего и матрицы ковариации из предыдущих значений среднего и матрицы ковариации. Для вывода правила обновления в общем (многомерном) случае требуется большой объем выкладок в линейной алгебре, поэтому пока остановимся на очень простом одномерном случае, а позже будут даны результаты для общего случая. Но даже в одномерном случае вычисления являются довольно трудоемкими; тем не менее авторы считают, что с ними следует ознакомиться, поскольку применимость фильтра Калмана слишком тесно связана с математическими свойствами гауссовых распределений.

Во временной модели, которая будет здесь рассматриваться, представлено случайное блуждание единственной непрерывной переменной состояния x_t , зарегистрированное с помощью зашумленных результатов наблюдения z_t . Одним из соответствующих примеров может служить показатель "доверия потребителя", который может быть промоделирован как переменная, подвергающаяся каждый месяц случайному изменению с вероятностью, представленной с помощью гауссова распределения, и измеряемая с помощью опроса случайно выбранных потребителей, в котором также вносится гауссов шум формирования выборки. Предполагается, что распределение априорных вероятностей является гауссовым, с дисперсией σ_0^2 :

Ч $P(x_0) = \frac{1}{\sigma_0 \sqrt{2\pi}} \exp\left(-\frac{x_0^2}{2\sigma_0^2}\right)$ (Для упрощения в этом разделе мы будем использовать один и тот же символ σ для обозначения всех констант нормализации.) В модели перехода просто добавляется гауссово возмущение постоянной дисперсии σ^2 к текущему состоянию: $P(x_{t+1}|x_t) = \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(x_{t+1}-x_t)^2}{2\sigma^2}\right)$ Это означает, что в модели восприятия должно быть принято предположение о наличии гауссова шума с дисперсией σ_z^2 : $P(z_t|x_t) = \frac{1}{\sigma_z \sqrt{2\pi}} \exp\left(-\frac{(z_t - h(x_t))^2}{2\sigma_z^2}\right)$ Теперь, после получения распределения априорных вероятностей $P(x_0)$, мы можем вычислить распределение, прогнозируемое на один этап, с помощью уравнения 15.15: $P(x_1) = \int P(x_1|x_0) P(x_0) dx_0 = \int \frac{1}{\sigma \sqrt{2\pi}} \exp\left(-\frac{(x_1-x_0)^2}{2\sigma^2}\right) \frac{1}{\sigma_0 \sqrt{2\pi}} \exp\left(-\frac{x_0^2}{2\sigma_0^2}\right) dx_0$ На первый взгляд этот интеграл кажется довольно сложным. Ключом к его упрощению может стать такое замечание, что экспонента представляет собой сумму двух выражений, которые квадратично зависят от x_0 , и поэтому сама экспонента квадра-

точно зависит от x_0 . Но известно, что любое квадратное уравнение $ax_0^2 + bx_0 + c$ может быть переписано как сумма термина, возведенного в квадрат, $a(x_0 - \mu)^2$ и остаточного термина $c - a\mu^2$. Поэтому остаточный терм может быть вынесен за пределы интеграла, что приводит к получению следующего уравнения:

$M(x) = \int_{-\infty}^{\infty} P(x) dx$ Теперь рассматриваемый интеграл представляет собой обычный интеграл гауссова распределения по всей области его определения, который равен 1. Таким образом, от квадратного уравнения сохраняется лишь его остаточный терм.

Вторым важным этапом является преобразование, выполняемое на основе того наблюдения, что остаточный терм должен иметь квадратичную зависимость от x ; в действительности после его упрощения получаем следующее: $P(x) = \frac{1}{\sigma^2} \exp(-\frac{x^2}{2\sigma^2})$. Таким образом, распределение, прогнозируемое на один этап, представляет собой гауссово распределение с тем же средним μ и дисперсией, равной сумме первоначальной дисперсии σ_0^2 и дисперсии перехода σ^2 . Даже краткие размышления позволяют понять, что такое соотношение интуитивно вполне оправдано.

Для завершения этапа обновления необходимо обусловить вероятность результатами наблюдения на первом временном этапе, а именно z . Согласно уравнению 15.16, такая операция осуществляется с помощью следующего уравнения:

$P(x|z) = \frac{1}{\sigma_z} \exp(-\frac{(x - \mu_z)^2}{2\sigma_z^2})$ Снова объединим экспоненты и дополним квадрат (упр. 15.6), получая следующее:

$P(x|z) = \frac{1}{\sigma_z} \exp(-\frac{(x - \mu_z)^2}{2\sigma_z^2})$ Таким образом, после одного цикла обновления будет получено новое гауссово распределение для переменной состояния.

На основании гауссовой формулы, приведенной в уравнении 15.17, можно определить, что новые значения среднего и среднеквадратичного отклонения можно вычислить на основе старых значений среднего и среднеквадратичного отклонения следующим образом:

$\mu_{t+1} = \mu_t + \frac{\sigma^2}{\sigma_t^2 + \sigma^2} (z - \mu_t)$ На рис. 15.6 показан один цикл обновления для конкретных значений модели перехода и модели восприятия.

Рис. 15.6. Этапы цикла обновления фильтра Калмана для случайного блуждания с априорной вероятностью, заданной параметрами $\mu_0 = 0.0$ и $\sigma_0 = 1.0$, шумом перехода, заданным $\sigma = 2.0$, шумом восприятия, заданным $\sigma_z = 1.0$, и первым результатом наблюдения $z = 2.5$ (это значение показано звездочкой на оси x).

Теперь следует отметить, что под влиянием шума перехода предсказание $P(x_i)$ сглаживается относительно $P(x_{0j})$. Заслуживает также внимания то, что среднее апостериорной вероятности $P(x_i/z_{ij})$ находится немного левее от результата наблюдения z_{ij} поскольку это среднее представляет собой взвешенное среднее от предсказания и наблюдения. Приведенная выше пара уравнений играет точно такую же роль, как и общее уравнение фильтрации, 15.3, или уравнение фильтрации НММ, 15.10. Но в связи с особым характером гауссовых распределений эти уравнения обладают также некоторыми интересными дополнительными свойствами. Во-первых, можно интерпретировать вычисление нового значения среднего $\hat{x}_{t+1}$ как вычисление взвешенного среднего от новых результатов наблюдения z_{t+1} и старого значения среднего $\hat{x}_t$. Если результаты наблюдения являются ненадежными, то значение $\hat{a}_t^2$ увеличивается и мы придаем больший вес старому значению среднего, а если ненадежно старое значение среднего (велико значение $\hat{a}_t^2$) или процесс является в высшей степени непредсказуемым (велико значение $\hat{a}_t^2$), то придаем больший вес результатам наблюдения. Во-вторых, следует отметить, что обновление для дисперсии $\hat{a}_{t+1}^2$ является независимым от результатов наблюдения. Поэтому можно заранее определить путем вычисления, какой должна быть последовательность значений дисперсии.

В-третьих, последовательность значений дисперсии быстро сходится к постоянному значению, которое зависит только от $\hat{a}_0^2$ и $\hat{a}_1^2$, что способствует существенному упрощению дальнейших вычислений (см. упр. 15.7).

Общий случай Приведенные выше результаты анализа иллюстрируют ключевое свойство гауссовых распределений, которое обеспечивает функционирование методов калмановской фильтрации: тот факт, что экспонента находится в квадратичной форме.

Указанное свойство относится не только к одномерному случаю; полное многомерное гауссово распределение имеет следующую форму: $N(\hat{x}, P) = \frac{1}{(2\pi)^n |P|^{1/2}} \exp\left\{-\frac{1}{2}(\hat{x} - \bar{x})^T P^{-1}(\hat{x} - \bar{x})\right\}$ Кроме того, произведение термов в экспоненте ясно показывает, что экспонента также является квадратичной функцией от случайных переменных x_i которые относятся к $\hat{x}$. Как и в одномерном случае, операция обновления фильтрации сохраняет гауссов характер распределения вероятностей состояний.

Вначале определим общую временную модель, применяемую в процедуре калмановской фильтрации. И модель перехода, и модель восприятия позволяют применять линейное преобразование с дополнительным гауссовым шумом. Таким образом, получаем следующее:

$P(x_{t+1}|x_t) = \text{tf}(P x_t, Z x_t) (x_{t+1})$ $P(z_t|x_t) = \text{tf}(H x_t, Z z_t) (z_t)$ A5.19 где F и Z_x — матрицы, описывающие линейную модель перехода и ковариацию шума перехода; H и Z_z — соответствующие матрицы для модели восприятия. Теперь уравнения обновления

для среднего и ковариации в их полном, ужасающе сложном виде становятся таковыми:

$H_{t+1} = F_{jt} + K_{t+1}(z_{t+1} - HF_{jt})$ $2_{t+1} = (I - K_{t+1})(FSt_{t+1} + l_x)$ A5.20) где $K_{t+1} = (FZt_{t+1} + ?x)HT(H(FZt_{t+1} + ?x)HT + ?x)^{-1}$ называется *& калмановской матрицей усиления. Хотите — верьте, хотите — нет, но эти уравнения имеют определенный интуитивный смысл. Например, рассмотрим обновление для оценки значения среднего $|y|$ для некоторого состояния. Терм F_{jnt} представляет собой прогнозируемое состояние в момент времени $t+1$, поэтому HF_{jnt} является прогнозируемым результатом наблюдения. Таким образом, терм $z_{t+1} - HF_{jnt}$ соответствует ошибке в прогнозируемых результатах наблюдений. Это значение умножается на K_{t+1} для корректировки прогнозируемого состояния, поэтому K_{t+1} представляет собой меру того, насколько важными следует считать новые результаты наблюдения применительно к предсказанию. Как и при использовании уравнения 15.18, соблюдается такое свойство, что обновление дисперсии не зависит от результатов наблюдений.

Поэтому последовательность значений Z_t и K_t может быть вычислена в автономном режиме, т.е. фактический объем вычислений, требуемых во время оперативного слежения, становится весьма скромным.

Для иллюстрации этих уравнений в действии мы применили их к задаче слежения за объектом, движущимся на плоскости X-Y. Переменными состояниями являются $x = (X, Y, \dot{X}, \dot{Y})^T$, поэтому $F, 2X, H$ представляют собой матрицы с размерами 4×4 . На рис. 15.7, а показаны истинная траектория, ряд зашумленных результатов

наблюдения и траектория, оцениваемая с помощью калмановской фильтрации, наряду с ковариациями, указанными с помощью контуров единичного среднеквадратичного отклонения. Процесс фильтрации позволяет весьма успешно следить за фактическим перемещением, к тому же, как и предполагалось, дисперсия быстро достигает фиксированной точки.

Двухмерная фильтрация Двухмерное сглаживание Позиция -*- истинная • наблюдаемая —"-- сглаженная 10 12 14 16 18 20 22 24 26 X а) 10 12 14 16 18 20 22 24 26 X б) Рис. 15.7. Примеры применения уравнений фильтрации и сглаживания: результаты калмановской фильтрации для объекта, движущегося по плоскости X—у, которые показывают истинную траекторию (слева направо), ряд зашумленных наблюдений и траекторию, оцениваемую с помощью калмановской фильтрации; дисперсия в оценке позиции показана с помощью овалов (а); результаты калмановского сглаживания для той же последовательности результатов наблюдения (б) Мы можем вывести не только уравнения фильтрации с помощью линейных гауссовых моделей, но и уравнения сглаживания. Результаты сглаживания показаны на рис. 15.7, б. Обратите внимание на то, как резко сокращается дисперсия

в оценке позиции, за исключением концов траектории (объясните, почему), и насколько более гладкой становится оцениваемая траектория.

Области применения калмановской фильтрации. Методы, основанные на использовании фильтров Калмана и их модификаций, применяются в самых различных приложениях. Одним из "классических" приложений является слежение за самолетами и ракетами с помощью радаров. К такому же типу относятся приложения, в которых осуществляется слежение за подводными лодками и наземными транспортными средствами по звуку, а также визуальное слежение за транспортными средствами и людьми. К немного более узким областям применения относится использование фильтров Калмана для реконструкции траектории частиц по фотографиям, сделанным в пузырьковой камере, и океанских течений по данным измерений, выполненных на поверхности океана со спутников.

Но спектр таких приложений далеко выходит за пределы простого отслеживания движений — к ним относится любая система, характеризующаяся непрерывными переменными состояниями и зашумленными результатами измерений. К числу подобных систем относятся целлюлозные фабрики, химические установки, ядерные реакторы, экосистемы растений и национальные экономики.

Тот факт, что калмановская фильтрация может применяться к некоторой системе, не означает, что результаты этого будут действительными или полезными, поскольку используемые при этом допущения (о том, что модели перехода и модели восприятия относятся к типу линейных гауссовых) являются очень строгими. В [^]расширенном фильтре Калмана (Extended Kalman Filter — EKF) предпринимается попытка преодолеть нелинейности моделируемой системы. Система является нелинейной, если ее модель перехода нельзя описать с помощью матричного умножения векторов состояния, как в уравнении 15.19. Фильтр EKF действует посредством моделирования системы как локально линейной в области $x_t = jnt$, т.е. в той области, где переменные x_t равны среднему текущему распределению вероятностей состояний. Этот фильтр хорошо действует применительно к гладким системам с устойчивым поведением и позволяет программе слежения сопровождать и обновлять гауссово распределение вероятностей состояния, которое является приемлемой аппроксимацией истинной апостериорной вероятности.

А что подразумевается под системой, которая "не является гладкой" или "поведение которой неустойчиво"? Формально под этим подразумевается, что отклик системы в области, "близкой" (согласно ковариации S_t) к текущему среднему jnt , показывает существенную нелинейность. Чтобы понять суть этого описания неформально, рассмотрим пример слежения за птицей, которая летит через джунгли.

Иногда создается впечатление, что птица направляется на высокой скорости прямо на ствол дерева. Фильтр Калмана (обычный или расширенный) позволяет получить только гауссово предсказание местонахождения птицы, притом что среднее соответствующего гауссова распределения будет находиться напротив центра ствола, как показано на рис. 15.8, а. Но более приемлемая модель полета птицы, с другой стороны, должна предсказывать ее действия по уклонению от удара об ствол путем поворота в одну сторону или в другую, как показано на рис. 15.8, б. Такая модель является в высшей степени нелинейной, поскольку птица принимает решение по уклонению от удара внезапно, в зависимости от того, где именно она находится по отношению к стволу.

Очевидно, что для работы с примерами, подобными этому, требуется более выразительный язык представления поведения моделируемой системы. В сообществе специалистов по теории управления, для которых в таких задачах, как маневры самолета по предотвращению столкновения, возникают аналогичные сложности, разработан стандартный подход — $\wedge$ переключательные фильтры Калмана. В этом подходе предусмотрена одновременная эксплуатация нескольких фильтров Калмана, в каждом из которых используются разные модели систем, например, в одном из них моделируется прямой полет, в другом — резкий поворот налево, а в третьем — резкий поворот направо. При этом используется взвешенная сумма предсказаний, где вес зависит от того, насколько полно данные каждого фильтра совпадают с текущими данными. Как показано в следующем разделе, такой подход представляет собой частный случай общей модели динамической байесовской сети, созданной путем введения дискретной переменной состояния "маневра" в сеть, показанную на рис. 15.5. Переключательные фильтры Калмана рассматриваются дополнительно в упр. 15.5.

Ф 3Ь а) б) Рис. 15.8. Пример с птицей, летящей прямо на дерево (вид сверху): фильтр Калмана предсказывает местонахождение птицы с использованием единственного гауссова распределения, центр которого находится напротив препятствия (а); более реалистичная модель допускает выполнение птицей действия по уклонению от столкновения с препятствием, предсказывая, что птица облетит препятствие с одной стороны или с другой (б) 15.5. Динамические байесовские сети $\wedge$ Динамической байесовской сетью, или сокращенно DBN (Dynamic Bayesian Network), называется байесовская сеть, которая представляет временную вероятностную модель такого типа, как описано в разделе 15.1. В данной главе уже рассматривались примеры сетей DBN: сеть для задачи с зонтиком (см. рис. 15.2) и сеть фильтра Калмана (см. рис. 15.5). Вообще говоря, каждый временной срез сети DBN может иметь любое количество переменных состояния x_t и переменных свидетельства E_t . Для упрощения мы будем предполагать, что переменные и связи между ними точно тиражируются от среза к срезу и что сеть DBN представляет марковский процесс

первого порядка, так что каждая переменная может иметь родительские переменные только в своем собственном временном срезе или в непосредственно предшествующем временном срезе.

Должно быть очевидно, что любая скрытая марковская модель может быть представлена в виде сети DBN с единственной переменной состояния и с единственной переменной свидетельства. Справедливо также утверждение, что каждая сеть DBN с дискретными переменными может быть представлена в виде модели HMM; как было описано в разделе 15.3, можно скомбинировать все переменные состояния в сети DBN в одну переменную состояния, значениями которой являются все возможные кортежи значений отдельных переменных состояния. Итак, если каждая модель HMM представляет собой сеть DBN, а каждая сеть DBN может быть преобразована в модель HMM, то в чем состоит различие между ними? Это различие заключается в том, что с[°] благодаря декомпозиции состояния сложной системы на составляющие его переменные сеть DBN позволяет воспользоваться преимуществами разреженности временной вероятностной модели. Предположим, например, что в се-

ти DBN имеется 20 булевых переменных состояния, каждая из которых имеет три родительских переменных в предшествующем срезе. В таком случае модель перехода DBN включает $20 \times 23 = 160$ вероятностей, а соответствующая модель HMM имеет 220 состояний и поэтому 240 (или примерно триллион) вероятностей в матрице перехода. Такая ситуация неприемлема по меньшей мере по трем причинам: во-первых, требуется гораздо больше пространства для самой модели HMM; во-вторых, из-за огромной матрицы перехода вероятностный вывод с помощью модели HMM становится гораздо более дорогостоящим; и, в-третьих, из-за проблем, связанных с изучением такого огромного количества параметров, чистая модель HMM становится непригодной для решения крупных задач. Связь между сетями DBN и моделями HMM примерно аналогична связи между обычными байесовскими сетями и полностью табулированными совместными распределениями.

Как уже было описано выше, каждая модель с фильтром Калмана может быть представлена в виде сети DBN с непрерывными переменными и линейными гауссовыми распределениями условных вероятностей (см. рис. 15.5). Согласно сведениям, приведенным в конце предыдущего раздела, должно быть очевидно, что не каждая сеть DBN может быть представлена с помощью модели с фильтром Калмана.

В фильтре Калмана текущее распределение вероятностей состояния всегда представляет собой единственное многомерное гауссово распределение, т.е. распределение с единственным "максимумом", расположенным в определенном месте. Сети DBN, с другой стороны, позволяют моделировать произвольные

распределения. Такая гибкость является весьма существенным подспорьем для многих реальных приложений.

Рассмотрим, например, текущее местонахождение ключей от дома, принадлежащих некоторому лицу. Они могут находиться в его кармане, на ночном столике, в ящике кухни или торчать в замочной скважине входной двери. Единственный гауссов максимум, который охватывает распределения вероятностей нахождения ключей во всех этих местах, назначил бы значительную вероятность тому предположению, что ключи находятся где-то в промежуточной позиции, например висят прямо в воздухе в прихожей. Таким образом, реальный мир, характеризующийся наличием целенаправленных агентов, препятствий и тупиков, приводит к созданию "нелинейности" и поэтому требует применения сочетаний дискретных и непрерывных переменных для того, чтобы можно было создавать приемлемые модели.

Процедура создания сетей DBN Для того чтобы создать сеть DBN, необходимо определить три вида информации: распределение априорных вероятностей по переменным состояниям, $P(x_0)$; модель перехода, $P(X_{t+1} | X_t)$, и модель восприятия, $P(E_t | x_t)$. Чтобы задать модель перехода и модель восприятия, необходимо определить топологию связей между последовательными срезами, а также между переменными состояниями и свидетельствами.

Поскольку предполагается, что модели перехода и восприятия являются стационарными (одинаковыми для всех t), удобнее всего задать их для первого среза. Например, полная спецификация DBN для мира задачи с зонтиком дана с помощью сети с тремя узлами, показанной на рис. 15.9, а. На основании этой спецификации по мере необходимости может быть создана полная (полубесконечная) сеть DBN путем копирования первого среза.

а) б) Рис. 15.9. Примеры создания сетей DBN: спецификация распределения априорных вероятностей модели перехода и модели восприятия для сети DBN задачи с зонтиком; предполагается, что все последующие срезы являются копиями среза 1 (а); простая сеть DBN для моделирования движения робота на плоскости $X-Y$ (б) Теперь рассмотрим более интересный пример: текущий контроль за роботом с аккумуляторным питанием, который движется на плоскости $X-Y$ (о нем впервые шла речь в разделе 15.1). Прежде всего необходимо определить переменные состояния, в состав которых мы включим и переменную $X_t = (X_t, Y_t)$, обозначающую положение, и переменную $\dot{X}_t = (\dot{X}_t, \dot{Y}_t)$, обозначающую скорость.

Предполагается, что для измерения координат положения используется определенный метод (возможно, фиксированная телекамера или бортовая система GPS (Global Positioning System— глобальная система позиционирования)), позволяющий получить результаты измерений z_t . Положение робота в следующем

временном интервале зависит от текущего положения и скорости, как и при использовании стандартной модели с фильтром Калмана. Скорость в следующем временном интервале зависит от текущей скорости и состояния зарядки аккумулятора. Введем переменную *Batteryt* для обозначения фактического уровня зарядки аккумулятора, родительскими переменными которой являются предыдущий уровень зарядки аккумулятора и скорость, а также введем переменную *BMetert*, которая измеряет уровень зарядки аккумулятора. В результате будет получена исходная модель, показанная на рис. 15.9, б.

Характер модели восприятия для переменной *BMetert* заслуживает более глубокого анализа. Для упрощения предположим, что переменные *Batteryt* и *BMetert* могут принимать дискретные значения от 0 до 5, во многом аналогично измерительному прибору в типичном портативном компьютере, который применяется для контроля за аккумулятором. Если этот прибор всегда дает точные показания, то таблица условных вероятностей $P(BMetert \setminus Batteryt)$ должна содержать вероятности 1. 0 в элементах, расположенных "вдоль диагонали", и вероятности 0. 0 во всех других элементах. Но в действительности в результаты измерения всегда проникает шум, поэтому при использовании непрерывных измерений вместо этих результатов может использоваться гауссово распределение с небольшой дисперсией⁴.

Применительно к дискретным переменным, рассматриваемым в данном примере, гауссово распределение можно аппроксимировать с помощью распределения, в котором снижение вероятности ошибки соответствует реальной ситуации, поэтому вероятность крупной ошибки весьма мала. Мы будем использовать термин $\wedge$ гауссова модель ошибки применительно и к непрерывной, и к дискретной версиям.

Те, кто имеет практический опыт работы в области робототехники, компьютеризированного управления процессами или в области применения других форм автоматического сбора информации, охотно подтвердят тот факт, что небольшие количества измерительного шума часто являются не самыми серьезными проблемами.

Гораздо важнее то, что настоящие датчики отказывают, а когда датчик отказывает, он не всегда посылает сигнал с сообщением: "Между прочим, данные, которые я собираюсь вам отправить, можно считать бессмысленными". Вместо этого он просто передает бессмыслицу. Отказом простейшего типа является $\wedge$ временный отказ, при котором датчик время от времени передает бессмысленные данные. Например, может оказаться, что датчик уровня зарядки аккумулятора имеет свойство передавать нулевое значение каждый раз, когда робот ударяется о препятствие, даже если аккумулятор полностью заряжен.

Рассмотрим, что произойдет при возникновении временного отказа, если используется гауссова модель ошибок, которая не приспособлена к таким отказам.

Предположим, например, что робот спокойно ожидает и наблюдает за 20 последовательными показаниями датчика аккумулятора, равными 5. Затем датчик аккумулятора допускает временный сбой и передает следующее показание: $BMeter21=0$.

К какому решению должна привести нас простая гауссова модель ошибки применительно к этому значению $Battery21$? Согласно правилу Байеса, ответ на этот вопрос зависит и от модели восприятия $P(BMeter21=0 \mid Battery21)$, и от предсказания $B(Battery21 \mid BMeter1:20)$. Если вероятность большой ошибки датчика является значительно менее правдоподобной, чем вероятность перехода в состояние $Battery21=0$, даже если последняя ситуация весьма неправдоподобна, то в распределении апостериорных вероятностей будет присвоена высокая вероятность той ситуации, что аккумулятор разряжен. Если же в момент времени $t=22$ будет получено еще одно показание, равное нулю, то такой вывод станет почти полностью безоговорочным. А после того, как этот временный отказ исчезнет и показания вернуться к 5, начиная с момента $t=23$ и продолжаясь в последующие моменты, то оценка уровня зарядки аккумулятора, как по волшебству, быстро вернется к 5. Такой ход событий проиллюстрирован на верхней кривой, приведенной на рис. 15.10, а, где показано ожидаемое изменение значения переменной $Battery_t$ во времени при использовании дискретной гауссовой модели ошибки.

Несмотря на последующее восстановление правильных показаний, есть такой момент времени ($t=22$), в котором робот получил сообщение о разрядке аккумулятора, а в такой ситуации он должен, в принципе, передать сигнал тревоги и отключиться. Итак, к сожалению, чрезмерно упрощенная модель восприятия завела робота в тупик. Как можно исправить такое положение? Рассмотрим знакомый многим 4 Строго говоря, гауссово распределение не совсем подходит, поскольку в нем присваивается ненулевая вероятность большим отрицательным уровням зарядки аккумулятора. Иногда для переменных, область определения которых ограничена, лучше подходит бета-распределение.

пример, в котором при вождении автомобиля на резких поворотах или крутых подъемах иногда загорается сигнал "топливный бак пуст". Но, вместо того чтобы искать телефон аварийной службы, водитель вспоминает, что датчик уровня топлива иногда допускает очень большую ошибку, когда топливо плещется в баке. Мораль этой истории состоит в следующем: $s^{\wedge}$ для того чтобы система правильно учитывала отказы датчика, модель восприятия должна допускать вероятность его отказа.

В модели отказа простейшего вида для датчика допускается определенная вероятность того, что датчик может выдать полностью неправильное значение, независимо от истинного состояния мира. Например, если прибор на аккумуляторе

на время отказывает, возвращая значение 0, то можно ввести значение $P(BMeter_t=0 \setminus Battery_t=5) = 0.03$ которое, очевидно, значительно больше, чем вероятность, присваиваемая при использовании простой гауссовой модели ошибки. Назовем соответствующую модель $\wedge$ моделью временного отказа. Как она может помочь, если мы столкнемся с показанием датчика, равным 0? При условии, что прогнозируемая вероятность полной разрядки аккумулятора, согласно полученным до сих пор показаниям, гораздо меньше 0.03, то наилучшим объяснением причин наблюдения $BMeter_{t1}=0$ является то, что произошел временный отказ датчика. Интуитивно ясно, что можно рассматривать уверенность в истинности данных об уровне зарядки аккумулятора как имеющую определенную долю "инерции", которая позволяет преодолеть временные сбои в показаниях датчика. Верхняя кривая на рис. 15.10, б показывает, что модель временного отказа позволяет преодолевать временные отказы без катастрофического изменения в представлениях об истинности данных.

На этом описание временных отказов оканчивается. А что будет, если отказ датчика окажется постоянным? К сожалению, отказы такого типа встречаются слишком часто. Если датчик возвратит 20 показаний со значением 5, за которыми последует 20 показаний со значением 0, то применение модели временного отказа датчика, описанной в предыдущем абзаце, приведет к тому, что робот постепенно придет к выводу, что его аккумулятор разряжен, тогда как в действительности мог произойти отказ датчика. Нижняя кривая, приведенная на рис. 15.10, б, показывает "траекторию" изменения уверенности в истинности показаний датчика для этого случая. Ко времени $t=25$ (после получения пяти показаний датчика, равных 0) робот приходит к выводу, что его аккумулятор разряжен. Безусловно, мы предпочли бы, чтобы робот приобрел уверенность в том, что неисправен прибор на его аккумуляторе (если такая ситуация действительно является гораздо более вероятной).

Нет ничего удивительного в том, что для учета постоянных отказов требуется $\wedge$ модель постоянного отказа, которая описывает, как датчик ведет себя при нормальных условиях и после отказа. Для этого необходимо дополнить скрытое состояние системы дополнительной переменной, скажем, $BMBroken$, которая описывает состояние прибора аккумулятора. Постоянство отказа может быть промоделировано дугой, связывающей переменные $BMBroke$ и $BMBroke$ $\wedge$ Такая $\wedge$ дуга постоянства имеет таблицу условных вероятностей, которая задает на каждом временном интервале малую вероятность отказа, допустим 0.001, но определяет, что датчик после выхода из строя остается неисправным. Если датчик исправен, то модель восприятия для переменной $BMe\ ter$ идентична модели временного отказа, а после того

как датчик становится неисправным, эта модель указывает, что значение BMeter всегда равно 0, независимо от фактической зарядки аккумулятора.

E(Battery\...S555N°555...) Ж Ж Ж Ж Ж Ж Ж-ж^Л—|—|—|—|—|—|—|—|—h X *-X- -
 KK—X-*--x- -к ?(^/A?/yJ...5555000000...) i i i 15 20 25 30 Время/ Время/ а) б) Рис. 15.10.
 Пример применения модели временного отказа: верхняя кривая — траектория ожидаемого значения переменной Batteryt для последовательности наблюдений, состоящей из всех значений 5, кроме показаний, равных 0, в моменты времени t=21 и t=22, если используется простая гауссова модель ошибки; нижняя кривая — траектория, при которой результаты наблюдения остаются на уровне 0, начиная с момента времени t=21 (а); такой же эксперимент, проведенный с использованием модели временного отказа (б); обратите внимание на то, что временный отказ преодолевается успешно, а постоянный приводит к излишне пессимистическому поведению Модель постоянного отказа для датчика аккумулятора показана на рис. 15.11, а.

Показатели ее производительности при двух последовательностях данных (временный сбой и постоянный отказ) приведены на рис. 15.11, б. В отношении этих кривых необходимо сделать несколько замечаний. Прежде всего, в случае временного сбоя вероятность того, что датчик вышел из строя, существенно повышается после второго показания со значением 0, но немедленно падает вновь до нуля после получения результатов наблюдения 5. Далее, в случае постоянного отказа вероятность того, что датчик неисправен, быстро повышается почти до 1 и остается на этом уровне. Наконец, как только становится известно, что датчик стал неисправным, робот может лишь руководствоваться предположением, что его аккумулятор разряжается с "обычной" скоростью, как показывает постепенно снижающийся уровень E(Batteryt |...).

В приведенном выше описании мы лишь слегка коснулись поверхности проблемы представления сложных процессов. Применяемое на практике разнообразие моделей перехода является буквально огромным и охватывает такие разные направления, как моделирование эндокринной системы человека и моделирование потока, состоящего из большого количества автомобилей, движущихся по скоростному шоссе. Создание моделей восприятия также представляет собой обширную самостоятельную область, но практика показала, что динамические байесовские сети позволяют явно представить даже такие тонкие феномены, как дрейф датчика, внезапная раскалибровка и влияние на показания датчика внешних условий (таких как погода).

I 2 * 1 -1 E(Battery\...S555005555...) н—i—i—|—h -X-X-- x-*--x--x--x--x--x
 ?N°//^|...5555000000...) 5 i I 2 * 1 o -1

*0 P(B)_j 1,000 0,001 ?ftoteryj...5555005555...) ?"№^rvJ-5555000000..X)
P(BM_{Bn}kenj...5555S(mm...)) P(BM_{Broken}i...5555005555...) 15 20 25 30 Время / б) Рис. 15.11.
Пример применения модели постоянного отказа: фрагмент сети DBN, в котором показаны переменные состояния датчика, необходимые для моделирования постоянного отказа датчика аккумулятора (а); верхние кривые — траектории ожидаемого значения переменной Battery_t для последовательностей наблюдений, характерных для "временного отказа" и "постоянного отказа"; нижние кривые — траектории вероятностей для переменной BM_{Broken} при наличии двух указанных последовательностей наблюдений (б) Точный вероятностный вывод в сетях DBN
Кратко рассмотрев некоторые идеи, касающиеся представления сложных процессов в виде сетей DBN, перейдем теперь к вопросу вероятностного вывода. В определенном смысле на этот вопрос уже был получен ответ: динамические байесовские сети прежде всего представляют собой байесовские сети, а мы уже имеем алгоритмы для осуществления вероятностного вывода в байесовских сетях. При наличии последовательности наблюдений может быть создано представление сети DBN в виде полной байесовской сети путем повторения временных срезов до тех пор, пока сеть не станет достаточно большой, чтобы в ней можно было учесть все наблюдения, как показано на рис. 15.12. Такой метод называется ^ разворачиванием. (С формальной точки зрения сеть DBN эквивалентна полубесконечной сети, полученной путем разворачивания в одну сторону до бесконечности.

Но временные срезы, вводимые за пределами последнего наблюдения, не оказывают влияния на вероятностные выводы в пределах периода наблюдения и поэтому могут быть исключены.) После того как сеть DBN развернута, в ней может использоваться любой из алгоритмов вероятностного вывода (алгоритм с устранением переменной, методы соединенного дерева и т.д.), описанные в главе 14.

К сожалению, непродуманное применение разворачивания не всегда оказывается достаточно эффективным. В частности, если требуется выполнение фильтрации или сглаживания с использованием длинной последовательности наблюдений $e_{1:t}$, то для развернутой сети потребуется пространство $O(t)$, а рост ее по мере добавления новых результатов наблюдений будет происходить неограниченно. Более того, если после каждого добавления новых результатов наблюдения будет просто вновь вызываться на выполнение алгоритм вероятностного вывода, то затраты времени на вероятностный вывод в расчете на каждое обновление также будут расти пропорционально $O(t)$.

RI t f Щ)\ 0,9 0,2 *i t РЩ n *1 t f РЩ 0,9 0,2 1 j P(i^ 0)) 0.2 *i t f Щ)\ m Рис. 15.12.
Разворачивание динамической байесовской сети: для размещения результатов последовательности наблюдений дублируются временные срезы (обозначенные

овалами с жирными контурами). Следующие срезы не влияют на вероятностные выводы в период наблюдения. Еще раз обратившись к разделу 15.2, можно отметить, что постоянных затрат времени и пространства в расчете на каждое обновление при фильтрации можно достичь, если существует возможность выполнять вычисление в рекурсивной форме.

По сути обновление результатов фильтрации в уравнении 15.3 осуществляется по принципу исключения путем суммирования переменных состояния, относящихся к предыдущему временному этапу, что позволяет получить распределение для нового временного этапа. Исключение переменных путем суммирования представляет собой именно то, что выполняет алгоритм устранения переменной (см. листинг 14.2), и, как оказалось, применение процедуры устранения переменной к переменным во временном порядке точно моделирует функционирование рекурсивного обновления результатов фильтрации в уравнении 15.3. В модифицированном алгоритме предусмотрено одновременное хранение в памяти не больше двух временных срезов: начиная со среза 0, добавляем срез 1, затем исключаем путем суммирования срез 0, после этого добавляем срез 2, на следующем этапе исключаем путем суммирования срез 1 и т.д. Такая организация вычислений позволяет добиться постоянных затрат пространства и времени в расчете на каждое обновление результатов фильтрации.

(Такой же производительности можно достичь путем введения соответствующих модификаций в алгоритм соединенного дерева.) В упр. 15.10 предлагается проверить это утверждение на примере сети для задачи с зонтиком.

До сих пор рассматривались только преимущества рекурсивного подхода, но он имеет и недостатки: как оказалось, "постоянные" значения временной и пространственной сложности каждой операции обновления почти во всех случаях экспоненциально зависят от количества переменных состояния. В связи с этим в ходе осуществления процесса устранения переменной количество факторов возрастает так, что в их состав начинают входить все переменные состояния (или, точнее, все те переменные состояния, которые имеют родительские переменные в предыдущем временном срезе). Максимальный размер фактора составляет $O(dn+1)$, а стоимость обновления измеряется как $O(cT+2)$.

Безусловно, такие значения намного меньше по сравнению со стоимостью обновления НММ, которая составляет $O(d^2n)$, но они все еще неприемлемы при наличии большого количества переменных. С этим обескураживающим фактом довольно трудно смириться, поскольку он означает, что даже несмотря на то, что сети DBN могут использоваться для представления очень сложных временных процессов с многочисленными переменными, характеризующимися разрозненными связями между

ними, не существует возможности эффективно и точно формировать вероятностные рассуждения об этих процессах. Сама модель DBN, которая представляет априорное совместное распределение по всем переменным, может быть разложена на составляющие ее таблицы условных вероятностей, но обусловленное последовательностью наблюдений апостериорное совместное распределение (т.е. прямое сообщение), как правило, не поддается разбиению на факторы. До сих пор еще никому не удалось найти способа решения этой проблемы, несмотря на то, что многие важные области науки и техники получили бы огромную выгоду благодаря такому решению.

Поэтому нам приходится обращаться к приближенным методам.

Приближенный вероятностный вывод в сетях DBN В главе 14 были описаны два алгоритма аппроксимации— взвешивание с учетом правдоподобия (см. листинг 14.5) и метод Монте-Карло на основе цепи Маркова (алгоритм MCMC, см. листинг 14.6). Из этих двух алгоритмов наиболее легко к контексту DBN адаптируется первый алгоритм. Тем не менее, как будет показано ниже, в стандартный алгоритм взвешивания с учетом правдоподобия необходимо внести несколько усовершенствований, прежде чем появится практически применимый метод.

Напомним, что метод взвешивания с учетом правдоподобия действует по принципу осуществления в топологическом порядке выборок в узлах сети, не являющихся узлами свидетельства, и взвешивания каждой выборки с учетом правдоподобия того, что она соответствует наблюдаемым переменным свидетельства. Как и при использовании точных алгоритмов, алгоритм взвешивания с учетом правдоподобия можно было бы применить непосредственно к развернутой сети DBN, но по мере увеличения длины последовательностей наблюдений это привело бы к возникновению таких же сложностей, связанных с увеличением требований ко времени и пространству в расчете на каждое обновление. Проблема состоит в том, что в стандартном алгоритме каждая выборка обрабатывается последовательно, по всей сети.

Вместо этого можно просто пропустить через сеть DBN все N выборок вместе, проходя каждый раз через один временной срез. Этот модифицированный алгоритм имеет такую же общую форму, как и другие алгоритмы фильтрации, но в нем в качестве прямого сообщения используется множество из N выборок. Поэтому первым ключевым усовершенствованием должно быть то, чтобы в этом алгоритме $\wedge$ в качестве приближенного представления текущего распределения вероятностей состояния использовались сами выборки. Такая организация работы соответствует требованию обеспечения "постоянных" затрат времени в расчете на каждое обновление, хотя само это постоянное значение зависит от количества выборок, необходимых для достижения приемлемой аппроксимации истинного апостериорного распределения.

Кроме того, нет необходимости разворачивать сеть DBN, поскольку в памяти требуется держать только текущий временной срез и следующий временной срез.

В описании метода взвешивания с учетом правдоподобия, приведенного в главе 14, было указано, что точность алгоритма снижается, если переменные свидетельства находятся в "прямом направлении" от переменных, по которым осуществляется выборка, поскольку в таком случае выборки формируются, не испытывая какого-либо влияния со стороны свидетельства. Рассматривая типичную структуру сети DBN (допустим, сети DBN для задачи с зонтиком на рис. 15.12), можно убедиться в том, что в действительности выборку ранее полученных переменных состояния можно осуществлять, не пользуясь полученным в дальнейшем свидетельством.

Проанализировав фактически этот вопрос более внимательно, можно обнаружить, что ни у одной из переменных состояния не имеется среди ее предков ни одной переменной свидетельства! Поэтому, хотя вес каждой выборки зависит от свидетельства, фактически сформированное множество выборок является полностью независимым от свидетельства. Например, даже если директор ходит с зонтиком каждый день, в процессе осуществления выборки все еще может создаваться впечатление, что солнечные дни не кончаются. С точки зрения практики это означает, что доля выборок, остающихся достаточно близкими к фактическому ряду событий, падает экспоненциально со значением t , т.е. с длиной последовательности наблюдений; иными словами, чтобы поддерживать заданный уровень точности, необходимо увеличивать количество выборок экспоненциально в зависимости от t . Учитывая то, что алгоритм фильтрации, работающий в реальном времени, может использовать лишь фиксированное количество выборок, на практике происходит то, что после небольшого количества этапов обновления ошибка становится весьма значительной.

Очевидно, что требуется лучшее решение. Поэтому второе важное нововведение состоит в том, что (3^N множество выборок в основном следует формировать в областях пространства состояний, характеризующихся высокой вероятностью. Такую задачу можно выполнить, отбрасывая выборки, которые, согласно наблюдениям, имеют очень малый вес, вместе с тем увеличивая количество выборок, имеющих большой вес. Благодаря этому появляется возможность создавать множества выборок, которые остаются достаточно близкими к действительным данным. Если выборки рассматриваются как информационные ресурсы для моделирования распределения апостериорных вероятностей, то имеет смысл формировать больше выборок в тех областях пространства состояний, где апостериорная вероятность выше.

Для решения именно этой задачи предназначено семейство алгоритмов, называемых алгоритмами $\wedge$ фильтрации частиц. Метод фильтрации частиц

действует следующим образом: прежде всего создается популяция из N выборок путем формирования выборок из распределения априорных вероятностей в момент времени 0, $P(X_0)$, затем, как описано ниже, для каждого временного интервала повторяется цикл обновления.

- Каждая выборка распространяется в прямом направлении путем формирования выборки значения переменной следующего состояния x_{t+1} . Для этого в качестве выборки берется текущее значение x_t и используется модель перехода $P(X_{t+1} | x_t)$.
- Каждая выборка взвешивается с учетом правдоподобия, которое она присваивает новому свидетельству, $P(e_{t+1} | x_{t+1})$.
- В этой популяции выборок снова осуществляется формирование выборки для создания новой популяции из N выборок. Каждая новая выборка берется из текущей популяции; вероятность того, что будет получена конкретная выборка, пропорциональна ее весу. Данные о весах новых выборок уничтожаются.

Этот алгоритм подробно показан в листинге 15.3, а пример его применения к сети DBN для задачи с зонтиком приведен на рис. 15.13.

Листинг 15.3. Алгоритм фильтрации частиц, реализованный как рекурсивная операция обновления данных о состоянии (множества выборок). Каждый из этапов формирования выборок состоит в том, что формируется выборка значений соответствующих переменных временного среза в топологическом порядке, во многом так же, как и в процедуре Prior-Sample. Операция Weighted-Sample-with-Replacement может быть реализована так, чтобы она выполнялась за ожидаемое время $O(N)$

```
function Particle-Filtering( $e$ ,  $N$ ,  $dbn$ ) returns множество выборок для
следующего временного интервала
inputs:  $e$ , новое полученное свидетельство  $N$ ,
количество выборок, которые должны сопровождаться алгоритмом  $dbn$ , сеть DBN с
распределением априорных вероятностей  $P(X_0)$ , моделью перехода  $P(X_{i+1}|X_i)$  и
моделью восприятия  $P(E_i|X_i)$ 
static:  $S$ , вектор выборок с размером  $N$ , первоначально
формируемый из  $P(X_0)$ 
local variables:  $W$ , вектор весов с размером  $N$ 
for  $i = 1$  to  $N$  do
 $S[i] \leftarrow$  выборка из  $P(X_i | X_0=S[i])$ 
 $W[i] \leftarrow P(E_i | X_i=S[i])$ 
 $S \leftarrow$  Weighted-Sample-With-Replacement( $JV$ ,  $S$ ,  $W$ )
return  $S$ 
```

Рис. 15.13. Пример применения цикла обновления алгоритма фильтрации частиц к сети DBN для задачи с зонтиком при $N=10$, в котором показаны популяции выборок в каждом состоянии: во время t обнаруживается, что 8 выборок показывают Rain, а 2 выборки показывают -zRain. Каждая из них распространяется в прямом направлении путем формирования выборок в следующем состоянии через модель перехода. Во время $t + 1$ обнаруживается, что 6 выборок показывают Rain, а 4 выборки показывают -zRain (a); в момент времени $t + 1$ наблюдается -/Umbrella. Каждая выборка взвешивается с учетом ее правдоподобия применительно к этому наблюдению, как показывают размеры кружков (б); формируется новое множество из 10 выборок путем случайного выбора со взвешиванием из текущего множества, что приводит к

получению 2 выборок, которые показывают Rain, и 8 выборок, которые показывают -zRain (в) Рассматривая, что происходит во время одного цикла обновления, можно показать, что этот алгоритм является согласованным (позволяет получить правильные значения вероятностей, если N стремится к бесконечности). Предполагается, что создание популяции выборок начинается с использования правильного представле-

ния прямого сообщения $f_{1:t}$ во время t . Поэтому, записав выражение $iV(x_t|e_{1:t})$ для количества выборок, занимающих состояние x_t после обработки наблюдений $e_{1:t}$, t , получаем следующее соотношение для больших значений ЛГ.

$N(x_t|e_{1:t})/N = P(x_t|e_{1:t})$ A5.21) Теперь распространим каждую выборку в прямом направлении, осуществляя формирование выборок значений переменных состояния во время $t+1$ и взяв для каждой выборки значения во время t . Количество выборок, достигающих состояния x_{t+1} из каждого состояния x_t , равно вероятности перехода, умноженной на величину популяции x_t , поэтому общее количество выборок, достигающих x_{t+1} , будет равно следующему: $t f(X_t + l|e_{1:t}) = \sum_i P(X_t + l|X_t) N(X_t + l|e_{1:t})$ x_t После этого выполним взвешивание каждой выборки по ее правдоподобию применительно к свидетельству во время $t+1$. Любая отдельная выборка в состоянии x_{t+1} получает вес $P(e_{t+1}|x_{t+1})$. Это означает, что суммарный вес выборок в состоянии x_{t+1} после получения свидетельства e_{t+1} определяется таким образом:

$W(X_t + l|e_{1:t} + l) = P(e_{t+1}|X_t + l) iV(X_t + l|e_{1:t})$ Далее выполняется этап повторного формирования выборки. Поскольку каждая выборка тиражируется с вероятностью, пропорциональной ее весу, количество выборок в состоянии x_{t+1} после повторного формирования выборки пропорционально суммарному весу в состоянии x_{t+1} перед повторным формированием выборки, как показано ниже. $iV(x_{t+1}|e_{1:t+1})/iV = a P_i(x_{t+1}|e_{1:t+1}) = a P(e_{t+1}|x_{t+1}) iV(x_{t+1}|e_{1:t}) = a P(e_{t+1}|x_{t+1}) 2^{-P(x_{t+1}|x_t)} N(x_t|e_{1:t}) x_t = a N P(e_{t+1}|x_{t+1}) \cdot P(x_{t+1}|x_t) P(x_t|e_{1:t})$ (согласно 15.21) $x_t a' P(e_{t+1}|x_{t+1}) 2^{-P(x_{t+1}|x_t)} P(x_t|e_{1:t}) = P(X_{t+1}|e_{1:t+1})$ (согласно 15.3) Поэтому популяция выборок после одного цикла обновления правильно представляет прямое сообщение во время $t+1$.

Итак, алгоритм фильтрации частиц является согласованным, но характеризуется ли он достаточной эффективностью? Создается впечатление, что на практике ответ на этот вопрос является положительным: по-видимому, фильтрация частиц позволяет поддерживать хорошую аппроксимацию истинных апостериорных вероятностей с использованием постоянного количества выборок. Тем не менее теория еще не дает такой гарантии; в настоящее время в области фильтрации частиц продолжаются интенсивные исследования. Предложено много вариантов и усовершенствований,

а спектр приложений этого алгоритма стремительно растет. Поскольку алгоритм фильтрации представляет собой алгоритм формирования выборок, его

можно легко применить к гибридным и непрерывным сетям DBN, что дает возможность воспользоваться этим алгоритмом в таких областях, как отслеживание сложных движущихся образов в видеозаписях [719] и предсказание курсов акций на фондовой бирже [343].

15.6. Распознавание речи В данном разделе рассматривается одно из наиболее важных приложений временных вероятностных моделей — ^ распознавание речи. Задача состоит в том, чтобы выявить последовательность слов, произнесенных говорящим, используя акустический сигнал. Речь — это доминирующая форма общения людей, и поэтому надежное распознавание речи с помощью машин было бы чрезвычайно полезным.

Еще более важной задачей является понимание речи — идентификация смысла фрагментов речи. Но изучение этой темы мы отложим до главы 22.

Речь — это одно из первых проявлений грубого неоткристаллизовавшегося мира реальных сенсорных данных, с которыми сталкивается человек после своего рождения. Эти данные являются зашумленными, в буквальном смысле слова: в них может присутствовать не только фоновый шум, но и помехи, возникающие в процессе самого преобразования в осознаваемую человеком форму; слова иногда произносятся по-разному, даже одним и тем же говорящим; различные слова могут звучать одинаково и т.д. По этим причинам со временем возникло понимание того, что распознавание речи должно рассматриваться как одна из задач вероятностного вывода.

На наиболее общем уровне эту задачу вероятностного вывода можно определить следующим образом. Предположим, что $Words$ — случайная переменная, пробегающая по всем возможным последовательностям слов, которые могут быть произнесены, а также допустим, что $signal$ — наблюдаемая последовательность акустических сигналов. В таком случае наиболее вероятной интерпретацией фрагмента речи является то значение переменной $Words$, которое максимизирует вероятность $P(words | signal)$. Как и во многих других случаях, нам может помочь применение правила Байеса:

$P(words | signal) = \frac{P(signal | words) P(words)}{P(signal)}$ Выражение $P(signal | words)$ называется ^ акустической моделью. Эта модель описывает звуки слов, например, говорит о том, что слово "ceiling" (потолок) начинается с мягкого звука "с" и звучит так же, как "sealing" (уплотнение). (Слова, звучащие одинаково, часто называют домофонами.) Выражение $P(words)$ принято называть языковой моделью. Эта модель задает априорную вероятность каждого фрагмента речи, например указывает, что последовательность слов "high ceiling"

(высокий потолок) является гораздо более вероятной, чем "high sealing" (высокое уплотнение).

Языковые модели, используемые в системах распознавания речи, обычно являются очень простыми. Модель двухсловных сочетаний, которая будет описана ниже в данном разделе, задает вероятность каждого слова, которое следует за каждым другим словом. Акустическая модель является гораздо более сложной. В ее основе лежит важное открытие, сделанное в области ^ фонологии (науки о звуках устной речи), согласно которому во всех человеческих языках используется ограниченный набор звуков, называемых ^ фонемами, количество которых находится в пределах от 40 до 50. Грубо говоря, фонема — это звук, который соответствует одной гласной или согласной букве, но существуют некоторые сложности; например, некоторые сочетания букв, такие как "th" и "ng", в английском языке соответствуют единственным фонемам, а некоторые буквы произносятся как разные фонемы в различных контекстах (в качестве примера можно указать букву "a" в словах "rat" и "rate").

В табл. 15.1 перечислены фонемы, используемые в английском языке, с примером для каждой из них. Итак, ^ фонема — это наименьший фрагмент звукового сигнала, который имеет различимый смысл для людей, говорящих на конкретном языке. Например, в английском языке фонема "t" в слове "stick" является той же самой, что и фонема "t" в слове "tick", но в тайском языке они различаются как две отдельные фонемы.

Таблица 15.1. Фонетический алфавит DARPA, или ARPAbet, в котором перечислены все фонемы, используемые в американском диалекте английского языка. Существует также несколько альтернативных систем обозначения фонем, включая международный фонетический алфавит (International Phonetic Alphabet — IPA), который описывает фонемы всех известных языков

Гласные	Согласные
B—N	P—Z
Фонема [iy] [ih] [eh] [ae] [ah] [ao] [ow] [uh] [ey] [er] [ay] [oy] [axr] [aw] [ax] [ix] [aa]	Пример beat bit bet bat but bought boat book bait Bert buy boy diner down about roses cot
Фонема [b] [ch] [d] [f] [g] [hh] [hv] [jh] [k] [l] [el] [m] [em] [n] [en] [ng] [eng]	Пример bet Chet debt fat get hat high let kick let bottle met bottom net button sing washing
Фонема [p] [r] [s] [sh] [t] [th] [tdh] [dx] [v] [w] [wh] [y] [z] [zh]	Пример pet rat set shoe ten thick that butter vet wet which yet zoo measure

отсутствует звука. Благодаря существованию фонем появляется возможность разделить акустическую модель на две части. Первая часть касается ^ произношения и задает для каждого слова распределение вероятностей по возможным последовательностям фонем.

Например, слово "ceiling" произносится как [s iy 1 ih ng]; или иногда как [s iy 1 ix ng], а иногда даже как [s iy 1 en]. Фонемы не являются непо-

средственно наблюдаемыми, поэтому, грубо говоря, речь может быть представлена как скрытая марковская модель, переменная состояния которой, X_t , определяет, какая фонема произносится в момент времени t .

Вторая часть акустической модели относится к тому способу, с помощью которого фонемы реализуются в виде акустических сигналов. Другими словами, переменная свидетельства E_t для скрытой марковской модели задает наблюдаемые характеристики акустического сигнала в момент времени t , а акустическая модель определяет вероятность $P(E_t|X_t)$, где X_t — текущая фонема. Эта модель позволяет также учитывать ударение, скорость и громкость речи и основана на методах из области ^ обработки сигналов, позволяющих создавать описания сигналов, которые являются достаточно устойчивыми по отношению ко всем указанным влияниям.

В оставшейся части данного раздела приведено описание указанных моделей и алгоритмов, которое построено от нижнего уровня к верхнему, начиная от акустических сигналов и фонем, проходя через отдельные слова и заканчивая целыми предложениями. В заключение будет показано, как происходит обучение всех этих моделей и насколько хорошо работают результирующие системы.

Звуки речи Звуковые волны представляют собой периодические изменения давления, которые распространяются через воздух. Звук может быть измерен микрофоном, диафрагма которого смещается под воздействием изменений давления и вырабатывает непрерывно изменяющийся ток. Аналогово-цифровой преобразователь измеряет величину тока (которая соответствует текущей амплитуде звуковой волны) через дискретные интервалы, определяемые ^ частотой дискретизации. Для обработки речи, как правило, применяется частота дискретизации от 8 до 16 кГц (т.е. от 8 до 16 тысяч раз в секунду). (Дискретизация высококачественных музыкальных записей осуществляется с частотой 44 кГц или больше.) Точность каждого измерения определяется ^ коэффициентом квантования; в системах распознавания речи обычно применяется от 8 до 12 битов. Это означает, что в системах низкого класса дискретизация происходит с частотой 8 кГц и с квантованием 8 битами, а это требует для передачи фрагмента речи, занимающего одну минуту, примерно половины мегабайта. Было бы практически невозможно создавать и манипулировать распределениями вероятностей $P(\text{signal} \setminus \text{phone})$ с таким большим объемом воспринимаемой информации, поэтому необходимо разработать более краткие описания акустического сигнала.

Прежде всего необходимо отметить следующее: хотя звуковые частоты в речи могут достигать нескольких килогерц, изменения в содержимом этого сигнала происходят гораздо менее часто, возможно, с частотой не больше 100 Гц. Поэтому в системах распознавания речи суммируются свойства сигнала за более продолжительные интервалы, называемые ^ фреймами. Длина фрейма равна приблизительно 10 миллисекундам (т.е. соответствует 80 выборкам на частоте 8 кГц); это означает, что она достаточно мала, чтобы обеспечить исключение с помощью процесса суммирования некоторых помех, отличающихся меньшей продолжительностью. В пределах каждого фрейма происходящее в нем представляется с помощью вектора

^ акустических характеристик. Например, во фрейме можно охарактеризовать количество энергии в каждом из нескольких частотных диапазонов.

К другим важным характеристикам относится общее количество энергии во фрейме и его отличие от предыдущего фрейма. Извлечение характеристик из речевого сигнала можно сравнить с прослушиванием выступления оркестра и определением того, что "теперь валторны звучат громко, а скрипки — тихо". На рис. 15.14 показано, как происходят преобразования из непосредственно измеряемого звука в последовательность фреймов. Обратите внимание на то, что фреймы перекрываются; это позволяет предотвратить потерю информации, которая могла бы произойти, если бы важное акустическое событие случайно совпало с границей одного из фреймов.

Аналоговый акустический сигнал Дискретизированный ||| 1 i l 1 1 i 1 i i l l 1 1 1 l l l l
1 i и квалифицированный цифровой сигнал l ' l l m ' m . 10 15 38 . . 22 63 24 . 10 12 73
Фреймы с характеристиками Рис. 15.14. Преобразование акустического сигнала в последовательность фреймов; для описания каждого фрейма применяются значения трех акустических характеристик В данном случае показаны фреймы только с тремя характеристиками. В реальных системах используются десятки или даже сотни характеристик. Если применяется p характеристик и каждая из них имеет, скажем, 256 возможных значений, то любой фрейм представляется в виде точки в n -мерном пространстве и существует 256^p возможных фреймов. При $p > 2$ была бы практически неосуществимой попытка представить распределение вероятностей $P(\text{features} | \text{phone})$ в виде явно заданной таблицы, поэтому требуется дальнейшее сжатие. Ниже описаны два возможных подхода к решению этой задачи. • В методе ^ векторного квантования, или сокращенно VQ (Vector Quantization), все n -мерное пространство подразделяется, допустим, на 256 областей, обозначенных метками от C1 до C256. В таком случае появляется возможность представить каждый фрейм с помощью одной метки, а не вектора из p чисел.

Поэтому в табулированном распределении $P(VQ \backslash \text{phone})$ имеется 256 вероятностей, заданных для каждой фонемы. Но метод векторного квантования больше не находит широкого применения в крупномасштабных системах. • Вместо дискретизации пространства характеристик для описания распределения $P(\text{features} \backslash \text{phone})$ может использоваться параметризованное непрерывное распределение. Например, для каждой фонемы может применяться гауссово распределение с различным средними и матрицами ковариаций.

Такой метод становится приемлемым, если акустические реализации каждой фонемы кластеризованы в отдельной области пространства характеристик.

Но на практике звуки могут распределяться по некоторым областям, поэтому приходится использовать сочетание гауссовых распределений. Такое сочетание

представляет собой взвешенную сумму к отдельных распределений, поэтому в распределении $P(\text{features} \setminus \text{phone})$ имеется к весов, к векторов средних $Hv^{\wedge}O$

с размером пик матриц ковариации с размером l_2 , т.е. для представления каждой фонемы применяется $O(kp^2)$ параметров.

Очевидно, что при переходе от полного речевого сигнала к метке VQ или к множеству параметров сочетания распределений некоторая информация теряется. Весь секрет успешной обработки сигналов заключается в том, что характеристики и области (или гауссовы распределения) должны быть выбраны так, чтобы потери полезной информации свелись к минимуму. Любой конкретный звук речи может быть произнесен с помощью слишком многих способов: громко или тихо, быстро или медленно, с высоким или низким ударением, на фоне тишины или шума, а также любым из миллионов разных говорящих людей, каждый из которых имеет свой акцент и обладает разными характеристиками речевого тракта. Обработка сигналов должна осуществляться таким образом, чтобы были устранены все эти вариации и вместе с тем сохранилось то общее, чем характеризуется воспринимаемый звук⁵.

В простую модель, описанную выше, необходимо внести еще два уточнения.

Первое из них относится к временной структуре фонем. При обычной речи большинство фонем имеет продолжительность 50-100 миллисекунд, т.е. фонемы занимают 5—10 фреймов. Для всех этих фреймов вероятностная модель $P(\text{features} \setminus \text{phone})$ является одинаковой, тогда как большинство фонем обладает ярко выраженной внутренней структурой. Например, фонема [t] представляет собой одну из нескольких $\wedge$ взрывных согласных, при произнесении которых поток воздуха прерывается на короткое время, после чего резко освобождается. Изучая акустический сигнал, можно обнаружить, что фонема [t] имеет тихое начало, небольшой взрыв в середине и (обычно) шипение в конце. Эта внутренняя структура фонем может быть описана с помощью модели $\wedge$ фонемы с тремя состояниями; каждая фонема имеет состояние Onset (Вступление), Mid (Середина) и End (Конец), а каждое состояние имеет свое собственное распределение среди вероятностей характеристик.

Второе уточнение касается контекста, в котором произносится фонема. Звучание каждой конкретной фонемы может изменяться под влиянием окружающих фонем⁶.

Напомним, что звуки речи вырабатываются в результате движения губ, языка и нижней челюсти и проталкивания воздуха через голосовой тракт. Для координации этих сложных движений на скорости в пять или больше фонем в секунду мозг инициирует действия, относящиеся ко второй фонеме, еще до того, как оканчивается произнесение первой, что приводит к модификации одной или обеих фонем.

Например, при произнесении слова "sweet" (сладкий) губы округляются еще во время произнесения фонемы [s] в предвидении того, что за ней последует фонема [w].

Такие ^ коартикуляционные эффекты частично охватываются ^ трехфонемной моделью, в которой в рамках акустической модели обеспечивается учет зависимости каждой фонемы от предшествующей и последующей фонем. Поэтому фонема [w] в слове "sweet" записывается как [w(s,iy)], т.е. как [w] с левым контекстом [s] и правым контекстом [iy].

5 Противоположной задачей является задача идентификации диктора, в которой необходимо устранить общие характеристики и сохранить индивидуальные отличия, после чего попытаться сопоставить эти отличия с моделями устной речи отдельных людей.

6 Это означает, что "модель фонем" речи следует рассматривать, скорее, как полезную аппроксимацию, а не как незыблемый закон.

Результатом совместного применения модели трех состояний и трехфонемной модели становится увеличение количества возможных состояний временного процесса с p фонем первоначального фонетического алфавита ($l \sim 50$ в случае ARPAbet) до $3l^3$. Но опыт показывает, что при этом достигается повышение точности, которое сторицей окупает дополнительные затраты на вероятностный вывод и обучение.

Слова Каждое слово можно рассматривать как определяющее отдельное распределение вероятностей $p(x_{1:t} | \text{word})$, где $x_{1:t}$ задает состояние фонемы в i -м фрейме. Как правило, такое распределение делится на две части. Модель произношения задает распределение вероятностей по последовательностям фонем (игнорируя такие измерения, как время и состав фреймов), а модель фонем описывает то, как фонемы отображаются в последовательность фреймов.

Рассмотрим слово "tomato" (помидор). Согласно Гершвину [546], допустимыми являются варианты произношения этого слова [t ow m ey t ow] и [t ow m aa t ow]. На рис. 15.15, сверху показана модель перехода, в которой учитываются эти варианты. В данной модели имеются два возможных пути, один из которых соответствует последовательности фонем [t ow m ey t ow], а другой — последовательности [t ow m aa t ow]. Вероятность любого из этих путей равна произведению вероятностей дуг, из которых состоит этот путь, как показано ниже. а) Рис. 15.15. Две модели произношения слова "tomato"; каждая модель показана в виде диаграммы перехода с состояниями, обозначенными кружками, и допустимыми переходами, обозначенными стрелками, на которых показаны соответствующие вероятности: модель, допускающая учет различий между диалектами. Числовые оценки 0.5 основаны на том, что один из авторов данной книги предпочитает один из этих

вариантов произношения, а другой автор предпочитает другой вариант (а); модель, в которой учитывается коартикуляционный эффект, возникающий при произнесении первой гласной; эта модель допускает наличие фонемы [ow] или [ah] (б)

$P([towmeytow] | "tomato") = P([towmaatow] | "tomato") = 0.5$ Вторым источником фонетических вариаций является коартикуляция. Например, фонема [t] формируется, когда язык находится в верхней части ротовой полости, а при произнесении фонемы [ow] язык должен находиться в нижней части. Во время быстрой речи язык часто оказывается в промежуточном положении и поэтому произносятся фонемы [t ah], а не [t ow]. На рис. 15.15, снизу приведена более сложная модель произношения слова "tomato", в которой принят в расчет этот коартикуляционный эффект. В данной модели имеются четыре отдельных пути, поэтому вероятности становятся таковыми:

$P([towmeytow] | "tomato") = P([towmaatow] | "tomato") = 0.1$ $P([tahmeytow] | "tomato") = P([tahmaatow] | "tomato") = 0.4$ Аналогичные модели могут быть составлены для каждого слова, которое мы хотим распознать.

Модель для фонемы с тремя состояниями показана в виде диаграммы перехода между состояниями на рис. 15.16. Эта модель относится только к одной конкретной фонеме, [т], но все фонемы должны иметь модели с аналогичной топологией. Для каждого состояния фонемы показана связанная с ней акустическая модель, в которой принято предположение, что соответствующий акустический сигнал представлен меткой VQ. Например, согласно этой модели, $P(E_t = C_1 | x_t = [m]_0 \text{onset}) = 0.5$.

Обратите внимание на то, что на данном рисунке показаны петли; например, состояние [m]Mid сохраняется с вероятностью 0.9, а это означает, что состояние [m]Mid имеет ожидаемую продолжительность 10 фреймов. В рассматриваемой модели продолжительность каждой фонемы является независимой от продолжительности других фонем; в более сложной модели могут проводиться различия между быстрой и медленной речью.

Скрытая марковская модель для фонемы [т] 0,3 0,9 0,4 Вероятности выходов для скрытой марковской модели этой фонемы Onset: Mid: End:

C₁: 0,5 C₃:0,2 C₄:0,1 C₂:0,2 C₄: 0,7 Q: 0,5 C₃:0,3 C₅:0,1 C₇:0,4 Рис. 15.16. Скрытая марковская модель для фонемы [т] с тремя состояниями. Каждое состояние имеет несколько возможных выходов, каждый из которых обладает собственной вероятностью. Метки VQ от C_i до C₇ выбраны произвольно, в качестве примера. Аналогичные модели можно составить для каждой фонемы, возможно, с учетом трехфонемного контекста. Модель каждого слова, в сочетании с моделями его фо-

нем, задает полную спецификацию некоторой скрытой марковской модели, которая, в свою очередь, определяет вероятности перехода между состояниями фонем от фрейма к фрейму, а также вероятности акустических характеристик для каждого состояния фонем.

Если требуется распознавать $\wedge$ отдельные слова (т.е. слова, произнесенные без какого-либо окружающего контекста и с четкими границами), то необходимо найти слово, которое максимизирует следующее выражение:

$P(\text{word} \setminus e1:t) = a P(e1:t \setminus \text{word}) P(\text{word})$ Априорную вероятность $P(\text{word})$ можно получить по результатам обработки фактических речевых данных, а $P(e1:t \setminus \text{word})$ представляет собой правдоподобие последовательности акустических характеристик, соответствующих модели рассматриваемого слова word . Вопросу о том, как вычисляются такие значения правдоподобия, посвящен раздел 15.2; в частности, в уравнении 15.5 определен простой метод рекурсивного вычисления, стоимость которого линейно зависит от t и от количества состояний марковской цепи. Чтобы найти наиболее вероятное слово, можно выполнить это вычисление для каждой возможной модели слова, умножить полученное значение на априорную вероятность и в соответствии с этим выбрать наиболее подходящее слово.

Предложения Для того чтобы поддерживать разговор с людьми, машина должна обладать способностью распознавать $\wedge$ непрерывную речь, а не просто отдельные слова. На первый взгляд может показаться, что непрерывная речь представляет собой не что иное, как последовательность слов, к которой вполне можно применить алгоритм, приведенный в предыдущем разделе. Но этот подход оканчивается неудачей по двум причинам. Прежде всего, как уже было показано (с. 1), последовательность наиболее вероятных слов не является наиболее вероятной последовательностью слов.

Например, в кинофильме "Take the Money and Run" (Бери деньги и беги) банковский кассир прочитал каракули в записке героя Вуди Аллена как слова "I have a gub"

(У меня есть штука). Хорошая языковая модель должна была бы предложить в качестве намного более вероятной последовательности слова "I have a gun" (У меня есть пушка), даже несмотря на то, что последнее слово больше похоже на "gub", чем на "gun". Вторая проблема, с которой приходится сталкиваться при обработке непрерывной речи, связана с $\wedge$ сегментацией — с проблемой определения того, где оканчивается одно слово и начинается следующее. С этой проблемой знаком любой, кто пытался изучать иностранный язык с помощью прослушивания устной речи, — на первых порах кажется, что все слова сливаются друг с другом. Но постепенно иностранец учится выделять отдельные слова из беспорядочных звуков. В данном случае первые впечатления вполне оправдываются; спектрографический

анализ показывает, что в беглой речи слова действительно следуют одно за другим без пауз между ними. Поэтому нам приходится учиться определять границы между словами, несмотря на отсутствие пауз.

Начнем с языковой модели, назначение которой при распознавании речи состоит в определении вероятности каждой возможной последовательности слов.

Используя запись $w_1 \dots w_n$ для обозначения строки из n слов и w_i для обозначения i -го

слова в строке, можно составить выражение для вероятности некоторой строки с использованием цепного правила следующим образом⁷:

$P(W_1 \dots W_n) = P(W_1) P(W_2 | W_1) P(W_3 | W_1 W_2) \dots P(W_n | W_1 \dots W_{n-1})$ $P = 11 P(W_i | v_{i-1} \dots t_{i-1})$ $i=1$
 Большинство термов этого соотношения являются весьма сложными, а задача их оценки или вычисления является трудной. К счастью, возможно аппроксимировать эту формулу немного более простым соотношением и вместе с тем сохранить в целости значительную часть языковой модели. Одним из простых, широко применяемых и эффективных подходов является модель 2 двухсловных сочетаний. В этой модели вероятность $P(W_i | W_{i-1} \dots W_1)$ аппроксимируется вероятностью $P(W_i | W_{i-1})$. Иначе говоря, в этом подходе принимается предположение о том, что для последовательностей слов можно использовать марковскую цепь первого порядка.

Значительным преимуществом такой модели с двухсловными сочетаниями является то, что можно легко провести обучение этой модели, подсчитав, сколько раз каждая пара слов встречается в представительной совокупности строк, и используя эти подсчеты для оценки вероятности. Например, если "a" встречалось в обучающей совокупности 10 000, а за ним 37 раз следовало "gun", то $P(\text{дил}1 | a1_1) = 37/10,000$, где под P подразумевается оцениваемая вероятность. После такого обучения следует ожидать, что слова "have" и "a gun" будут иметь высокие оцениваемые вероятности, а "I has" и "an gun" — низкие вероятности. В табл. 15.2 показаны некоторые результаты подсчета количества двухсловных сочетаний на примере слов в оригинале данной книги.

Возможно также перейти к использованию модели 3 трехсловных сочетаний, в которой предусмотрены значения для $P(W_i | W_{i-1} W_{i-2})$. Это — более мощная языковая модель, позволяющая судить о том, что слова "ate a banana" (съесть банан) являются более вероятными, чем "ate a bandanna" (съесть бандану — цветной платок). Подходы, в которых предусмотрено применение моделей трехсловных сочетаний и в меньшей степени моделей двухсловных и однословных сочетаний, характеризуются наличием одной проблемы, которая связана с нулевыми результатами подсчета частоты: мы не должны утверждать, что какая-то комбинация слов невозможна, лишь потому, что она по стечению обстоятельств не встретилась в обучающей совокупности. Для того чтобы можно было назначить таким

комбинациям небольшую ненулевую вероятность, применяется процесс сглаживания.

Эта тема обсуждается на с. 1104. Модели двухили трехсловных сочетаний являются менее сложными по сравнению с некоторыми грамматическими моделями, которые будут рассматриваться в главах 22 и 23, но они позволяют лучше учесть локальные эффекты, связанные с контекстными зависимостями, и способны отразить определенные локальные синтаксические связи. Например, тот факт, что пары слов "I has" (я имеет) и "man have"

7 Строго говоря, вероятность последовательности слов строго зависит от контекста фрагмента речи; например, слова "I have a gun" гораздо чаще встречаются в записках, передаваемых банковскому кассиру, чем, скажем, в статьях из журнала Wall Street Journal. Контекст учитывается лишь в немногих системах распознавания речи, а именно в тех, которые созданы путем изучения языковой модели специального назначения для решения конкретной задачи.

(мужчина имею) получают низкие оценки, отражает общепринятые синтаксические соглашения по совместному использованию пар существительное-глагол. Проблема состоит в том, что подобные связи с помощью моделей сочетаний могут быть обнаружены только локально: неправильная языковая конструкция "the man have"

(мужчина имею) получает низкую оценку, но более пространственный оборот "the man with the yellow hat have" (мужчина в желтой шляпе имею) не рассматривается как ошибочный.

Таблица 15.2. Часть таблицы частот однословных и двухсловных сочетаний для слов в оригинале данной книги. В ней наиболее часто применяемым отдельным словом является "the", и общее количество случаев, в которых встречается это слово, равно 33 508 (из общего количества слов, равного 513 893). Наиболее часто встречающимся двухсловным сочетанием является "of the", с общим количеством 3833. Некоторые частоты оказались больше ожидаемого (например, 4 раза встречается невероятное сочетание "on is"), поскольку при подсчете количества двухсловных сочетаний игнорируются знаки препинания, одно предложение может оканчиваться словом "on", а другое — начинаться со слова "is"

Предыдущее слово Слово Количество of in is on to from model agent однословных сочетаний the on of to is model agent idea 33508 15474 11527 10566 Теперь рассмотрим, как скомбинировать языковую модель со словесными моделями, чтобы иметь возможность правильно обрабатывать последовательности слов.

Для упрощения предполагается, что будет использоваться двухсловная языковая модель. С помощью такой модели можно скомбинировать все словесные модели

(которые, в свою очередь, состоят из моделей произношения и моделей фонем) в одну большую модель НММ. Состоянием в однословной модели НММ является фрейм с меткой, представляющей собой текущую фонему и состояние фонемы (например, [m] onset); любое состояние в модели НММ непрерывной речи снабжается также меткой в виде слова, как, например, [m] SSsSt° - Если каждое слово в своей модели произношения имеет в среднем p фонем с тремя состояниями, а общее количество слов равно W , то модель НММ непрерывной речи имеет $3pW$ состояний.

Переходы могут происходить между состояниями фонем в пределах данной конкретной фонемы, между фонемами данного конкретного слова, а также между конечным состоянием одного слова и начальным состоянием другого. Переходы между словами происходят с вероятностями, заданными с помощью двухсловной модели.

После составления такой комбинированной модели НММ ее можно использовать для анализа непрерывного речевого сигнала. В частности, для обнаружения наиболее вероятной последовательности состояний может применяться алгоритм Витерби, представленный в виде уравнения 15.9. Затем из этой последовательности состояний можно извлечь последовательность слов, считывая метки слов из состояний. Таким образом, алгоритм Витерби позволяет решить проблему сегментации непрерывной речи на отдельные слова, поскольку в нем (по сути) используется динамическое программирование для одновременного учета не только всех возможных последовательностей слов, но и границ между словами.

Обратите внимание на то, что выше не было сказано, будто с помощью алгоритма Витерби "можно извлечь наиболее вероятную последовательность слов". Дело в том, что наиболее вероятная последовательность слов не обязательно является такой, которая содержит наиболее вероятную последовательность состояний. Это связано с тем, что вероятность последовательности слов представляет собой сумму вероятностей по всем возможным последовательностям состояний, совместимых с данной последовательностью слов. Например, сравнивая две последовательности слов, скажем "a back" (спина) и "aback" (абак), можно обнаружить, что имеется десять альтернативных последовательностей состояний для "a back", каждая из которых имеет вероятность 0,03, но только одна последовательность состояний для "aback" с вероятностью 0,20. Алгоритм Витерби выбирает "aback", но фактически более вероятной является последовательность "a back".

На практике это затруднение не исключает возможности применения данного подхода, но является достаточно серьезным для того, чтобы были предприняты попытки использовать другие подходы. Наиболее часто применяемым из них является алгоритм $\wedge$ декодера A^* , в котором предусмотрено остроумное

использование поиска A^* (см. главу 4) для обнаружения наиболее вероятной последовательности слов.

Идея этого алгоритма состоит в том, что каждая последовательность слов рассматривается как путь через граф, узлы которого обозначены метками в виде слов.

Преемниками любого узла являются все слова, которые могут следовать за словом, являющимся меткой для этого узла; таким образом, граф для всех предложений с длиной, равной или меньшей l , имеет l уровней, причем каждый из этих уровней имеет максимальную ширину w , где W — количество возможных слов. При использовании двухсловной модели стоимость $g(w_1 w_2)$ любой дуги между узлами с метками w_1 и w_2 задается выражением $\log P(w_2 | w_1)$, таким образом, общая стоимость пути, соответствующего некоторой последовательности, может быть представлена следующим образом: $\text{Cost}(w_1 \dots w_n) = -\sum_{i=1}^n \log P(w_i | w_{1:i-1})$. При использовании такого определения стоимости пути задача поиска кратчайшего пути становится полностью эквивалентной задаче поиска наиболее вероятной последовательности слов. Для того чтобы этот процесс был достаточно эффективным, необходимо также иметь хорошую эвристику $h(w_i)$ для оценки стоимости дополнения последовательности слов. Очевидно, что при этом подходе необходимо также учитывать, какая часть речевого сигнала еще не заменена словами из текущего пути. Тем не менее для решения этой задачи еще не были предложены эвристики, которые оказались бы особенно удачными.

Разработка устройства распознавания речи. Качество системы распознавания речи зависит от качества всех ее компонентов — языковой модели, моделей произношения слов, моделей фонем и алгоритмов обработки сигналов, используемых для извлечения спектральных характеристик из акустического сигнала. Выше описано, как может быть составлена языковая модель, и указано, что для ознакомления с подробными сведениями об обработке сигналов следует обратиться к другим учебникам. Кроме того, в данной книге не рассматриваются модели произношения и модели фонем. Структура моделей произношения (таких как модели произношения слова "tomato", показанные на рис. 15.15) обычно разрабатывается вручную. В настоящее время для английского языка и других языков составлены большие словари произношения, но далеко не все они отличаются приемлемой точностью. Структура моделей фонем с тремя состояниями является одинаковой для всех фонем, как показано на рис. 15.16. При использовании таких моделей остается только правильно определить сами вероятности. Как же можно получить такие данные, учитывая то, что для этих моделей могут потребоваться сотни тысяч или миллионы параметров?

Единственный осуществимый метод состоит в том, чтобы проводить обучение этих моделей по фактическим речевым данным, объем которых, безусловно, является

буквально неограниченным. Очередная проблема заключается в том, как организовать такое обучение. Полный ответ на этот вопрос будет дан в главе 20, но в этом разделе мы можем изложить основные идеи. Рассмотрим двухсловную языковую модель; в данной главе описывалось, как провести ее обучение, подсчитывая частоты пар слов в реальном тексте. А можно ли применить такой же подход для определения вероятностей перехода между фонемами в модели произношения? Ответ на этот вопрос будет положительным, но только если кто-то возьмет на себя труд обозначить каждое вхождение каждого слова правильной последовательностью фонем. Это — трудная и чреватая ошибками задача, но она была выполнена для некоторых стандартных наборов данных, соответствующих нескольким часам речевых записей.

Если известны последовательности фонем, то можно оценить вероятности перехода для моделей произношения на основе данных о частотах пар фонем. Аналогичным образом, если дано состояние фонем для каждого фрейма (а для получения этих данных требуется выполнить еще более трудоемкую работу по расстановке меток вручную), то можно оценить вероятности перехода для моделей фонем. Кроме того, если известны состояния и акустические характеристики фонем в каждом фрейме, то можно также оценить качество акустической модели либо непосредственно по данным о частотах (для моделей VQ), либо с использованием методов статистической подгонки (применительно к моделям, в которых применяется сочетание гауссовых распределений; см. главу 20).

Но указанный подход может не получить широкого распространения по таким причинам: данные с метками, проставленными вручную, обходятся дорого и встречаются редко, причем может оказаться, что даже доступные наборы данных с метками, расставленными вручную, не соответствуют тем типам говорящих людей и тем акустическим условиям, которые обнаруживаются в новом контексте распознавания речи. К счастью, алгоритм ожидания-максимизации, или сокращенно алгоритм EM (Expectation Maximization), позволяет изучать модели перехода и модели восприятия НММ без необходимости использования данных с метками. Оценки, полученные на

основе данных с метками, расставленными вручную, могут использоваться для инициализации моделей; после этого управление берет на себя алгоритм EM и обеспечивает обучение моделей, предназначенных для решения предъявленной задачи.

Идея функционирования этого алгоритма является простой: если дана некоторая модель НММ и последовательность наблюдений, то можно использовать алгоритмы сглаживания, описанные в разделах 15.2 и 15.3, для вычисления вероятности каждого состояния на каждом временном интервале, а затем, с помощью несложного дополнения, использовать его для вычисления вероятности каждой

пары "состояние—состояние" на последовательных временных интервалах. Эти вероятности могут рассматриваться как неопределенные метки. С помощью этих неопределенных меток можно оценить новые вероятности перехода и восприятия, после чего повторить процедуру применения алгоритма ЕМ. Такой метод гарантирует увеличение согласования между моделью и данными после каждой итерации и обычно сходится к гораздо более лучшему множеству значений параметров по сравнению с теми, которые были получены с помощью первоначальных оценок, сформированных по данным, размеченным вручную.

В современных системах распознавания речи используются колоссальные наборы данных и мощные вычислительные ресурсы для обучения применяемых в них моделей. В процессе распознавания отдельных сказанных слов в хороших акустических условиях (без фонового шума или реверберации) с помощью словаря из нескольких тысяч слов и при одном дикторе точность может превышать 99%. При распознавании неограниченной непрерывной речи с разными дикторами обычной является точность 60-80%, даже при хороших акустических условиях. А при наличии фонового шума и искажений, характерных для передачи речи по телефону, точность снижается еще больше. Хотя практически применяемые системы совершенствовались в течение нескольких десятилетий, все еще остаются возможности для внедрения новых идей.

15.7. Резюме В настоящей главе рассматривалась общая проблема представления и формирования рассуждений о вероятностных временных процессах. Ниже перечислены основные идеи, изложенные в этой главе. • Изменение состояния мира можно учесть, используя множество случайных переменных для представления этого состояния в каждый момент времени. • Такие представления могут быть спроектированы таким образом, чтобы они удовлетворяли свойству марковости, согласно которому будущее не зависит от прошлого, если дано настоящее. В сочетании с предположением о том, что рассматриваемый процесс является стационарным (т.е. таким, что его законы не изменяются во времени), это позволяет намного упростить представление. • Временная вероятностная модель может рассматриваться как содержащая модель перехода, которая описывает процесс развития, и модель восприятия, описывающая процесс наблюдения. • Основными задачами вероятностного вывода во временных моделях являются фильтрация, предсказание, сглаживание и определение с помощью вычислений

наиболее вероятного объяснения. Каждая из этих задач может быть решена с использованием простых, рекурсивных алгоритмов, время выполнения которых линейно зависит от длины рассматриваемой последовательности. • Немного более подробно были описаны три семейства временных моделей: скрытые марковские модели, фильтры Калмана и динамические байесовские сети (последняя модель включает две первых в качестве частных случаев). • Двумя важными приложениями

для временных вероятностных моделей являются распознавание речи и слежение.

- Если не приняты особые предположения, как при использовании фильтров Калмана, точный вероятностный вывод при наличии многих переменных состояния, по-видимому, становится неосуществимым. Создается впечатление, что на практике эффективным алгоритмом аппроксимации является алгоритм фильтрации частиц.

Библиографические и исторические заметки Многие важные идеи, касающиеся оценки состояния динамических систем, были высказаны математиком К.Ф. Гауссом [526], который сформулировал детерминированный алгоритм наименьших квадратов для решения задачи прогнозирования орбит небесных тел на основании астрономических наблюдений. Российский математик А.А. Марков [983] изложил в своих трудах, посвященных анализу стохастических процессов, подход, получивший в дальнейшем название марковского предположения; он провел оценку свойств марковской цепи первого порядка, состоящей из букв текста поэмы "Евгений Онегин". Важная классификационная работа по фильтрации была выполнена во время Второй мировой войны Винером [1588] для непрерывных временных процессов и Колмогоровым [825] для дискретных временных процессов. Хотя эта научная деятельность привела к важным технологическим усовершенствованиям, достигнутым в течение следующих 20 лет, в ней использовалось представление на основе данных об области определения частот, поэтому многие вычисления оказались весьма громоздкими. Как и было указано Сверлингом [1482] и Калманом [764], непосредственное моделирование стохастических процессов с помощью пространства состояний оказалось намного проще. В последней статье предложен метод прямого вероятностного вывода в линейных системах с гауссовым шумом, который теперь известен под названием фильтров Калмана. Важные результаты в области сглаживания были получены Раухом и др. [1269], и метод, получивший выразительное название метода сглаживания Рауха-Тунга—Стрибеля, все еще широко применяется и в наши дни. Многие ранние результаты исследований были собраны в [531]. В [71] приведена более современная трактовка в байесовском стиле, а также многочисленные ссылки на необъятную литературу по этой теме.

В [241] рассматривается "классический" подход к анализу временных рядов.

Во многих приложениях калмановской фильтрации приходится сталкиваться не только с неопределенными данными восприятия и неизвестными законами, но также и с неопределенной идентификацией; это означает, что если ведется текущий контроль за многочисленными объектами, система должна определить, какие данные наблюдений собраны от тех или иных объектов, прежде чем появится возмож-

ность обновить оценки состояний каждого из этих объектов. В этом заключается проблема $\wedge$ ассоциирования данных [70], [71]. При наличии последовательностей наблюдений и последовательностей слежения (т.е. в довольно благоприятном случае)

существует $n!$ возможных присваиваний последовательностей наблюдений трактам слежения; в правильной вероятностной трактовке должны учитываться все эти варианты присваивания, поэтому можно показать, что такая задача является NP-трудной [301], [302]. По-видимому, на практике хорошо работают методы аппроксимации с полиномиальными затратами времени, основанные на использовании алгоритма МСМС [1180]. Любопытно отметить, что задача ассоциирования данных представляет собой один из экземпляров задачи вероятностного вывода в языке первого порядка; в отличие от большинства задач вероятностного вывода, которые являются чисто пропозициональными, в задаче ассоциирования данных рассматриваются объекты, а также отношение идентификации. Поэтому она тесно связана с вероятностными языками первого порядка, которые упоминались в главе 14. В одной недавно опубликованной работе было показано, что формирование рассуждений об идентичности в общем и ассоциирование данных в частности могут осуществляться в рамках вероятностной инфраструктуры первого порядка [1179].

Скрытая марковская модель и связанные с ней алгоритмы вероятностного вывода и обучения, включая прямой-обратный алгоритм, были разработаны Баумом и Петри [85]. Аналогичные идеи были также высказаны независимо от них в сообществе специалистов по калмановской фильтрации [1269]. Прямой—обратный алгоритм был одним из основных предшественников более общей формулировки алгоритма ЕМ [383]; см. также главу 20. Описание процедуры сглаживания в постоянном пространстве впервые появилось в [127], так же как и алгоритм, действующий по принципу "разделяй и властвуй", который должен быть разработан при решении упр. 15.3.

Динамические байесовские сети (Dynamic Bayesian network — DBN) могут рассматриваться как способ разреженного кодирования марковского процесса; они были впервые применены в искусственном интеллекте Дином и Канадзава [361], Николсоном [1137] и Кьерульфом [803]. Последняя работа включает описание общего дополнения к системе сетей доверия Hugin, которое предоставляет необходимые средства для формирования и компиляции динамической байесовской сети.

Динамические байесовские сети нашли широкое применение для моделирования различных сложных процессов движения в системах машинного зрения [698], [718].

В [1443] явно показана связь между моделями НММ и сетями DBN, а также между прямым—обратным алгоритмом и алгоритмом распространения в байесовской сети.

Результаты дальнейшего обобщения фильтров Калмана (и других статистических моделей) опубликованы в [1314].

Особенно интересной является история алгоритма фильтрации частиц, описанного в разделе 15.5. Первые алгоритмы формирования выборок для фильтрации были разработаны Хендшиным и Мейном [611], которые принадлежали к сообществу специалистов по теории управления, а идея повторного формирования выборок, лежащая в основе алгоритма фильтрации частицы, появилась в одной из публикаций в советском журнале по системам управления [1639]. В дальнейшем этот алгоритм был еще раз открыт в статистике и назван последовательным повторным формированием выборок с учетом их важности, или SIR (Sequential Importance-sampling Resampling) [939], [1315], в теории управления, под названием фильтрация частиц [581], [582], в искусственном интеллекте, под названием выживание наиболее при-

способленного [769], и в области машинного зрения, под названием конденсация [719]. Статья Канадзава и др. [769] включает одно усовершенствование, называемое обращением свидетельства, согласно которому выборка в состоянии на момент времени $t+1$ осуществляется условно, в зависимости от состояния во время t и свидетельства во время $t+1$. Это позволяет обеспечить непосредственное влияние свидетельства на формирование выборок; в [406] было показано, что такой метод позволяет уменьшить ошибку аппроксимации.

Другие методы для аппроксимированной фильтрации включают алгоритм вырожденной модели МСМС [991] и метод факторизованной аппроксимации [164]. Оба метода обладают тем важным свойством, что ошибка аппроксимации не расходится во времени. Кроме того, для временных моделей были разработаны вариационные методы (см. главу 14). В [547] обсуждается алгоритм аппроксимации для факторной модели НММ — сети DBN, в которой две или несколько независимо развивающихся марковских цепей связаны с помощью разделяемого потока наблюдений. В [747] рассматривается целый ряд других приложений. Свойства продолжительностей смешивания обсуждаются в [959] и [1164].

Предыстория систем распознавания речи началась в 1920-х годах с создания игрушки Radio Rex— игрушечной собачки, активизируемой голосом. Собачка Rex прыгала в ответ на звуковые частоты около 500 Гц, которые соответствуют звучанию гласной [eh] в слове "Rex!". Немного более серьезная работа в этой области началась после Второй мировой войны. В АТТ Bell Labs была создана система для распознавания отдельно произносимых цифр [333] с помощью простого согласования акустических характеристик с шаблонами. Вероятности перехода между фонемами впервые использовались в системе, созданной в лондонском University College Фраем [508] и Денесом [384]. Начиная с 1971 года Агентство перспективных исследовательских программ (Defense Advanced Research Projects Agency— DARPA) Министерства обороны США финансировало четыре конкурирующих пятилетних проекта по разработке систем распознавания речи с

высокой эффективностью. Победителем этого соревнования и единственной системой, соответствующей требованиям по распознаванию словаря из 1000 слов с точностью 90%, стала система Harpy8, разработанная в университете CMU [952], [953]. Окончательная версия системы Harpy была создана на основе системы Dragon, разработанной аспирантом CMU Джеймсом Бейкером [62]; в системе Dragon впервые использовались скрытые марковские модели для распознавания речи. Почти одновременно с этим в компании IBM была разработана еще одна система на основе модели НММ [730]. Начиная с этого времени вероятностные методы в целом и скрытые марковские модели в частности стали доминировать в исследованиях и разработках по распознаванию речи. Последние годы характеризуются постепенным прогрессом, применением все более крупных наборов данных и моделей, а также ужесточением конкуренции в области решения все более реалистичных речевых задач. Некоторые исследователи изучали возмож8 Система Hearsay-II [440], занявшая второе место в этом соревновании, испытала значительное влияние со стороны других направлений исследований в области искусственного интеллекта, поскольку в ней использовалась архитектура классной доски. Она представляла собой экспертную систему на основе правил с многочисленными, более или менее независимыми, модульными источниками знаний, взаимодействовавшими через общую классную доску, на которой они могли писать и читать. Системы классной доски стали основой современных архитектур пользовательского интерфейса.

ность использования сетей DBN вместо моделей НММ для распознавания речи с целью применения большей выразительной мощи сетей DBN для более полного охвата сложного скрытого состояния речевого аппарата [1286], [1652].

По проблематике распознавания речи имеется несколько хороших учебников: [568], [699], [731], [1263]. В [1550] собраны важные статьи в этой области, включая некоторые учебные руководства. Материал, представленный в данной главе, основан на обзоре, приведенном в [781], и на учебнике [756]. Результаты исследований в области распознавания речи публикуются в журналах Computer Speech and Language, Speech Communications и IEEE Transactions on Acoustics, Speech, and Signal Processing, в сборнике материалов семинаров DARPA Workshops on Speech and Natural Language Processing, а также в трудах конференций Eurospeech, ICSLP и ASRU.

Упражнения 15.1. Покажите, что любой марковский процесс второго порядка может быть переоформлен в виде марковского процесса первого порядка с дополненным множеством переменных состояния. Может ли такое преобразование всегда быть выполнено экономно, т.е. без увеличения количества параметров, необходимых для определения модели перехода?

15.2. В этом упражнении рассматривается, что происходит с вероятностями в мире задачи с зонтиком по мере приближения к пределу в длинных временных последовательностях. а) Предположим, что наблюдается нескончаемая последовательность дней, в которых директор появляется на работе с зонтиком или без зонтика.

Покажите, что, по мере того, как проходят эти дни, вероятность дождя в текущий день возрастает монотонно в направлении к фиксированной точке. Рассчитайте эту фиксированную точку. б) Теперь рассмотрим задачу прогнозирования все дальше и дальше в будущее по данным только первых двух наблюдений с зонтиком. Вначале рассчитайте вероятность $P(R_{2+k} \mid U_{1:2})$ для $k=1, \dots, 20$ и нанесите результаты на график. Вы должны обнаружить, что эта вероятность сходится в фиксированной точке. Рассчитайте точное значение для этой фиксированной точки.

15.3. В данном упражнении разрабатывается вариант прямого—обратного алгоритма, приведенного в листинге 15.1, характеризующийся эффективным использованием пространства. Требуется вычислить значение $P(x_k \mid e_{1:t})$ для $k=1, \dots, t$. Такую задачу можно решить с помощью подхода по принципу "разделяй и властвуй". а) Для упрощения примем предположение, что значение t является нечетным, и допустим, что промежуточная точка определяется выражением $h = (t+1)/2$. Покажите, что значение $p(x_k \mid e_{1:t})$ можно вычислить для $k=1, \dots, h$, если даны лишь первоначальное прямое сообщение $e_{1:h}$, обратное сообщение $e_{h+1:t}$ и свидетельство $e_{1:h}$. б) Покажите аналогичный результат для второй половины последовательности.

в) Если даны результаты выполнения заданий 15.3, а и 15.3, б, рекурсивный алгоритм "разделяй и властвуй" можно сформировать, вначале выполнив прогон в прямом направлении вдоль последовательности, а затем в обратном направлении от ее конца, сохранив лишь необходимые сообщения в середине и в концах. Затем алгоритм вызывается на каждой половине последовательности. Составьте подробный листинг этого алгоритма. г) Определите временную и пространственную сложность алгоритма как функцию от t , длины последовательности. Как изменятся эти результаты, если входные данные будут разделены больше чем на две части?

15.4. На с. 732 была кратко описана ошибочная процедура определения наиболее вероятной последовательности состояний, в которой используется последовательность наблюдений. В этой процедуре предусматривается поиск в каждом временном интервале наиболее вероятного состояния, применение операции сглаживания и возврат последовательности, в которой собраны эти состояния.

Покажите, что при использовании некоторых временных/х вероятностных моделей и последовательностей наблюдений эта процедура возвращает невозможную

последовательность состояний (т.е. такую последовательность, что ее апостериорная вероятность равна нулю).

15.5. Часто возникает необходимость осуществлять текущий контроль за системой с непрерывным состоянием, поведение которой переключается непредсказуемым образом с одного режима на другой в множестве из k различных режимов. Например, самолет, пытающийся избежать поражения ракетой, может выполнить ряд различных маневров, которые попытается отследить система управления ракетой. Представление такой модели переключательного фильтра Калмана в виде байесовской сети показано на рис. 15.17. © © Рис. 15.17. Представление переключательного фильтра Калмана в виде байесовской сети. Переключательная переменная St представляет собой дискретную переменную состояний, значение которой определяет модель перехода для непрерывных переменных состояний Xt . Для любого дискретного состояния i модель перехода $P(X_{t+1} | x_t, St=i)$ представляет собой линейную гауссову модель, так же как и в обычном фильтре Калмана. Модель перехода для дискретного состояния, $P(St+1 | St)$, может рассматриваться как матрица, по аналогии со скрытой марковской моделью

а) Допустим, что дискретное состояние st имеет k возможных значений и что априорная непрерывная оценка состояния $P(x_0)$ представляет собой многомерное гауссово распределение. Покажите, что предсказание $P(x_t)$ представляет собой сочетание гауссовых распределений, т.е. такую взвешенную сумму гауссовых распределений, что веса в сумме составляют 1. б) Покажите, что если текущая оценка непрерывного состояния $P(x_t | e_{1:t})$ представляет собой сочетание t гауссовых распределений, то в общем случае обновленная оценка состояния $P(x_{t+1} | e_{1:t+1})$ будет представлять собой сочетание $k \cdot m$ гауссовых распределений. в) Какой аспект временного процесса представляют веса в сочетании гауссовых распределений?

Результаты выполнения заданий 15.5, а и 15.5, б, вместе взятые, показывают, что объем этого представления апостериорных вероятностей беспредельно возрастает даже при использовании переключательных фильтров Калмана, которые являются простейшими гибридными динамическими моделями.

15.6. Дополните недостающий этап вывода уравнения 15.17 — первый этап обновления для одномерного фильтра Калмана.

15.7. Рассмотрим ход выполнения операции обновления дисперсии в уравнении 15.18. а) Нанесите на график значения выражения ct^2 как функции от t при наличии различных значений для ax^2 и a^2 . б) Покажите, что эта операция обновления имеет фиксированную точку, такую, что $a^2 a^2 - \sigma^2$, по мере того как $t \rightarrow \infty$, и рассчитайте значение a^2 . в) Дайте качественное объяснение того, что происходит по мере того, как $ax^2 \rightarrow 0$ и $a^2 \rightarrow 0$.

15.8. Покажите, как представить модель НММ в виде рекурсивной реляционной вероятностной модели в соответствии с предложением, приведенным в разделе 14.6.

15.9. В этом упражнении более подробно анализируется устойчивая к отказам модель для датчика аккумулятора, показанная на рис. 15.11, а. а) График на рис. 15.11, 5 обрывается при $t=32$. Дайте качественное описание того, что должно произойти по мере стремления t к бесконечности, $t \rightarrow \infty$, если датчик продолжает выдавать показания 0. б) Предположим, что температура окружающей среды влияет на датчик аккумулятора таким образом, что по мере возрастания температуры временные отказы становятся все более вероятными. Покажите, как дополнить с учетом этого структуру сети DBN, приведенную на рис. 15.11, а, и объясните, какие изменения потребуются внести в таблицы условных вероятностей. в) После определения новой структуры этой сети, может ли робот использовать показания датчика аккумулятора для вероятностного вывода данных о текущей температуре?

15.10. Рассмотрите задачу применения алгоритма устранения переменной к сети DBN для задачи с зонтиком, развернутую на три времени/х среза, в которой

используется запрос $P(R_3 \setminus \{U_2, I_3\})$. Покажите, что сложность этого алгоритма (размер наибольшего фактора) является одинаковой, независимо от того, устраняются ли переменные, касающиеся дождя, в прямом или обратном порядке.

15.11. В модели произношения слова "tomato", приведенной на рис. 15.15, допускается коартикуляция с первой гласной, поскольку даны две возможные фонемы. Альтернативный подход состоит в использовании трехфонемной модели, в которой фонема $[ow(t,m)]$ автоматически включает изменение в гласном звуке. Составьте полную трехфонемную модель для слова "tomato", включая вариант, касающийся диалекта.

15.12. Вычислите наиболее вероятный путь через модель НММ, приведенную на рис. 15.16, для выходной последовательности $[C_1, C_2, C_3, C_4, C_6, C_7]$.

Кроме того, приведите значение его вероятности.

Глава 16. Принятие простых решений

16 Принятие простых РЕШЕНИЙ В этой главе показано, как должен принимать решения агент, чтобы получать то, что ему требуется, по крайней мере в среднем количестве случаев.

В данной главе мы вернемся к идее теории полезности, которая была представлена в главе 13, и покажем, как можно объединить эту теорию с теорией вероятностей, чтобы создать агента, действующего на основе теории решений, т.е. агента, способного принимать рациональные решения с учетом того, в чем он убежден и к чему стремится. Такой агент может принимать решения в таких ситуациях, когда из-

за неопределенности и конфликтующих целей логический агент остается неспособным что-либо решить. По существу, агент, основанный на цели, может лишь проводить бинарное различие между хорошими (целевыми) и плохими (нецелевыми) состояниями, тогда как агент, основанный на теории решений, пользуется непрерывными показателями качества состояния.

В разделе 16.1 изложен основной принцип теории решений— максимизация ожидаемой полезности. В разделе 16.2 показано, что поведение любого рационального агента можно понять, определив функцию полезности, которую он максимизирует. В разделе 16.3 более подробно обсуждаются характерные особенности функций полезности и, в частности, то, как они связаны с отдельными величинами, такими как деньги. В разделе 16.4 показано, как обращаться с функциями полезности, которые зависят от нескольких величин. В разделе 16.5 описана реализация систем принятия решений. В частности, в этом разделе описан формальный подход, называемый сетями принятия решений (известный также под названием диаграмм влияния); такие сети являются дополнением байесовских сетей, в которое включены действия и показатели полезности. В оставшейся части этой главы рассматриваются проблемы, связанные с применением теории решений в экспертных системах.

16.1. Совместный учет убеждений и желаний В книге Port-Royal Logic ("Логика Пор-Ройяль"), написанной в 1662 году, французский философ Арно изложил следующую мысль.

"Чтобы судить о том, что следует делать, чтобы получить хорошее или избежать плохого, необходимо рассматривать не только хорошее и плохое само по себе, но и вероятность того, произойдет ли оно или не произойдет, а также рассматривать математически пропорцию, в которой все эти обстоятельства встречаются вместе."

В современной литературе вместо понятий хорошего или плохого применяется понятие полезности, но общий принцип остается таким же. Для описания предпочтений агента, с помощью которых он различает состояния мира, применяется функция полезности, которая присваивает состоянию единственное числовое значение, чтобы показать, насколько оно желательно. Полезности объединяются с вероятностями действий для определения ожидаемой полезности каждого действия.

В этой главе будет использоваться запись $u(S)$ для обозначения полезности состояния S с точки зрения агента, принимающего решения. На данный момент мы будем рассматривать состояния как полные снимки параметров мира, по аналогии с ситуациями, которые рассматривались в главе 10. На первых порах такой подход позволяет упростить изложение данной темы, но когда придется отдельно

определять полезность каждого возможного состояния, он может стать довольно громоздким.

В разделе 16.4 будет показано, как можно выполнить в некоторых обстоятельствах декомпозицию состояний в целях присваивания значений полезности.

Любое недетерминированное действие A имеет возможные результирующие состояния $Result_i(A)$, где индекс i пробегает по различным результатам. Прежде чем осуществить действие A , агент присваивает вероятность $P(Result_i(A) \mid Do(A), E)$ каждому результату, где E представляет собой сумму доступных агенту свидетельств о мире, а $Do(A)$ — высказывание, согласно которому действие A выполняется в текущем состоянии. Таким образом, можно вычислить $\hat{U}$ ожидаемую полезность действия с учетом свидетельства, $EU(A \mid E)$, с использованием следующей формулы:

$$EU(A \mid E) = \sum_i P(Result_i(A) \mid Do(A), E) U(Result_i(A))$$
 А6.1) i Принцип "сЭч максимальной ожидаемой полезности (Maximum Expected Utility — MEU) гласит, что рациональный агент должен выбирать действие, которое максимизирует ожидаемую полезность для агента. А если бы с помощью этого уравнения потребовалось выбрать наилучшую последовательность действий, то пришлось бы перенумеровать все последовательности действий и выбрать наилучшую; очевидно, что такой подход при наличии длинных последовательностей действий становится неосуществимым. Поэтому данная глава посвящена главным образом описанию простых решений (которые обычно предусматривают единственное действие), а в следующей главе будут представлены новые методы, позволяющие эффективно применять последовательности действий.

В определенном смысле принцип MEU может рассматриваться как определение всего искусственного интеллекта. Все, что должен делать интеллектуальный агент, сводится к вычислению различных количественных величин, определению максимальной полезности по всем своим действиям, а затем осуществлению этих действий. Но сказанное не означает, что тем самым проблема искусственного интеллекта решена по определению!

Хотя принцип MEU позволяет определить правильное действие, которое должно быть выполнено в любой задаче принятия решений, связанный с этим объем вычислений может оказаться неосуществимым, а иногда нелегко даже полностью сформулировать саму задачу. Для того чтобы определить начальное состояние мира, требуется применить восприятие, обучение, представление знаний, логический и вероятностный вывод. Для вычисления вероятностей $P(Result_i(A) \mid Do(A), E)$ необходимо иметь полную причинную модель мира, а также, как было показано в главе 14, осуществлять NP-трудный вероятностный вывод в байесовских сетях. Для вычисления полезности каждого состояния, $U(Result_i(A))$, часто требуется поиск или планирование, поскольку агент не может определить, насколько хорошим

является состояние, до тех пор, пока не узнает, чего он может достичь из этого состояния.

Поэтому теория принятия решений — это не панацея, которая позволила бы решить всю проблему искусственного интеллекта. С другой стороны, она предоставляет инфраструктуру, с помощью которой можно определить, где должны найти свое место те или иные компоненты любой системы искусственного интеллекта.

Очевидно, что принцип MEU связан с идеей показателей производительности, которая была представлена в главе 2. Эта основная идея очень проста. Рассмотрим варианты среды, действия в которых могут привести к получению агентом данной конкретной истории восприятий, а также предположим, что существует возможность спроектировать несколько разных агентов. & Если агент максимизирует функцию полезности, правильно отражающую показатели производительности, по которым можно судить о его поведении, то этот агент достигнет наивысших возможных значений показателей производительности, если будет проведено усреднение полученных значений показателей по всем вариантам среды, в которые может быть помещен этот агент. Это определение представляет собой также основное обоснование для самого принципа MEU. Хотя на первый взгляд такое определение может показаться содержащим тавтологию, фактически оно воплощает в себе очень важный переход от глобального, внешнего критерия рациональности (по результатам оценки производительности на основании историй восприятия в среде) к локальному, внутреннему критерию, основанному на максимизации функции полезности применительно к следующему состоянию.

В данной главе будут рассматриваться только единственные, или $\wedge$ единоразовые решения, тогда как в главе 2 были определены показатели производительности, измеряемые по историям восприятия в среде, которые обычно становятся результатом многих решений. В следующей главе, посвященной описанию последовательных решений, будет показано, как можно согласовать эти два подхода к оценке функционирования агента.

16.2. Основы ТЕОРИИ ПОЛЕЗНОСТИ Интуитивно ясно, что принцип максимальной ожидаемой полезности (Maximum Expected Utility — MEU) может стать основой приемлемого способа принятия решений, но нет никаких оснований полагать, что это — единственный рациональный способ. В конечном итоге, на каком основании следует придавать такое значение подходу, в котором предусматривается максимизация средней полезности? Почему бы не попытаться максимизировать сумму кубов возможных полезностей или не рассмотреть подход с минимизацией наихудшей возможной потери? Кроме того,

может ли агент рационально организовать свои действия, лишь выразив отношение предпочтения между состояниями и не присваивая им числовых значений?

Наконец, почему вообще должна существовать функция полезности с требуемыми свойствами? Вполне допустимо такое предположение, что рациональный агент может иметь структуру предпочтений, являющуюся слишком сложной для того, чтобы ее можно было представить с помощью такого простого метода, как присваивание единственного действительного числового значения каждому состоянию.

Ограничения, налагаемые на рациональные предпочтения. Ответы на эти вопросы можно получить, записав некоторые ограничения, распространяющиеся на предпочтения, которые должен иметь рациональный агент, а затем показав, что принцип MEU можно вывести из этих ограничений. Для описания предпочтений агента будут использоваться приведенные ниже обозначения.

$A \succ B$. Вариант A предпочтительнее, чем B . $A \sim B$. Агент безразличен к выбору между вариантами A и B . $A \succeq B$. Агент предпочитает вариант A варианту B или безразличен к выбору между ними. Теперь напрашивается очевидный вопрос, к какого рода понятиям относятся A и B ? Если действия агента являются детерминированными, то A и B обычно представляют собой конкретные, полностью заданные результирующие состояния этих действий. В более общем, недетерминированном случае лотереи представляют собой " $\wedge$ лотереи. Лотерея по сути является распределением вероятностей по множеству фактических результатов ("призов" в лотерее). Лотерея L с возможными результатами $C_1, \dots, C_n$, которые могут возникать с вероятностями $p_1, \dots, p_n$ записывается следующим образом:

$L = [p_1, C_1; p_2, C_2; \dots; p_n, C_n]$ (Лотерея только с одним результатом может быть записана либо как A , либо как $[1, A]$.) Вообще говоря, каждым результатом лотереи может быть атомарное состояние или другая лотерея. Основная проблема теории полезности состоит в том, чтобы понять, как предпочтения между сложными лотереями связаны с предпочтениями между основополагающими состояниями в этих лотереях.

Для этого мы должны наложить на это отношение предпочтения приемлемые ограничения, во многом аналогично тому, как были наложены ограничения рациональности на степени уверенности для получения аксиом вероятностей в главе 13.

Одно из разумных ограничений состоит в том, что предпочтение должно быть транзитивным, т.е. если $A \succ B$ и $B \succ C$, то следует ожидать, что $A \succ C$. Свойство транзитивности можно обосновать, показав, что агент, предпочтения которого не соответствуют свойству транзитивности, будет вести себя нерационально.

Предположим, например, что агент имеет нетранзитивное предпочтение $A \succ B \succ C \succ A$, где A , B и C — товары, которые могут свободно обмениваться друг на друга. Если агент в настоящее время имеет товар A , то можно предложить обменять C на A и

немного наличных. Агент предпочитает товар С и поэтому должен быть готов предос-

После этого мы вернемся к такому же положению, с которого начинали, за исключением того, что теперь агент имеет меньше денег (рис. 16.1, а). Такое движение по циклу может продолжаться до тех пор, пока у агента больше не останется денег.

Очевидно, что в этом случае агент не действовал рационально.

(\-p)(\-q) а) б) Рис. 16.1. Пример нарушения свойства транзитивности: циклическое повторение обменов товаром, которое показывает, что нетранзитивные предпочтения А у В у С у А приводят к нерациональному поведению (а); графическая иллюстрация аксиомы декомпозируемости (б) Приведенные ниже шесть ограничений известны как аксиомы теории полезности. Они определяют самые очевидные семантические ограничения, которые распространяются на предпочтения и лотереи. • $\wedge$ Упорядочиваемого». Если даны два состояния, то рациональный агент должен либо предпочесть одно другому, либо рассматривать их оба как в равной степени предпочтительные. Это означает, что агент не может избежать принятия решений. Как было сказано на с. 637, отказ сделать ставку аналогичен тому, что агент отказывается предпринимать активные действия и предоставляет все дальнейшее естественному течению событий.

$(A \succ B) \vee (B \succ A) \vee (A \sim B)$ • $\wedge$ Транзитивность. Если даны три состояния, такие, что агент предпочитает состояние А состоянию В и предпочитает состояние В состоянию С, то агент должен предпочесть состояние А состоянию С.

$(A \succ B) \wedge (B \succ C) \Rightarrow (A \succ C)$ • $\wedge$ Непрерывность. Если некоторое состояние В находится в порядке предпочтений между А и С, то существует некоторая вероятность р того, что рациональный агент будет безразличен к тому, чтобы определенно выбрать в или лотерею, результатом которой является состояние А, с вероятностью р, и состояние С, с вероятностью 1-р.

лотерею, результатом которой является состояние А, с вероятностью р, и состояние С, с вероятностью 1 -р.

$A \succ B \succ C \Rightarrow \exists p [p, A; 1-p, C] \sim B$ • $\wedge$ Заменяемость. Если агент безразличен к выбору между двумя лотереями, А и В, то агент безразличен и к выбору между двумя более сложными лотереями, которые являются одинаковыми, за исключением того, что в одной из них подставлена лотерея в вместо А. Такое свойство сохраняется независимо от вероятностей и от других результатов лотерей.

$A \sim B \Rightarrow [p, A; 1-p, C] \sim [p, B; 1-p, C]$ • $\wedge$ Монотонность. Предположим, что две лотереи имеют два одинаковых результата, айв. Если агент предпочитает состояние А

состоянию B, то агент должен предпочесть лотерею, которая имеет более высокую вероятность для состояния A (и наоборот).

$A \cup B \Rightarrow (p > q \Leftrightarrow [p, A; 1-p, B] \succ [q, A; 1-q, B]) \cdot \wedge$ Декомпозируемость. Сложные лотереи можно свести к простым, используя законы вероятностей. Это свойство получило название правила "экономии количества ставок", поскольку согласно ему две последовательные лотереи могут быть сжаты в одну эквивалентную лотерею¹ (см. рис. 16.1, б). $[p, A; 1-p, [q, B; 1-q, C]] \sim [p, A; A-p \cdot q, B; A-p \cdot (1-q), C]$ В начале была Полезность Обратите внимание на то, что в аксиомах теории полезности ничего не сказано о самой полезности; в них речь идет только о предпочтениях.

Предполагается, что основным свойством рациональных агентов является умение пользоваться предпочтениями, а существование функции полезности следует из аксиом полезности, как показано ниже.

1. Принцип полезности Если предпочтения агента подчиняются аксиомам полезности, то существует функция u с реальными значениями, областью определения которой являются состояния, такая, что $u(A) > u(B)$ тогда и только тогда, когда A является более предпочтительным, чем B, и $u(A) = u(B)$ тогда и только тогда, когда агент безразличен к выбору между A и B.

$u(A) > u(B) \Leftrightarrow A \succ B$ $u(A) = u(B) \Leftrightarrow A \sim B$ 2. Принцип максимальной ожидаемой полезности Полезность лотереи равна сумме произведений вероятности каждого результата на полезность этого результата.

¹ Мы можем учесть саму привлекательность игры на деньги, включив события игры на деньги в описание состояния; например, действие "взять с собой 10 долларов и сделать ставку" может рассматриваться как более предпочтительное, чем "взять с собой 10 долларов и не сделать ставку".

Другими словами, как только будут определены вероятности и полезности всех возможных результирующих состояний, полезность сложной лотереи, охватывающей эти состояния, становится полностью определенной. Поскольку результатом недетерминированного действия является лотерея, существует возможность вывести это правило принятия решений на основании принципа MEU из уравнения 16.1.

Важно помнить, что из существования функции полезности, которая описывает поведение агента по выбору предпочтений, не обязательно следует, что агент явно максимизирует эту функцию полезности в своих собственных размышлениях. Как было показано в главе 2, рациональное поведение может быть выработано с помощью самых различных способов, причем некоторые из них являются более эффективными по сравнению с явной максимизацией полезности. Но наблюдение за предпочтениями рационального агента дает возможность составить функцию

полезности, которая служит представлением того, что фактически пытается достичь агент своими действиями.

16.3. Функции полезности Полезность — это функция, которая отображает состояния на действительные числа. Исчерпывается ли на этом все, что можно сказать о функциях полезности?

Строго говоря, так оно и есть. С учетом соблюдения ограничений, перечисленных выше, агент может иметь любые предпочтения, какие пожелает. Например, агент может предпочесть держать на своем банковском счете такое количество долларов, которое измеряется простым числом; в этом случае, если ему на счет поступило 16 долларов, он может растратить 3 доллара. Агент вправе предпочесть "зубастый"

Ford Pinto выпуска 1973 года сверкающему новому автомобилю Mercedes. Кроме того, предпочтения могут взаимодействовать друг с другом; например, агент вправе предпочитать иметь количество долларов, выражающихся простыми числами, когда он владеет автомобилем Ford Pinto, а когда в его собственности находится Mercedes, он может предпочитать иметь больше долларов, чем меньше.

Но если бы все функции полезности были такими же произвольными, как эта, то теория полезности не могла бы оказать нам значительную помощь, поскольку пришлось бы понаблюдать за предпочтениями агента во всех возможных сочетаниях обстоятельств, прежде чем получить возможность делать какие-либо предсказания в отношении его поведения. К счастью, предпочтения реальных агентов обычно в большей степени укладываются в определенную систему. И наоборот, существуют систематические способы проектирования функций полезности, которые после установки их в искусственном агенте вынуждают этого агента вырабатывать варианты поведения таких типов, какие нам требуются.

Полезность денег Корни теории полезности скрываются в экономике, а экономика предоставляет одного очевидного кандидата для использования в качестве меры полезности — деньги (или, более конкретно, общий суммарный капитал агента). Почти универсальная способность денег к обмену на всевозможные товары и услуги подсказывает, что деньги играют важную роль в функциях полезности людей. (В действительно-

сти большинство людей рассматривают экономику как науку о деньгах, тогда как фактически по своему происхождению слово экономия относится к управлению хозяйством, а современное направление экономических исследований нацелено на обоснование рационального выбора.) Если мы ограничим свое внимание только такими действиями, которые влияют на количество денег, имеющихся у агента, то, как правило, обнаружим, что при всех прочих равных условиях агент предпочитает иметь больше денег, а не меньше.

Таким образом, можно утверждать, что агент проявляет склонность к $\wedge$ монотонному предпочтению применительно к определенным суммам денег. Однако этого недостаточно, чтобы можно было использовать деньги в качестве значения функции полезности, поскольку в этом определении ничего не сказано о предпочтениях между лотереями, связанными с денежными ставками.

Представьте себе, что вы одержали победу над всеми соперниками в телевизионном игровом шоу, и ведущий предлагает вам выбор: забирайте свой приз в 1 000 000 долларов или сделайте на него ставку, бросив монету. Если выпадет орел, вы ничего не получите, а если выпадет решка, то получите 3 000 000 долларов. Если вы — такой же, как большинство людей, то откажетесь от этой ставки и положите в карман миллион.

Является ли это решение нерациональным? При условии, что вы уверены в подлинности этой монеты, $\wedge$ ожидаемое денежное значение (Expected Monetary Value — EMV) этой ставки равно $1/2 \cdot 0 + 1/2 \cdot 3\,000\,000 = 1\,500\,000$ долларов, а значение EMV взятия первоначального приза, безусловно, равно 1 000 000 долларов, т.е. меньше. Но такой расчет не обязательно означает, что принятие предложения сделать эту ставку является лучшим решением. Предположим, что мы используем запись S_n для обозначения состояния, соответствующего обладанию всей суммой n долларов, а ваши текущие накопления составляют k долл. В таком случае ожидаемые полезности двух действий, соответствующих принятию предложения сделать ставку (Accept) и отказу от него (Decline), выражаются следующими соотношениями:

$EU(\text{Accept}) = 1/2 U(S_k) + 1/2 U(S_{k+3\,000\,000})$
 $EU(\text{Decline}) = U(S_{k+1\,000\,000})$

Чтобы определить, что делать, необходимо присвоить значения полезности результирующим состояниям. Полезность не является прямо пропорциональной денежному значению, поскольку полезность вашего первого миллиона (связанная с положительным изменением образа жизни) очень высока (по крайней мере, все так говорят), тогда как полезность еще одного миллиона гораздо меньше.

Предположим, что присвоено значение полезности 5 текущему финансовому состоянию (S_k), 10 — состоянию $S_{k+3\,000\,000}$ и 8 — состоянию $S_{k+1\,000\,000}$. В таком случае рациональное действие должно состоять в том, чтобы отказаться от предложения сделать ставку, поскольку ожидаемая полезность его принятия равна только 7.5 (меньше 8, что соответствует отказу от этого предложения). С другой стороны, предположим, что некто уже имеет 500 000 000 долларов на банковском счете (и, вполне можно предположить, участвует в игровых шоу только ради развлечения). В таком случае указанное предложение, по-видимому, является вполне приемлемым,

так как дополнительная польза от появления 503-го миллиона, скорее всего, почти не отличается от той, которая соответствует получению 501-го миллиона.

В своем оригинальном исследовании фактически применяемых функций полезности Грейсон [589] обнаружил, что полезность денег почти точно пропорциональна логарифму их количества (предположение об этом впервые высказал Бернулли [111]; см. упр. 16.3). Одна конкретная кривая, относящаяся к данным о предпочтениях некоего мистера Берда, показана на рис. 16.2, а. Полученные Грейсоном данные о предпочтениях мистера Берда совместимы со следующей функцией полезности для диапазона от $l = -150\,000$ долларов до $l = 800\,000$ долларов:

$U(S_k + n) = -263.31 + 22.09 \log(l + 150\,000)$ и и а) б) Рис. 16.2. Кривая полезности денег: эмпирические данные о предпочтениях мистера Берда, измеренные в ограниченном диапазоне (а); типичная кривая для полного диапазона (б) Не следует считать, что это — безусловно верная функция полезности для денежных значений, но создается впечатление, что большинство людей руководствуются функцией полезности, которая является вогнутой в области положительных значений денежных накоплений. Брать в долг обычно считается катастрофическим решением, но предпочтения между различными уровнями задолженности могут показывать обратное поведение по отношению к вогнутости, связанной с положительными денежными накоплениями. Например, если некто уже имеет долг 10 000 000 долларов, то вполне может принять предложение сделать ставку на подбрасывание подлинной монеты, с выигрышем в 10 000 000 долларов после выпадения орла и проигрышем в 20 000 000 долларов после выпадения решки². Такое поведение соответствует S-образной кривой, показанной на рис. 16.2, б.

Если мы ограничим наше внимание положительной частью таких кривых, где уклон постепенно уменьшается, то для любой лотереи L полезность решения, при котором придется столкнуться с выбором в этой лотерее, меньше, чем полезность получения ожидаемого денежного значения в этой лотерее без всяких условий:

$U(L) < U(SEm(L))$ 2 Такое поведение можно назвать отчаянным, но оно рационально, если человек уже находится в безнадежной ситуации.

Это означает, что агенты с кривыми полезности такой формы $\wedge$ избегают риска: они предпочитают надежное приобретение, пусть даже с меньшей отдачей по сравнению с ожидаемым денежным значением возможной ставки. С другой стороны, в "безнадежной" области с большими отрицательными накоплениями на рис. 16.2, б поведение характеризуется $\wedge$ стремлением к риску. Сумма, приобретаемая агентом вместо лотереи, называется $\wedge$ эквивалентом определенности лотереи. Исследования показали, что большинство людей предпочитают 400 долларов вместо ставки, розыгрыш которой позволяет получить

в половине случаев 1000 долларов, а в другой половине случаев получить 0 долларов; это означает, что эквивалентом определенности для этой лотереи является 400 долларов. Разность между ожидаемым денежным значением лотереи и ее эквивалентом определенности называется $\wedge$ страховой премией. Неприятие риска является основой индустрии страхования, поскольку такое поведение означает, что страховые премии становятся положительными. Люди предпочитают заплатить небольшую страховую премию, нежели делать ставку на всю стоимость своего дома против шанса потери его в огне. А с точки зрения страховой компании цена отдельного дома весьма мала по сравнению с общими резервами этой компании. Это означает, что кривая полезности страховщика в таком небольшом регионе остается приблизительно линейной и для этой компании ставка на стоимость дома против страховой премии является беспримысленной.

Обратите внимание на то, что при небольших изменениях в уровне денежных накоплений по сравнению с текущими накоплениями почти любая кривая полезности должна быть приблизительно линейной. Агент, который руководствуется такой линейной кривой, называется $\wedge$ нейтрально относящимся к риску. Поэтому в случае ставок на небольшие суммы предполагается соблюдение свойства нейтрального отношения к риску. В определенном смысле это свойство является обоснованием упрощенной процедуры, в которой применяются небольшие ставки для оценки вероятностей, а также обоснованием аксиом вероятностей, приведенных в главе 13.

Субъективные суждения и присущее человеку свойство ошибаться Теория принятия решений является $\wedge$ нормативной — она описывает, как должен действовать рациональный агент. Область применения экономической теории удалось бы значительно расширить, если бы существовала также какая-то $\wedge$ описательная теория фактического принятия решений людьми.

Однако имеются экспериментальные свидетельства, которые показывают, что люди систематически нарушают аксиомы теории полезности. Один из примеров такого поведения приведен психологами Тверским и Канеманом [1523], который основан на примере экономиста Алле [14]. Участникам проводимого им эксперимента был предоставлен выбор между лотереями A и B, а затем между лотереями C и D:

A: 80% шансов на получение 4000 долларов B: 100% шансов на получение 3000 долларов C: 20% шансов на получение 4000 долларов D: 25% шансов на получение 3000 долларов Большинство участников предпочли B перед A и C перед D. Но если присвоить значению полезности нулевой суммы нулевое значение, $U(0) = 0$, то

из первого из этих выборов следует, что $U(4000) > U(3000)$, а из второго следует прямо противоположное. Другими словами,

создается впечатление, что не существует функции полезности, которая была бы совместимой с этими выборами. Одно из возможных заключений состоит в том, что люди действуют нерационально с точки зрения стандартов, определяемых приведенными выше аксиомами полезности. Но в одном из альтернативных подходов к трактовке этого явления предполагается, что в этом анализе не учитывается [^] сожаление — чувство, которое, как известно людям, они будут испытывать, если откажутся от надежного приобретения (В) в обмен на 80%-ные шансы более высокого вознаграждения, а затем проигранут. Иначе говоря, если будет выбрана лотерея А, то перед людьми будет стоять 20%-ный шанс не получить никаких денег и почувствовать себя полным идиотом.

Канеман и Тверский приступили к разработке описательной теории, которая объясняет, почему люди избегают риска в условиях высокой вероятности выигрыша, но готовы делать более рискованные ставки при менее вероятном вознаграждении. Связь между этими исследованиями и искусственным интеллектом состоит в том, что выборы, сделанные нашими агентами, являются лишь настолько качественными, насколько являются таковыми предпочтения, на которых они основаны. Если же люди, информирующие нас о своих взглядах, настаивают на своих противоречивых суждениях о предпочтениях, то искусственный агент не может ничего сделать, чтобы получить возможность поступать в дальнейшем так же, как они.

К счастью, суждения людей, касающиеся предпочтений, часто бывают открыты для пересмотра в свете дополнительных размышлений. В своей ранней работе по оценке полезности денег, выполненной в Гарвардской школе бизнеса, Кини и Райффа [788] изложили описанные ниже результаты. • "Значительный объем проведенных эмпирических исследований показал серьезный недостаток применяемого нами протокола оценки. Участники экспериментов проявляли слишком большую склонность избегать риска в малом и поэтому... составленные на основании экспериментов функции полезности показывают недопустимо большие премии за риск для лотерей с большим разбросом значений выигрыша. ...Но большинство участников эксперимента смогли понять, что их действия не обоснованы, и испытали такие чувства, будто ими освоен важный урок в отношении того, как им следует себя вести. Сделав соответствующие выводы, некоторые участники эксперимента отказались от страховки против автомобильной аварии и заключили договора страхования своей жизни на более продолжительный срок."

Даже в наши дни продолжаются интенсивные исследования в области рациональности (нерациональности) поведения людей.

Шкалы полезности и оценка полезности Если даже известно, каково поведение агента в отношении предпочтений, аксиомы полезности не позволяют определить для него уникальную функцию полезности.

Например, любую функцию полезности $u(S)$ можно преобразовать в другую функцию:

$$U'(S) = k_1 + k_2 U(S)$$

где k_1 — некоторая константа; k_2 — любая положительная константа. Очевидно, что в результате этого линейного преобразования поведение агента останется неизменным.

В детерминированных контекстах, где имеются состояния, но не лотереи, поведение не изменяется под действием любого монотонного преобразования. Например, можно вычислить квадратный корень всех значений полезности, не повлияв на упорядочение действий по предпочтениям. Принято считать, что агент в детерминированной среде руководствуется $^{\wedge}$ функцией значения, или $^{\wedge}$ порядковой функцией полезности; по существу, эта функция обеспечивает лишь ранжирование состояний и не позволяет получить осмысленные числовые значения. Это различие было показано в главе 6 для игр: функции оценки в таких детерминированных играх, как шахматы, представляют собой функции значения, тогда как функции оценки в недетерминированных играх, подобных нардам, являются истинными функциями полезности.

Одна из процедур оценки полезностей состоит в том, что определяется шкала с "наилучшим возможным выигрышем" при $U(S)=u_T$ и "наихудшим возможным проигрышем" при $U(S) = u_i$. Для $^{\wedge}$ нормализованных значений полезности используется шкала с $u_i=0$ и $u_T=1$. Оценка полезностей промежуточных результатов осуществляется путем опроса агента, который должен обозначить свое предпочтение между заданным результирующим состоянием S и $^{\wedge}$ стандартной лотереей $[p, u_T; A-p, u_i]$. Вероятность p корректируется до тех пор, пока агент не становится безразличным к выбору между S и этой стандартной лотереей. Это означает, что при наличии нормализованных полезностей полезность S определяется вероятностью p .

В задачах принятия решений, касающихся медицинского обслуживания, транспорта и охраны окружающей среды, кроме всего прочего, ставками становятся жизни людей. В таких случаях u_i представляет собой значение, присвоенное немедленной смерти (или, возможно, многим смертям). u_T = Хотя все испытывают смущение, когда назначается цена человеческой жизни, истина состоит в том, что во всех критических ситуациях приходится применять компромиссы с учетом этой цены.

Самолеты проходят полный цикл технического обслуживания через интервалы, определяемые количеством полетов и длиной пробега в километрах, а не после каждого полета. Корпуса автомобилей изготавливаются из относительно тонкого листового металла для уменьшения расходов, несмотря на то, что это приводит к уменьшению относительного количества людей, выживших после аварии.

Этилированное топливо продолжает широко использоваться, даже несмотря на то, что всем известно, какой вред оно наносит здоровью. Как ни парадоксально, отказ "назначить цену жизни в деньгах" означает, что жизнь часто недооценивается. Росс Шахтер рассказывал о своем опыте общения с одним правительственным агентством, которое заказало исследование по вопросу целесообразности удаления асбестовых изделий из школ.

Шахтер провел исследование, в котором было принято предположение, что цена жизни ребенка школьного возраста имеет конкретное долларовое выражение, и доказал, что при таком предположении рациональным выбором должно стать удаление асбестовых изделий. Правительственное агентство, ссылаясь на соображения морали, даже не стало рассматривать отчет по результатам этого исследования, после чего было принято решение о том, что не следует заниматься удалением асбестовых изделий.

Было сделано несколько попыток определить, какую цену назначают люди за свои собственные жизни. Двумя "валютами", широко используемыми в медицинских и страховых исследованиях, являются $\wedge$ микрошанс смерти (micromort — один

из миллиона шансов смерти) и $\wedge$ QALY (Quality-Adjusted Life Year), или год жизни с поправкой на качество жизни (который эквивалентен году, прожитому в добром здравии, без каких-либо заболеваний). Целый ряд исследований, проведенных с охватом самых разных слоев населения, показал, что микрошанс смерти стоит примерно 20 долларов (в долларах по курсу за 1980 год). Как уже было показано, функции полезности не обязательно должны быть линейными, поэтому из полученных результатов не следует, что некое лицо, принимающее решение, согласилось бы подвергнуться смерти за 20 миллионов долларов. К тому же локальная линейность любой кривой полезности означает, что показатели микрошанса смерти и QALY являются наиболее приемлемыми для анализа небольших инкрементных рисков и вознаграждений.

16.4. Многоатрибутные функции полезности Принятие решений в области общественной политики, с одной стороны, связано с затратами в миллионы долларов, а с другой стороны, часто касается вопросов жизни и смерти. Например, принимая решение о том, какие уровни канцерогенного вещества являются допустимыми в окружающей среде, лица, устанавливающие нормы допустимых загрязнений, вынуждены искать компромисс между требованиями по предотвращению преждевременных смертей и экономическими трудностями, которые могут возникнуть из-за отказа от некоторых промышленных продуктов и процессов. При поиске строительной площадки для нового аэропорта приходится учитывать, какой вред окружающей среде будет нанесен этим строительством, стоимость земельного участка, расстояние от центров сосредоточения большого

количества населения, шум, связанный с деятельностью аэропорта, проблемы безопасности, обусловленные местной топографией и погодными условиями и т.д.

Задачи, подобные этим, в которых результаты характеризуются двумя или несколькими атрибутами, рассматриваются в $\wedge$ теории многоатрибутной полезности.

Обозначим эти атрибуты как $x = x_1 f \dots, x_p$; полный вектор присваиваний принимает вид $x = \langle x_1 f \dots, x_p \rangle$. Вообще говоря, предполагается, что каждый атрибут имеет дискретные или непрерывные скалярные значения. Для упрощения принимается допущение, будто каждый атрибут определен таким образом, что при всех прочих равных условиях более высокие значения атрибута соответствуют большим полезностям. Например, если в качестве одного из атрибутов в задаче с аэропортом будет выбрано отсутствие шума *AbsenceOfNoise*, то решение будет тем лучше, чем выше значение этого атрибута. В некоторых случаях может потребоваться подразделить диапазон значений так, чтобы значение полезности изменялось монотонно в каждом поддиапазоне.

Начнем с анализа случаев, в которых решения могут быть приняты без комбинирования значений атрибутов в одно значение полезности. Затем рассмотрим случаи, в которых полезности комбинаций атрибутов могут быть определены очень кратко.

Доминирование Предположим, что площадка для аэропорта $S_{\pm}$ стоит меньше, способствует выработке меньшего шумового загрязнения и характеризуется большей безопасностью,

чем площадка S_2 . В таком случае следует без колебаний отвергнуть вариант с площадкой S_2 . В этой ситуации применяется такая формулировка, что имеет место $\wedge$ строгое доминирование варианта s_1 над вариантом s_2 . Вообще говоря, если некоторый вариант характеризуется меньшими значениями всех атрибутов по сравнению с каким-то другим вариантом, то нет необходимости продолжать его дальнейшее рассмотрение. Отношение строгого доминирования часто бывает очень полезным, когда требуется сократить перечень вариантов выбора, оставив лишь реальных претендентов, хотя его применение редко приводит к тому, что остается лишь один уникальный вариант. На рис. 16.3, а показана диаграмма для случая с двумя атрибутами.

Со Эта область доминирует над A $A <_k i \parallel a$) б) Рис. 16.3. Строгое доминирование: детерминированный случай; над вариантом A строго доминирует вариант B , но не варианты C или D (а); неопределенный случай; над вариантом A строго доминирует вариант B , но не вариант C (б) Такой подход является вполне применимым для детерминированного случая, в котором точно известны значения атрибутов. А как следует поступать в общем случае, когда результаты действий являются

неопределенными? И в этих обстоятельствах может применяться непосредственный аналог отношения строгого доминирования, в котором, несмотря на неопределенность, все возможные конкретные результаты для S_1 строго доминируют над всеми возможными результатами для S_2 (см. рис. 16.3, б). Безусловно, что такая ситуация, вполне вероятно, может возникать даже реже по сравнению с детерминированным случаем.

К счастью, возможно более полезное обобщение, называемое $\wedge$ стохастическим доминированием, которое встречается очень часто в реальных задачах. Принцип стохастического доминирования проще понять в контексте задачи с одним атрибутом.

Допустим, исследования показали, что стоимость строительства аэропорта на площадке s^1 равномерно распределена в пределах от 2,8 миллиарда долларов до 4,8 миллиарда долларов, а стоимость строительства на площадке S_2 равномерно распределена в пределах от 3 миллиардов долларов до 5,2 миллиарда долларов. На рис. 16.4, а показаны эти распределения в виде графиков, на которых указанные значения отображены в виде отрицательных значений. В таком случае при наличии лишь той информации, что полезность уменьшается с увеличением стоимости, можно прийти к заключению, что вариант S_1 стохастически доминирует над вариантом S_2 (и поэтому вариант S_2 может быть отброшен). Важно отметить, что такой вывод не следует из сравнения ожидаемых затрат. Например, если бы было известно,

что стоимость варианта S_i точно равна 3,8 миллиарда долларов, то мы не смогли бы принять решение без дополнительной информации о полезности денег³.

0,6 ! 1,2 g 0,6 0,4 0,2 -1 |l /' . Г""""!"""" 1 ' 1 S ^1 /У _6 -5,5 -5 -4,5 -4 -3,5 -3 -2,5 -2 -6 -5,5 -5 -4,5 -4 -3,5 -3 -2,5 -2 Отрицательная стоимость Отрицательная стоимость а) б) Рис. 16.4. Стохастическое доминирование: вариант S_1 стохастически доминирует над вариантом S_2 по стоимости (а); кумулятивные распределения для отрицательной стоимости вариантов S_i и S_2 (б) Точные соотношения между распределениями стоимостей атрибутов, необходимые для определения стохастического доминирования, можно проще всего оценить, исследуя кумулятивные распределения, показанные на рис. 16.4, б. В кумулятивном распределении измеряется вероятность того, что стоимость меньше или равна какой-либо заданной сумме, т.е. в этом распределении интегрируется первоначальное распределение. Если кумулятивное распределение для s_1 всегда находится справа от кумулятивного распределения для S_2 , то с точки зрения стохастической оценки вариант S_1 дешевле, чем S_2 . С формальной точки зрения, если два действия, A_1 и A_2 , приводят к созданию распределений вероятностей $p_1(x)$ и $p_2(x)$ по атрибуту X , то действие A_1 стохастически доминирует над действием A_2 по атрибуту X , если справедливо следующее соотношение:

$\forall x \int P_i(x') dx' < \int P_2(x') dx'$ Возможность применения этого определения для выбора оптимальных решений вытекает из следующего свойства: если действие A_1 стохастически доминирует над действием A_2 , то для любой не убывающей монотонно функции полезности $U(x)$ ожидаемая полезность действия A_1 является, по меньшей мере, столь же высокой, как и ожидаемая полезность действия A_2 . Если какое-то действие стохастически доминирует над другим действием по всем атрибутам, то последнее действие должно быть отброшено.

3 На первый взгляд может показаться странным, что увеличение объема информации о стоимости варианта S_i может уменьшить способность агента к принятию решений. Этот парадокс можно разрешить, отметив, что решение, достигнутое в отсутствии точной информации о стоимости, с меньшей вероятностью будет иметь максимальную отдачу с точки зрения полезности.

На первый взгляд может показаться, что условие стохастического доминирования является довольно формальным и, возможно, не позволяющим проводить вычисления без трудоемких вероятностных расчетов. Но в действительности оно во многих случаях позволяет легко принимать решения. Предположим, например, что стоимость строительства зависит от расстояний до центров сосредоточения населения. Сама стоимость остается неопределенной, но чем больше указанные расстояния, тем выше стоимость. Если площадка S_i менее удалена, чем S_2 , то вариант S_i будет доминировать над S_2 по стоимости. Хотя в данной книге эта тема не рассматривается, существуют точные алгоритмы распространения качественной информации такого рода среди неопределенных переменных в $\wedge$ качественных вероятностных сетях, которые позволяют системе вырабатывать рациональные решения на основе отношений стохастического доминирования, без использования каких-либо числовых значений.

Структура предпочтений и многоатрибутная полезность Предположим, что имеются p атрибутов, каждый из которых имеет d различных возможных значений. Чтобы определить полную функцию полезности $U(x_1, \dots, x_p)$, в худшем случае требуется d^p значений. Итак, наихудший случай соответствует ситуации, в которой предпочтения агента вообще не отличаются какой-либо регулярностью.

Теория многоатрибутной полезности основана на гипотезе о том, что предпочтения типичных агентов более структурированы по сравнению с указанной ситуацией. Основной подход состоит в том, что следует выявлять регулярные структуры в том поведении агента по отношению к предпочтениям, которое, по всей вероятности, будет наблюдаться в действительности, и использовать так называемые $\wedge$ теоремы представления для обоснования того, что агент со структурой предпочтений определенного рода имеет следующую функцию полезности:

$U(x_1, \dots, x_n) = f[f_1(x_1), \dots, f_n(x_n)]$ где f , в соответствии с оптимистическим предположением, представляет собой простую функцию, такую как сложение. Обратите внимание на то, что попытка определить структуру предпочтений аналогична использованию байесовских сетей для декомпозиции совместного распределения вероятностей нескольких случайных переменных.

Предпочтение без неопределенности Начнем с детерминированного случая. Напомним, что для детерминированных вариантов среды у агента имеется функция значений $V(x_1, \dots, x_n)$; цель состоит в том, чтобы представить эту функцию в более краткой форме. Основное свойство регулярности, которое наблюдается в детерминированных структурах предпочтений, называется $\wedge$ независимостью предпочтений. Два атрибута, x_1 и x_2 , являются независимыми по предпочтениям от третьего атрибута, x_3 , если предпочтение между результатами (x_1, x_2, x_3) и (x_1', x_2', x_3) не зависит от конкретного значения x_3 для атрибута $\wedge$.

Возвращаясь к примеру с аэропортом, в котором нужно было рассмотреть (кроме других атрибутов) атрибуты Noise (Шум), Cost (Стоимость) и Deaths (Количество смертных случаев), можно предположить, что атрибуты Noise и Cost независимы

по предпочтениям от атрибута Deaths. Например, если мы предпочтем состояние с 20 000 людей, проживающих в районах, над которыми выполняются полеты, и стоимостью строительства 4 миллиарда долларов, состоянию с 70 000 людей, проживающих в районах полетов, и стоимостью 3,7 миллиарда долларов, притом что уровень безопасности в обоих случаях равен 0,06 смертей в расчете на миллионный пассажирооборот, то будем иметь одни и те же предпочтения, когда уровень безопасности равен 0,13 и когда он равен 0,01. Такие же отношения независимости имеют место для предпочтений между любыми другими парами значений атрибутов Noise и Cost. Очевидно также, что атрибуты Cost и Deaths независимы по предпочтениям от Noise, а Noise и Deaths независимы по предпочтениям от Cost.

В этих случаях принято считать, что множество атрибутов {Noise, Cost, Deaths} обнаруживает свойство $\wedge$ взаимной независимости по предпочтениям (Mutual Preferential Independence — MPI). Согласно свойству MPI, вне зависимости от того, насколько важен каждый атрибут, он не влияет на отношения, в которых другие атрибуты сопоставляются друг с другом.

Свойство взаимной независимости по предпочтениям в определенной степени представляет собой идеализацию, но благодаря замечательной теореме, предложенной экономистом Дебре [365], на его основе можно вывести очень простую форму для функции стоимости агента: CF^* если атрибуты $X_1, \dots, X_n$ являются взаимно независимыми по предпочтениям, то поведение агента в отношении его предпочтений можно описать как максимизацию следующей функции:

$V(x_1, \dots, x_n) = \sum V_j(x_j)$ где каждое слагаемое V_j представляет собой функцию значения, зависящую только от атрибута x_j . Например, вполне допустима такая возможность, что решение по размещению аэропорта может быть принято на основе следующей функции значения:

$V(\text{noise}, \text{cost}, \text{deaths}) = -\text{noise} \times 10^4 - \text{cost} - \text{deaths} \times 10^{12}$ Функция значения такого типа называется $\sum$ аддитивной функцией значения.

Аддитивные функции представляют собой исключительно естественный способ описания любой функции значения агента и действительно правильно описывают многие реальные ситуации. И даже если свойство MUI, строго говоря, не соблюдается, что может иметь место при крайних значениях атрибутов, аддитивная функция значения все еще может предоставлять хорошую аппроксимацию для предпочтений агента. Такое утверждение особенно полно оправдывается, когда нарушения свойства MUI возникают в тех частях диапазонов атрибутов, которые редко встречаются на практике.

Предпочтения с неопределенностью Если в рассматриваемой проблемной области присутствует неопределенность, то необходимо также рассмотреть структуру предпочтений между лотереями и понять результирующие свойства функций полезности, а не просто функций значения.

Математические основы решения этой проблемы могут оказаться весьма сложными, поэтому здесь мы представим только один из основных результатов, чтобы дать понять, как может быть решена эта проблема. Для ознакомления с исчерпывающим обзором работ в этой области рекомендуем читателю обратиться к [788].

Основное понятие $\sum$ независимости полезностей позволяет расширить понятие независимости предпочтений так, чтобы оно охватывало лотереи: множество атрибутов X является независимым по полезности от множества атрибутов Y , если предпочтения между лотереями по атрибутам x независимы от конкретных значений атрибутов Y . Множество атрибутов является $\sum$ взаимно независимым по полезностям (Mutually Utility-Independent— MUI), если каждое из его подмножеств является независимым по полезностям от остальных атрибутов. Опять-таки предположение о том, что атрибуты задачи с аэропортом обладают свойством MUI, кажется вполне резонным.

Из свойства MUI следует, что поведение агента может быть описано с помощью $\sum$ мультипликативной функции полезности [787]. С общей формой мультипликативной функции полезности можно проще всего ознакомиться, рассмотрев случай с тремя атрибутами. В целях сокращения мы будем использовать запись u_i для обозначения $U_i(x_i)$:

$U = k_x U_i + k_2 U_2 + k_3 U_3 + k_1 k_2 U_1 U_2 + k_2 k_3 U_2 U_3 + k_i k_i U_i U_x + k_1 k_2 k_3 U_1 U_2 U_3$
 Хотя это соотношение на первый взгляд не кажется очень простым, оно содержит лишь три одноатрибутных функции полезности и три константы. Вообще говоря, любую n -атрибутную задачу, характеризующуюся наличием свойства MUI, можно промоделировать с использованием n одноатрибутных полезностей и n констант. Каждая из одноатрибутных функций полезности может быть разработана независимо от других атрибутов, а применение комбинации этих функций гарантирует формирование правильных общих предпочтений. Для получения чисто аддитивной функции полезности необходимо ввести некоторые дополнительные предположения.

16.5. Сети принятия решений В этом разделе рассматривается общий механизм принятия рациональных решений. Описанную здесь систему обозначений часто называют $\wedge$ диаграммами влияния [695], но мы будем использовать более описательный термин $\wedge$ сети принятия решений. В сетях принятия решений байесовские сети комбинируются с узлами дополнительных типов, которые обозначают действия и полезности. В качестве примера будет рассматриваться задача выбора площадки для строительства аэропорта.

Способы представления задачи принятия решений с помощью сети принятия решений В своей наиболее общей форме любая сеть принятия решений представляет информацию о текущем состоянии агента, его возможных действиях, о состоянии, которое станет результатом данного действия агента, и о полезности этого состояния.

Таким образом, данная сеть может служить основой для реализации агентов, действующих с учетом полезности, такого типа, который был впервые представлен в разделе 2.4. На рис. 16.5 показана сеть принятия решений в задаче выбора площадки для строительства аэропорта. Этот рисунок может служить иллюстрацией того, как используются узлы трех описанных ниже типов.

Рис. 16.5. Простая сеть принятия решений в задаче выбора площадки для строительства аэропорта • $\wedge$ Узлы жеребьевки (овалы) представляют собой случайные переменные, как и в байесовских сетях. Агент может не иметь определенной информации о стоимости строительства, интенсивности воздушного трафика и о потенциальных возможностях урегулирования формальностей, связанных с получением разрешения на строительство, а также о значениях переменных $Dea\ ths$, $Noise$ и суммарной стоимости $Cost$, поскольку каждое из этих значений зависит от особенностей выбранной площадки. Каждый узел жеребьевки имеет связанное с ним распределение условных вероятностей, которое проиндексировано по состояниям его родительских узлов. В сетях принятия решений родительские узлы могут включать узлы принятия решений, а также узлы жеребьевки. Обратите внимание на то, что каждый из узлов жеребьевки в текущем

состоянии может войти в состав более крупной байесовской сети, применяемой для оценки затрат на строительство, интенсивностей воздушного трафика или потенциальных возможностей формального урегулирования. • [^] Узлы принятия решений (прямоугольники) представляют собой точки, в которых лицу, принимающему решение, предоставляется выбор вариантов действий. В этом случае действие AirportSite может принимать различное значение для каждой площадки, подлежащей рассмотрению. Этот выбор влияет на стоимость, безопасность и шум, т.е. на те параметры, которые станут следствием строительства аэропорта. В данной главе предполагается, что нам придется иметь дело только с единственным узлом принятия решений, а в главе 17 рассматриваются случаи, в которых необходимо принимать больше одного решения. • [^] Узлы полезности (ромбы) представляют функцию полезности агента⁴.

Родительскими переменными узла полезности являются все переменные, описывающие результат, который непосредственно влияет на полезность. С узлом 4 Такие узлы в литературе часто называют узлами значения, но авторы предпочитают подчеркивать различие между функциями полезности и функциями значения, как было описано выше, по- [^]пью рс г[^]тирующее состояние мсжет представлять собой лотерею.

полезности связано описание полезности агента как функции от родительских атрибутов. Это описание может представлять собой табуляцию функции или может быть выражено в виде параметризованной аддитивной или мультилинейной функции.

Кроме того, во многих случаях применяется также упрощенная форма.

Используемая при этом система обозначений остается неизменной, но исключаются узлы жеребьевки, описывающие результирующее состояние. Вместо этого узел полезности связывается непосредственно с узлами текущего состояния и с узлом принятия решений. В данном случае вместо представления функции полезности от состояний узел полезности представляет ожидаемую полезность, связанную с каждым действием, как было определено в уравнении 16.1. Поэтому такие таблицы авторы настоящей книги называют [^]таблицами "действие—полезность". На рис. 16.6 показано представление задачи с аэропортом в форме "действие—полезность".

AirportSite Рис. 16.6. Упрощенное представление задачи выбора площадки для строительства аэропорта. Исключены узлы жеребьевки, соответствующие результирующим состояниям Обратите внимание на то, что узлы жеребьевки Noise, Deaths и Cost, показанные на рис. 16.5, ссылаются на будущее состояние, поэтому их значения ни в коем случае не должны определяться в виде переменных свидетельства. Таким образом, упрощенную версию, в которой исключены эти узлы, можно использовать во всех тех случаях, когда допустимо использование более

общей формы. Однако, несмотря на то, что в упрощенной форме содержится меньше узлов, исключение явного описания результатов решения по выбору площадки означает, что такая сеть является менее гибкой по отношению к возможным изменениям обстоятельств. Например, на рис. 16.5 изменение допустимых уровней шума самолета можно отразить в виде изменения в таблице условных вероятностей, связанной с узлом Noise, тогда как изменение веса, касающегося компонента с описанием шумового загрязнения в функции полезности, может быть отражено с помощью изменения в таблице полезности. С другой стороны, в схеме "действие—полезность", приведенной на рис. 16.6, все такие изменения должны быть отражены в виде изменений в таблице

"действие-полезность". По сути формулировка на основе "действия—полезности" представляет собой откомпилированную версию первоначальной формулировки.

Вычисления с помощью сетей принятия решений Действия выбираются путем проведения с помощью сети принятия решений соответствующих вычислений для каждого возможного ряда значений узла принятия решений. После того как определено значение узла принятия решений, он ведет себя полностью аналогично узлу жеребьевки, которому были присвоены значения по такому же принципу, как переменной свидетельства. Алгоритм проведения вычислений в сетях принятия решений описан ниже.

1. Определить значения переменных свидетельства для текущего состояния.
2. Для каждого возможного значения узла принятия решений: а) ввести это значение в узел принятия решений; б) вычислить апостериорные вероятности для родительских узлов узла полезности, используя стандартный алгоритм вероятностного вывода; в) вычислить результирующее значение полезности для данного действия.
3. Возвратить действие с самым высоким значением полезности.

Этот алгоритм представляет собой непосредственное расширение алгоритма вычислений в байесовской сети и может быть внедрен непосредственно в проект агента, приведенный в листинге 13.1. Как будет показано в главе 17, эта задача становится намного более интересной, когда существует возможность последовательного выполнения нескольких действий.

16.6. Стоимость ИНФОРМАЦИИ В приведенном выше анализе предполагалось, что агенту, прежде чем он приступает к принятию решения, предоставляется вся относящаяся к делу информация или, по меньшей мере, вся доступная информация. Но на практике такая ситуация возникает чрезвычайно редко, с^ Одной из наиболее важных составляющих процесса принятия решений являются знания о том, какие вопросы следует задавать.

Например, врач не может рассчитывать на то, что ему будут предоставлены результаты всех возможных диагностических тестов и опросов к тому времени, как пациент впервые войдет в его кабинет⁵. Медицинские тесты часто являются дорогостоящими, а иногда даже опасными (такая опасность может возникать, во-первых, непосредственно, а во-вторых, из-за связанных с ними задержек). Важность проведения медицинских тестов зависит от двух факторов: от того, в какой степени получение результатов этих тестов приведут к разработке значительно лучшего плана решения, а также от того, насколько велика вероятность различных результатов тестов.

В настоящем разделе описана [^] теория стоимости информации, которая позволяет любому агенту решить, какую информацию он должен приобрести. Получение в США единственным вопросом, который всегда задают заранее, является то, есть ли у пациента страховка.

информации осуществляется с помощью действий по восприятию (см. главу 12).

Поскольку функция полезности агента редко ссылается на содержимое внутреннего состояния агента, притом что общее назначение действий по восприятию сводится к оказанию влияния на это внутреннее состояние, мы должны оценивать качество действий по восприятию на основании того, какое влияние они оказывают на последующие "реальные" действия агента. Таким образом, теория стоимости информации связана с определенной формой последовательного принятия решений.

Простой пример Предположим, что нефтедобывающая компания надеется приобрести лицензию на один из p равнозначных по своей перспективности участков океанского шельфа для проведения разведочных работ. Кроме того, примем дополнительное предположение, что точно один и только один из этих участков обладает запасами нефти стоимостью C долларов и что цена каждого участка равна C/p долларов. Если эта компания нейтрально относится к риску, то она должна быть безразлична к выбору между покупкой лицензии на один из участков и отказом от такой покупки.

А теперь допустим, что некий сейсмолог доложил руководству этой компании результаты проведенного исследования участка номер 3, которые определенно показывают, что на этом участке имеется нефть. Какую сумму должна быть готова компания заплатить за эту информацию? Один из способов получения ответа на этот вопрос состоит в том, чтобы проверить, какие действия предприняла бы компания, обладая указанной информацией, как описано ниже.

- С вероятностью $1/p$ исследование покажет наличие нефти на участке 3.

В этом случае компания купит участок 3 за C/p долларов и получит прибыль в $C - C/p = (p-1)C/p$ долларов.

- С вероятностью $(p-1)/p$ исследование покажет, что участок

не содержит нефти, и в этом случае компания должна купить другой участок. Теперь вероятность обнаружения нефти на одном из других участков измеряется значением от $1/p$ до $1/(p-1)$, поэтому компания получит ожидаемую прибыль $C/(p-1) - C/p = C/(p(p-1))$ долларов.

Теперь мы можем рассчитать ожидаемую прибыль при наличии информации о результатах исследования:

$1/(p-1)C - 1/C - X + X = C/p - C/(p(p-1))$ Поэтому компания должна быть готова заплатить сейсмологу за эту информацию вплоть до C/p долларов, поскольку данная информация стоит столько же, сколько и сам участок.

Стоимость информации определяется тем фактом, что при наличии такой информации можно изменить собственную стратегию таким образом, чтобы она соответствовала действительной ситуации. Наличие информации позволяет выявить отличительные особенности рассматриваемой ситуации, а без этой информации в лучшем случае можно лишь найти среднее значение по всем возможным ситуациям. Вообще говоря, стоимость данного конкретного фрагмента информации опре-

деляется той разницей в ожидаемых значениях между наилучшими действиями, которая возникает до и после получения этой информации.

Общая формула Общую математическую формулу для стоимости информации получить несложно. Обычно предполагается, что информация — это полученное точное свидетельство, касающееся значения некоторой случайной переменной E_j , поэтому используется выражение $\wedge$ стоимость полной информации (Value of Perfect Information — VPIN).

Обозначим текущие знания агента как E . В таком случае стоимость текущего наилучшего действия a определяется с помощью соотношения $EU\{a|E\} = \max U(Resul\ tL(A) \mid P(Resul\ ti(A) \mid Do(A), E))$ А стоимость нового наилучшего действия (после получения нового свидетельства E_6) принимает вид $EU\{a|E_j \setminus E, E_j\} = \max U(Resul\ ti(A) \mid P(Resul\ tL(A) \mid Do(A), E, E_j))$ А Но $E^\wedge$ — это случайная переменная, значение которой в настоящее время неизвестно, поэтому необходимо выполнить усреднение по всем возможным значениям e_{jk} переменной E_j , которые только могут быть обнаружены, с использованием текущих степеней уверенности в том, что эта переменная имеет данное значение.

Поэтому стоимость обнаружения значения E_j при наличии текущей информации E определяется следующим образом:

$L\ VPIN(E_j) = \wedge P(E_3 = e_{jk}|E) EU(Oe.jE, E_i = eft) EU(a|E)$ Для того чтобы сформировать определенное интуитивное представление о том, какой смысл имеет эта формула,

рассмотрим простой случай, в котором имеются только два действия, $A_1 \setminus A_2$, подлежащих выбору в процессе принятия решений.

Текущими ожидаемыми полезностями этих действий являются u_1 и u_2 . Получение информации E_j приведет к определению каких-то новых значений ожидаемых полезностей u_1 и u_2' для этих действий, но прежде чем будет получена информация E_j , уже будут существовать определенные распределения вероятностей по всем возможным значениям u_1 и u_2' (которые, согласно принятому предположению, являются независимыми).

Предположим, что действия a_1 и A_2 представляют собой прохождение по двум разным маршрутам через горную цепь зимой. В действии A_1 предусмотрен проезд по удобному прямому пути через невысокий перевал, а в действии A_2 — проезд по извилистой грунтовой дороге через вершину. Даже если дана только эта информация, б. Не полную информацию о переменной x можно промоделировать с помощью полной информации о переменной Y , которая имеет вероятностную связь с переменной X ; пример применения такого подхода приведен в упр. 16.11.

очевидно, что предпочтительным является действие A_1 , поскольку весьма вероятно, что второй маршрут может быть заблокирован из-за лавин, и вместе с тем весьма маловероятно, что первый маршрут заблокирован из-за интенсивного трафика.

Поэтому очевидно, что полезность u_1 выше по сравнению с u_2 . Но возможно, что результаты наблюдений со спутника E_j ? касающиеся фактического состояния каждой дороги, приведут к получению новых оценок двух путей через горный хребет, u_1 и u_2' . Распределения вероятностей для исходных ожиданий показаны на рис. 16.7, а. Очевидно, что в этом случае нет смысла оплачивать получение данных со спутника, поскольку маловероятно, что полученная с их помощью информация приведет к изменению плана. Если получение новой информации не приводит к какому-либо изменению, то она не имеет реальной стоимости.

$P(u_1|E_j)$ $P(u_2|E_j)$ A_1 A_2 u_1 u_2 u_1' u_2' и? и. + и Рис. 16.7. Три наиболее общих случая, касающихся определения стоимости информации: действие A_j почти со всей определенностью будет оставаться лучшим по сравнению с действием A_2 , поэтому дополнительная информация не нужна (а); выбор неясен, поэтому информация крайне важна (б); выбор неясен, но поскольку разница между полезностями действий невелика, информация не имеет такой уж большой ценности (в) А теперь предположим, что необходимо выбрать одну из двух извилистых грунтовых дорог, имеющих немного разную длину, для того чтобы вывезти за перевал пациента с серьезной травмой. В таком случае, даже если полезности u_1 и u_2 достаточно близки, распределения вероятностей u_1' и u_2' являются очень широкими.

Существует значительная вероятность того, что второй маршрут окажется свободным, а первый — заблокированным, и в этом случае разность между

полезностями будет очень большой. Формула VPI показывает, что в данном случае вполне оправдано получение отчета со спутника. Подобная ситуация показана на рис. 16.7, б.

Далее, предположим, что осуществляется выбор между двумя фунтовыми дорогами летом, когда их блокировка из-за лавин является маловероятной. В этом случае отчеты со спутника могут показать, что одна дорога является более живописной, чем другая, из-за того, что вдоль нее расположены цветущие альпийские луга, или, возможно, немного более влажной из-за блуждающих потоков. Поэтому весьма вероятно, что турист, путешествующий через горы, изменил бы свой план, если бы имел подобную информацию. Но и в таком случае разница в значениях между двумя маршрутами все еще, по-видимому, остается очень небольшой, поэтому нет смысла тратить лишние усилия на получение отчетов со спутника. Такая ситуация показана на рис. 16.7, в.

Подводя итог, можно сказать, что $c^{\wedge}$ стоимость информации определяется той степенью, в которой она может вызвать изменение плана, а также той степенью, в какой новый план окажется значительно лучше по сравнению со старым.

Свойства показателей стоимости информации Напрашивается очевидный вопрос—возможно ли, чтобы информация была вредной, иными словами, может ли она фактически иметь отрицательную ожидаемую стоимость? Интуитивно ясно, что такая ситуация невозможна. В конечном итоге в наихудшем случае можно просто проигнорировать ненужную информацию и сделать вид, как будто она так и не была получена. Данное интуитивное представление подтверждается приведенной ниже теоремой, которая относится к любому агенту, действующему на основе теории принятия решений. $c^{\wedge}$ Стоимость информации является неотрицательной: $\forall j, E VPIE\{E_j\} > 0$ Эта теорема следует непосредственно из определения свойства VPI , и мы оставляем доказательство этой теоремы читателю в качестве упражнения (упр. 16.12).

Важно помнить, что свойство VPI зависит от текущего состояния информации, именно поэтому в формулировке данной теоремы это свойство обозначено подстрочным индексом. Значение VPI по мере получения дополнительной информации может изменяться. В крайнем случае оно может стать равным нулю, если рассматриваемая переменная уже имеет известное значение. Таким образом, свойство VPI не аддитивно. Это означает, что справедливо следующее соотношение:

$VPIE(E_j, E_b) \neq VPIE(E_j) + VPIE(E_k)$ (в общем случае) Но свойство VPI не зависит от порядка рассматриваемых в нем переменных, что должно быть интуитивно ясно. Это означает, что справедливо такое соотношение:

$VPIE(E_j, E_k) = VPIE(E_j) + VPIE(E_k) = VPIE(E_k) + VPIE(E_j)$ В силу того, что действия по восприятию не зависят от последовательности их выполнения, они отличаются от

обычных действий, а задача вычисления значения последовательности действий по восприятию упрощается.

Реализация агента, действующего на основе сбора информации. Успешно действующий агент должен задавать вопросы пользователю в приемлемом порядке, не требовать ответов на вопросы, не относящиеся к делу, учитывать важность каждого фрагмента информации применительно к стоимости его получения и прекращать задавать вопросы, когда сложившаяся обстановка требует перехода к другим действиям. Все эти возможности можно воплотить в проекте агента, используя в качестве критерия стоимость информации.

В листинге 16.1 показан общий проект агента, который способен осуществлять интеллектуальный сбор информации, прежде чем приступать к действиям. На данный момент мы будем предполагать, что с каждой наблюдаемой переменной свидетельства E_j связана соответствующая стоимость $Cost(E_j)$, которая отражает стоимость получения этого свидетельства с помощью проведения тестов, организации консультаций, получения ответов на дополнительные вопросы или других подобных

действий. Агент запрашивает фрагменты информации, которые представляются для него наиболее ценными по сравнению с их стоимостью. Предполагается, что результатом действия по осуществлению запроса $Request(E_j)$ является то, что следующий результат восприятия предоставляет значение E_j . А если ни одно наблюдение не оправдывает его стоимость, агент выбирает "реальное" действие.

Листинг 16.1. Проект простого агента, действующего на основе сбора информации. Этот агент функционирует, снова и снова выбирая наблюдение с наивысшим информационным значением, до тех пор, пока стоимость следующего наблюдения не станет выше по сравнению с ожидаемой от него пользой $function Information-Gathering-Agent(percept) returns действие action static: D, сеть принятия решений$ включить данные о восприятии $percept$ в сеть D $j \leftarrow \text{значение, максимизирующее выражение } VPI(E_j) - Cost\{E_j\}$ if $VPI\{E_j\} > Cost\{E_j\}$ then return $Request(E_j)$ else return наилучшее действие из D Описанный здесь алгоритм агента реализует один из подходов к сбору информации, называемый $\wedge$ близоруким. Это связано с тем, что в данном подходе формула VPI используется без дальновидных расчетов и значение информации определяется так, как будто было бы достаточно получить значение единственной переменной свидетельства. А если нет ни одной переменной свидетельства, которая оказала бы значительную помощь, близорукий агент может преждевременно приступить к действиям, тогда как было бы лучше вначале запросить значения еще двух или нескольких переменных и только после этого начинать действовать. Близорукие методы управления основаны на той же эвристической идее, что и жадный поиск, и часто хорошо работают на практике (например, было показано, что подобные системы управления превосходят по

своей производительности опытных врачей, когда речь идет о подборе необходимых диагностических тестов). Но агент, действующий на основе сбора информации, который является идеально рациональным, должен рассматривать все возможные последовательности информационных запросов, приводящие к внешнему действию, а также все возможные результаты этих запросов.

Поскольку содержание второго запроса зависит от результатов первого запроса, агент должен исследовать пространство условных планов, как было описано в главе 12.

16.7. Экспертные системы, основанные на использовании теории принятия решений
В научной области ^ анализа проблемы принятия решений, которая бурно развивалась в 1950—1960-х годах, изучалось применение теории принятия решений к реальным задачам принятия решений. Результаты, полученные в этой сфере, использовались для упрощения задачи принятия рациональных решений во многих важных проблемных областях, где ставки достаточно высоки, таких как бизнес, государственное управление, юриспруденция, военная стратегия, медицинская диагностика и здравоохранение, техническое проектирование и управление ресурсами.

Применяемый при этом процесс предусматривал тщательное исследование всех действий и результатов, а также учет предпочтений, назначенных каждому результату. По традиции в области анализа проблем принятия решений специалисты подразделяются на две категории: ^ лицо, принимающее решения, формулирует отношения предпочтений между результатами, а ^ лицо, анализирующее решения, составляет список возможных действий и результатов, а также получает от лица, принимающего решения, информацию о предпочтениях, чтобы определить наилучшую стратегию. До начала 1980-х годов основное назначение анализа решений состояло в том, чтобы помочь людям принимать решения, которые действительно отражают их собственные предпочтения. А в настоящее время, когда процессы принятия решений во все большей степени становятся автоматизированными, анализ решений используется для обеспечения того, чтобы эти автоматизированные процессы действовали в соответствии с предъявленными к ним требованиями.

Как было описано в главе 14, на первых порах исследования в области экспертных систем сосредоточивались на получении ответов на вопросы, а не на принятии решений. Такие системы, которые рекомендуют действия, а не предоставляют оценки сложившихся обстоятельств, как правило, функционируют на основе правил "условие—действие", а не с использованием явных представлений результатов и предпочтений. Но после разработки теории байесовских сетей в конце 1980-х годов появилась возможность создавать крупномасштабные системы, способные

формировать обоснованные вероятностные выводы на основании полученных свидетельств. А внедрение в практику сетей принятия решений означало появление возможности создания экспертных систем, способных рекомендовать оптимальные решения с учетом предпочтений пользователя, а также доступных свидетельств.

Система, в которой учитываются полезности, способна избежать одной из наиболее распространенных ловушек, связанных с процессом предоставления консультаций, — смешивания правдоподобия и важности. Например, наиболее широко применяемой стратегией в ранних медицинских экспертных системах было ранжирование возможных диагнозов в порядке правдоподобия и выдача сообщения о наиболее вероятном диагнозе. К сожалению, такой подход иногда оказывался катастрофическим! Для большинства пациентов в общей медицинской практике двумя наиболее вероятными диагнозами обычно являются следующие: "У вас нет ничего серьезного" и "Вы сильно простудились", но если третьим по степени вероятности диагнозом для данного конкретного пациента (который тем не менее не был сообщен системой) является рак легких — это уже серьезная ситуация! Очевидно, что план медицинского обследования или лечения должен зависеть и от учета вероятностей, и от учета полезностей.

Теперь мы опишем процесс инженерии знаний для экспертных систем, основанных на теории принятия решений. В качестве примера рассмотрим задачу выбора медицинского лечения для определенного вида сердечного заболевания у детей обоих полов (см. работу Лукаса [962]).

Около 0,8% детей рождаются с той или иной сердечной аномалией, причем наиболее распространенной из них является $\wedge$ коарктация аорты (сужение аорты). Этот дефект можно исправить с помощью хирургического вмешательства, ангиопластики (расширения аорты с помощью надувного баллона, помещенного внутри этой артерии) или терапевтического лечения. Проблема состоит в том, чтобы определить, ка-

кой способ лечения следует использовать и когда его проводить: чем младше ребенок, тем выше риск, связанный с применением определенных способов лечения, но ожидание также не должно продолжаться слишком долго. Экспертная система, основанная на использовании теории принятия решений, которая предназначена для решения данной проблемы, может быть создана группой специалистов, состоящей по меньшей мере из одного специалиста в данной проблемной области (детского кардиолога) и одного инженера по знаниям. Сам этот процесс можно разбить на следующие этапы (который читатель может сравнить с этапами разработки системы на основе логики, описанными в разделе 8.4). • Создание причинной модели. Определить, каковыми являются возможные симптомы, нарушения, способы лечения и результаты. Затем провести между ними дуги, указывающие, какими нарушениями вызваны те или иные симптомы и какие

способы лечения позволяют устранить те или иные нарушения. Некоторые из этих сведений должны быть хорошо известны специалисту в данной проблемной области, а другие сведения он может почерпнуть из литературы. Эта модель часто во многом напоминает неформальные графические описания, приведенные в медицинских учебниках. • Упрощение причинной модели до уровня качественной модели принятия решений.

Поскольку применяемая модель предназначена для принятия решений, касающихся способа лечения, а не для других целей (таких как определение совместной вероятности некоторых комбинаций симптом/нарушение), часто можно упростить причинную модель, удаляя переменные, которые не требуются в процессе принятия решений, касающихся лечения. Кроме того, иногда возникает необходимость разделить или соединить переменные, чтобы они соответствовали интуитивным представлениям специалиста. Например, предположим, что первоначальная модель коарктации аорты включала переменную Treatment (Лечение) со значениями surgery (хирургическое вмешательство), angioplasty (ангиопластика) и medication (терапевтическое лечение), а также отдельную переменную Timing для определения сроков выполнения процедуры лечения. Но допустим, что специалисту нелегко рассматривать все эти переменные отдельно, поэтому они были объединены так, что переменная Treatment принимает значения типа surgery in 1 month (проведение хирургического вмешательства в течение одного месяца). В результате будет получена модель, приведенная на рис. 16.8. • Присвоить значения вероятностей. Вероятности можно определить по базам данных о пациентах, по результатам исследований, приведенным в литературе, или на основании субъективных оценок самого специалиста. В тех случаях, если в литературе даны сведения о вероятностях не совсем подходящих типов, для вычисления требуемых вероятностей можно применить такие методы, как правило Байеса и маргинализация. Исследования показали, что специалисты в проблемной области в большей степени обладают способностью оценить вероятность результата, если дана причина (например, $P\{\text{dyspnoea} \setminus \text{heartfailure}\}$), а не наоборот. • Присвоение значений полезностей. Если количество возможных результатов невелико, то их можно перечислить и оценить отдельно. Допустим, что в дан-

ном случае создается шкала результатов от наилучшего к наихудшему и каждому из них присваивается числовое значение, например случаю смерти присваивается значение -1000, а полному излечению — значение 0. После этого на данную шкалу можно поместить другие результаты. Такая задача может быть выполнена специалистом в данной проблемной области, но лучше, если в ее решении примет участие пациент (или, если речь идет о детях, то родители пациентов), поскольку разные люди имеют различные предпочтения. Если же количество результатов растет экспоненциально, то может потребоваться определенный способ,

позволяющий комбинировать их с использованием многоатрибутных функций полезности. Например, можно утверждать, что отрицательная полезность различных осложнений является аддитивной.

Рис. 16.8. Диаграмма влияний для задачи принятия решений, касающихся коарктации аорты (предоставлена Питером Лукасом)

- Проверка и уточнение модели. Для проверки работоспособности системы потребуется множество правильных пар "вход—выход" — {input, output} — так называемый $\wedge$ золотой стандарт, с которым можно выполнить сравнение.

Для медицинских экспертных систем это обычно означает, что можно собрать самых лучших врачей, дать им на рассмотрение несколько случаев и попросить у них сообщить их диагноз и рекомендуемый план лечения. Затем осуществляется проверка того, насколько результаты, полученные данной системой, согласуются с указанными рекомендациями. Если согласование оказывается неприемлемым, то нужно попытаться выделить ее части, которые действуют неправильно, и провести их доработку. Может также оказаться полезным выполнение прогона системы "в обратном направлении": вместо того чтобы вводить в систему симптомы и запрашивать диагнозы, можно представить ей диагноз, такой как "сердечная недостаточность", определить предсказанную вероятность симптомов, таких как тахикардия, и сравнить это значение с данными, полученными из медицинской литературы.

- Осуществление анализа чувствительности. На этом важном этапе проверяется, чувствительно ли наилучшее решение к небольшим изменениям в присвоенных значениях вероятностей и полезностей; для этого систематически осуществляется варьирование этих параметров и повторное проведение вычислений. Если небольшие изменения приводят к получению namного отличающихся решений, то может потребоваться затратить больше ресурсов на сбор более качественных данных. Если же все небольшие изменения приводят к получению одного и того же решения, то пользователь будет больше доверять этому решению как правильному. Анализ чувствительности особенно важен, поскольку одно из основных критических замечаний в адрес вероятностных подходов к созданию экспертных систем состоит в том, что трудно оценить необходимые числовые значения вероятностей. Анализ чувствительности часто показывает, что достаточно задать многие числовые данные только очень приблизительно. Например, мы можем не знать, каково значение априорной вероятности $P\{\text{tachycardia}\}$, но после опробования многих разных значений этой вероятности и получения в каждом случае одинакового рекомендованного действия по диаграмме влияния можно меньше беспокоиться о том, что отсутствует соответствующая достоверная информация.

16.8. Резюме В данной главе показано, как объединить теорию полезности с теорией вероятностей, чтобы дать возможность агенту выбрать действия, которые

максимизируют его ожидаемую производительность. • Теория вероятностей описывает, в чем должен быть уверен агент согласно полученному свидетельству, теория полезности показывает, к чему должен стремиться агент, а теория принятия решений позволяет объединить подходы этих двух теорий для определения того, что должен делать агент. • Теория принятия решений может использоваться для создания систем, которые принимают решения, рассматривая все возможные действия и выбирая из

них именно то, которое приводит к наилучшему ожидаемому результату.

Такая система известна под названием рационального агента.

Теория полезностей показывает, что агент, руководствующийся отношениями предпочтения между лотереями, совместимыми с множеством простых аксиом, может быть описан как обладающий функцией полезности; кроме того, агент выбирает действия так, чтобы можно было максимизировать его ожидаемую полезность.

Теория многоатрибутной полезности посвящена изучению полезности, которая зависит от нескольких разных атрибутов состояний. Стохастическое доминирование представляет собой особенно удобный метод принятия непротиворечивых решений даже при отсутствии точных значений полезности для атрибутов.

Сети принятия решений представляют собой простую формальную систему для описания и решения задач принятия решений. Они являются естественным расширением байесовских сетей и, кроме узлов жеребьевки, содержат узлы решения и узлы полезности.

Иногда для решения задачи приходится заниматься поиском дополнительной информации, прежде чем принимать решение. Стоимость информации определена как ожидаемое повышение полезности по сравнению с принятием решений без этой информации.

Экспертные системы, в которых предусматривается использование информации о полезности, обладают дополнительными возможностями по сравнению с системами, в которых применяется исключительно вероятностный вывод.

Они не только обладают способностью вырабатывать решения, но и могут использовать стоимость информации для определения того, следует ли стремиться к ее получению, а также способны рассчитать чувствительность своих решений к небольшим изменениям в оценках вероятности и полезности.

Библиографические и исторические заметки Одним из первых примеров применения принципа максимальной ожидаемой полезности (хотя и не совсем правильным, поскольку в нем использовались бесконечные значения полезности) был рассказ о пари Паскаля, впервые опубликованный в книге Port-Royal Logic [40].

Даниил Бернулли [111], исследовавший санктпетербургский парадокс (см. упр. 16.3), был первым, кто понял важность измерения предпочтений в отношении лотерей и написал такие слова: "Стоимость любого предмета должна быть основана не на его цене, а на той пользе, которую он может принести" (курсив Бернулли). Джереми Бентам [100] предложил гедонистическое исчисление для взвешивания "удовольствий" и "неприятностей", доказывая, что все решения (а не только касающиеся денег) можно свести к сравнению полезностей.

Определение числовых значений полезности на основе предпочтений было впервые выполнено Рамзеем [1265]; аксиомы предпочтений, приведенные в настоящей книге, ближе всего по своей форме тем, которые были вновь открыты в книге *Theory of Games and Economic Behavior* [1546]. Хорошее описание этих аксиом в рамках дискуссии о предпочтении риска приведено в [693]. Рамзей предложил способ вычисле-

ния субъективных вероятностей (а не только полезностей) на основе предпочтений агента; Сзведж [1354] и Джеффри [727] предложили более современные вычислительные конструкции такого рода. В [1547] изложены современные перспективы анализа проблемы принятия решений и показана ее связь со структурами предпочтений людей. Такая мера полезности, как микрошанс смерти, обсуждается в [694].

В обзоре, опубликованном журналом *Economist* в 1994 году, указано, что стоимость жизни находится в пределах от 750 000 долларов и до 2,6 миллиона долларов. Однако Ричард Талер [1503] обнаружил нерациональные отклонения в оценках той денежной суммы, которую люди готовы заплатить, чтобы избежать риска смерти, в сравнении с суммой, которую они готовы получить, чтобы принять на себя этот риск.

С вероятностью 1/1000 его респонденты не заплатили бы больше 200 долларов, чтобы исключить риск, но не были согласны получить даже 50 000 долларов, чтобы подвергнуться риску.

В принятии решений, касающихся политики в области здравоохранения и социального обеспечения, гораздо более широкое распространение находит такой показатель, как QALY, а не микрошанс смерти; типичный пример обоснования одного из крупных изменений политики в области общественного здравоохранения на основе повышения ожидаемой полезности, измеряемого в единицах QALY, приведен в [1320].

Книга *Decisions with Multiple Objectives: Preferences and Value Tradeoffs* [788] содержит исчерпывающее введение в теорию многоатрибутной полезности (MultiAttribute Utility Theory — MAUT). В ней описаны первые компьютерные реализации методов выявления необходимых параметров для многоатрибутной функции полезности и приведены исчерпывающие отчеты о результатах

практического применения этой теории. В области искусственного интеллекта основным источником сведений о теории многоатрибутной полезности является статья Уэллмана [1572], которая включает описание системы URP (Utility Reasoning Package), позволяющей использовать коллекцию высказываний о независимости предпочтений и условной независимости для анализа структуры задач принятия решений. Результаты обширного исследования в области использования понятия стохастического доминирования в сочетании с качественными вероятностными моделями приведены в [1573], [1574].

В [1578] изложен предварительный набросок подхода к созданию метода, с помощью которого можно использовать сложный набор отношений независимости полезностей для создания структурированной модели функции полезности, во многом аналогично тому, как байесовские сети позволяют создавать структурированные модели совместных распределений вероятностей. В [52], [53] и [876] приведены дальнейшие результаты, полученные в данном научном направлении.

Теория принятия решений является стандартным инструментальным средством в экономике, финансах и науке управления с 1950-х годов. До 1980-х годов основным средством, применяемым для представления простых задач принятия решений, были деревья решений. В [1438] приведен обзор методологии анализа проблемы принятия решений. Сети принятия решений, или диаграммы влияния, были разработаны Говардом и Матесоном [695] на основе одной из ранних работ, выполненной группой специалистов (включая Говарда и Матесона) в институте SRI [1051]. Метод Говарда и Матесона обеспечивает формирование дерева решений на основе сети принятия решений, но в общем случае сформированное дерево имеет экспоненциальные размеры. Шахтер [1383] разработал метод принятия решений, основанный исключительно на использовании сети принятия решений, без создания промежу-

точного дерева решений. Этот алгоритм оказался также одним из первых алгоритмов, который обеспечивает полный вероятностный вывод в многосвязных байесовских сетях. В недавно опубликованной работе Нильссона и Лауритцена [1139] показано, какое отношение имеют алгоритмы для сетей принятия решений к продолжающимся разработкам в области создания алгоритмов кластеризации для байесовских сетей. В сборнике статей [1155] приведен целый ряд полезных статей по сетям принятия решений, как и в специальном выпуске журнала *Networks*, который вышел в 1990 году. Кроме того, статьи по сетям принятия решений и моделированию полезностей регулярно публикуются в журнале *Management Science*.

Теория стоимости информации была впервые проанализирована Роном Говардом [692]. Его статья оканчивается замечанием: "Если теория стоимости информации и

связанные с ней структуры теории принятия решений не составят в будущем значительную часть образования инженеров, то люди с инженерными профессиями уступят свою традиционную роль в управлении научными и экономическими ресурсами в пользу людей, посвятивших себя другим профессиям". До настоящего времени предсказанная им революция в области методов управления еще не наступила, но такое может случиться после того, как получат более широкое распространение методы использования теории стоимости информации в байесовских экспертных системах.

Как это ни удивительно, но лишь немногие исследователи в области искусственного интеллекта приняли на вооружение инструментальные средства теории принятия решений после появления самых первых приложений принятия решений в медицине, которые описаны в главе 13. Одним из немногих исключений стал Джерри Фельдман, который применил теорию принятия решений в задачах машинного зрения [461] и планирования [460]. После возрождения интереса к вероятностным методам в искусственном интеллекте в 1980-х годах получили широко распространение экспертные системы на основе теории принятия решений [686]. Фактически начиная с 1991 года и до настоящего времени на обложке журнала *Artificial Intelligence* изображается сеть принятия решений, хотя и создается впечатление, что автор рисунка этой сети позволил себе некоторые художественные вольности при выборе направления стрелок.

Упражнения 16.1. {Адаптировано из книги Дэвида Хекермана.) Это упражнение касается содержания игры *Almanac Game* (игра на знание фактов из справочника), которая используется аналитиками решений для калибровки числовых оценок. На каждый из приведенных ниже вопросов дайте наилучший предполагаемый вами ответ, т.е. число, которое, по вашему мнению, с такой же вероятностью является слишком большим, с какой оно может быть слишком малым. Кроме того, приведите вашу гипотезу с оценкой на уровне 25-й процентиля, т.е. такое число, которое, по вашему мнению, имеет 25% шансов на то, чтобы быть слишком высоким, и 75% шансов на то, чтобы быть слишком низким.

Приведите такое же значение и для 75-й процентиля. (Таким образом, вы должны дать всего три оценки для каждого вопроса — низкую, среднюю и высокую.)

а) Количество пассажиров, которые совершали полеты между Нью-Йорком и Лос-Анджелесом в 1989 году. б) Население Варшавы в 1992 году. в) Год, в который испанский конкистадор Коронадо открыл реку Миссисипи. г) Количество голосов, полученных Джимми Картером во время президентских выборов в 1976 году. д) Возраст самого старого живого дерева по состоянию на 2002 год. е) Высота плотины Гувера (Hoover Dam) в футах. ж) Количество яиц, произведенных в штате Орегон в 1985 году. з) Количество буддистов в мире в 1992 году. и) Количество смертных

случаев из-за СПИДа в Соединенных Штатах в 1981 году. к) Количество американских патентов, выданных в 1901 году.

Правильные ответы приведены после последнего упражнения этой главы.

С точки зрения анализа решений интересно не то, насколько ваши средние предположения подошли к реальным ответам, но, скорее, то, насколько часто реальный ответ попал в установленные вами границы 25 и 75%. Если такая ситуация возникла примерно в половине случаев, то указанные вами границы были достаточно точными. Но если вы похожи на большинство людей, то проявите больше самоуверенности, чем следует, и более половины ответов выйдет за пределы этих границ. Постоянно практикуясь, вы сможете откалибровать свои оценки, чтобы устанавливаемые пределы стали более реалистичными и тем самым приносили больше пользы при предоставлении информации для принятия решений. Попробуйте ответить на второй ряд вопросов и определите, достигнуты ли вами какие-либо улучшения. а) Год рождения актрисы За За Габор (Zsa Zsa Gabor). б) Максимальное расстояние от Марса до Солнца в милях. в) Стоимость в долларах пшеницы, экспортированной из Соединенных Штатов в 1992 году. г) Количество тонн груза, обработанных в порту Гонолулу в 1991 году. д) Ежегодный заработок в долларах губернатора Калифорнии в 1993 году. е) Население Сан-Диего в 1990 году. ж) Год, в который Роджер Уильямс основал г. Провиденс, штат Род-Айленд. з) Высота горы Килиманджаро в футах. и) Длина Бруклинского моста в футах. к) Количество смертных случаев из-за автомобильных аварий в Соединенных Штатах в 1992 году.

16.2. Билеты в лотерею стоят 1 доллар. Существуют два возможных приза: выигрыш в 10 долларов с вероятностью $1/50$ и выигрыш в 1 000 000 долларов с вероятностью $1/2\,000\,000$. Какова ожидаемая денежная стоимость лотерейного билета? Когда решение по приобретению такого билета является рациональным (если оно вообще бывает таковым)? Дайте точный ответ — составьте уравнение, касающееся полезностей. Вы можете принять предположение, что ваш текущий капитал равен k долларов и что $C'(k) = 0$. Вы можете также предпо-

ложить, что $C'(k + y) = 10x/(k + y)$, но не должны принимать никаких предположений в отношении полезности $U(k + 1\,000\,000)$. Социологические исследования показывают, что люди с низкими доходами покупают несоответствующее их благосостоянию количество лотерейных билетов. Как вы считаете, связано ли это с тем, что они не умеют принимать рациональные решения, или с тем, что они руководствуются другой функцией полезности?

16.3. В 1738 году Даниил Бернулли исследовал Санкт-Петербургский парадокс, который заключается в следующем. У вас есть возможность сыграть в игру, в которой подлинная монета подбрасывается повторно до тех пор, пока не выпадет орлом вверх. Если орел впервые появится на n -м броске, вы выигрываете

2пдолларов. а) Покажите, что ожидаемое денежное значение этой игры является бесконечно большим. б) Сколько бы вы лично заплатили за участие в этой игре? в) Бернулли разрешил кажущийся парадокс, связанный с нежеланием людей участвовать в этой игре, несмотря на ее привлекательность, выдвинув предположение, что полезность денег измеряется логарифмической шкалой (т.е. $U(S_n) = a \log_2 n + b$, где S_n — денежное состояние, связанное с наличием n долларов). Какова ожидаемая полезность этой игры согласно указанному предположению? г) Какова максимальная сумма, решение по уплате которой за участие в этой игре было бы рациональным, при условии, что первоначальное состояние рассматриваемого лица измеряется суммой j с долларов?

16.4. Определите вашу собственную оценку полезности различных постепенно увеличивающихся сумм денег, выполнив ряд проверок предпочтения между некоторой определенной суммой M_x и лотереей $[p, M_2; A-p, 0]$. Выбирайте различные значения M_x и M_2 и варьируйте вероятность p до тех пор, пока для вас эти два варианта не станут безразличными. Нанесите полученную в результате функцию полезности на график.

16.5. (й) Напишите компьютерную программу для автоматизации процесса, описанного в упр. 16.4. Проверьте работу вашей программы на нескольких людях с разным собственным капиталом и различными политическими взглядами.

Прокомментируйте результаты сравнения согласованности полученных данных как для отдельного лица, так и для разных лиц.

16.6. Какова стоимость микрощанса смерти для вас? Разработайте определенный протокол, позволяющий узнать это значение. Задавайте вопросы, основанные и на том, сколько вы готовы заплатить, чтобы избежать риска смерти, и на том, сколько вы готовы принять в качестве платы за то, чтобы вы взяли на себя этот риск.

16.7. Покажите, что если переменные x_1 и x_2 независимы по предпочтениям от переменной x_3 , а x_2 и x_3 независимы по предпочтениям от x_1 до x_3 и x_1 независимы по предпочтениям от x_2 .

16.8. (И) В этом и двух следующих упражнениях завершается анализ задачи выбора площадки для размещения аэропорта, приведенной на рис. 16.5.

а) Приведите приемлемые данные об областях определения переменных, вероятностях и полезностях для этой сети, при условии, что имеются три возможных площадки. б) Решите эту задачу принятия решений. в) Что произойдет, если будут внедрены такие технологические усовершенствования, что каждый самолет станет вырабатывать вдвое меньше шума? г) А что произойдет, если требования по предотвращению шума станут в три раза более значимыми? д) Рассчитайте значение VPI для переменных вашей модели AirTraffic (Интенсивность воздушного

движения), Litigation (Возможности урегулирования формальностей) и Construction (Условия строительства аэропорта).

16.9. Повторите упр. 16.8, используя представление "действие—полезность", показанное на рис. 16.6.

16.10. К какому элементу таблицы условных вероятностей является наиболее чувствительным значение полезности на любой из схем выбора площадки для аэропорта из упр. 16.8 и 16.9, если даны все доступные свидетельства?

16.11. (Адаптировано из J1191J.) Покупатель подержанного автомобиля может принять решение выполнить различные проверки с разной стоимостью (например, постучать по шинам, показать автомобиль квалифицированному механику), а затем, в зависимости от результата этих проверок, принять решение о том, какой автомобиль следует купить. Предполагается, что покупатель принимает решение о покупке автомобиля с тем, что он собирается провести самое большее одну проверку и что этой проверкой автомобиля с_г является t15 которая стоит 50 долларов.

Автомобиль может находиться в хорошем состоянии (качество д+) или в плохом состоянии (качество д~), а проверка может показать, в каком состоянии находится автомобиль. Автомобиль с_х стоит 1500 долларов, а его рыночная стоимость равна 2000 долларов, если он находится в хорошем состоянии; если же нет, то потребуется ремонт стоимостью 700 долларов, чтобы привести его в хорошее состояние. Оценка покупателя состоит в том, что автомобиль с_г имеет 70% шансов на то, чтобы оказаться в хорошем состоянии. а) Нарисуйте сеть принятия решений, которая представляет данную задачу. б) Вычислите ожидаемую чистую прибыль от покупки автомобиля с₁? если не проводится проверка. в) Проверки можно описать с помощью оценки вероятности того, пройдет ли автомобиль или не пройдет данную конкретную проверку, позволяющую определить, находится ли автомобиль в хорошем или плохом состоянии. Имеется следующая информация:

$P(\text{pass}(c|f\ t_i) | g+(c_i)) = 0.8$ $P(\text{pass}(c_i, t_i) | g^-(c_i)) = 0.35$ Примените теорему Байеса для вычисления вероятности успешного прохождения (или не прохождения) автомобилем проверки и следовательно, вероятности того, что он находится в хорошем (или плохом) состоянии, с учетом каждого возможного результата проверки.

г) Рассчитайте оптимальные решения при условии прохождения или не прохождения проверки, а также их ожидаемые полезности. д) Рассчитайте стоимость информации о проверке и разработайте оптимальный условный план для покупателя.

16.12. Докажите, что стоимость информации является неотрицательной и независимой от последовательности восприятий, как утверждалось в разделе 16.6.

Объясните, как может случиться, что после получения информации будет принято худшее решение, чем было бы до ее получения.

16.13. (И) Модифицируйте и дополните программы байесовской сети, приведенные в репозитории кода, чтобы обеспечить создание и оценку сетей принятия решений, а также вычисление стоимости информации.

Ответы к упр. 16.1: • первый ряд вопросов: 3 000 000, 1 600 000, 1541, 41000 000, 4768, 221, 649 000 000, 295 000 000, 132, 25 546; • второй ряд вопросов: 1917, 155 000 000, 4 500 000, 11 000 000, 120 000, 1 100 000, 1636, 19 340, 1595, 41710.

Глава 17. Принятие сложных решений

17 Принятие сложных РЕШЕНИЙ В данной главе рассматриваются методы принятия решений о том, что следует делать в настоящее время, при условии, что в дальнейшем может быть принято другое решение.

В этой главе описано, какие расчеты связаны с принятием решений. В главе 16 речь шла о задачах принятия единоразовых или эпизодических решений, в которых полезность результата каждого действия была вполне известна, а в настоящей главе рассматриваются ^ задачи последовательного принятия решений, в которых полезность действий агента зависит от последовательности решений. Задачи последовательного принятия решений, в которых рассматриваются полезности, степени неопределенности и результаты восприятия, являются обобщением задач поиска и планирования, описанных в частях II и IV. В разделе 17.1 описано, как должны быть определены задачи последовательного принятия решений, а в разделах 17.2 и 17.3 показано, как их следует решать, чтобы выработать оптимальные правила поведения, в которых уравниваются риски и вознаграждения, связанные с осуществлением действий в неопределенной среде. В разделе 17.4 эти идеи распространяются на случай частично наблюдаемых вариантов среды, а в разделе 17.5 разрабатывается полный проект для агентов, действующих на основе теории принятия решений в частично наблюдаемых вариантах среды; в этом проекте объединяются динамические байесовские сети, описанные в главе 15, и сети принятия решений, описанные в главе 16.

Во второй части данной главы рассматриваются варианты среды с многочисленными агентами. В таких вариантах среды понятие оптимального поведения становится гораздо более сложным из-за взаимодействия агентов. В разделе 17.6 представлены основные идеи теории игр, включая ту идею, что рациональным агентам может потребоваться вести себя случайным образом. В разделе 17.7 показано, как следует проектировать мультиагентные системы для того, чтобы несколько агентов могли достичь общей цели.

17.1. Задачи последовательного принятия решений Пример Предположим, что агент находится в среде с размерами 4×3 , показанной на рис. 17.1, а. Начиная с начального состояния, он должен выбирать какое-то действие в каждом временном интервале. Взаимодействие со средой оканчивается после того, как агент достигает одного из целевых состояний, обозначенных +1 и -1.

В каждом местонахождении в распоряжении агента имеются действия Up (Вверх), Down (Вниз), Left (Влево) и Right (Вправо). На данный момент предполагается, что эта среда является полностью наблюдаемой, поэтому агент всегда знает, где он находится. ш START L±±J 1 -И 12 3 4 а) б) Рис. 17.1. Определение задачи: простая среда с размерами 4×3 , в которой перед агентом поставлена задача последовательного принятия решений (а); модель перехода для этой среды: "намеченный" результат достигается с вероятностью 0.8, а с вероятностью 0.2 агент движется под прямыми углами влево или вправо от намеченного направления (б). Столкновение со стеной приводит к тому, что дальнейшее движение не происходит. С двумя конечными состояниями связаны вознаграждения +1 и -1 соответственно, а со всеми другими состояниями связано вознаграждение -0.04. Если бы эта среда была полностью детерминированной, то достижение требуемого решения было бы несложным: [Up, Up, Right, Right, Right]. К сожалению, среда не всегда реагирует правильно на осуществление этого решения, поскольку действия выполняются ненадежно. Конкретная принятая нами модель стохастического движения показана на рис. 17.1, б. Каждое действие достигает намеченной цели с вероятностью 0.8, но в течение всего остального времени в результате выполнения действия агент движется под прямыми углами к выбранному направлению. Более того, если агент ударяется в стену, то остается в том же квадрате. Например, выполняемое из начального квадрата A,1) действие Up перемещает агента в квадрат A,2) с вероятностью 0.8, но с вероятностью 0.1 агент движется вправо, в квадрат B,1), а с вероятностью 0.1 он движется влево, ударяется в стену и остается в квадрате A,1). В такой среде последовательность действий [Up, Up, Right, Right, Right] позволяет обойти барьер и достичь целевого состояния, квадрата D,3), с вероятностью

$0.85 = 0.32768$. Существует также небольшой шанс случайно достичь цели, обойдя барьер с другой стороны с вероятностью 0.14×0.8 , поэтому суммарная вероятность достижения цели равна 0.32776 (см. также упр. 17.1).

Спецификацию вероятностей результатов каждого действия в каждом возможном состоянии принято называть $\hat{\cdot}$ моделью перехода (или просто "моделью", если не может возникнуть путаница). Для обозначения вероятности достижения состояния s' , если в состоянии s было выполнено действие a , будет применяться запись $T(sf a, s')$. Предполагается, что эти переходы являются марковскими в том смысле, какой указан в главе 15, т.е. что вероятность достижения состояния s' из s зависит только от s , а не от истории пребывания в предыдущих состояниях. На данный момент

запись $T(s, a, s_x)$ может рассматриваться как большая трехмерная таблица, содержащая вероятности. В дальнейшем, в разделе 17.5, будет показано, что модель перехода может быть представлена как динамическая байесовская сеть, точно так же, как и в главе 15.

В завершение этого определения среды задачи необходимо сформулировать функцию полезности для агента. Поскольку эта задача принятия решений является последовательной, функция полезности должна зависеть от последовательности состояний (от истории пребывания в среде), а не от отдельного состояния. Ниже в этом разделе будет приведено описание того, как такие функции полезности могут быть определены в целом, а на данный момент просто примем предположение, что в каждом состоянии s агент получает $\wedge$ вознаграждение $R(s)$, которое может быть положительным или отрицательным, но должно быть ограниченным. В данном конкретном примере вознаграждение равно -0.04 во всех состояниях, кроме конечных (с которыми связаны вознаграждения $+1$ и -1). Полезность, связанная с историей пребывания в среде (на данный момент), рассматривается как сумма полученных вознаграждений. Например, если агент достиг состояния $+1$ после 10 шагов, суммарная полезность его действий будет равна 0.6 . Отрицательное вознаграждение -0.04 побуждает агента быстрее достичь квадрата $D,3$), поэтому данная среда представляет собой стохастическое обобщение вариантов среды, которые рассматривались в задачах поиска в главе 3. Еще один способ описать эту игровую ситуацию состоит в том, что агенту "не нравится" находиться в этой среде, поэтому он стремится выйти из игры как можно быстрее.

Такая спецификация задачи последовательного принятия решений для полностью наблюдаемой среды с марковской моделью перехода и дополнительными вознаграждениями называется спецификацией $\wedge$ марковского процесса принятия решений, или сокращенно MDP (Markov Decision Process). Любая задача MDP определяется тремя перечисленными ниже компонентами. • Начальное состояние — SQ . • Модель перехода — $T(s,a, s_x)$. • Функция вознаграждения¹ — $R\{s\}$.

1 В некоторых определениях задач MDP допускается, чтобы вознаграждение зависело также от действия и результата, поэтому функция вознаграждения принимает вид $R(s, a, s')$. Такой подход позволяет упростить описание некоторых вариантов среды, но не приводит к какому-либо фундаментальному изменению самой задачи.

Следующий вопрос состоит в том, как должно выглядеть решение этой задачи.

Выше в данной главе было показано, что какая-либо фиксированная последовательность действий не может служить решением этой задачи, поскольку в конечном итоге после ее выполнения агент может оказаться в состоянии, отличном от целевого. Поэтому в решении должно быть указано, что следует делать агенту в

любом состоянии, которого он может достичь. Решение такого рода — это так называемая " $\wedge$ " стратегия. Для обозначения стратегии обычно принято использовать y ; а $y(s)$ — это действие, рекомендованное в соответствии со стратегией y для состояния s .

Если агент имеет полное описание стратегии, то всегда знает, что делать дальше, независимо от результата любого действия.

Каждый раз, когда осуществляется данная конкретная стратегия, начиная с начального состояния, стохастический характер среды приводит к формированию другой истории пребывания в среде. Поэтому качество определения стратегии измеряется по ожидаемой полезности возможных историй пребывания в среде, создаваемых с помощью этой стратегии. " $\wedge$ " Оптимальной стратегией называется такая стратегия, которая позволяет достичь максимальной ожидаемой полезности. Для обозначения оптимальной стратегии принято использовать запись y^* . Если агенту указана стратегия y^* , он принимает решение, что делать, проверяя свои текущие результаты восприятия, которые сообщают ему, что он находится в текущем состоянии s , а затем выполняя действие $y^*(s)$. В любой стратегии функция агента представлена явно, поэтому стратегия является описанием простого рефлексного агента, сформированным с учетом информации, которая используется агентом, действующим на основе полезности.

Оптимальная стратегия для мира, приведенного на рис. 17.1, показана на рис. 17.2, а. Обратите внимание на то, что стоимость выполнения одного шага довольно мала по сравнению со штрафом, который связан со случайным попаданием в квадрат D,2), поэтому оптимальная стратегия для состояния C,1) является предельно осторожной. Эта стратегия рекомендует, что нужно совершить дальний обход препятствия, а не пытаться пройти по короткому пути и тем самым подвергнуться риску попасть в квадрат D,2).

Равновесие между риском и вознаграждением изменяется в зависимости от значения функции $R(s)$ для нетерминальных состояний. На рис. 17.2, б показаны оптимальные стратегии для четырех различных диапазонов изменения значения $R(s)$. Если $R(s) < -1.6284$, жизнь настолько мучительна, что агент направляется прямо к ближайшему выходу, даже если стоимость этого выхода равна -1 . Если $-0.4278 < R(s) < -0.0850$, жизнь довольно дискомфортна; агент выбирает кратчайший маршрут к состоянию $+1$ и стремится избежать риска случайного попадания в состояние -1 . В частности, агент выбирает короткий путь из квадрата C,1). А если жизнь не так уж неприятна ($-0.0221 < R(s) < 0$), оптимальная стратегия состоит в том, чтобы избегать вообще какого-либо риска. В квадратах D,1) и C,2) агент направляется буквально прочь от состояния -1 , чтобы случайно не попасть туда ни при каких обстоятельствах, даже несмотря на то, что из-за этого ему приходится

несколько раз удариться головой о стену. Наконец, если $R(s) > 0$, то жизнь агента становится весьма приятной и он избегает обоих выходов.

При условии, что используются действия, показанные в квадратах D,1), C,2) и C,3), любая стратегия является оптимальной и агент получает бесконечно боль-

шое суммарное вознаграждение, поскольку он никогда не попадает в терминальное состояние. Как это ни удивительно, но оказывается, что существуют шесть других оптимальных стратегий для различных диапазонов значений $R(s)$; в упр. 17.7 предлагается найти эти стратегии.

Пш\ EEJ _*] $-0,4278 < R(s) < -0,0850$ $-0,0221 < OD < 0$ $R(s) > 0$ а) б) Рис. 17.2. Примеры оптимальных стратегий: оптимальная стратегия для стохастической среды со значениями $R(s) = -0.04$ в нетерминальных состояниях (а); оптимальные стратегии для четырех различных диапазонов значений $R(s)$ (б) Тщательное уравнивание риска и вознаграждения является характерной особенностью задач MDP, которая не возникает в детерминированных задачах поиска; более того, такое уравнивание характерно для многих реальных задач принятия решений. По этой причине задачи MDP изучаются в нескольких научных областях, включая искусственный интеллект, исследование операций, экономику и теорию управления. Для вычисления оптимальных стратегий были предложены десятки алгоритмов. В разделах 17.2 и 17.3 описываются два наиболее важных семейства алгоритмов. Но вначале мы должны завершить начатое исследование полезностей и стратегий для задач последовательного принятия решений.

Оптимальность в задачах последовательного принятия решений В примере задачи MDP (см. рис. 17.1) производительность агента определялась по сумме вознаграждений, связанных с посещенными состояниями. Такой выбор показателя производительности нельзя назвать произвольным, но он не является также единственно допустимым. В данном разделе рассматриваются возможные варианты показателей производительности, т.е. варианты способов определения функции полезности по историям пребывания в среде, которые могут записываться как $u_h([s_0 / s_i, \dots, s_n])$. Этот раздел основан на идеях, изложенных в главе 16, и является довольно формальным; основные его пункты подытожены в конце.

Первый вопрос, на который нужно найти ответ, состоит в том, существует ли $\wedge$ конечный горизонт или $\wedge$ бесконечный горизонт для принятия решений. Наличие конечного горизонта означает, что есть такое фиксированное время N , после котор \ш ел] ЕЛ _н t | t ED GO 4 | ЕШ ED tj

рого все теряет смысл, — так сказать, игра все равно окончена. Таким образом, $U_h([s_0, s_1, \dots, s_k]) = C/h([s_0, s_1, \dots, s_k])$ для всех $k > 0$. Например, предположим, что агент начинает свое движение с квадрата C,1) в мире с размерами 4×3 , показанном на рис. 17.1, а также допустим, что $N=3$. В таком случае, чтобы получить хоть малейший шанс

достичь состояния $+1$, агент должен направиться непосредственно к нему, и оптимальное действие состоит в том, чтобы двигаться в направлении Up. С другой стороны, если №100, то запас времени настолько велик, что можно выбрать безопасный маршрут в направлении Left, с[^] Поэтому при наличии конечного горизонта оптимальное действие в каждом конкретном состоянии со временем может измениться. Принято считать, что оптимальная стратегия при наличии конечного горизонта является "с[^] нестационарной.

С другой стороны, если нет заданного предела времени, то нет смысла вести себя поразному в одном и том же состоянии в разное время. Поэтому оптимальное действие зависит только от текущего состояния и оптимальная стратегия является "с[^] стационарной.

Таким образом, стратегии для случая с бесконечным горизонтом проще по сравнению с теми, которые применяются в случае с конечным горизонтом, и в данной главе будет в основном рассматриваться случай с бесконечным горизонтом². Обратите внимание на то, что понятие "бесконечного горизонта" не обязательно означает, что все последовательности состояний являются бесконечными; оно просто говорит о том, что для их выполнения не устанавливаются фиксированные сроки. В частности, в любой задаче MDP с бесконечным горизонтом могут существовать конечные последовательности состояний, содержащие терминальное состояние.

Следующий вопрос, на который необходимо найти ответ, состоит в том, как рассчитать полезность последовательностей состояний. Мы будем рассматривать задачу поиска ответа на этот вопрос как задачу многоатрибутной теории полезности (см. раздел 16.4), где каждое состояние s_i рассматривается как атрибут последовательности состояний $[s_0, s_1, s_2, \dots]$. Чтобы получить простое выражение в терминах атрибутов, необходимо принять своего рода предположение о независимости предпочтений. Наиболее естественное предположение состоит в том, что отношение предпочтения агента между последовательностями состояний является с[^] стационарным.

Стационарность предпочтений означает следующее: если две последовательности состояний, $[s_0, s_1, s_2, \dots]$ и $[s'_0, s'_1, s'_2, \dots]$, начинаются с одного и того же состояния (т.е. $s_0 = s'_0$), то эти две последовательности должны быть упорядочены по предпочтениям таким же образом, как и последовательности $[s_1, s_2, \dots]$ и $[s'_1, s'_2, \dots]$. На естественном языке эту мысль можно выразить так, что если вы предпочитаете одно будущее развитие событий, начинающееся завтра, другому развитию событий, то вы должны также предпочесть это будущее развитие событий, если оно начнется сегодня. На первый взгляд, предположение о стационарности выглядит довольно безобидно, но влечет за собой весьма важные последствия: как оказалось, в

условиях стационарности существуют только два способа присваивания значений полезности последовательностям, которые описаны ниже.

1. [^]Аддитивные вознаграждения. Полезность последовательности состояний определяется следующим образом:

$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + R(s_1) + R(s_2) + \dots$ 2 Это утверждение касается полностью наблюдаемых вариантов среды. Как будет показано ниже, для частично наблюдаемых вариантов среды случай с бесконечным горизонтом не так уж прост.

В мире 4x3, показанном на рис. 17.1, используются аддитивные вознаграждения. Обратите внимание на то, что свойство аддитивности уже было определено неявно в используемых нами функциях стоимости пути для алгоритмов эвристического поиска (см. главу 4).

2. [^]Обесцениваемые вознаграждения, Полезность последовательности состояний определяется с помощью следующего соотношения:

$U_h([s_0, s_1, s_2, \dots]) = R(s_0) + \gamma R(s_1) + \gamma^2 R(s_2) + \dots$ где γ — это [^]коэффициент обесценивания, который представляет собой число от 0 до 1. Коэффициент обесценивания описывает предпочтение агентом текущих вознаграждений перед будущими вознаграждениями. Если коэффициент γ близок к 0, вознаграждения, которые должны быть получены в отдаленном будущем, рассматриваются как малозначимые, а если коэффициент γ равен 1, то обесцениваемые вознаграждения полностью эквивалентны аддитивным вознаграждениям, поэтому аддитивные вознаграждения представляют собой частный случай обесцениваемых вознаграждений. Повидимому, обесценивание представляет собой хорошую модель изменения во времени предпочтений и животных, и человека. Коэффициент обесценивания γ эквивалентен процентной ставке $A/\gamma - 1$.

По причинам, которые вскоре станут очевидными, до конца этой главы предполагается, что используются обесцениваемые вознаграждения, хотя иногда допускается применение значения $\gamma=1$.

Сделанный нами выбор бесконечных горизонтов становится причиной возникновения определенной проблемы: если среда не содержит терминальное состояние или если агент никогда его не достигает, то все истории пребывания в среде будут иметь бесконечную длину, а полезности, связанные с аддитивными вознаграждениями, в общем случае будут бесконечными. Дело в том, что, безусловно, $+\infty$ лучше, чем $-\infty$, но гораздо сложнее сравнивать две последовательности состояний, притом что обе имеют полезность $+\infty$. Для решения этой проблемы можно применить три описанных ниже подхода, два из которых уже упоминались в этой главе.

1. При наличии обесцениваемых вознаграждений полезность любой бесконечной последовательности является конечной. В действительности, если вознаграждения ограничены значением $R^{\wedge}$ и $\gamma < 1$, то можно получить следующее соотношение с использованием стандартной формулы суммы бесконечных геометрических рядов:

$$\sum_{t=0}^{\infty} \gamma^t (R(s_t) - \gamma V(s_t)) = \frac{R(s_0) - \gamma V(s_0)}{1 - \gamma} \quad (7.1)$$

2. Если среда содержит терминальные состояния и гарантируется достижение агентом в конечном итоге одного из этих состояний, то нам никогда не придется сравнивать бесконечные последовательности действий. Стратегия, которая гарантирует достижение терминального состояния, называется γ -правильной стратегией. При наличии правильных стратегий можно использовать $\gamma = 1$ (т.е. аддитивные вознаграждения). Первые три стратегии, пока-

занные на рис. 17.2, б, являются правильными, а четвертая — неправильной.

В ней достигается бесконечное суммарное вознаграждение за счет предотвращения попадания в терминальные состояния, притом что вознаграждение за пребывание в нетерминальных состояниях является положительным. Само существование неправильных стратегий в сочетании с использованием аддитивных вознаграждений может стать причиной неудачного завершения стандартных алгоритмов решения задач MDP, поэтому является веским доводом в пользу применения обесцениваемых вознаграждений.

3. Еще один подход состоит в том, чтобы сравнивать бесконечные последовательности по γ -среднему вознаграждению, получаемому в расчете на каждый временной интервал. Предположим, что с квадратом A,1) в мире 4x3 связано вознаграждение 0.1, тогда как для других нетерминальных состояний предусмотрено вознаграждение 0.01. В таком случае стратегия, в которой агент предпочтет оставаться в квадрате A,1), позволит получать более высокое среднее вознаграждение по сравнению с той стратегией, в которой агент находится в каком-то другом квадрате. Среднее вознаграждение представляет собой полезный критерий для некоторых задач, но анализ алгоритмов со средним вознаграждением выходит за рамки данной книги.

Подводя итог, можно сказать, что использование обесцениваемых вознаграждений связано с наименьшими трудностями при оценке последовательностей состояний. Заключительный этап состоит в том, чтобы показать, как осуществляется выбор между стратегиями с учетом того, что каждая конкретная стратегия вырабатывает не только одну последовательность состояний, но целый ряд возможных последовательностей состояний, притом что каждая из этих последовательностей имеет конкретную вероятность, определяемую моделью перехода для данной среды.

Таким образом, стоимость любой стратегии представляет собой ожидаемую сумму полученных обесцениваемых вознаграждений, где это ожидаемое значение вычисляется по всем возможным последовательностям состояний, которые могут возникнуть при осуществлении данной стратегии. Любая оптимальная стратегия π^* удовлетворяет следующему соотношению:

$$\pi^* = \arg\max_{\pi} E_{\pi} [\sum_{t=0}^{\infty} \gamma^t R(s_t)]$$
 В следующих двух разделах описаны алгоритмы поиска оптимальных стратегий.

17.2. Итерация по значениям В этом разделе представлен алгоритм вычисления оптимальной стратегии, называемый Q -итерацией по значениям. Основная его идея состоит в том, что нужно рассчитать полезность каждого состояния, а затем использовать полезности состояний для выбора оптимального действия в каждом состоянии.

Полезности состояний Полезность состояний определяется в терминах полезности последовательностей состояний. Грубо говоря, полезность любого состояния представляет собой ожидаемую полезность последовательностей состояний, которые могут привести к этому состоянию. Очевидно, что перечень таких последовательностей состояний зависит от осуществляемой стратегии, поэтому начнем с определения полезности $U(s)$ по отношению к конкретной стратегии π . Если мы предположим, что s_t — это состояние, в котором находится агент после осуществления стратегии π в течение t шагов (обратите внимание на то, что s_t — случайная переменная), то получим следующее: $U(s) = E_{\pi} [\sum_{t=0}^{\infty} \gamma^t R(s_t) | s_0 = s]$ (A7.3) На основании этого определения можно утверждать, что истинная полезность любого состояния, которую обозначим как $U(s)$, представляет собой $U^*(s)$, т.е. ожидаемую сумму обесцениваемых вознаграждений, при условии, что агент осуществляет оптимальную стратегию. Обратите внимание на то, что $U(s)$ и $R(s)$ — совершенно разные величины; $R(s)$ — это "кратковременное" вознаграждение за пребывание в состоянии s ; $U(s)$ — "долговременное" суммарное вознаграждение, которое начинается с состояния s и продолжается дальше. На рис. 17.3 показаны рассматриваемые значения полезности для мира 4×3 . Заслуживает внимания то, что значения полезности по мере приближения состояний к выходу +1 становятся выше, поскольку уменьшается количество шагов, требуемых для достижения этого выхода.

0,812 0,762 0,705 0,868 0,655 0,918 0,660 0,611 0,388 12 3 4 Рис. 17.3. Полезности состояний в мире 4×3 , рассчитанные при $\gamma = 0.9$ для нетерминальных состояний Эта функция полезности $U(s)$ позволяет агенту выбирать действия с использованием принципа максимальной ожидаемой полезности, приведенного в главе 16, т.е. выбирать действие, которое максимизирует ожидаемую полезность в следующем состоянии:

$i^*(s) = \arg \max_a T(s,a,s') V(s')$ A7.4) а s , Итак, если полезность некоторого состояния представляет собой ожидаемую сумму обесцениваемых вознаграждений, начиная с данного момента и дальше, то существует прямая связь между полезностью состояния и полезностью его соседних состояний: СГЗ полезность некоторого состояния равна сумме непосредственного вознаграждения за пребывание в этом состоянии и ожидаемой обесцениваемой полезности следующего состояния, при условии, что агент выбирает оптимальное действие. Это означает, что полезность любого состояния можно определить с помощью следующего соотношения:

$U(s) = R(s) + \gamma \max_a V(s') T(s,a,s')$ A7.5) а s , Уравнение 17.5 называется [^].уравнением Беллмана в честь Ричарда Беллмана [97]. Полезности состояний (определяемые с помощью уравнения 17.3 как ожидаемые полезности дальнейших последовательностей состояний) являются решениями множества уравнений Беллмана. В действительности, как будет показано в следующих двух разделах, они являются уникальными решениями.

Рассмотрим одно из уравнений Беллмана для мира 4x3. Уравнение для состояния A,1) приведено ниже.

$GA,1) = -0.04 + \gamma \max \{0.8 [7A,2) + 0.1 ?7B,1) + 0.1 ?7A,1) , (Up) 0.9 ?7A,1) + 0.1 ?7A,2), (Left) 0.9 ?7A,1) + 0.1 ?7B,1), (Down) 0.8 ?7B,1) + 0.1 ?7A,2) + 0.1 ?7A,1)\}$ (Right) После подстановки в это уравнение чисел, приведенных на рис. 17.3, можно обнаружить, что наилучшим действием является Up.

Алгоритм итерации по значениям Уравнение Беллмана является основой алгоритма итерации по значениям, применяемого для решения задач MDP. Если существует p возможных состояний, то количество уравнений Беллмана также равно p , по одному для каждого состояния.

Эти p уравнений содержат p неизвестных — полезностей состояний. Поэтому можно было бы заняться поиском решений системы этих уравнений, чтобы определить полезности. Тем не менее возникает одна проблема, связанная с тем, что эти уравнения являются нелинейными, поскольку оператор "max" — это нелинейный оператор. Системы линейных уравнений могут быть решены очень быстро с использованием методов линейной алгебры, а для решения систем нелинейных уравнений необходимо преодолеть некоторые проблемы. Один из возможных подходов состоит в использовании итерационных методов. Для этого нужно начать с произвольных исходных значений полезностей, вычислить правую часть уравнения и подставить ее в левую, тем самым обновляя значение полезности каждого состояния с учетом полезностей его соседних состояний. Такая операция повторяется до тех пор, пока не достигается равновесие. Допустим, что $U_i(s)$ — это значение полезности для со-

стояния s в i -й итерации. Шаг итерации, называемый $\wedge$ обновлением Беллмана, выглядит следующим образом: $U_i(s) \leftarrow R(s) + \gamma \max_{a \in A(s)} \sum_{s'} T(s,a,s') U_i(s')$ A1.6) а s , Если обновление Беллмана используется неопределенно большое количество раз, то гарантируется достижение равновесия (см. следующий подраздел), и в этом случае конечные значения полезности должны представлять собой решения уравнений Беллмана. В действительности они также представляют собой уникальные решения, и соответствующая стратегия (полученная с помощью уравнения 17.4) является оптимальной. Применяемый при этом алгоритм, называемый Value Iteration, показан в листинге 17.1.

Листинг 17.1. Алгоритм итерации по значениям для вычисления полезностей состояний. Условие завершения работы взято из уравнения 17.8

```
function Value-Iteration{mdp,  $\epsilon$ } returns функция полезности
inputs: mdp, задача MDP с состояниями  $S$ , моделью перехода  $T$ , функцией вознаграждения  $R$ , коэффициентом обесценивания  $\gamma$ 
local variables:  $U$ ,  $C7'$ , векторы полезностей для состояний из  $S$ , первоначально равные нулю
5, максимальное изменение полезности любого состояния во время итерации
repeat  $U \leftarrow U1$ ;  $\delta \leftarrow 0$ 
for each состояние  $s$  in  $S$  do
 $U'[s] \leftarrow R[s] + \gamma \max_{a \in A(s)} \sum_{s'} T(s,a,s') U[s']$ 
a  $s$ , if  $|U'[s] - U[s]| > \delta$  then  $\delta \leftarrow |U'[s] - U[s]|$ 
until  $\delta < \epsilon$ 
return  $U$ 
```

Мы можем применить алгоритм итерации по значениям к миру 4x3 (см. рис. 17.1, а).

Начиная с исходных значений, равных нулю, полезности изменяются, как показано на рис. 17.4, а. Обратите внимание на то, как состояния, находящиеся на различных расстояниях от квадрата D,3), накапливают отрицательное вознаграждение до тех пор, пока в какой-то момент не обнаруживается путь к состоянию D,3), после чего значения полезности начинают возрастать. Алгоритм итерации по значениям может рассматриваться как способ распространения информации через пространство состояний с помощью локальных обновлений.

0,8 0,6 0,4 0,2 -0,2 -D,3) "C,3) A,1) C,1) -D,1) 0 5 10 15 20 25 30 Количество выполненных итераций

а) 1e+07 | 1e+06 | 100000 | 10000 | 1000 | 100 | ? γ ϵ = 0.0001 ϵ = 0.001 ϵ = 0.01 ϵ = 0.1 0,5 0,55 0,6 0,65 0,7 0,75 0,8 0,85 0,9 0,95 1 Коэффициент обесценивания γ

б) Рис. 17.4. Пример применения алгоритма итерации по значениям: график, показывающий изменение полезностей выбранных состояний в процессе итерации по значениям (а); количество итераций по значениям k , необходимое для того, чтобы можно было гарантировать, что ошибка не превышает $\epsilon = \gamma R_{\max}$ для различных значений ϵ , как функция от коэффициента обесценивания γ (б)

Сходимость итерации по значениям Выше было указано, что процедура итерации по значениям в конечном итоге сходится к уникальному множеству решений уравнений Беллмана. В этом разделе показано, почему это происходит. В ходе этого будут представлены некоторые полезные математические идеи и получены

определенные методы оценки ошибки в значении функции полезности, возвращаемом при преждевременном завершении работы алгоритма; это важно, поскольку означает, что количество применяемых итераций алгоритма не обязательно должно стремиться к бесконечности.

Изложение в этом разделе является весьма формальным.

Основным понятием, используемым при доказательстве того, что процедура итерации по значениям сходится, является $\wedge$ сжатие. Грубо говоря, функция сжатия — это функция от одного параметра, которая после ее последовательного применения к двум различным входным значениям вырабатывает два выходных значения, которые "ближе друг к другу" по меньшей мере на некоторую постоянную величину, чем первоначальные фактические параметры. Например, функция "деления на два" представляет собой функцию сжатия, поскольку после деления двух чисел на два разница между ними уменьшается наполовину. Обратите внимание на то, что функция "деления на два" имеет фиксированную точку, а именно нуль, которая остается неизменной в результате применения этой функции. На основании данного примера можно установить два важных свойства функций сжатия, описанных ниже.

- Функция сжатия имеет только одну фиксированную точку; если бы были две фиксированные точки, они бы не приближались друг к другу после применения функции, поэтому такая функция не соответствовала бы определению функции сжатия.
- После применения функции к любому параметру полученное значение должно стать ближе к фиксированной точке (поскольку фиксированная точка не

движется), поэтому в пределе повторное применение функции сжатия всегда приводит к достижению фиксированной точки.

Теперь предположим, что обновление Беллмана (уравнение 17.6) рассматривается как оператор v , который используется для одновременного обновления значений полезности каждого состояния. Обозначим через $C7_{\pm}$ вектор полезностей для всех состояний в i -й итерации. В таком случае уравнение обновления Беллмана может быть записано следующим образом:

$U_{i+1} \leftarrow BU_i$ Затем нужно найти способ измерения расстояний между векторами полезностей.

Мы будем использовать $\wedge$ нормализованный максимум, который измеряет длину вектора по длине его максимального компонента, следующим образом: $|C7| = \max |U(s)|$. При использовании этого определения "расстояние" между двумя векторами, $|U_i - U_{i+1}|$, представляет собой максимальную разность между двумя соответствующими элементами. Основным математическим результатом данного раздела является такое утверждение: СГ5 допустим, что $C7_{\pm}$ и $C7_{\pm}'$ — два вектора полезностей. В таком случае получим следующее: $|BU_i - BU_{i+1}| < \gamma |U_i - U_{i+1}|$ (A7.7)

Это означает, что обновление Беллмана представляет собой функцию сжатия на коэффициент γ , применяемую к пространству векторов полезностей. Таким образом, процедура итерации по значениям всегда сходится к уникальному решению уравнений Беллмана.

В частности, можно заменить значение C_i^t в уравнении 17.7 истинными полезностями U_i для которых $U_i = U$. В таком случае будет получено следующее неравенство: $\|C_i^t - C_i^*\| < \gamma \|U_i - U\|$. Поэтому, если $\|U_i - U\|$ рассматривается как ошибка в оценке C_i^t то можно видеть, что эта ошибка уменьшается при каждой итерации на коэффициент, по меньшей мере равный γ . Это означает, что процедура итерации по значениям сходится экспоненциально быстро. Можно легко рассчитать количество итераций, требуемых для достижения заданной предельной ошибки δ , как описано ниже. Вначале напомним, что, как показывает уравнение 17.1, полезности всех состояний ограничены значением $\pm R_{\max}/(1-\gamma)$. Из этого следует, что максимальная начальная ошибка определяется соотношением $\|U_i - U\| < 2R_{\max}/(1-\gamma)$. Предположим, что для достижения ошибки, не превышающей δ , выполнено N итераций. В таком случае потребуется $\gamma^N \cdot 2R_{\max}/(1-\gamma) < \delta$ итераций, поскольку ошибка уменьшается каждый раз по меньшей мере на величину γ . Взяв логарифмы от этого выражения, можно определить, что достаточно применить следующее количество итераций:

$N = \lceil \log_{\gamma} (\delta(1-\gamma)/(2R_{\max})) \rceil$ На рис. 17.4, б показано, как количество итераций N изменяется в зависимости от γ при различных значениях отношения $R_{\max}/\delta$. Положительной особенностью этого соотношения является то, что из-за экспоненциально быстрой сходимости значение

N не очень зависит от отношения $R_{\max}/\delta$, а отрицательной особенностью — то, что N быстро возрастает по мере приближения значения γ к 1. Уменьшение значения γ позволяет добиться ускорения сходимости, но это фактически приводит к сужению горизонта агента и может не позволить агенту обнаруживать долговременные последствия своих действий.

Анализ предельной ошибки, приведенный выше, позволяет получить определенное представление о том, какие факторы влияют на продолжительность прогона данного алгоритма, но сам подход, основанный на определении предельной ошибки, иногда становится слишком консервативным способом принятия решения о прекращении итераций. Для последней цели можно использовать предел, связывающий ошибку с размерами обновления Беллмана в каждой конкретной итерации.

На основании свойства сжатия (уравнение 17.7) можно показать, что если обновление невелико (т.е. не происходит значительного изменения полезности ни одного состояния), то ошибка также является небольшой по сравнению с истинным

значением функции полезности. Точнее, выполняется следующее условие: if $||C7_{i+1} - C7_i| < \epsilon(1-Y)/y$ then $||C7_{i+1} - C7_i| < \epsilon$ A7.8) В этом и состоит условие завершения, используемое в алгоритме Value Iteration, который приведен в листинге 17.1.

До сих пор мы анализировали ошибку в значении функции полезности, возвращаемом алгоритмом итерации по значениям. СГЗ Но для агента фактически гораздо важнее то, насколько успешно он будет действовать, принимая свои решения на основе данной функции полезности. Предположим, что после i итераций в процедуре итерации по значениям агент получает оценку $C7^i$ истинной полезности и определяет максимальную ожидаемую полезность стратегии $7\Gamma^i$ на основе прогнозирования на один шаг вперед с использованием значения U_L (как в уравнении 17.4). Будет ли выбранное в итоге поведение почти столь же хорошим, как и оптимальное поведение?

Это — крайне важный вопрос для любого реального агента, и было показано, что ответ на него является положительным. Значение $|f_i(s)$ — это полезность, достигаемая, если, начиная с состояния s , осуществляется стратегия π_1^y а $\wedge$ убыточность стратегии $||f_i - u||$ — это самая большая часть полезности, которую агент может потерять, осуществляя стратегию π вместо оптимальной стратегии π^* . Убыточность стратегии π связана с ошибкой в значении полезности U_i следующим неравенством: if $||U_i - U|| < \epsilon$ then $||f_i - u|| < 2\gamma/(A-y)$ A7.9) На практике часто происходит так, что стратегия $7\Gamma^i$ становится оптимальной задолго до того, как сходится значение U_i . На рис. 17.5 показано, как максимальная ошибка в значении U_L и убыточность стратегии приближаются к нулю по мере осуществления процедуры итерации по значениям для среды 4×3 со значением $Y = 0.9$. Стратегия π_A становится оптимальной при $i=4$, даже несмотря на то, что максимальная ошибка в значении U_i все еще остается равной 0.46.

Теперь подготовлено все необходимое для использования процедуры итерации по значениям на практике. Известно, что процедура итерации по значениям в пределе сходится к правильным значениям полезности; ошибка в оценках полезностей может быть ограничена, даже если процедура итерации по значениям останавливается после конечного количества итераций; кроме того, может быть ограничена убы-

точность стратегии, которая связана с осуществлением соответствующей стратегии с максимальной ожидаемой полезностью. В качестве заключительного замечания отметим, что все результаты, приведенные в данном разделе, соответствуют такому случаю, когда применяется обесценивание полезностей, а $y < 1$. Если $y=1$ и среда содержит терминальные состояния, то можно вывести аналогичное множество результатов оценки сходимости и определения предельных значений ошибок, если выполняются некоторые формальные условия.

« 2 Максимальная ошибка - Убыточность стратегии - О 2 4 6 8 10 12 14 Количество выполненных итераций Рис. 17.5. Зависимости максимальной ошибки $|U_i - u|$ в оценках полезности и убыточности стратегии π_i по сравнению с оптимальной стратегией от количества итераций в процедуре итерации по значениям 17.3. Итерация по стратегиям В предыдущем разделе было показано, что возможно выработать оптимальную стратегию, даже если оценка функции полезности является неточной. Если очевидно, что одно действие лучше по сравнению со всеми остальными, то нет необходимости точно определять истинные значения величины полезности всех рассматриваемых состояний. Эта идея подсказывает альтернативный метод поиска оптимальных стратегий. В алгоритме π итерации по стратегиям чередуются описанные ниже два этапа, начиная с некоторой исходной стратегии π_0 .

- π Оценка стратегии. На основе стратегии π_i вычислить $J_i = [J_i]$, полезность каждого состояния, если будет осуществлена стратегия π_i .
- π Усовершенствование стратегии. Вычислить новую стратегию π_{i+1} с максимальной ожидаемой полезностью, используя прогноз на один шаг и исходя из значения U (как в уравнении 17.4).

Алгоритм завершает свою работу после того, как этап усовершенствования стратегии не приводит к изменению значений полезности. Как известно, в этот момент функция полезности U представляет собой фиксированную точку обновления Беллмана, поэтому является решением уравнений Беллмана, а π_i должна быть оп-

тимальной стратегией. Поскольку для каждого конечного пространства состояний количество возможных стратегий является конечным и можно показать, что каждая итерация приводит к определению лучшей стратегии, то алгоритм итерации по стратегиям должен всегда завершать свою работу. Этот алгоритм показан в листинге 17.2.

Листинг 17.2. Алгоритм итерации по стратегиям для вычисления оптимальной стратегии

```
function Policy-Iteration(mdp) returns стратегия
inputs: mdp, задача MDP с состояниями S, моделью перехода T
local variables: U, U\ векторы полезностей для состояний из S, первоначально равные нулю
я, вектор стратегий, индексированный по состояниям, первоначально сформированный случайным образом
repeat
  U ← Policy-Evaluation(я, U, mdp)
until unchanged?
for each состояние s in S do
  if max_a Σ T(s,a,s') U[s'] > Σ T(s,a,s') U[s'] then
    я[s] ← argmax_a Σ T(s,a,s') U[s']
until unchanged?
return я
```

Очевидно, что этап усовершенствования стратегии является несложным, а как реализовать процедуру Policy-Evaluation? Оказалось, что осуществление такого подхода намного проще по сравнению с решением стандартных уравнений Беллмана (а именно это происходит в алгоритме итерации по значениям), поскольку действие, применяемое в каждом состоянии, зафиксировано в соответствии с выбранной стратегией.

Стратегия γ_i определяет действие $\pi_i(s)$, выполняемое в состоянии s на i -й итерации.

Это означает, что можно воспользоваться упрощенной версией уравнения Беллмана A7.5), которая связывает полезность состояния s (соответствующую стратегии π) с полезностями его соседних состояний, следующим образом:

$U_i(s) = R(s) + \gamma \sum_{s'} P_{ij}(s, s') V_j(s')$ A7.10) Например, предположим, что γ_{ii} — это стратегия, показанная на рис. 17.2, а.

В таком случае имеет место $\gamma_{i1} = U_p$, $\gamma_{i2} = U_p$ и т.д., а упрощенные уравнения Беллмана принимают следующий вид:

$V_1(l, l) = -0.04 + 0.8 V_1(l, 2) + 0.1 V_1(l, l) + 0.1 V_{\pm B \neq 1}(l, 2) = -0.04 + 0.8 V_1(l, 3) + 0.2 V_1(A, 2)$ Важно отметить, что эти уравнения — линейные, поскольку оператор "max" был удален. Для p состояний имеется p линейных уравнений с p неизвестными, которые

могут быть решены точно за время $O(p^3)$ с помощью стандартных методов линейной алгебры.

Для небольших пространств состояний оценка стратегии с использованием точных методов решения часто является наиболее эффективным подходом, а для больших пространств состояний затраты времени $O(p^3)$ могут оказаться чрезмерно большими. К счастью, точная оценка стратегии не требуется. Вместо этого можно выполнить некоторое количество упрощенных этапов итерации по значениям (они являются упрощенными, поскольку стратегия зафиксирована) для получения достаточно хорошей аппроксимации полезности. Упрощенное обновление Беллмана для этого процесса определяется таким соотношением:

$U_{i+1}(s) \leftarrow R(s) + \gamma \sum_{s'} T(s, \pi_i(s), s') V_i(s')$ и определяемая в нем операция подстановки повторяется k раз для получения следующей оценки полезности. Результирующий алгоритм называется модифицированной итерацией по стратегиям. Он часто оказывается намного более эффективным, чем стандартная итерация по стратегиям или итерация по значениям.

Алгоритмы, описанные до сих пор в данной главе, требуют одновременного обновления полезности или стратегии для всех состояний. Как оказалось, применение такой организации работы не является строго необходимым. В действительности в каждой итерации можно выбирать любое подмножество состояний и применять к этому подмножеству либо тот, либо другой вид обновления (усовершенствование стратегии или упрощенную итерацию по значениям). Такой наиболее общий алгоритм называется асинхронной итерацией по стратегиям. При соблюдении определенных условий выбора исходной стратегии и функции полезности гарантируется сходимость асинхронной итерации по стратегиям к

определенной оптимальной стратегии. А то, что мы вправе выбирать для работы с ними любые состояния, означает, что могут быть разработаны гораздо более эффективные эвристические алгоритмы, например, алгоритмы, которые сосредотачиваются на обновлении значений состояний, которые с наибольшей вероятностью будут достигнуты при осуществлении качественной стратегии. Такой подход имеет гораздо больше смысла в реальной жизни — если человек не намеревается попасть на прибрежную полосу, спрыгнув с высокой скалы, то для него нет смысла заниматься точной оценкой стоимости связанных с этим результирующих состояний.

17.4. Марковские процессы принятия решений в частично наблюдаемых вариантах среды В описании марковских процессов принятия решений, приведенном в разделе 17.1, предполагалось, что среда является полностью наблюдаемой. При использовании этого предположения агент всегда знает, в каком состоянии он находится. Это предположение, в сочетании с предположением о марковости модели перехода, означает, что оптимальная стратегия зависит только от текущего состояния. А если среда является только частично наблюдаемой, то вполне очевидно, что ситуация становится гораздо менее ясной. Агент не всегда точно знает, в каком состоянии находится, поэтому не

может выполнить действие $k(s)$, рекомендуемое для этого состояния. Кроме того, полезность состояния s и оптимальное действие в состоянии s зависят не только от s , но и от того, насколько много агент знает, находясь в состоянии s . По этим причинам задачи $\wedge$ MDP в частично наблюдаемой среде (Partially Observable MDP — POMDP, читается как "пом-ди-пи") обычно рассматриваются как намного более сложные по сравнению с обычными задачами MDP. Однако невозможно игнорировать необходимость решения задач POMDP, поскольку реальный мир изобилует такими задачами.

В качестве примера еще раз рассмотрим мир с размерами 4×3 (см. рис. 17.1), но на этот раз предположим, что агент вообще не имеет датчиков, а также не представляет себе, где находится. Точнее, допустим, что начальным состоянием агента с равной вероятностью может быть любое из девяти нетерминальных состояний (рис. 17.6, а). Очевидно, что если бы агент знал, что он находится в квадрате C,3), то отправился бы направо, выполнив движение Right, а если бы знал, что он — в квадрате A,1), то направился бы вверх с помощью движения Up, но поскольку агент может находиться в любом квадрате, то что ему делать? Один из возможных ответов состоит в том, что агенту необходимо вначале действовать так, чтобы уменьшить неопределенность своего положения и только после этого отправиться к выходу +1. Например, если агент выполнит движение Left пять раз, то с наибольшей вероятностью окажется у левой стены (см. рис. 17.6, б), а если он после этого пять раз выполнит движение Up, то, вполне вероятно, будет находиться вверху,

возможно даже, в левом верхнем углу (см. рис. 17.6, в). Наконец, если он пять раз выполнит движение Right, то получит хорошие шансы (около 77,5%) достижения выхода + 1 (см. рис. 17.6, г). Продолжение после этого движения вправо повышает его шансы до 81,8%. Поэтому такая стратегия является удивительно безопасной, но при ее использовании агенту потребуется довольно много времени для достижения желаемого выхода, а ожидаемая полезность будет составлять лишь около 0.08.

Оптимальная стратегия, который вскоре будет описана, позволяет достичь намного лучших результатов.

0,111 0,111 0,111 0,111 0,111 0,111 0,111 0,111 ПШо1 [тага 0,111 0,622 0,005 0,003 0,221 ш 0,024 0,071 0,003 0,003 [Щ4] шш 0,000 0,005 0,034 0,005 0,007 0,006 0,019 0,007 0,008 Idjzsl Г57Т051 0,030 1 0,300 0,221 0.371 0,010 ш 0,012 0,008 0,059 0,008 [одюо] |0,012| 0,000 а) б) в) г) Рис. 17.6. Пример реализации стратегии агента, не основанной на оптимальном подходе: первоначальное распределение вероятностей для местонахождения агента (а); распределение вероятностей после выполнения движения Left пять раз (б); то же, после выполнения движения Up пять раз (в); то же, после выполнения движения Right пять раз (г) Чтобы найти подход к решению задач POMDP, необходимо вначале определить их должным образом. Любая задача POMDP состоит из таких же компонентов, как и задача MDP (модель перехода $T(s, a, s')$) и функция вознаграждения $R(s)$), но имеет также $\wedge$ модель наблюдения $O\{s, o\}$, которая задает вероятность получения

результатов наблюдения o в состоянии s . Например, рассматриваемый в данном случае агент без датчиков имеет только одно возможное наблюдение (пустое наблюдение), и такое наблюдение возникает с вероятностью 1 в любом состоянии.

В главах 3 и 12 рассматривались задачи планирования в недетерминированных и частично наблюдаемых вариантах среды и было определено доверительное состояние (множество фактических состояний, в которых может находиться агент) как ключевая концепция для описания и вычисления решений. В задачах POMDP это понятие требует определенного уточнения. Теперь доверительным состоянием β становится распределение вероятностей по всем возможным состояниям. Например, начальное доверительное состояние в ситуации, показанной на рис. 17.6, я, может быть записано как $iiiiiiii \wedge \text{'Э'Э'Э'Э'Э'Э'Э'Э'}$ * Мы будем обозначать через $b(s)$ вероятность, присвоенную фактическому состоянию s доверительным состоянием β . Агент может вычислить свое текущее доверительное состояние как распределение условных вероятностей по фактическим состояниям, если дана последовательность происшедших до сих пор наблюдений и действий. Такая задача по сути сводится к задаче фильтрации (см. главу 15).

Основное рекурсивное уравнение фильтрации (см. уравнение 15.3) показывает, как вычислить новое доверительное состояние из предыдущего доверительного

состояния и нового наблюдения. Для решения задач POMDP необходимо также учитывать определенное действие и использовать немного другую систему обозначений, но результат остается по сути тем же самым. Если предыдущим доверительным состоянием было $b(s)$, а агент выполнил действие a и получил результаты наблюдения o , то новое доверительное состояние определяется следующим соотношением: $b'(s') = \frac{1}{Z} \sum_o P(o|a,s') b(s) A^{7.11}$ где A — нормализующая константа, при использовании которой сумма вероятностей доверительных состояний становится равной 1. Это уравнение можно сокращенно записать как $b' = \text{Forward}(b, a, o)$.

Основная идея, необходимая для понимания сути задач POMDP, состоит в следующем: s^* оптимальное действие зависит только от текущего доверительного состояния агента. Это означает, что оптимальную стратегию можно описать, отобразив стратегию $\pi^*(b)$ с доверительных состояний на действия. Она не зависит от фактического состояния, в котором находится агент. Это — очень благоприятная особенность, поскольку агент не знает своего фактического состояния; все, что он знает, — это лишь его доверительное состояние. Поэтому цикл принятия решений агентом POMDP состоит в следующем.

1. С учетом текущего доверительного состояния b выполнить действие $a = \pi^*(b)$.

3 Модель наблюдения по сути идентична модели восприятия для временных процессов, как было описано в главе 15. Как и функция вознаграждения для задач MDP, модель наблюдения также может зависеть от действия и результирующего состояния, но связанное с этим изменение не является фундаментальным.

2. Получить результаты наблюдения o . 3. Установить текущее доверительное состояние равным $\text{Forward}(b, a, o)$ и повторить ту же процедуру.

Теперь мы можем рассматривать задачи POMDP как требующие поиска в пространстве доверительных состояний, во многом аналогично тем методам, которые применялись для решения задач в отсутствие датчиков и задач в условиях непредвиденных ситуаций, описанных в главе 3. Основное различие состоит в том, что пространство доверительных состояний POMDP является непрерывным, поскольку доверительное состояние POMDP — это распределение вероятностей. Например, доверительное состояние для мира 4×3 представляет собой точку в 11-мерном непрерывном пространстве. Любое действие изменяет не только физическое состояние, но и доверительное состояние, поэтому оценивается согласно информации, полученной агентом в качестве результата. Таким образом, задачи POMDP должны включать стоимость информации в качестве одного из компонентов задачи принятия решений (см. раздел 16.6).

Рассмотрим более внимательно результаты действий. В частности, рассчитаем вероятность того, что агент, находящийся в доверительном состоянии b , достигнет

доверительного состояния b' после выполнения действия a . Итак, если известно действие и последующее наблюдение, то уравнение 17.11 должно обеспечить получение детерминированного обновления доверительного состояния, иными словами, $b' = \text{Forward}(b, a, o)$. Безусловно, результаты последующего наблюдения еще не известны, поэтому агент может перейти в одно из нескольких возможных доверительных состояний b' , в зависимости от того наблюдения, которое последует за данным действием. Вероятность получения результатов наблюдения o , при условии, что действие a было выполнено в доверительном состоянии b , определяется путем суммирования по всем фактическим состояниям s' , которых может достичь агент:

$$P(o|a,b) = \sum_{s'} P(o|a,s',b) P(s'|a,b) = \sum_{s'} 0(s^*, o) P(s'|a,b) \sum_{s'} 0(s',o) V^* T(s,a,s') b(s)$$

Обозначим вероятность достижения состояния b' из b , если дано действие a , как $t(b, a, b')$. В таком случае справедливо следующее соотношение: $t(b, a, b') = P(b'|a,b) = \sum_{o} P(b'|o,a,b) P(o|a,b) = \sum_{o} \sum_{s'} P(b'|o,a,b) V O(s',o) \sum_{s'} T(s,a,s') b(s)$ 17.12. $O(s',o) = 1$ где $P(b'|o, a,b)$ равно 1, если $b' = \text{Forward}(b, a, o)$, и 0 — в противном случае.

Уравнение 17.12 можно рассматривать как определение модели перехода для пространства доверительных состояний. Мы можем также определить функцию вознаграждения для доверительных состояний (т.е. ожидаемое вознаграждение, относящееся к фактическим состояниям, в которых может находиться агент) следующим образом: $r(b) = \sum_{s'} b(s) R(s)$ Итак, создается впечатление, что $t(b, a, b')$ и $r(b)$ совместно определяют наблюдаемую задачу MDP в пространстве доверительных состояний. Кроме того, можно показать, что оптимальная стратегия для этой задачи MDP, $\pi^*(b)$, является также оптимальной стратегией для оригинальной задачи POMDP. Другими словами, π^* = решение любой задачи POMDP в пространстве физических состояний можно свести к решению задачи MDP в соответствующем пространстве доверительных состояний.

Этот факт, возможно, станет менее удивительным, если мы вспомним, что доверительное состояние по определению всегда является наблюдаемым для агента.

Но необходимо отметить следующее: хотя мы свели задачу POMDP к задаче MDP, полученная задача MDP имеет непрерывное (а иногда многомерное, с большим количеством размерностей) пространство состояний. Для решения подобных задач MDP нельзя непосредственно применить ни один из алгоритмов MDP, описанных в разделах 17.2 и 17.3. Но, как оказалось, существует возможность разработать версии алгоритмов итерации по значениям и итерации по стратегиям, которые могут применяться для решения задач MDP с непрерывными состояниями.

Основная идея состоит в том, что стратегия $\pi(b)$ может быть представлена как множество областей пространства доверительных состояний, каждая из которых

связана с конкретным оптимальным действием⁴. Функция стоимости связывает с каждой из областей отдельную линейную функцию от b . На каждом этапе итерации по значениям или по стратегиям уточняются границы областей и могут вводиться новые области.

Подробное описание соответствующих алгоритмов выходит за рамки данной книги, но мы сообщаем решение для мира 4×3 без датчиков. Оптимальная стратегия состоит в следующем: [Left, Up, Up, Right, Up, Up, Right, Up, Up, Right, Up, Right, Up, Right, Up, ...] Эта стратегия представляет собой последовательность, поскольку рассматриваемая задача в пространстве доверительных состояний является детерминированной — в ней нет наблюдений. Воплощенный в этой стратегии "секрет" состоит в том, что нужно предусмотреть для агента однократное движение Left для проверки того, что он не находится в квадрате D,1), с тем чтобы в дальнейшем было достаточно безопасно продолжать движения Up и Right для достижения выхода +1.

Агент достигает выхода +1 в 86,6% попыток и добивается этого гораздо быстрее по сравнению со стратегией, приведенной выше в данном разделе, поэтому его ожидаемая полезность повышается до 0.38, что гораздо больше по сравнению с 0.08.

4 Для некоторых задач POMDP оптимальная стратегия имеет бесконечное количество областей, поэтому простой подход с использованием списка областей не позволяет добиться успеха, и для поиска даже приближенного решения нужны более изощренные методы.

Для более сложных задач POMDP с непустыми результатами наблюдений приближенный поиск оптимальных стратегий является очень сложным (фактически такие задачи являются PSPACE-трудными, т.е. действительно чрезвычайно трудными). Задачи с несколькими десятками состояний часто оказываются неразрешимыми. В следующем разделе описан другой, приближенный метод решения задач POMDP, основанный на опережающем поиске.

17.5. Агенты, действующие на основе теории решений В этом разделе будет описан исчерпывающий подход к проектированию агентов для частично наблюдаемых, стохастических вариантов среды. Как показано ниже, основные элементы этого проекта должны быть уже знакомы читателю. • Модели перехода и наблюдения представлены в виде динамических байесовских сетей (см. главу 15). • Динамическая байесовская сеть дополняется узлами принятия решений и узлами полезности, по аналогии с теми, которые использовались в сетях принятия решений в главе 16. Результирующая модель называется ^динамической сетью принятия решений (Dynamic Decision Network — DDN). • Для учета данных о каждом новом восприятии и действии и для обновления представления доверительного состояния

используется алгоритм фильтрации. • Решения принимаются путем проектирования в прямом направлении возможных последовательностей действий и выбора наилучших из этих последовательностей.

Основное преимущество использования динамической байесовской сети для представления модели перехода и модели восприятия состоит в том, что такая сеть позволяет применять декомпозицию описания состояния на множество случайных переменных во многом аналогично тому, как в алгоритмах планирования используются логические представления для декомпозиции пространства состояний, применяемого в алгоритмах поиска. Поэтому проект агента представляет собой практическую реализацию агента, действующего с учетом полезности, который был кратко описан в главе 2.

Поскольку в этом разделе будут использоваться динамические байесовские сети, вернемся к системе обозначений главы 15, где символом x_t обозначается множество переменных состояния во время t , а E_t — переменные свидетельства. Таким образом, там, где до сих пор в этой главе использовалось обозначение s_t (состояние во время t), теперь будет применяться обозначение x_t . Для обозначения действия во время t будет использоваться запись A_t , поэтому модель перехода $T(s, < a, s')$ представляет собой не что иное, как $P (X_{t+1} | x_t / A_t)$, а модель наблюдения $O(s, o)$ — то же, что и $P (E_t | x_t)$. Для обозначения вознаграждения, полученного во время t , будет применяться запись R_t , а для обозначения полезности состояния во время t — запись u_t . При использовании такой системы обозначений динамическая сеть принятия решений принимает вид, подобный показанному на рис. 17.7.

Рис. 17.7. Универсальная структура динамической сети принятия решений. Переменные с известными значениями выделены затенением. Текущим временем является t , а агент должен решить, что делать дальше, т.е. выбрать значение для A_t . Сеть развернута в будущее на три этапа и представляет будущее вознаграждение, а также полезность состояния на горизонте прогноза. Динамические сети принятия решений позволяют получить краткое представление крупных задач POMDP, поэтому могут использоваться в качестве входных данных для любого алгоритма POMDP, включая те из них, которые относятся к методам итерации по значениям и итерации по стратегиям. В этом разделе мы сосредоточимся на прогностических методах, которые проектируют последовательности действий в прямом направлении от текущего доверительного состояния во многом таким же образом, как и алгоритмы ведения игр, описанные в главе 6. Сеть, приведенная на рис. 17.7, спроектирована в будущее на три этапа; неизвестными являются все текущие и будущие решения, а также будущие наблюдения и вознаграждения.

Обратите внимание на то, что сеть включает узлы вознаграждений для x_{t+1} и x_{t+2} , но для x_{t+3} — только узел полезности. Это связано с тем, что агент должен максимизировать (обесцениваемую) сумму всех будущих вознаграждений, а

полезность $U(X_{t+3})$ представляет и вознаграждение, относящееся к X_{t+3} , и все будущие вознаграждения.

Как и в главе 6, предполагается, что значение полезности U доступно только в некоторой приближенной форме, поскольку, если бы были известны точные значения полезности, то не было бы необходимости заглядывать вперед на глубину больше 1.

На рис. 17.8 показана часть дерева поиска, соответствующего приведенной на рис. 17.7 сети DDN, развернутой в будущее на три этапа. Каждый из узлов, обозначенных треугольником, представляет собой доверительное состояние, в котором агент принимает решение A_{t+i} для $i = 0, 1, 2, \dots$. Узлы, обозначенные кружками, соответствуют выборам, сделанным средой, а именно тому, какие получены результаты наблюдений E_{t+i} . Обратите внимание на то, что в этой сети нет узлов жеребьевки, соответствующих результатам действий; это связано с тем, что обновление доверительного состояния для любого действия является детерминированным, независимо от фактического результата.

Доверительное состояние каждого обозначенного треугольником узла можно вычислить, применив алгоритм фильтрации к ведущей к нему последовательности наблюдений и действий. Таким образом, в алгоритме учитывается тот факт, что для принятия решения о выполнении действия A_{t+i} агент должен иметь доступные результаты восприятия $E_{t+1}, \dots, E_{t+i}$, даже несмотря на то, что во время t он не знает, какими будут эти результаты восприятия. Благодаря этому агент, действующий на основе теории принятия решений, автоматически учитывает стоимость информации и выполняет действия по сбору информации, когда это потребуется.

Рис. 17.8. Часть прогностического решения для сети DDN, приведенной на рис. 17.7. Из данного дерева поиска можно извлечь информацию о решении, резервируя значения полезности, взятые из листовых узлов, вычисляя среднее в узлах жеребьевки и определяя максимальные значения в узлах принятия решений. Такая организация работы аналогична применяемой в алгоритме Expectiminimax для деревьев игр с узлами жеребьевки, за исключением того, что, во-первых, вознаграждения могут быть предусмотрены и в состояниях, отличных от листовых, и, во-вторых, узлы принятия решений соответствуют доверительным состояниям, а не фактическим состояниям. Временная сложность исчерпывающего поиска до глубины d выражается как $O(D^{d-1} E^d)$, где D — количество доступных действий; E — количество возможных наблюдений. Для получения решений, близких к оптимальным, при решении таких задач, в которых коэффициент обесценивания γ не слишком близок к 1, часто бывает вполне приемлемым поверхностный поиск. Существует также возможность аппроксимировать этап усреднения в узлах жеребьевки, осуществляя выборку из множества возможных наблюдений вместо

суммирования по всем возможным наблюдениям. Могут также применяться некоторые другие способы быстрого поиска качественных приближенных решений, но мы отложим их описание до главы 21.

Действующие по принципам теории решений агенты, основанные на динамических сетях принятия решений, имеют целый ряд преимуществ по сравнению с другими, более простыми агентами, проекты которых представлены в предыдущих главах. В частности, они способны функционировать в частично наблюдаемых неопределенных вариантах среды и могут легко пересматривать свои "планы" с учетом непредвиденных результатов наблюдений. При использовании подходящих моделей восприятия эти агенты могут справиться с ситуациями наподобие отказа датчиков и способны составлять планы по сбору информации. Под давлением жестких требований ко времени и в сложных вариантах среды эти агенты проявляют способность осуществлять "корректный переход к более примитивному поведению" (graceful degradation) с использованием различных методов вычисления приближенных решений. Так чего же в них недостает? Наиболее важным недостатком агентов, осно-

ванных на использовании алгоритмов динамической сети принятия решений, является то, что в них используется прямой поиск, полностью аналогичный тому, который предусмотрен в алгоритмах поиска в пространстве состояний, описанных в части II. В части IV было показано, что способность рассматривать частично упорядоченные, абстрактные планы с использованием целенаправленного поиска обеспечивает существенное расширение возможностей решения задач, особенно если при этом применяются библиотеки планов. Кроме того, были предприняты попытки распространить эти методы на вероятностную проблемную область, но до сих пор они оказывались неэффективными. Еще одной связанной с этим проблемой является слишком простой язык динамических сетей принятия решений, который по сути является пропозициональным. Было бы желательно распространить на задачи принятия решений некоторые идеи вероятностных языков первого порядка, описанные в разделе 14.6. Современные исследования показали, что такое расширение возможно и что оно позволяет получить существенные преимущества, как описано в заметках в конце данной главы.

17.6. Принятие решений при наличии нескольких агентов: теория игр Данная глава в основном посвящена теме принятия решений в неопределенных вариантах среды. А как обстоят дела в том случае, если неопределенность связана с наличием других агентов и осуществлением ими решений, которые они принимают? И что будет, если на решения этих агентов, в свою очередь, влияют решения нашего агента? Эти вопросы уже рассматривались в настоящей книге при описании игр в главе 6. Но в этой главе речь в основном шла об играх с полной информацией, в которых игроки делают ходы по очереди: в подобных играх для определения оптимальных ходов

может использоваться минимаксный поиск. А в данном разделе рассматриваются некоторые идеи [^] теории игр, которые могут применяться при анализе игр с одновременно выполняемыми ходами. Для упрощения изложения вначале рассмотрим игры, которые продолжаются только в течение одного хода. На первый взгляд может показаться, что слово "игра" не совсем подходит для обозначения такого упрощения, которое сводится к одному ходу, но в действительности теория игр используется в очень серьезных ситуациях принятия решений, включая ведение дел о банкротстве, организацию аукционов по распределению спектра радиочастот, принятие решений по разработке промышленной продукции и назначению на нее цен, а также национальную оборону. В таких ситуациях речь часто идет о миллиардах долларов и сотнях тысяч человеческих жизней. Теория игр может использоваться по меньшей мере в двух описанных ниже направлениях.

1. Проектирование агента. Теория игр позволяет анализировать решения агента и вычислять ожидаемую полезность для каждого решения (с учетом предположения, что другие агенты действуют оптимальным образом согласно теории игр). Например, в игре в чет и нечет на двух пальцах (эту игру на пальцах называют также топа, от итальянского слова сатогга — группа) два игрока, О (Odd — нечетный) и Е (Even — четный), одновременно показывают один или два пальца. Допустим, что общее количество показанных пальцев равно f . Если число f является нечетным, игрок О получает f долларов от игрока Е,

а если число f — четное, игрок Е получает f долларов от игрока О. Теория игр позволяет определить наилучшую стратегию в игре против рационально действующего игрока и ожидаемый выигрыш для каждого игрока⁵.

2. Проектирование механизма. Если в среде присутствует много агентов, то может существовать возможность так определить правила действий в этой среде (т.е. правила игры, в которую должны играть агенты), чтобы общее благосостояние всех агентов максимизировалось, если каждый агент принимает обоснованное теорией игр решение, максимизирующее его собственную полезность. Например, теория игр позволяет проектировать такие протоколы для коллекции маршрутизаторов трафика Internet, чтобы каждый маршрутизатор стремился действовать в направлении максимизации глобальной пропускной способности. Проектирование механизма может также использоваться для создания интеллектуальных мультиагентных систем, которые решают сложные задачи в распределенной форме без необходимости для каждого агента знать о том, какая задача решается в целом.

Любая игра в теории игр определяется с помощью описанных ниже компонентов. • [^] Игроки, или агенты, которые должны принимать решения. Наибольшее внимание в исследованиях уделялось играм с двумя игроками, хотя достаточно часто рассматриваются также игры с n игроками, где $n > 2$. В этой главе имена игроков записываются с прописной буквы, например Alice и Bob или Он Е. • [^] Действия,

которые могут быть выбраны игроками. В этой главе имена действий записываются строчными буквами, например *one* или *testify*. В распоряжении игроков могут находиться одинаковые или неодинаковые множества действий. • ^ Матрица вознаграждений, которая определяет полезность для каждого игрока каждой комбинации действий всех игроков. Матрица вознаграждений для игры чет или нечет на двух пальцах приведена в табл. 17.1 (*one*— выбор действия, в котором игрок показывает один палец, *two* — два пальца).

Таблица 17.1. Матрица вознаграждений для игры чет или нечет на двух пальцах

	one	two
one	0, 2	-2, 0
two	3, 0	-3, 0

Например, в нижнем правом углу показано, что если игрок О выбирает действие *two*, а игрок Е также выбирает *two*, то вознаграждение для Е равно 4, а для О равно -4.

Каждый игрок, участвующий в игре, должен выработать, а затем осуществить стратегию (напомним, что такой же термин используется для обозначения способа выбора действий не только в теории игр, но и в теории принятия решений). ^ Чистая стратегия — это детерминированная стратегия, определяющая конкретное действие в каждой ситуации. 5 Игра в чет и нечет — это развлекательная версия реальной игры в инспекцию. В таких играх инспектор выбирает день для инспектирования предприятия (такого как ресторан или завод биологического оружия), а оператор предприятия выбирает день, в который нужно спрятать все запрещенные предметы. Если эти дни не совпадают, выигрывает инспектор, а если совпадают — выигрывает оператор предприятия.

действие, которое должно быть выполнено в каждой ситуации; в игре, состоящей из одного хода, чистая стратегия состоит из одного действия. Анализ игр приводит к формулировке идеи ^ смешанной стратегии, которая представляет собой рандомизированную стратегию, предусматривающую выбор конкретных действий среди доступных действий в соответствии с определенным распределением вероятностей. Смешанная стратегия, в которой обычно выбирается действие *a* с вероятностью *p*, а в противном случае выбирается действие *b*, условно обозначается как $[p:a; (1-p):b]$. Например, смешанной стратегией для игры в чет и нечет на двух пальцах может быть $[0.5: \text{one}; 0.5: \text{two}]$. ^ Профилем стратегии называется вариант присваивания стратегии каждому игроку; после того как задан профиль стратегии, ^ результат игры для каждого игрока принимает определенное числовое значение. ^ Решением игры называется профиль стратегии, в котором каждый игрок принимает рациональную стратегию. Как будет показано ниже, наиболее важной проблемой в теории игр является определение того, что подразумевается под словом "рациональный", когда каждый агент выбирает только часть профиля стратегии, определяющую этот результат. Важно понять, что результаты представляют собой фактические итоги ведения игры, а решения являются теоретическими конструкциями, которые используются для анализа игры. Ниже будет показано, что некоторые игры имеют решение только в смешанных стратегиях. Но это не означает,

что игрок должен в буквальном смысле слова принимать смешанную стратегию, чтобы действовать рационально.

Рассмотрим описанную ниже историю. Два отпетых грабителя, Алиса и Боб, были пойманы с поличным недалеко от места совершенного ими ограбления, и теперь их отдельно допрашивают следователи. Оба они знают, что, признавшись в совместном совершении этого преступления, получают по 5 лет тюремного заключения за грабеж, а если оба откажутся признаваться, то получают только по 1 году каждый за менее грубое правонарушение — владение краденым имуществом. Но следователи предлагают отдельно каждому из них такую сделку: если вы дадите свидетельство против вашего партнера как главаря шайки грабителей, то вас освободят, а партнера осудят на 10 лет. Теперь Алиса и Боб сталкиваются с так называемой $\wedge$ дилеммой заключенного: должны ли они свидетельствовать (testify) или отказаться (refuse)?

Будучи рациональными агентами, и Алиса, и Боб желают максимизировать свою собственную ожидаемую полезность. Предположим, что Алиса полностью безразлична к судьбе своего партнера, а ее оценка полезности уменьшается пропорционально количеству лет, которые она проведет в тюрьме, независимо от того, что случится с Бобом. Боб думает точно так же. Чтобы упростить для себя выработку рационального решения, оба грабителя составляют матрицу вознаграждений, приведенную в табл. 17.2.

Таблица 17.2. Матрица вознаграждений для дилеммы заключенного Alice:testify Alice:refuse Bob: testify A = -5, B = -5 A = -10, B = 0 Bob:refuse A = 0, B = -10 A = -1, B = -1 Алиса анализирует эту матрицу вознаграждений следующим образом: предположим, что Боб будет свидетельствовать против меня. В таком случае я получу 5 лет,

если буду свидетельствовать против него, и 10 лет — если откажусь, поэтому в данном случае лучше свидетельствовать против него. С другой стороны, если Боб откажется, то я получу 0 лет, если буду свидетельствовать, и 1 год, если откажусь, поэтому и в данном случае лучше свидетельствовать. Итак, и в том и в другом случае для меня лучше свидетельствовать против Боба, поэтому так я и должна поступить.

Алиса обнаружила, что testify— это $\wedge$ доминантная стратегия для рассматриваемой игры. Принято считать, что стратегия s для игрока p $\wedge$ строго доминирует над стратегией s' , если результат стратегии s лучше для игрока p , чем результат стратегии s' , при любом выборе стратегий другими игроками. Стратегия s $\wedge$ слабо доминирует над s' , если s лучше чем s' по меньшей мере в одном профиле стратегий и не хуже в любом другом. Доминантной стратегией является стратегия, которая доминирует над всеми остальными. Нерационально вести игру на основе стратегии, над которой строго доминируют другие стратегии, и нерационально не вести игру на основе

доминантной стратегии, если она существует. Будучи рациональным агентом, Алиса выбирает доминантную стратегию. Прежде чем перейти к дальнейшему изложению, необходимо рассмотреть еще несколько терминов: принято считать, что некоторый результат является $\wedge$ оптимальным согласно принципу Парето, если нет другого результата, который предпочли бы все игроки. Над результатом $\wedge$ доминирует по принципу Парето другой результат, если все игроки предпочитают этот другой результат.

А если Алиса — не только рациональный, но и умный агент, она должна продолжить рассуждение следующим образом: доминантной стратегией Боба также является свидетельство против меня. Поэтому он будет свидетельствовать, и мы оба получим по пять лет. Если оба игрока имеют доминантную стратегию, то комбинация этих стратегий называется $\wedge$ равновесием доминантных стратегий. Вообще говоря, профиль стратегий образует $\wedge$ равновесие, если ни один игрок не может извлечь выгоду от переключения с одной стратегии на другую, при условии, что все остальные игроки продолжают придерживаться одной и той же стратегии. Равновесие по сути представляет собой локальный оптимум в пространстве стратегий; оно является вершиной пика, вокруг которого находятся спады вдоль всех измерений, где измерения соответствуют вариантам выбора стратегии игроком.

Парадоксальность дилеммы заключенного состоит в том, что результат в точке равновесия для обоих игроков хуже по сравнению с результатом, которого они достигли бы, если бы оба отказались свидетельствовать друг против друга. Иными словами, результат для равновесного решения доминируется по принципу Парето результатом $(-1, -1)$, который соответствует обоюдному отказу от свидетельства, (refuse, refuse).

Существует ли какой-либо способ, с помощью которого Алиса и Боб могли бы формально прийти к результату $(-1, -1)$? Безусловно, что для них обоих вариант, в котором они отказываются свидетельствовать, является допустимым, но этот вариант маловероятен. Любой игрок, анализирующий вариант хода refuse, поймет, что для него было бы лучше выбрать ход testify. В этом состоит притягательная мощь точки равновесия.

Математик Джон Нэш (род. в 1928 году) доказал теорему, согласно которой $\wedge$ = каждая игра имеет равновесие такого типа, которое определено в данном примере.

6 Оптимальность по принципу Парето названа в честь экономиста Вильфредо Парето (1848-1923).

Теперь указанное условие называют в его честь равновесием Нэша. Очевидно, что равновесием доминантных стратегий является равновесие Нэша (упр. 17.9), но не все игры имеют доминантные стратегии. Теорема Нэша означает, что равновесные стратегии могут существовать даже при отсутствии доминантных стратегий.

В дилемме заключенного равновесием Нэша является только профиль стратегий (testify, testify). Трудно понять, как рациональные игроки могут избежать такого результата, поскольку в любом предложенном неравновесном решении по меньшей мере один из игроков будет подвергаться соблазну изменить свою стратегию. Специалисты в области теории игр соглашались с тем, что обязательным условием того, чтобы некоторый ход представлял собой решение, является принадлежность его к равновесию Нэша, но еще не достигнуто полное согласие в отношении того, является ли это условие достаточным.

Решения (testify, testify) можно довольно легко избежать, немного изменив правила игры (или взгляды игроков). Например, можно перейти к итерационной игре, в которой игроки знают, что когда-то обязательно снова встретятся и вспомнят, как действовали при прошлой встрече (но крайне важно то, что они не должны иметь определенной информации о том, через какое время встретятся).

Кроме того, если агенты имеют моральные убеждения, которые способствуют сотрудничеству и справедливому отношению друг к другу, то можно изменить матрицу вознаграждения так, чтобы она отражала для каждого агента полезность взаимодействия с другим агентом. Как будет показано ниже, на результатах может также отразиться такая модификация агентов, чтобы они обладали ограниченной вычислительной мощностью, а не способностью рассуждать абсолютно рационально, а также предоставление одному агенту информации о том, что способности другого рассуждать рационально ограничены.

Теперь рассмотрим игру, в которой отсутствует доминантная стратегия.

Предположим, что компания Acme, изготовитель аппаратных средств для видеоигр, должна решить, будут ли в ее следующей игровой машине использоваться DVD или CD.

Между тем компания Best, производитель программного обеспечения для видеоигр, должна принять решение о том, следует ли выпускать свою очередную игру на DVD или CD. Для обеих компаний прибыль будет положительной, если они примут согласованные решения, и отрицательной, если решения не будут согласованными, как показывает матрица вознаграждений, приведенная в табл. 17.3.

Таблица 17.3. Матрица вознаграждений для компаний Acme и Best

	Acme:dvd	Acme:cd
Best:dvd	A=9, B=9	A=-4, B=-1
Best:cd	A=-3, B=-1	A=5, B=5

Для этой игры отсутствует равновесие доминантных стратегий, но имеются два равновесия Нэша: {dvd, dvd} и {cd, cd}. Известно, что это — равновесия Нэша, поскольку, если один из игроков примет одностороннее решение перейти на другую стратегию, ситуация для него ухудшится. Теперь эти агенты сталкиваются с такой проблемой: s^* имеется несколько приемлемых решений, но если каждый агент выберет другое решение, то результирующий профиль стратегий вообще не будет представлять собой решение,

и оба агента понесут убытки. Каким образом эти игроки могут согласованно прийти к какому-то решению? Один из возможных ответов состоит в

том, что оба игрока должны выбрать решение, оптимальное по принципу Парето, — {dvd, dvd}; это означает, что можно ограничить определение понятия "решения" уникальным, оптимальным по принципу Парето равновесием Нэша, при условии, что оно существует. Каждая игра имеет по меньшей мере одно оптимальное по принципу Парето решение, но в любой игре может быть несколько таких решений, или эти решения могут не оказаться точками равновесия. Например, можно было бы установить вознаграждения за решение {dvd, dvd}, равные 5, а не 9. В этом случае имеются две одинаковые точки равновесия, оптимальные по принципу Парето. Чтобы выбрать между ними, агенты должны либо пользоваться догадками, либо прибегать к общению, что можно сделать, приняв соглашение об упорядочении решений до начала игры, или проводить переговоры, чтобы достичь обоюдного выгодного решения во время игры (это может означать, что в состав многоходовой игры должны быть включены коммуникативные действия). Таким образом, необходимость в общении возникает в рамках теории игр точно по тем же причинам, что и в мультиагентном планировании, описанном в главе 12. Игры, подобные этой, в которых игроки должны вступать во взаимодействие, называются $\wedge$ координационными играми.

Выше было показано, что игра может иметь больше одного равновесия Нэша; но на основании чего мы можем утверждать, что каждая игра должна иметь по меньшей мере одно такое равновесие? Может оказаться, что в игре отсутствует равновесие Нэша для чистой (не смешанной) стратегии. Рассмотрим, например, любой профиль чистых стратегий для игры в чет и нечет на двух пальцах (с. 839). Если общее количество показанных пальцев является четным, то игрок О может захотеть переключиться на другую стратегию, а если это количество нечетно, то будет стремиться переключиться игрок Е. Поэтому ни один профиль чистых стратегий не может представлять собой равновесие и приходится рассматривать смешанные стратегии.

Но какой должна быть смешанная стратегия? В 1928 году фон Нейман разработал метод поиска оптимальной смешанной стратегии для игр с двумя игроками, называемых $\wedge$ играми с нулевой суммой. Игрой с нулевой суммой называется игра, в которой вознаграждения в каждой ячейке матрицы вознаграждения в сумме равны нулю⁷. Очевидно, что игра в чет и нечет является именно таковой. Известно, что для игр с двумя игроками и нулевой суммой вознаграждения являются равными и противоположными, поэтому достаточно рассмотреть вознаграждения только для одного игрока, который будет считаться максимизирующим игроком (точно так же, как и в главе 6). Применительно к игре в чет и нечет выберем в качестве максимизирующего игрока Е, который выбрал для себя в качестве выигрышного

результата четное количество пальцев, поэтому можно определить матрицу вознаграждений на основе значений $u_E(e, o)$ — вознаграждение, получаемое игроком E , если игрок E выбирает действие e , а O — действие o .

Метод фон Неймана называется методом $\wedge$ максимина и действует, как описано ниже.

7 Более общим является понятие игр с постоянной суммой, в которых сумма в каждой ячейке матрицы вознаграждений игры равна некоторой константе s . Любую игру с постоянной суммой и n участниками можно преобразовать в игру с нулевой суммой, вычтя из каждого вознаграждения значение s/n . Таким образом, шахматы, в которых по традиции применяется вознаграждение 1 за победу, $1/2$ — за ничью и 0 — за проигрыш, формально представляет собой игру с постоянной суммой, где $s=1$, но ее можно легко преобразовать в игру с нулевой суммой, вычтя $1/2$ из каждого вознаграждения.

• Предположим, что правила игры изменились таким образом, что игрок E вынужден раскрывать свою стратегию первым, а за ним следует игрок O . В таком случае мы имеем дело с игрой, где ходы выполняются поочередно, к которой можно применить стандартный минимаксный алгоритм из главы 6. Допустим, что такая игра приводит к получению результата u_{Ei0} . Очевидно, что эта игра окончится в пользу игрока O , поэтому истинная полезность и данной игры (сточки зрения игрока E) равна по меньшей мере u_{Et0} . Например, если рассматриваются только чистые стратегии, то минимаксное дерево игры имеет корневое значение, равное -3 (рис. 17.9, а), поэтому известно, что $U > -3$. • Теперь предположим, что правила изменились таким образом, что свою стратегию вынужден раскрывать игрок O , а за ним следует игрок E . В таком случае минимаксное значение этой игры становится равным $U_{0,E}$, а поскольку игра складывается в пользу игрока E , то известно, что полезность и самое большее равна U_{0iE} . При использовании чистых стратегий это значение равно $+2$ (см. рис. 17.9, б), поэтому известно, что $U < +2$.

Рассматривая эти два предположения совместно, можно прийти к заключению, что истинная полезность и рассматриваемого решения должна удовлетворять следующему неравенству:

$U_{E,o} \wedge U < U_{0,E}$ или в данном случае $-3 < U < 2$ Чтобы точно определить значение U , необходимо перейти к анализу смешанных стратегий. Вначале отметим следующее: $\wedge$ как только первый игрок раскрыл свою стратегию, второй игрок не может проиграть, ведя игру согласно чистой стратегии.

Причина этого проста — если второй игрок ведет игру на основе смешанной стратегии, $[p: one; A-p] : two$, то ожидаемая полезность этой игры представляет собой линейную комбинацию $\{p \cdot u_{one} + (A-p) \cdot u_{two}\}$ полезностей чистых стратегий u_{one} и u_{two} . Эта линейная комбинация ни при каких условиях не будет лучше по

сравнению с лучшим из значений u_{one} и u_{two} , поэтому второй игрок вполне может просто выбрать для ведения игры чистую стратегию.

С учетом этого замечания минимаксные деревья можно рассматривать как имеющие бесконечное количество ветвей, исходящих от корня, которые соответствуют бесконечному количеству смешанных стратегий, доступных для выбора первым игроком. Каждая из этих ветвей ведет к узлу с двумя ветвями, соответствующими чистым стратегиям для второго игрока. Эти бесконечные деревья можно изобразить как конечные, предусмотрев один "параметризованный" выбор у корня, как описано ниже.

- Ситуация, возникающая, если игрок Е ходит первым, показана на рис. 17.9, в.

Игрок Е делает из корневой позиции ход $[p:one; A-p] : two$, а затем игрок О выбирает ход с учетом значения p . Если игрок О выбирает ход one , то ожидаемое вознаграждение (для Е) становится равным $2p-3$; $A-p = 5p-3$; если игрок О выбирает ход two , то ожидаемое вознаграждение равно $-3p+4$; $A-p = 4-7p$.

Зависимости, выражающие величину этих двух вознаграждений, можно изобразить в виде прямых линий на графике, где p изменяется от 0 до 1 вдоль оси x , как показано на рис. 17.9, д. Игрок О, минимизирующий стоимость игры, должен всегда выбирать наименьшее значение на двух прямых линиях, как показано на этом рисунке жирными отрезками прямых. Поэтому наилучшее решение, которое может

принять игрок Е, выбирая ход, подлежащий выполнению из корневой позиции, состоит в том, чтобы выбрать значение p , соответствующее точке пересечения и определяемое следующим образом: а) two в) E г) O д) $[p:one; (1-p):two] \text{ т те } / \setminus \text{ two } 2/7 - 3A-/7) \ 3/7 + 4A-/7) [q: one; A - q): two] \ 20-3A \text{two } 3\$ + 4(l-0 +4 J +3- +2- + 1 - -1- -2- - 3L V /WO \text{oneyr }] \setminus ' 1 " ^$ Рис. 7 7. Р. Анализ игры с двумя игроками: минимаксные деревья игры в чет и нечет на двух пальцах, если игроки ходят по очереди, ведя игру на основе чистых стратегий (а), (б); параметризованные деревья игры, в которой первый игрок использует смешанную стратегию, причем вознаграждения зависят от параметра вероятности (p или q) в смешанной стратегии (в), (г); для любого конкретного значения параметра вероятности второй игрок выбирает "наилучшее" этих двух действий, поэтому значение для смешанной стратегии первого игрока задается жирными линиями; первый игрок выбирает параметр вероятности для смешанной стратегии в точке пересечения (д), (е)

$5p-3 = 4-7p \Rightarrow p=7/12$ Полезность для игрока Е в этот момент времени равна $UEi0 = -1/12$.

- А если первым ходит игрок О, то складывается ситуация, показанная на рис. 17.9, г. Игрок О из корневой позиции делает ход $[g: one; A-d] : two$, после чего игрок Е выбирает ход с учетом значения q . При этом вознаграждения определяются соотношениями $8 \ 2g-3(l-g)=5g-3$ и $-3g+4(l-g)=4-7g$.

Опять-таки на рис. 17.9, е показано, что наилучший ход, который может быть сделан игроком О из корневой позиции, состоит в выборе точки пересечения, следующим образом:

$5d-3 = 4-7d \Rightarrow d=7/12$ Полезность для игрока Е в этот момент равна $u_O^i E = -1/12$.

Теперь известно, что истинная полезность этой игры находится в пределах от $-1/12$ до $-1/12$, т.е. она точно равна $-1/12$! (Общий вывод состоит в том, что в эту игру лучше играть от имени игрока О, а не е.) Кроме того, истинная полезность достигается при использовании смешанной стратегии $[7/12 : one; 5/12 : two]$, которой должны придерживаться оба игрока. Такая стратегия называется $\wedge$ максиминным равновесием игры и соответствует равновесию Нэша. Обратите внимание на то, что каждая составляющая стратегия в равновесной смешанной стратегии имеет одну и ту же ожидаемую полезность. В данном случае и ход one, и ход two имеют ту же ожидаемую полезность, $-1/12$, что и сама смешанная стратегия.

Приведенный выше результат для игры в чет и нечет на двух пальцах представляет собой пример общего результата, полученного фон Нейманом: с⁵ каждая игра с нулевой суммой с двумя игроками имеет максиминное равновесие, если разрешены смешанные стратегии. Кроме того, каждое равновесие Нэша в игре с нулевой суммой представляет собой максиминное равновесие для обоих игроков. Но общий алгоритм поиска максиминных равновесий в играх с нулевой суммой немного сложнее по сравнению с тем, что показано в виде схем на рис. 17.9, д и е. Если количество возможных действий равно n , то смешанная стратегия представляет собой точку в n -мерном пространстве и прямые линии становятся гиперплоскостями. Возможно также, что над некоторыми чистыми стратегиями для второго игрока будут доминировать другие стратегии, так что они перестанут быть оптимальными по отношению к любой стратегии для первого игрока. После удаления всех подобных стратегий (а эту операцию может потребоваться выполнить неоднократно) оптимальным вариантом хода из корневой позиции становится самая высокая (или самая низкая) точка пересечения оставшихся гиперплоскостей. Поиск этого варианта представляет собой пример задачи линейного программирования — максимизации целевой функции с учетом линейных ограничений. Такие задачи могут быть решены с помощью стандартных методов за время, полиномиально зависящее от количества действий (а также формально и от количества битов, используемых для определения функции вознаграждения).

8 То, что эти уравнения являются такими же, как и для p , обусловлено лишь совпадением; совпадение возникло, поскольку $u_E(one, two) = u_E(two, one) = -3$. Это совпадение также объясняет, почему оптимальная стратегия является одинаковой для обоих игроков.

Остается нерешенным следующий вопрос: как фактически должен действовать рациональный агент при ведении такой одноходовой игры, как игра в чет и нечет?

Рациональный агент пришел логическим путем к выводу, что $[7/12:one; 5/12 : two]$ представляет собой максиминную равновесную стратегию, и исходит из предположения, что знаниями об этом обладает и его рациональный противник.

Агент может использовать игральную кость с 12 сторонами или генератор случайных чисел для выбора случайным образом хода, соответствующего этой смешанной стратегии, и в этом случае ожидаемое вознаграждение для игрока E будет равно $-1/12$.

В ином случае агент может просто решить сделать ход one или two. В любом случае для игрока E ожидаемое вознаграждение остается равным $-1/12$. Удивительно то, что односторонний выбор конкретного действия не уменьшает ожидаемое вознаграждение для данного игрока, но если другой агент будет иметь возможность узнать, что данный игрок принял такое одностороннее решение, то ожидаемое вознаграждение изменится, поскольку противник сможет откорректировать свою стратегию соответствующим образом.

Поиск решений для конечных игр с ненулевой суммой (т.е. равновесий Нэша) немного сложнее. Общий подход заключается в использовании двух этапов.

Во-первых, необходимо составить список из всех возможных последовательностей действий, которые могут образовывать смешанные стратегии. Например, вначале следует проверить все профили стратегий, в которых каждый игрок выполняет одно действие, затем те, в которых каждый игрок выполняет либо одно, либо два действия, и т.д. Количество таких проверок экспоненциально зависит от количества действий, поэтому может применяться только в относительно простых играх.

Во-вторых, для каждого профиля стратегий, включенного в список на первом этапе, необходимо провести проверку для определения того, представляет ли он некоторое равновесие. Такая задача выполняется путем решения ряда уравнений и неравенств, аналогичных используемым в случае с нулевой суммой. В игре с двумя игроками эти уравнения являются линейными и могут быть решены с помощью основных методов линейного программирования, но в случае трех или большего количества игроков они являются нелинейными и задача поиска их решения может оказаться очень сложной.

До сих пор мы рассматривали только такие игры, которые состоят из одного хода.

Простейшей разновидностью игры, состоящей из нескольких ходов, является ^Эч повторяющаяся игра, в которой игроки снова и снова сталкиваются с одним и тем же выбором, но каждый раз пользуются знаниями истории всех предыдущих выборов всех игроков. Профиль стратегий для повторяющейся игры определяет

выбор действия для каждого игрока на каждом временном интервале для всех возможных историй предыдущих выборов. Как и в случае задач MDP, вознаграждения определяются аддитивной функцией от времени.

Рассмотрим повторяющуюся версию поиска решения дилеммы заключенного.

Будут ли Алиса и Боб действовать совместно и откажутся свидетельствовать друг против друга, зная о том, что им придется снова встретиться? Ответ зависит от деталей их соглашения. Например, предположим, Алиса и Боб знают, что им придется провести ровно 100 раундов игры в дилемму заключенного. В таком случае оба они знают, что 100-й раунд не будет повторяющейся игрой, т.е. что ее результат не сможет оказать влияния на будущие раунды, и поэтому оба они выберут в этом раунде доминантную стратегию *testify*. Но как только будет определен результат 100-го

раунда, 99-й раунд перестанет оказывать влияние на последующие раунды, поэтому в нем также будет достигаться равновесие доминантной стратегии в случае выбора действий (*testify*, *testify*). По индукции оба игрока должны выбирать действие *testify* в каждом раунде, заработав общий срок по 500 лет тюремного заключения на каждого.

Изменяя правила взаимодействия, можно получить другие решения. Например, предположим, что после каждого раунда существует 99% шансов, что игроки снова встретятся. В таком случае ожидаемое число раундов все еще остается равным 100, но ни один из игроков не знает точно, какой раунд будет последним. При таких условиях возможно поведение, характеризующееся большей степенью сотрудничества.

Например, одной из стратегий равновесия для каждого игрока является выбор действия *refuse*, если другой игрок никогда не выбирал действие *testify*. Такую стратегию можно назвать ∞ вечным наказанием. Предположим, что оба игрока приняли данную стратегию и это известно им обоим. В таком случае, при условии, что ни один из игроков не выберет действие *testify*, в любой момент времени ожидаемое суммарное вознаграждение в будущем для каждого игрока составляет следующее: $\infty \cdot 0.994 - 1 = -100$ $t=0$ Игрок, который выберет *testify*, получит 0 очков вместо -1 в каждом следующем ходе, но его суммарное ожидаемое будущее вознаграждение становится равным: $\infty \cdot 0 + 0.994 \cdot (-10) = -99$ $t=0$ Поэтому на каждом этапе игроки не имеют стимула, который заставил бы их отказаться от стратегии (*refuse*, *refuse*). Вечное наказание — это стратегия "взаимно гарантированного уничтожения" в рамках дилеммы заключенного: как только один из игроков решит выполнить действие *testify*, он обеспечит получение обоими игроками больших неприятностей. Но такая перспектива развития событий может

стать предостережением, только если другой игрок знает, что вы приняли эту стратегию или по меньшей мере что вы могли ее принять.

Существуют и другие стратегии в этой игре, которые являются не такими бескомпромиссными. Наиболее известная из них, называемая $\wedge$ отплатой "зуб за зуб", предусматривает, что игрок начинает с действия `refuse`, а затем повторяет предыдущий ход другого игрока во всех последующих ходах. Поэтому Алиса должна отказываться свидетельствовать против Боба до тех пор, пока Боб отказывается свидетельствовать против нее, затем должна выбирать в своем ходе дачу показаний против Боба, как только Боб даст показания против нее, но должна возвращаться к отказу от дачи показаний, после того как это сделает Боб. Хотя эта стратегия очень проста, оказалось, что она является в высшей степени надежной и эффективной в противодействии самым разнообразным стратегиям.

Кроме того, другие решения могут быть получены в результате модификации самих агентов, а не изменения правил их взаимодействия. Предположим, что агенты представляют собой конечные автоматы с p состояниями и играют в игру с общим количеством ходов $t > p$. Поэтому агенты в какой-то момент становятся неспособными представить целый ряд оставшихся ходов и должны рассматривать их как неизвестные. Это означает, что они не могут выполнять логический вывод по индукции и вправе переходить к наиболее благоприятному равновесию $\{refuse, refuse\}$.

В таком случае глупость идет на пользу или, скорее, идет на пользу мнению противника о том, что вы глупы. Ваш успех в таких повторяющихся играх зависит от мнения о вас другого игрока как о тупице или простачке, а не от ваших фактических характеристик.

Полное описание повторяющихся игр, которые представляют собой большую и важную научную область, выходит за рамки данной книги, но они возникают во многих ситуациях. Например, последовательную игру можно организовать, поместив двух агентов в мир 4×3 , показанный на рис. 17.1. Если будет определено, что не должно происходить никакого движения, если два агента пытаются одновременно перейти в один и тот же квадрат (эта проблема часто возникает на многих пересечениях разных направлений дорожного движения), то некоторые чистые стратегии могут привести к бесконечному тупику. Одно из решений состоит в том, чтобы для каждого агента был рандомизирован выбор между движением вперед и остановкой на месте; патовая ситуация будет быстро разрешена и оба агента смогут продолжить свое движение. Именно такой подход применяется при разрешении коллизий между пакетами в сетях Ethernet.

Известные в настоящее время методы выработки решений для повторяющихся игр напоминают методы, применяемые в играх с поочередными ходами, описанных в

главе 6, в том, что дерево игры может быть сформировано от корня вниз и решено от листьев вверх. Основное различие между ними состоит в том, что вместо простого определения максимума или минимума дочерних значений алгоритм должен найти решение игры в терминах смешанных стратегий на каждом уровне, при условии, что для дочерних узлов найдены решения и имеются точно определенные значения, с которыми можно дальше работать.

Повторяющиеся игры в частично наблюдаемых вариантах среды называются играми с $\wedge$ частичной информацией. К примерам таких игр относятся карточные игры наподобие покера и бриджа, в которых каждый игрок видит только некоторое подмножество карт, а также более серьезные "игры", такие как моделирование атомной войны, когда ни одна из сторон не знает местонахождение всех пусковых установок противника. Решения игр с частичной информацией можно найти, рассматривая дерево доверительных состояний, как и в случае задач POMDP (см. раздел 17.4).

Одно важное различие между ними состоит в том, что собственное доверительное состояние является наблюдаемым, а доверительное состояние противника — нет. Для таких игр практически применимые алгоритмы были разработаны только недавно.

Например, найдено решение для некоторой упрощенной версии покера и доказано, что вариант, в котором игроки блефуют, действительно является рациональным, по крайней мере в составе тщательно сбалансированной смешанной стратегии. В результате этих исследований было сделано одно важное открытие, которое заключается в том, что смешанные стратегии полезны не только для того, чтобы сделать действия игрока непредсказуемыми, но и для минимизации объема информации, которую противник может извлечь из наблюдений за действиями этого игрока.

Интересно отметить, что разработчики программ для игры в бридж хорошо понимают важность сбора и сокрытия информации, но ни один из них не предложил использовать рандомизированные стратегии.

До сих пор обнаруживались определенные барьеры, которые препятствовали широкому использованию теории игр в проектах агентов. Во-первых, следует отметить, что при поиске решения на основе равновесия Нэша игрок предполагает, что его противник со всей определенностью будет вести игру на основе равновесной стратегии. Это означает, что игрок не способен учесть какие-либо убеждения, которые у него могут быть в отношении того, как скорее всего будут действовать другие игроки, и поэтому не сможет воспользоваться своими важными преимуществами, защищаясь от угроз, которые так никогда и не материализуются. Эта проблема частично решается благодаря использованию понятия $\wedge$ равновесия

Байеса—Нэша, т.е. равновесия применительно к распределению априорных вероятностей игрока по отношению к стратегиям других игроков; иными словами, равновесие Байеса—Нэша выражает уверенность игрока в том, какие вероятные стратегии будут применять другие игроки. Во-вторых, в настоящее время отсутствует удобный способ совместного применения стратегий управления, основанных на теории игры и модели POMDP.

Из-за наличия этих и других проблем теория игр в основном использовалась для анализа вариантов среды, находящихся в равновесном состоянии, а не для управления агентами, действующими в некоторой среде. Но ниже будет показано, что теория игр может помочь и при проектировании вариантов среды.

17.7. Проектирование механизма В предыдущем разделе рассматривался вопрос: "Дана некоторая игра; каковой является рациональная стратегия?" В этом разделе приведен ответ на другой вопрос:

"Предположим, что агенты являются рациональными; какую игру следует для них спроектировать?" А именно, требуется спроектировать некоторую игру, решения которой, состоящие из действий каждого агента, осуществляющего свою собственную рациональную стратегию, приводят к максимизации некоторой глобальной функции полезности. Эта проблемная область называется [^] проектированием механизма, а иногда обратной теорией игр. Проектирование механизма представляет собой фундамент экономики и политологии. Применительно к коллекциям агентов этот подход обеспечивает возможность использования механизмов теории игр для создания успешно действующих систем из совокупности более ограниченных системных компонентов (даже противоборствующих системных компонентов), во многом аналогично тому, как создаются команды людей, способные достигать целей, далеко превосходящих возможности отдельно взятого человека.

К примерам применения принципов проектирования механизма относится организация аукционов по распродаже дешевых авиабилетов, маршрутизация пакетов TCP между компьютерами, принятие решения о том, как следует распределять выпускников медицинских учебных заведений по лечебным учреждениям, а также определение способа взаимодействия роботизированных игроков-футболистов со своими капитанами команд. Проектирование механизма вышло за рамки академической тематики в конце 1990-х годов, когда несколько государств, столкнувшись с проблемой аукционной распродажи лицензий на вещание в различных частотных диапазонах, потеряли сотни миллионов долларов потенциальных доходов в результате плохого проектирования механизма. Формально [^] механизм состоит, во-первых, из языка для описания (потенциально бесконечного) множества допустимых стратегий, которыми могут ру-

ководствоваться агенты, и, во-вторых, из правила определения результата G , которое регламентирует вознаграждения, получаемые агентами при наличии некоторого профиля стратегий, состоящего из допустимых стратегий.

На первый взгляд задача проектирования механизма может показаться тривиальной. Предположим, что глобальная функция полезности [декомпозируется на любое множество функций полезности отдельных агентов S_i такое, что $u = \sum u_i$]. В таком случае можно утверждать, что если каждый агент максимизирует свою собственную полезность, то нет сомнения в том, что это автоматически приведет к максимизации глобальной полезности. (Например, в лекциях по начальному курсу капитализма утверждается, что если каждый старается стать богаче, то общее благосостояние общества повышается.) К сожалению, такой принцип не оправдывается. Действия каждого агента могут повлиять на благосостояние других агентов так, что глобальная полезность уменьшится. Одним из примеров этого является трагическая деградация общих пастбищ (tragedy of the commons) — ситуация, в которой отдельные фермеры сгоняют все свои стада для того, чтобы они бесплатно паслись на общих сельских пастбищах, в результате чего наступает деградация этих общих пастбищ, что приводит к достижению отрицательной полезности для всех фермеров. Каждый фермер, отдельно взятый, действовал рационально, рассуждая, что он может использовать общие пастбища бесплатно, и хотя интенсивное использование общих пастбищ может привести к их деградации, его отказ выгонять на них свой скот делу не поможет (поскольку другие от этого все равно не откажутся).

Аналогичные доводы выдвигаются теми, кто не желает ограничивать выбросы промышленных загрязнений в атмосферу и в океаны.

Стандартный подход при проектировании механизма для решения подобных проблем состоит в том, что с каждого агента должна взиматься плата за использование общих пастбищ. Вообще говоря, следует обеспечить, чтобы все побочные последствия (отрицательные влияния на глобальную полезность, которые не сказываются на результатах, полученных отдельными агентами) были выражены явно. При решении задачи труднее всего правильно определить цены. В пределе этот подход сводится к созданию механизма, который действительно требует от каждого агента, чтобы он максимизировал глобальную полезность. Применительно к отдельному агенту, который не обладает возможностью оценивать текущее состояние мира и не может наблюдать за результатами действий всех других агентов, такая задача становится невероятно трудной. Поэтому проектирование механизма должно сосредоточиваться на поиске таких механизмов, при использовании которых задача принятия решений для отдельных агентов становится несложной.

Вначале рассмотрим аукционы. В своей наиболее общей форме аукцион представляет собой механизм продажи некоторых товаров членам определенного сообщества покупателей. Стратегиями являются стратегии ведения торгов, а результаты определяют, кто получит товары и сколько заплатит. Одним из примеров, в которых аукционы могут войти в состав тематики искусственного интеллекта, является принятие решения совокупностью агентов о том, будут ли они участвовать в совместном плане. Хансбергер и Грош [706] показали, что эта задача может быть эффективно решена с помощью аукциона, в котором агенты распределяют между собой роли в совместном плане.

В данном разделе рассмотрим аукционы, в которых, во-первых, имеется только один вид товара, во-вторых, каждый покупатель руководствуется собственным значением полезности V_j по отношению к данному товару, и, в-третьих, эти значения известны только покупателю. Покупатели вносят свои предложения b_i за товары передаются тому, кто сделал предложение с самой высокой ценой, но механизм определяет, как нужно делать эти предложения и какую цену платит победитель (она не обязательно должна быть равна b_L). Наиболее широко известным типом аукциона является "гэ, английский аукцион, в котором лицо, проводящее аукцион, повышает цену товара, проверяя, остались ли еще заинтересованные покупатели, до тех пор, пока не останется только один потенциальный покупатель. Этот механизм обладает тем свойством, что покупатель, руководствующийся наивысшим значением v_L , получает товары по цене $i^* + d$, где i^* — наивысшая предложенная цена среди цен, предложенных всеми другими игроками, ad — величина, на которую лицо, проводящее аукцион, наращивает цену от одного предложения к другому⁹. Поэтому английский аукцион обладает тем свойством, что участники аукциона руководствуются простой доминантной стратегией — продолжать выдвигать предложения до тех пор, пока текущая цена остается ниже назначенного лично вами значения. Напомним, что "доминантной" стратегией называется стратегия, позволяющая противодействовать всем другим стратегиям, а это, в свою очередь, имеет тот смысл, что игрок может ею руководствоваться, невзирая на то, что существуют любые другие стратегии. Поэтому игроки не обязаны терять время и энергию, пытаясь предугадать возможные стратегии других игроков. Механизм, в котором игроки имеют доминантную стратегию, позволяющую скрывать свои истинные побуждения, называется механизмом "гэ, защиты стратегии.

Одним из отрицательных свойств английского аукциона являются большие затраты на связь, поэтому либо следует проводить аукцион в одном помещении, либо предоставить всем участникам аукциона быстродействующие, надежные линии связи. Альтернативным механизмом, для которого требуется гораздо меньший объем связи, является $\wedge$ аукцион с запечатанными предложениями. В этом случае каждый участник аукциона подготавливает единственное предложение и сообщает

его лицу, проводящему аукцион; после сбора всех предложений побеждает предложение с наибольшей ценой. При использовании этого механизма стратегия, в которой участник аукциона выдвигает в качестве предложения то истинное значение, которым он руководствуется, больше не является доминантной. Если значение полезности для игрока равно v_i и он считает, что максимальным из предложений всех других игроков будет $2^{\wedge}$, то он должен выдвинуть предложение с ценой, меньшей v_i и равной $b_i + \epsilon$. Двумя недостатками аукциона с запечатанными предложениями является то, что игрок с наивысшим значением полезности V_i может не получить товары, а также то, что игроки должны затрачивать свои усилия на прогнозирование стратегий других игроков.

В результате небольшого изменения правил аукционов с запечатанными предложениями был разработан $\wedge$ аукцион с запечатанными предложениями на вторую по 9 Фактически шансы на то, что игрок с наибольшим значением v_i не сможет получить товары, невелики; это произойдет, только если $b_i < v_i < b_i + d$. Вероятность такого события может стать сколь угодно малой благодаря уменьшению приращения d .

величине цену, называемый также $\wedge$ аукционом Викри¹⁰. При проведении таких аукционов победитель платит цену, указанную во втором по величине предложении, а не цену, показанную в своем собственном предложении. Эта простая модификация позволяет полностью устранить необходимость в проведении сложных рассуждений, которые требовались в стандартных аукционах с запечатанными предложениями (т.е. в аукционах с первой по величине ценой), поскольку теперь доминантная стратегия состоит в том, чтобы выдвинуть в качестве предложения цену, соответствующую фактической собственной величине полезности. Чтобы убедиться в этом, достаточно отметить, что каждый игрок может рассматривать данный аукцион как игру с двумя игроками, игнорируя всех игроков, кроме себя и лица, выдвинувшего предложение с наибольшей ценой среди всех других игроков. Значение полезности для игрока i , выраженное в виде цены, указанной в его предложении, b_i ? само значение полезности v_i , которым он руководствуется, и наилучшее предложение среди других игроков, b_j , связаны между собой таким соотношением:

$U_i \{ D_i, A \}$ - о в противном случае Чтобы убедиться в том, что выбор значения $b_i = v_i$ представляет собой доминантную стратегию, отметим, что при положительном значении $(v_i - b_j)$ любое предложение, которое побеждает в аукционе, является оптимальным, и, в частности, аукцион можно выиграть, выдвинув предложение v_i . С другой стороны, когда значение $(v_i - b_j)$ является отрицательным, оптимальным становится любое предложение, которое проигрывает в этом аукционе, и, в частности, в аукционе проигрывает предложение, в котором применяется значение v_i . Поэтому выдвижение предложения на основе значения V_i представляет собой

оптимальную стратегию при всех возможных значениях b^L и действительно предложение на основе v^L — это единственное предложение, которое обладает таким свойством. Благодаря его простоте и минимальным вычислительным требованиям как к тем, кто предоставляет услуги, так и к тем, кто на них претендует, аукцион Викри широко используется при проектировании распределенных систем на основе искусственного интеллекта.

Теперь рассмотрим проблему маршрутизации в Internet. Игроки соответствуют ребрам в графе сетевых соединений. Каждый игрок знает стоимость c_i передачи сообщения по его собственному ребру, а стоимость того, что сообщение не будет передано для отправки, равна 0. Задача состоит в том, чтобы найти самый дешевый путь передачи сообщения от отправителя к получателю, где стоимость всего маршрута представляет собой сумму стоимостей отдельных ребер. В главе 4 приведено несколько алгоритмов вычисления кратчайшего пути с учетом стоимости ребер, поэтому остается только предусмотреть, чтобы каждый агент сообщал свою истинную стоимость c_i . К сожалению, если будет просто передан запрос каждому агенту, он сообщит стоимости, которые слишком велики, чтобы вынудить нас отправлять свои сообщения по каким-то другим каналам. Поэтому необходимо разработать механизм защиты стратегии. Один из таких механизмов состоит в том, чтобы выплачивать каждому игроку вознаграждение p_i равное длине кратчайшего пути, который 10 Названный в честь Уильяма Викри (1914-1996), лауреата Нобелевской премии по экономике за 1996 год.

не включает i -е ребро, за вычетом длины кратчайшего пути (вычисленной с помощью алгоритма поиска), где предполагается, что стоимость i -го ребра равна 0:

$P_i = \text{Length}(\text{путь, где } C_i = \infty) - \text{Length}(\text{путь, где } d = 0)$ Можно показать, что при использовании такого механизма доминантной стратегией для каждого игрока становится выдача правильных сведений о значении c_i и что применение такого подхода приводит к получению самого дешевого пути.

Но, несмотря на это желательное свойство, описанный механизм не используется на практике из-за высокой стоимости связи и централизованных вычислений.

Проектировщик механизма должен связаться со всеми n игроками, а затем решить задачу оптимизации. Применение такого подхода имело бы смысл, если бы затраты можно было амортизировать по многим сообщениям, но в реальной сети стоимости c_i непрерывно колеблются из-за заторов в каналах, а также из-за того, что некоторые компьютеры завершают свою работу аварийно, а другие, наоборот, переходят в оперативный режим. Полностью удовлетворительное решение этой проблемы еще не было предложено.

17.8. Резюме В этой главе показано, как использовать знания о мире для принятия решений, даже если результаты действий являются неопределенными, а

вознаграждения за действия могут оставаться недоступными до тех пор, пока не будет осуществлен целый ряд действий. Основные идеи этой главы кратко изложены ниже.

- Задачи последовательного принятия решений в неопределенных вариантах среды, называемые также марковскими процессами принятия решений (Markov Decision Process — MDP), определяются с помощью моделей перехода, задающих вероятностные результаты действий, и функции вознаграждения, которая показывает, какое вознаграждение соответствует каждому состоянию.
- Полезность последовательности состояний представляет собой сумму всех вознаграждений вдоль этой последовательности, которая, возможно, со временем подвергается обесцениванию. Решением задачи MDP является стратегия, в которой с каждым состоянием, достижимым для агента, связано некоторое решение. Оптимальная стратегия максимизирует полезность встречающейся последовательности состояний при ее осуществлении.
- Полезностью состояния является ожидаемая полезность последовательностей состояний, встречающихся при осуществлении оптимальной стратегии, начиная с этого состояния. Алгоритм итерации по значениям для решения задач MDP действует по принципу итеративного решения уравнений, связывающих полезности каждого состояния с полезностями его соседних состояний.
- В алгоритме итерации по стратегиям чередуются этап вычисления полезностей состояний согласно текущей стратегии и этап усовершенствования текущей стратегии по отношению к текущим полезностям.
- Задачи MDP в частично наблюдаемой среде, или задачи POMDP, являются гораздо более трудными для решения, чем задачи MDP. Они могут быть ре-

шены путем преобразования в задачу MDP в непрерывном пространстве доверительных состояний. Оптимальное поведение при решении задач POMDP должно предусматривать сбор информации для уменьшения неопределенности и поэтому принятия лучших решений в будущем.

- Для вариантов среды POMDP может быть создан агент, действующий на основе теории решений. В таком агенте для представления модели перехода и модели наблюдения для обновления его доверительного состояния и проектирования возможных последовательностей действий в прямом направлении используется динамическая сеть принятия решений.
- Теория игр описывает рациональное поведение для агентов в тех ситуациях, в которых одновременно взаимодействуют множество агентов. Решениями для игр являются равновесия Нэша — профили стратегий, в которых ни один из агентов не имеет стимулов, под влиянием которых он мог бы уклониться от определенной для него стратегии.
- Проектирование механизма может использоваться для определения правил, по которым должно быть организовано взаимодействие агентов в целях максимизации некоторой глобальной полезности благодаря функционированию отдельных рациональных агентов. Иногда удается найти механизмы, позволяющие достичь этой цели, не требуя от каждого агента, чтобы он учитывал то, какие варианты выбраны другими агентами.

Мы вернемся к тематике задач MDP и POMDP в главе 21, где описаны методы обучения с подкреплением, позволяющие агенту совершенствовать свое поведение на основании опыта, полученного в последовательных, неопределенных вариантах среды.

Библиографические и исторические заметки Основателем современного подхода к анализу задач последовательного принятия решений был Ричард Беллман [97], который в целом предложил использовать подход на основе динамического программирования и в частности алгоритм итерации по значениям. В тезисах докторской диссертации Рона Говарда [691] введено понятие итерации по стратегиям и изложена идея среднего вознаграждения, предназначенная для применения при решении задач с бесконечным горизонтом. Несколько дополнительных результатов было предложено в [96]. Модифицированный алгоритм итерации по стратегиям описан в [1245] и [1534]. Алгоритм асинхронной итерации по стратегиям был проанализирован Уильямсом и Бердом [1598], которые также доказали свойство граничной убыточности стратегии, рассматриваемое в уравнении 17.9. Результаты анализа обесценивания с точки зрения стационарных предпочтений приведены в [834]. В [120], [121] и [1244] дано строгое введение в проблематику задач последовательного принятия решений. В [1170] описаны результаты исследования вычислительной сложности задач MDP.

Важную роль в ознакомлении сообщества разработчиков в области искусственного интеллекта с задачами MDP сыграли оригинальные работы Саттона [1477] и Уоткинса [1558] по применению методов обучения с подкреплением для решения задач MDP, а также вышедший немного позже обзор [74]. (В более ранней работе [1580] содержались во многом аналогичные идеи, но они не были развиты до такой же степени.) Связь между задачами MDP и задачами планирования в искусственном интеллекте была впервые показана Свенон Кёнигом [817], который также продемонстрировал, что вероятностные операторы Strips позволяют создавать компактные представления для моделей перехода (см. также [1575]). В [359] и [1492] сделана попытка преодолеть комбинаторную сложность больших пространств состояний с использованием ограниченного горизонта поиска и абстрактных состояний.

Эвристики, основанные на стоимости информации, могут использоваться для определения в пространстве состояний таких областей, где локальное расширение горизонта приводит к значительному повышению качества решения. Агенты, применяющие такой подход, могут соразмерять свои усилия под давлением дефицита времени и вырабатывать некоторые варианты поведения (такие как использование знакомых "проторенных тропинок") для быстрого поиска путей через пространство состояний без необходимости повторно вычислять в каждой точке оптимальные решения.

В опубликованных недавно работах Бутильера и др. [158], [159] основные усилия сосредоточены на динамическом программировании с использованием символических представлений моделей перехода и функций стоимости на основе формул пропозициональной логики и логики первого порядка.

В [47] впервые было показано, что задачи MDP в частично наблюдаемой среде могут быть преобразованы в обычные задачи MDP с использованием доверительных состояний. Первый полный алгоритм точного решения для марковских процессов принятия решений в частично наблюдаемой среде (Partially-Observable Markov Decision Process— POMDP) был предложен Эдвардом Сондиком [1446] в его докторской диссертации (опубликованная позднее журнальная статья Смоллвуда и Сондика [1433] содержит некоторые ошибки, но является более доступной).

В [946] приведен обзор состояния разработок в области решения задач POMDP.

Первым значительным вкладом в рамках искусственного интеллекта был алгоритм Witness [227], [758] — усовершенствованная версия алгоритма итерации по значениям, применяемого для решения задач POMDP. Вслед за ним вскоре были разработаны другие алгоритмы, в том числе основанные на подходе, предложенном Хансеном [612], который предусматривает инкрементное определение стратегии с помощью конечного автомата. В представлении стратегии с помощью конечного автомата доверительные состояния непосредственно соответствуют конкретным состояниям автомата. Приблизительно оптимальные стратегии для задач POMDP могут формироваться с помощью прямого поиска, применяемого в сочетании с формированием выборок из возможных результатов наблюдений и действий [784], [1134]. Другие результаты исследований в области алгоритмов POMDP описаны в главе 21.

Основные идеи по созданию архитектуры агента с использованием динамических сетей принятия решений были предложены в [360]. В книге Planning and Control Дина и Уэллмана [363] этот подход развит намного глубже и установлена связь между моделями DBN/DDN и классической литературой теории управления, посвященной вопросам фильтрации. Татмен и Шахтер [1497] показали, как применять алгоритмы динамического программирования к моделям DDN. В [1325] описаны различные способы обеспечения применения таких агентов в более широких масштабах и указан ряд нерешенных исследовательских проблем.

Корни теории игр можно проследить до предложений по изучению конкурентных и кооперативных взаимодействий людей с помощью научного и математического подхода, которые были выдвинуты еще в XVII столетии Христианом Гюйгенсом и Готфридом Лейбницем. На протяжении XIX столетия некоторые ведущие экономисты создавали простые математические модели для анализа конкретных примеров конкурентных ситуаций. Первые формальные результаты в области

теории игр принадлежат Цермело [1641], который за год до этого предложил некоторую форму минимаксного поиска для игр, хотя и неправильную. Эмиль Борель [152] ввел понятие смешанной стратегии. Джон фон Нейман [1545] доказал, что любая игра с двумя участниками и нулевой суммой имеет максиминное равновесие в смешанных стратегиях и полностью определенное значение. Сотрудничество Джона фон Неймана с экономистом Оскаром Моргенштерном привело к публикации в 1944 году книги *Theory of Games and Economic Behavior* (Теория игр и экономического поведения) [1546], которая сыграла решающую роль в создании теории игр. Публикация этой книги задерживалась из-за нехватки бумаги во время войны до тех пор, пока один из членов семейства Рокфеллеров не субсидировал публикацию.

В 1950 году в возрасте 21 года Джон Нэш опубликовал свои идеи, касающиеся достижения равновесия в играх общего типа [1112]. Его определение равновесного решения получило известность под названием равновесия Нэша (хотя впервые появилось в работе Курно [297]). После длительной задержки из-за шизофрении, которой он страдал с 1959 года, Нэш получил Нобелевскую премию по экономике (наряду с Рейнхартом Селтенем и Джоном Харсаньи) в 1994 году.

Равновесие Байеса—Нэша описано в [622] и обсуждается в [757]. Некоторые проблемы использования теории игр для управления агентами рассматриваются в [129].

Дилемма заключенного была разработана для использования в качестве учебного упражнения Альбертом В. Такером в 1950 году и тщательно исследована в [50].

Понятие повторяющихся игр было представлено в [963], а игры с частичной информацией—в [862]. Первый практически применимый алгоритм для игр с частичной информацией был разработан в рамках искусственного интеллекта Коллером и др. [821]; в статье [822] дано удобное для чтения введение в эту общую область и описана действующая система представления и решения последовательных игр. Теория игр и задач MDP объединена в теорию марковских игр [937]. Шепли [1398] фактически описал алгоритм итерации по значениям до Беллмана, но его результаты не получили широкого признания, вероятно, потому, что были представлены в контексте марковских игр. К числу основных учебников по теории игр относятся [510], [1109] и [1161].

Задача, послужившая стимулом к созданию области проектирования механизма, трагическая деградация общих пастбищ, была представлена в [619]. Гурвич [709] создал математические основы для проектирования механизма. Милгром [1048] описал разработанный им механизм аукциона, который охватывает диапазон сделок в несколько миллиардов долларов. Понятие аукционов может также использоваться в планировании [706] и составлении расписаний [1267]. В [1539]

приведен краткий обзор тематики аукционов в связи с публикациями по компьютерным наукам, а в [1307] представлено описание способов применения этого подхода для решения распределенных задач искусственного интеллекта, занявшее целую книгу.

Родственные работы по проблематике распределенных задач искусственного интеллекта публикуются также под другими названиями, включая коллективный интеллект [1516] и управление на основе рынка [269]. Статьи по вычислительным проблемам, связанным с аукционами, часто публикуются в трудах конференции ACM Conferences on Electronic Commerce.

Упражнения 17.1. Для мира 4×3 (см. рис. 17.1) рассчитайте, какие квадраты могут быть достигнуты из квадрата A,1) с помощью последовательности действий [Up, Up, Right, Right, Right] и с какими вероятностями. Объясните, как эти вычисления связаны с задачей проектирования скрытой марковской модели.

17.2. Предположим, что в качестве полезности последовательности состояний определено максимальное вознаграждение, полученное в любом из состояний этой последовательности. Покажите, что данная функция полезности не приводит к формированию стационарных предпочтений между последовательностями состояний. Остается ли возможным определение на состояниях такой функции полезности, что принятие решений на основе полезности MEU позволит сформировать оптимальное поведение?

17.3. Может ли любая задача конечного поиска быть точно преобразована в марковскую задачу принятия решений, такую, что оптимальное решение последней является также оптимальным решением первой? Если да, то объясните, как преобразовать эту задачу и как выполнить обратное преобразование решения, а если нет, объясните, почему ваш ответ отрицателен (в частности, приведите контрпример).

17.4. Рассмотрите задачу MDP без обесценивания, имеющую три состояния, A, 2, 3), с вознаграждениями -1, -2, 0 соответственно. Состояние 3 является терминальным. В состояниях 1 и 2 имеются два возможных действия, а и б. Модель перехода описана ниже. • В состоянии 1 действие а переводит агента в состояние 2 с вероятностью 0,8 и оставляет агента в том же состоянии с вероятностью 0,2. • В состоянии 2 действие а переводит агента в состояние 1 с вероятностью 0,8 и оставляет агента в том же состоянии с вероятностью 0,2. • Либо в состоянии 1, либо в состоянии 2 действие б переводит агента в состояние 3 с вероятностью 0,1 и оставляет агента в том же состоянии с вероятностью 0,9.

Дайте ответы на приведенные ниже вопросы. а) Какие характеристики оптимальной стратегии в состояниях 1 и 2 могут быть определены качественно? б) Примените алгоритм итерации по стратегиям для определения оптимальной стратегии и

значений состояний 1 и 2, полностью демонстрируя каждый этап. Примите предположение, что исходная стратегия включает действие b в обоих состояниях. в) Как повлияет на работу алгоритма итерации по стратегиям включение в исходная стратегия действия a в обоих состояниях? Поможет ли применение обесценивания? Зависит ли оптимальная стратегия от коэффициента обесценивания?

17.5. Иногда задачи MDP формулируются на основе функции вознаграждения $R(s, a)$, которая зависит от выполненного действия, или функции вознаграждения $R(s, a, s')$, которая зависит также от результирующего состояния. а) Запишите уравнения Беллмана для этих формулировок. б) Покажите, как можно преобразовать задачу MDP с функцией вознаграждения $R(s, a, s')$ в другую задачу MDP с функцией вознаграждения $R(s, a)$, такую, что оптимальные стратегии в новой задаче MDP будут точно соответствовать оптимальным стратегиям в первоначальной задаче MDP. в) Выполните аналогичные действия для преобразования задачи MDP с функцией $R(s, a)$ в задачу MDP с функцией $R(s)$.

17.6. dID Рассмотрим мир 4×3 , показанный на рис. 17.1. а) Реализуйте имитатор для этой среды, такой, чтобы можно было легко изменять географию данной среды. Некоторый код для решения указанной задачи уже находится в оперативном репозитории кода. б) Создайте агента, в котором используется итерация по стратегиям, и измерьте его производительность в имитаторе среды, начиная с различных начальных состояний. Выполните несколько экспериментов из каждого начального состояния и сравните среднее суммарное вознаграждение, полученное за каждый прогон, с полезностью состояния, которая определяется применяемым вами алгоритмом. в) Проведите эксперименты в среде с увеличенными размерами. Как изменяется время прогона алгоритма итерации по стратегиям в зависимости от размеров этой среды?

17.7. Для среды, показанной на рис. 17.1, найдите все пороговые значения функции полезности $R(s)$, такие, что после пересечения этого порога изменяется оптимальная стратегия. Вам потребуется способ вычисления оптимальной стратегии и его значения для фиксированной функции $R(s)$.

(Подсказка. Докажите, что значение любой фиксированной стратегии линейно зависит от функции $R(s)$.) 17.8. В этом упражнении рассматриваются задачи MDP с двумя игроками, которые соответствуют играм с нулевой суммой и поочередными ходами, подобным описанным в главе 6. Допустим, что игроки обозначены как A и B , и предположим, что $R(s)$ — вознаграждение для игрока A в состоянии s . (Вознаграждение для игрока B всегда равно ему и противоположно.) а) Допустим, что $U_A(s)$ — полезность состояния s , когда очередь хода в состоянии s принадлежит игроку A ; $U_B(s)$ — полезность состояния s , когда очередь хода в состоянии s принадлежит игроку B . Все вознаграждения и полезности вычисляются с точки зрения игрока A (как и в минимаксном дереве игры).

Запишите уравнения Беллмана, определяющие $UA(s)$ и $V(s)$. б) Объясните, как осуществить итерацию по значениям для двух игроков с помощью этих уравнений, и определите подходящий критерий останова. в) Рассмотрите игру, приведенную на рис. 6.12. Изобразите пространство состояний (а не дерево игры), показывая ходы игрока А сплошными ли-

ниями, а ходы игрока В — штриховыми линиями. Обозначьте каждое состояние значением $R(s)$. Вы обнаружите, что удобно расположить состояния (s_A, s_B) в виде двумерной решетки, используя в качестве "координат" значения s_A и s_B . г) Теперь примените итерацию по значениям для двух игроков, чтобы найти решение этой игры, и определите оптимальную стратегию.

17.9. Покажите, что любое равновесие доминантной стратегии представляет собой равновесие Нэша, но обратное утверждение не верно.

17.10. В детской игре в камень, бумагу и ножницы каждый игрок в какое-то время пытается выяснить, кто выбрал камень, бумагу или ножницы. Бумага обертывает камень, камень тупит ножницы, а ножницы режут бумагу. В расширенной версии игры в камень, бумагу, ножницы, огонь и воду приняты следующие условия: огонь побеждает камень, бумагу и ножницы; камень, бумага и ножницы побеждают воду; вода побеждает огонь. Запишите матрицу вознаграждений и найдите решение со смешанной стратегией для этой игры.

17.11. Найдите решение для игры в чет и нечет на трех пальцах.

17.12. До 1999 года команды Национальной хоккейной лиги получали 2 очка за победу, 1 за ничью и 0 за поражение. Можно ли рассматривать хоккей с такими правилами как игру с постоянной суммой? В 1999 году правила были изменены таким образом, что команда получает 1 очко за проигрыш в дополнительное время. Победившая команда все еще получает 2 очка. Изменится ли с учетом этого дополнения ответ на вопрос, приведенный выше? Если бы за это не было наказания, то было бы рациональным для двух команд тайне договариваться, чтобы оканчивать отборочную игру ничьей, а затем доводить ее до результативного завершения в дополнительное время? Предполагается, что полезность для каждой команды измеряется количеством полученных ею очков и что обоюдно известна априорная вероятность p того, что первая команда победит в дополнительное время. При каких значениях p обеим командам следовало бы заключать такое соглашение?

17.13. Приведенная в табл. 17.4 матрица вознаграждений, впервые опубликованная Блиндером [137] и проанализированная Бернштейном [114], показывает, какую игру ведут между собой конгрессмены-политики (сокращенно Pol) и руководство Федеральной резервной системы (сокращенно Fed).

Таблица 17.4. Матрица вознаграждений в административной игре Pol: сузить Pol: ничего не делать Pol: расширить Fed: сузить F=7, P=1 F=8, P=2 F=3, P=3 Fed: ничего не делать F=9, P=4 F=5, P=5 F=2, P=7 Fed: расширить F=6, P=6 F=4, P=9 F=1, P=8 Конгрессмены могут расширять или сужать налоговую политику, а руководители Федеральной резервной системы могут расширять или сужать бюджетную политику (и, безусловно, та и иная сторона может выбрать вариант, в котором не предусматривается внесение каких-либо изменений.) Кроме того, каждая из этих сторон имеет определенные предпочтения в отношении того,

кто и что должен делать, поскольку ни те ни другие не хотят вызвать недовольство населения. Показанные выше вознаграждения представляют собой ранги упорядочения от 9 до 1, т.е. от первого варианта до последнего. Найдите равновесие Нэша для этой игры в рамках чистых стратегий. Является ли это решение оптимальным согласно критерию Парето? Рекомендуем читателю проанализировать в свете этих исследований политику администраций США последних созывов.