

Стюарт Рассел, Питер Норвиг

Искусственный интеллект: современный подход, 2-е изд.

Часть VIII. Заключение

Содержание

Часть VIII. Заключение	1
Глава 26. Философские основания	1
Глава 27. Настоящее и будущее искусственного интеллекта	35

Часть VIII. Заключение

Заключение Философские основания 1248 Настоящее и будущее искусственного интеллекта 1259

Глава 26. Философские основания

26 Философские основания В данной главе речь идет о том, что означает "мыслить", а также о том, могут ли и должны ли этим заниматься искусственно созданные объекты.

Как упоминалось в главе 1, философы размышляли над мировыми проблемами задолго до того, как появились компьютеры, и пытались решить некоторые проблемы, которые по сути относятся к искусственному интеллекту: "Как функционирует разум? Возможно ли, чтобы машины действовали столь же интеллектуально, как люди, а если ответ на этот вопрос является положительным, то будет ли это означать, что они обладают разумом? Каковы этические последствия создания интеллектуальных машин?" Во всех предыдущих главах настоящей книги рассматривались вопросы, касающиеся самого искусственного интеллекта, а здесь мы в рамках одной главы рассмотрим указанные выше философские проблемы.

Прежде всего введем некоторую терминологию: утверждение, согласно которому машины, возможно, обладают способностью действовать интеллектуально (повидимому, эту мысль лучше выразить таким образом, что машины, возможно, способны действовать так, как будто действительно являются интеллектуальными), философы называют гипотезой $\wedge$ слабого искусственного интеллекта, а утверждение, что машины действительно мыслят (а не просто имитируют мыслительные процессы), называется гипотезой $\wedge$ сильного искусственного интеллекта.

Большинство исследователей искусственного интеллекта принимают гипотезу слабого искусственного интеллекта как данную и не задумываются над тем, что может рассматриваться также гипотеза сильного искусственного интеллекта; коль

скоро разработанная ими программа успешно функционирует, их не волнует, назовут ли ее работу имитацией интеллекта или настоящим интеллектом. Но всех исследователей искусственного интеллекта должны заботить этические последствия их деятельности.

26.1. Слабый искусственный интеллект: могут ли машины действовать интеллектуально?

Некоторые философы пытались доказать, что создать искусственный интеллект невозможно, т.е. что машины никогда не смогут действовать интеллектуально.

Некоторые из них даже использовали свою эрудицию, чтобы призвать всех прекратить исследования искусственного интеллекта, приводя следующие доводы.

Искусственный интеллект, создаваемый в рамках культа компьютероцентризма, не дает даже ни малейшего шанса на то, что с его помощью удастся добиться долговременных результатов ...настало время направить усилия исследователей искусственного интеллекта (и значительные средства, выделяемые на их поддержку) в области, отличные от этого компьютеризированного подхода [1355].

Очевидно, что ответ на вопрос о том, возможно или невозможно создание искусственного интеллекта, зависит от того, как определено само понятие искусственного интеллекта. По существу создание искусственного интеллекта — это борьба за разработку наилучшей возможной программы агента в данной конкретной архитектуре.

При использовании такой формулировки создание искусственного интеллекта возможно по определению, поскольку для любой цифровой архитектуры, состоящей из k битов памяти, существует точно 2^k программ агентов, и для того чтобы найти наилучшую из них, достаточно просто последовательно проверить их все. Такой подход может оказаться неосуществимым при больших значениях k , но философы оперируют с теоретическими, а не практическими конструкциями.

Приведенное выше определение искусственного интеллекта вполне подходит для решения технической проблемы поиска приемлемой программы агента при наличии некоторой заданной архитектуры. Поэтому вполне можно было бы закончить этот раздел прямо сейчас, ответив положительно на вопрос, приведенный в его названии.

Но философов интересует также проблема сравнения двух вычислительных архитектур — человека и машины. К тому же в философии существует давняя традиция поиска ответа на вопрос: ^ Могут ли машины мыслить? К сожалению, сам этот вопрос определен неправильно. Для того чтобы понять, почему это так, рассмотрим приведенные ниже вопросы. • Могут ли машины совершать полеты? • Могут ли машины заниматься плаванием?

Большинство людей согласятся, что ответ на первый вопрос является положительным, поскольку самолеты предназначены именно для того, чтобы совершать полеты, но ответят на второй вопрос отрицательно; корабли и подводные лодки движутся над водой и под водой, но это мы не называем занятиями плаванием. Тем не менее ни приведенные вопросы, ни ответы не оказывают никакого влияния на повседневную деятельность специалистов по авиации и судоходству, а также на пользователей тех машин, которыми они управляют. К тому же ответы на эти вопросы никак не могут помочь лучше проектировать или расширять возможности самолетов и подводных лодок и в большей степени касаются выбора правильных способов словоупотребления. Слово "заниматься плаванием" (swim) в английском языке постепенно приняло смысл "продвигаться в воде за счет движений частей тела", а слово "совершать полеты" (fly) не налагает таких ограничений на выбор способов

передвижения¹. Практическая возможность пользоваться услугами "мыслящих машин" предоставляется человеку в течение всего лишь 50 лет, а этого еще недостаточно для того, чтобы толкование слова "мыслить" распространилось и на машины.

Алан Тьюринг в своей знаменитой статье "Computing Machinery and Intelligence" [1520] указал, что вместо поиска ответа на вопрос, могут ли машины мыслить, мы должны интересоваться тем, могут ли машины пройти поведенческий тест интеллектуальности, который в дальнейшем получил название теста Тьюринга. Этот тест заключается в том, что программа в течение 5 минут участвует в разговоре (складывающемся из сообщений, которые передаются в оперативном режиме) с некоторым собеседником. Затем этот собеседник должен определить, проводился ли этот разговор с программой или с другим человеком; программа успешно проходит тест, если ей удастся обмануть собеседника в 30% случаев. Тьюринг предсказал, что к 2000 году компьютер с объемом памяти в 10⁹ единиц удастся запрограммировать настолько успешно, чтобы он прошел этот тест, но оказался неправ. Некоторых людей еще раньше удавалось водить за нос в течение 5 минут; например, программа Eliza и чатбот (робот-собеседник) Mgonz, действующий в Internet, не раз обманывали людей, которые так и не могли понять, что они общаются с программой, а программа Alice смогла даже одурачить судью на соревнованиях за приз Лёбнера (Loebner Prize) 2001 года. Но ни одной программе не удалось приблизиться к 30%-ному критерию в борьбе против специально обученных судей, да и в самой области искусственного интеллекта тесту Тьюринга уделяют все меньше внимания.

Тьюринг также исследовал широкий перечень вероятных возражений против самой возможности создания интеллектуальных машин, в том числе сумел предвидеть практически все возражения, которые были выдвинуты в течение полувека,

прошедшего со времени появления его статьи. В этой главе будут рассмотрены некоторые из них.

Довод, исходящий из неспособности В "доводе, исходящем из неспособности", выдвигается претензия, что "машина никогда не сможет выполнить действие X". В качестве примеров действий X Тьюринг приводит следующий список.

Быть добрым, щедрым, красивым, дружелюбным, инициативным, иметь чувство юмора, отличать правду от лжи, совершать ошибки, влюбляться, наслаждаться земляникой и мороженым, заставлять влюбляться в себя, учиться на опыте, правильно употреблять слова, быть предметом собственных мыслей, проявлять такое же разнообразие в поведении, как и человек, создавать действительно что-то новое.

Тьюрингу пришлось воспользоваться своей интуицией для выдвижения предположений о том, что будет возможно в будущем, а мы имеем счастливую возможность оглянуться назад, чтобы узнать, чего уже удалось добиться компьютерам. Нельзя отрицать, что компьютеры в наши дни выполняют многие действия, которые раньше были прерогативой одних лишь людей. Программы играют в шахматы, шашки и другие игры, контролируют детали на сборочных конвейерах, проверяют правописание в документах, введенных с помощью текстового редактора, водят автомобили. В русском языке эквивалент английского слова "swim" не носит такого ограничительного оттенка, поэтому может применяться и к судам.

и вертолеты, диагностируют заболевания, а также выполняют сотни других работ столь же хорошо, как люди, или даже лучше. Компьютеры сделали небольшие, но важные открытия в астрономии, математике, химии, минералогии, биологии, компьютерных науках и других областях. В каждом из этих случаев требовалось обладать способностями на уровне человека-эксперта.

С учетом того что мы знаем о компьютерах, не удивительно, что они легко справляются с такими комбинаторными задачами, как игра в шахматы. Но алгоритмы действуют также на уровнях не ниже человека при решении таких задач, которые, на первый взгляд, не позволяют обойтись без человеческого суждения или, как выразил это Тьюринг, заставляют "учиться на опыте" и требуют наличия способностей "отличать правду от лжи". Еще в 1955 году Пауль Мель [1032] (см. также [600]) изучал процессы принятия решений обученными экспертами как субъективные задачи, аналогичные прогнозированию успешного овладения студентом программы обучения или повторного совершения преступления рецидивистом. В 19 из 20 рассмотренных им исследований Мель обнаружил, что простые алгоритмы статистического обучения (такие как алгоритмы линейной регрессии или наивные байесовские алгоритмы) вырабатывают лучшие

предсказания, чем люди-эксперты. В американской Службе образовательного тестирования (Educational Testing Service) с 1999 года использовалась автоматизированная программа для выставления оценок по обзорным вопросам на экзаменах GMAT.

Результаты работы программы согласовывались с результатами работы экзаменаторов, которым было поручено выставять такие оценки, в 97% случаев, а этот уровень соответствует совпадению оценок двух экзаменаторов [212].

Очевидно, что компьютеры могут выполнять многие действия столь же успешно или даже лучше, чем люди, включая такие работы, в которых, по мнению людей, требуется огромная человеческая прозорливость и понимание. Это, безусловно, не означает, что компьютеры при выполнении этих работ проявляют прозорливость и понимание (указанные свойства не входят в состав поведения, о чем будет сказано ниже), но суть заключается в том, что первые предположения о содержании мыслительных процессов, требуемых для выработки данного конкретного поведения, часто оказываются ложными. Безусловно, верно также то, что во многих областях компьютеры все еще не добились значительного успеха (это еще мягко сказано), включая поставленную Тьюрингом задачу ведения разговора на свободную тему.

Возражения, основанные на принципах математики. Благодаря работам Тьюринга [1518] и Гёделя [566] широко известно, что на некоторые математические вопросы нельзя даже в принципе найти ответ в рамках конкретных формальных систем. При этом наибольшую известность получила теорема Гёделя о неполноте (см. раздел 9.5). Кратко эту теорему можно сформулировать таким образом: для любой формальной аксиоматической системы F , достаточно мощной для того, чтобы в ней можно было представить арифметику, возможно сконструировать так называемое "предложение Гёделя" $G(F)$ с описанными ниже свойствами. • $G(F)$ — это предложение системы F , но оно не может быть доказано в рамках F . • Если система F является непротиворечивой, то предложение $G(F)$ — истинно.

Философы, в том числе Дж. Р. Лукас [960], утверждали, что эта теорема показывает, будто машины как мыслящие субъекты всегда будут стоять ниже людей, по-

скольку машины — это формальные системы, ограниченные в силу теоремы о неполноте (они не способны установить истинность относящегося к ним самим предложения Гёделя), а люди не имеют такого ограничения. Споры вокруг данного утверждения продолжались несколько десятилетий и породили огромное количество литературы, в том числе две книги математика сэра Роджера Пенроуза [1204], [1205], повторившего это утверждение с некоторыми новыми выкрутасами (такими как гипотеза, согласно которой человек отличается от машины, поскольку

его мозг действует на основе квантовой гравитации). В этой главе мы рассмотрим только три из основных проблем, связанных с этим утверждением.

Во-первых, теорема Гёделя о неполноте распространяется только на формальные системы, достаточно мощные для того, чтобы в них можно было представить арифметику. К таким формальным системам относятся машины Тьюринга, поэтому утверждение Лукаса частично основано на том предположении, что компьютеры представляют собой машины Тьюринга. Это — хорошая аппроксимация, но не совсем оправданная. Машины Тьюринга являются бесконечными, а компьютеры конечны, поэтому любой компьютер может быть описан как (очень большая) система в пропозициональной логике, на которую не распространяется теорема Гёделя о неполноте.

Во-вторых, агенту не следует стыдиться того, что он не может определить истинность некоторого высказывания, тогда как другие агенты могут. Рассмотрим приведенное ниже предложение.

Дж.Р. Лукас не может неоспоримо утверждать, что это предложение истинно.

Если бы Лукас подтвердил истинность этого предложения, то он бы противоречил самому себе, поэтому Лукас не может неоспоримо подтвердить истинность данного предложения, а это означает, что оно должно быть истинным. (Это предложение не может быть ложным, поскольку, если бы Лукас не мог неоспоримо его подтвердить, то оно было бы истинным.) Таким образом, мы продемонстрировали, что есть такое предложение, которое Лукас не может неоспоримо подтвердить, тогда как другие люди (и машины) могут. Но из-за этого никто не вправе изменить своего мнения о Лукасе в худшую сторону. В качестве еще одного примера укажем, что ни один человек за всю свою жизнь не сможет вычислить сумму 10 миллиардов десятизначных чисел, а компьютер способен выполнить такую операцию за секунды. Тем не менее мы не рассматриваем этот факт как свидетельство фундаментального ограничения способности человека мыслить. Люди вели себя интеллектуально за тысячи лет до того, как изобрели математику, поэтому маловероятно, что способность формировать математические рассуждения играет более чем периферийную роль в том, что подразумевается под понятием интеллектуальности.

В-третьих (и это — наиболее важное возражение), даже если принять предположение, что компьютеры ограничены в том, что они способны доказать, нет никаких оснований считать, будто эти ограничения не распространяются на людей.

Слишком легко вести этот спор, строго доказав, что формальная система не может выполнить действие X, а затем сообщив, что люди могут выполнить действие X, используя свои человеческие неформальные методы, но не дав ни одного свидетельства в пользу этого утверждения. И действительно, невозможно доказать,

что на формальные рассуждения, проводимые людьми, не распространяется теорема Гёделя о неполноте, поскольку любое строгое доказательство само должно содержать формализацию способностей человеческого гения, которые, как многие утверждают, являются не-

формализуемым, и поэтому должно опровергать само себя. Таким образом, нам остается лишь прибегать к интуитивному представлению о том, что люди иногда способны проявлять сверхчеловеческие черты математического прозрения. Подобные утверждения выражаются в виде доводов: "мы должны быть уверены в том, что мы мыслим правильно, поскольку иначе мышление вообще становится невозможным" [961]. Но если об этом зашла речь, то давно известна склонность людей совершать ошибки. Это, безусловно, касается повседневной мыслительной деятельности, но справедливо также в отношении плодов математических рассуждений, полученных в результате упорной работы. Одним из известных примеров является теорема о раскраске карты четырьмя цветами. Математик Альфред Кемпе опубликовал в 1879 году доказательство этой теоремы, которое было широко признано и стало одним из поводов к избранию этого математика в состав членов Королевского общества. Но в 1890 году Перси Хивуд указал на ошибку в этом доказательстве, и теорема оставалась недоказанной до 1977 года.

Довод, исходящий из неформализуемости. Одно из наиболее важных и трудно оспоримых критических замечаний в адрес искусственного интеллекта как сферы приложения человеческих усилий было сформулировано Тьюрингом как довод, основанный на "неформализуемости поведения". По сути это критическое замечание сводится к утверждению, что человеческое поведение является слишком сложным для того, чтобы его можно было описать с помощью какого-либо простого набора правил, а поскольку компьютеры не способны ни на что, кроме выполнения множества правил, они не способны и проявлять такое же интеллектуальное поведение, как люди. В искусственном интеллекте неспособность выразить все, что потребуется, в виде множества логических правил называют проблемой спецификации (см. главу 10).

Основными сторонниками этих взглядов были философы Хьюберт Дрейфус, который написал ряд влиятельных критических статей против искусственного интеллекта, в том числе "What Computers Can't Do" (Что не способны делать компьютеры) [414] и "What Computers Still Can't Do" [415], и его брат Стюарт, совместно с которым Хьюберт написал статью "Mind Over Machine" [416].

Положение дел, которое критиковали эти ученые, получило известность как "добрый старый искусственный интеллект", или сокращенно GOFAI (Good OldFashioned AI); этот термин был предложен Хоглендом [631]. При этом предполагается, что в основе GOFAI лежит утверждение, будто все интеллектуальное поведение может быть представлено с помощью системы, которая формирует

логические рассуждения на основании множества фактов и правил, описывающих рассматриваемую проблемную область. Поэтому GOFAL соответствует простейшему логическому агенту, описанному в главе 7. Дрейфус был прав, утверждая, что логические агенты действительно имеют слабое место, поскольку не позволяют решить проблему спецификации.

Но как было показано в главе 13, для использования в открытых проблемных областях в большей степени подходят вероятностные системы формирования рассуждений.

Поэтому критические замечания Дрейфуса относятся не к компьютерам как к таковым, а скорее к одному конкретному способу их программирования. Однако, вполне можно предположить, что более правильное название для статьи Дрейфуса, "What First-Order Logical Rule-Based Systems Without Learning Can't Do" (Что не способны делать

системы на основе правил логики первого порядка, в которых не применяются средства обучения), было бы гораздо менее впечатляющим.

Согласно взглядам Дрейфуса, человеческий опыт подразумевает наличие знаний о некоторых правилах, но лишь в качестве "целостного контекста" (или "основы"), в рамках которого действуют люди. Он приводит пример корректного социального поведения при вручении и получении подарков: "Обычно люди, вручая подходящий к случаю подарок, действуют в рамках сложившихся в данном случае обстоятельств". Очевидно, что люди обладают "непосредственным пониманием того, как следует действовать и чего следует ожидать". Такое же утверждение он выдвигает в контексте игры в шахматы: "Шахматисту среднего уровня может потребоваться обдумать следующий ход, а гроссмейстер просто видит, что положение на доске само требует определенного хода ...правильный ответ сам складывается в его голове".

Безусловно, нельзя отрицать, что основная часть мыслительных процессов лица, готовящего подарок, или гроссмейстера, выбирающего ход, осуществляется на уровне, недоступном для самоанализа со стороны пытливого разума. Но из этого не следует, что сами эти мыслительные процессы не происходят. Важный вопрос, на который не отвечает Дрейфус, состоит в том, как правильный ход появляется в голове гроссмейстера. Напомним читателю один из комментариев Дэниела Деннета [389], приведенный ниже.

Создается впечатление, будто философы взяли на себя роль толкователей приемов фокусников. Когда их спрашивают, как фокусник ставит свой трюк с распиливанием ассистентки пополам, они объясняют, что в этом нет ничего сложного: фокусник фактически никого не распиливает; он просто заставляет людей верить, что он это

делает. Если же философов спрашивают: "Но как ему удастся создать такое впечатление?", они отвечают:

"Мы в этом не компетентны". В статье братьев Дрейфус [416] предложен пятиэтапный процесс приобретения опыта, который начинается с обработки полученной информации на основе правил (осуществляемой по такому же принципу, как в GOFAL) и заканчивается приобретением способности мгновенно выбирать правильные ответы. Но внося свое предложение, братья Дрейфус по сути перешли из разряда критиков искусственного интеллекта в разряд его теоретиков — они предложили архитектуру нейронной сети, организованную в виде огромной "библиотеки примеров", указав при этом на несколько проблем. К счастью, все указанные ими проблемы полностью решены, причем некоторые частично, а другие полностью. Упомянутые братьями Дрейфус проблемы перечислены ниже.

1. Качественное обобщение на основании примеров не может быть достигнуто без фоновых знаний. Дрейфусы утверждают, что не существует способа, позволяющего использовать фоновые знания в процессе обучения нейронной сети. А в действительности, как было описано в главе 19, уже разработаны такие методы, которые позволяют использовать априорные знания в алгоритмах обучения. Тем не менее эти методы основаны на том, что в наличии имеются знания, представленные в явной форме, а этот подход братья Дрейфус упорно отрицают. По мнению авторов настоящей книги, взгляды этих ученых являются основательной причиной для серьезного перепроектирования современных моделей нейронной обработки информации, для того чтобы в них можно было воспользоваться знаниями, полученными ранее в процессе обу-

чения, по такому же принципу, как такие знания используются в других алгоритмах обучения.

2. Обучение нейронной сети представляет собой одну из разновидностей контролируемого обучения (см. главу 18), для которой требуется заблаговременное выявление релевантных входных данных и правильных выходных данных. Поэтому, по утверждению братьев Дрейфус, система обучения нейронной сети не может действовать автономно, без помощи учителя-человека.

В действительности обучение без учителя может осуществляться с помощью методов неконтролируемого обучения (см. главу 20) и обучения с подкреплением (см. главу 21).

3. Производительность алгоритмов обучения снижается при использовании большого количества характеристик, а если выбрано лишь подмножество характеристик, то, по словам этих ученых, "не существует способа введения новых характеристик в том случае, если будет обнаружено, что текущее множество не позволяет учитывать некоторые факты, усваиваемые в процессе обучения". В

действительности с большими множествами характеристик очень успешно справляются такие новые методы, как машины поддерживающих векторов. Как было показано в главе 19, существует также принципиальная возможность вырабатывать новые характеристики, хотя для этого требуется гораздо больше усилий.

4. Мозг способен направлять свои сенсоры на поиск релевантной информации и обрабатывать ее для извлечения аспектов, релевантных для текущей ситуации. Но Дрейфусы утверждают, что "в настоящее время неизвестны детали этого механизма и нет даже таких гипотез о его работе, которые направили бы исследования искусственного интеллекта по правильному пути". В действительности проблеме выбора правильной ориентации сенсоров посвящена область активного зрения, основанная на теории стоимости информации (см. главу 16), а полученные теоретические результаты уже были применены при создании некоторых роботов.

В конечном итоге многие проблемы, на которых сосредоточились братья Дрейфус (фоновые обыденные знания, проблема спецификации, неопределенность, обучение, компилированные формы средств принятия решений, важность применения агентов, реагирующих на текущую ситуацию, а не бестелесных машин логического вывода), уже были решены, а достигнутые результаты воплощены в стандартных проектах интеллектуальных агентов. По мнению авторов настоящей книги, это — свидетельство прогресса искусственного интеллекта, а не подтверждение неосуществимости поставленной перед ним цели.

26.2. Сильный искусственный интеллект: МОГУТ ЛИ МАШИНЫ ПО-НАСТОЯЩЕМУ МЫСЛИТЬ?

Многие философы утверждали, что даже машина, которая пройдет тест Тьюринга, все равно фактически будет не мыслить, а лишь имитировать мышление.

Тьюринг предвидел и это возражение против искусственного интеллекта. В частности, он процитировал приведенный ниже фрагмент речи профессора Джеффри Джефферсона [726].

Мы сможем согласиться, что машина равна мозгу, лишь после того, как она будет в состоянии написать сонет или сочинить концерт под воздействием своих мыслей и эмоций, а не благодаря случайному совпадению нужных символов; под этим подразумевается, что машина должна не только написать подобное произведение, но и понимать, что оно ею написано.

Тьюринг назвал это возражение доводом, основанным на понятии сознания; согласно этому доводу, машина должна понимать свои собственные психические состояния и действия. Безусловно, сознание — это важная тема, но ключевая идея Джефферсона фактически касается проблемы феноменологии, или изучения

непосредственного опыта, т.е. этот ученый требует, чтобы машина действительно ощущала эмоции.

Другие ученые сосредотачиваются на проблеме целенаправленности, т.е. на вопросе о том, действительно ли приписываемые машине убеждения, желания и другие внутренние представления касаются "чего-то", существующего в реальном мире.

Ответ Тьюринга на это возражение весьма интересен. Он мог продемонстрировать причины, по которым машины на самом деле способны были бы действовать сознательно (либо с точки зрения феноменологии, либо с точки зрения целенаправленности). Вместо этого он указал, что данный вопрос столь же некорректен, как и вопрос о том, могут ли машины мыслить. К тому же, на каком основании мы требуем применения к машинам более высоких стандартов, чем к людям? В конечном итоге в повседневной жизни мы никогда не получаем каких-либо прямых свидетельств о внутреннем психическом состоянии других людей. Тем не менее Тьюринг заявил: "Вместо ведения бесконечных споров на эту тему обычно принято заключать ^ джентльменское соглашение и считать, что мыслят все".

Тьюринг утверждает, что Джефферсон согласился бы распространить это джентльменское соглашение на машины, только если бы имел опыт общения с теми из них, которые действуют интеллектуально. Он процитировал действительно происходивший приведенный ниже диалог человека с машиной, который считается такой неотъемлемой частью передающихся из уст в уста легенд искусственного интеллекта, что мы просто обязаны его включить в эту главу.

Человек. In the first line of your sonnet which reads "shall I compare thee to a summer's day", would not a "spring day" do as well or better? (В первой строке вашего сонета сказано "я хочу сравнить вас с летним днем"; не было бы так же хорошо или даже лучше сказать "с весенним днем"?) Машина. It wouldn't scan. (Нарушилась бы ритмика.) Человек. How about "a winter's day". That would scan all right. (А как насчет слов "с зимним днем". Ритмика бы не нарушилась.) Машина. Yes, but nobody wants to be compared to a winter's day. (Да, но никто не хочет, чтобы его сравнивали с зимним днем.) Человек. Would you say Mr. Pickwick reminded you of Christmas? (Вы хотите сказать, что мистер Пиквик напомнил вам о Рождестве?) Машина. In a way. (В определенном смысле.) Человек. Yet Christmas is a winter's day, and I do not think Mr. Pickwick would mind the comparison. (Но все же Рождество — зимний день, и я не думаю, что мистер Пиквик возражал бы против такого сравнения.)

Машина. I don't think you're serious. By a winter's day one means a typical winter's day, rather than a special one like Christmas. (Я не думаю, что вы говорите серьезно. Под зимним днем подразумевается обычный зимний день, а не такой особый день, как Рождество.) В заключение Тьюринг отметил, что вопрос о сознании является

трудноразрешимым, но опроверг мнение о том, что он имеет большую значимость для практики искусственного интеллекта: "Я отнюдь не желаю, чтобы мои слова были истолкованы таким образом, будто я не считаю проблему сознания сложной загадкой... но я не думаю, что нужно обязательно разгадать все подобные загадки, прежде чем мы сможем ответить на тот вопрос, о котором идет речь в данной статье". Авторы настоящей книги согласны с Тьюрингом: мы заинтересованы в создании программ, которые действуют интеллектуально, а не в том, чтобы дать кому-то повод считать эти действия настоящими или имитированными. С другой стороны, эта проблема остается предметом острого интереса для многих философов. Для того чтобы понять суть такой заинтересованности, рассмотрим вопрос о том, считаются ли реальными другие искусственно созданные объекты.

В 1848 году Фредерик Вёлер впервые синтезировал искусственную мочевины. Это достижение было очень важным, поскольку стало доказательством единства органической и неорганической химии, а также позволило поставить точку в вопросе, который до сих пор был предметом горячих дебатов. После успешного осуществления этого синтеза химики согласились, что искусственная мочевина действительно представляет собой мочевины, поскольку обладает всеми правильными физическими свойствами. Аналогичным образом, нельзя отрицать, что искусственные подслащивающие вещества действительно являются подслащивающими веществами, а искусственное оплодотворение (еще один термин с аббревиатурой AI — Artificial Insemination) действительно является оплодотворением. С другой стороны, искусственные цветы — это не цветы, и, как указал Дэниел Деннет (Daniel Dennett), искусственное вино Шато Латур — это не вино Шато Латур, даже если образцы того и другого нельзя отличить друг от друга с помощью химического анализа, просто потому, что оно не было изготовлено в должном месте правильным способом. А искусственно выполненный рисунок Пикассо — это не рисунок Пикассо, независимо от того, похож он на оригинал или нет.

На основании изложенного можно сделать вывод, что в некоторых случаях важно лишь поведение искусственного объекта, а в других случаях играет роль также происхождение искусственного объекта. То, в каком случае приобретает важность последний фактор, по-видимому, обусловлено лишь принятыми соглашениями.

А когда речь идет об искусственном разуме, мы не можем опереться на принятое по этому поводу соглашение, и нам остается полагаться лишь на интуитивные предположения. Философ Джон Сирл [1376, с. 37, 38] выдвинул следующее весьма убедительное предположение.

Никто не думает, что компьютерная имитация грозы заставит его вымокнуть... так почему же люди, будучи в здравом уме, могут предположить, что компьютерная

имитация мыслительных процессов действительно представляет собой мыслительные процессы?

Безусловно, нельзя не согласиться, что компьютерные имитации гроз не заставят нас вымокнуть, но не совсем понятно, как можно перенести эту аналогию на компьютерные имитации мыслительных процессов. К тому же создаваемые в Голливуде имитации гроз, в которых используются опрыскиватели и воздуходувки, действительно заставляют актеров вымокнуть. Большинство людей, не задумываясь, скажет,

что компьютерная имитация сложения является сложением, а компьютерная имитация шахматной игры является шахматной игрой. Что больше напоминают мыслительные процессы — грозы или абстрактные операции, такие как арифметическое сложение и игра в шахматы? С чем их следует сравнивать — со штучными изделиями, такими как вино Шато Латур и картины Пикассо, или с массовой продукцией, такой как мочевины? Ответы на все эти вопросы зависят от принятой теории психических состояний и процессов.

В теории [^] функционализма утверждается, что психическим состоянием является любое промежуточное причинное условие, связывающее входные и выходные данные. Согласно теории функционализма, любые две системы с изоморфными причинными процессами должны иметь одни и те же психические состояния. Поэтому компьютерная программа может иметь такие же психические состояния, как и человек. Безусловно, мы еще не дали определения того, что действительно подразумевается под термином "изоморфный", но основное допущение состоит в том, что существует некоторый уровень абстракции, ниже которого конкретные детали реализации не имеют значения; при условии, что ниже этого уровня процессы являются изоморфными, возникают одни и те же психические состояния.

В отличие от этого, в теории [^] биологического натурализма утверждается, что психические состояния представляют собой высокоуровневые эмерджентные характеристики, которые вызваны неврологическими процессами низкого уровня в нейронах, и ведущую роль в этих процессах играют некоторые (неопределенные) свойства нейронов. Это означает, что психические состояния не могут быть продублированы лишь на основе некоторой программы, имеющей такую же функциональную структуру и проявляющей такое же поведение, выраженное в виде входных/выходных данных; мы должны потребовать, чтобы эта программа эксплуатировалась в архитектуре, обладающей такой же причинной мощностью, как и нейроны. В указанной теории ничего не говорится о том, почему нейроны обладают этой причинной мощностью, а также о том, существуют ли другие физические воплощения, которые могут иметь или не иметь эту причинную мощность.

Чтобы проанализировать эти две точки зрения, вначале рассмотрим одну из самых старых проблем в области философии разума, а затем обратимся к трем мысленным экспериментам.

Проблема разума и тела ^ Проблема разума и тела касается вопроса о том, как психические состояния и процессы связаны с физическими состояниями и процессами (а именно с процессами, происходящими в мозгу). Игнорируя достаточно высокую сложность этой проблемы, обобщим ее до уровня проблемы "архитектуры разума", что позволит нам вести речь о том, могут ли машины иметь разум.

Почему проблема разума и тела является такой сложной? Первую сложность обнаружил еще Рене Декарт, который размышлял над тем, как бессмертная душа взаимодействует со смертным телом, и пришел к выводу, что душа и тело — это два различных типа субстанций; в этом состоит так называемая теория ^ дуализма. С другой стороны, теория ^ монизма, часто называемая ^ материализмом, основана на том, что таких субстанций, как нематериальные души, просто не бывает; в мире имеются только материальные объекты. Поэтому все психические состояния

(возникающие, когда человек испытывает боль, осознает себя как скачущий на лошади или думает, что Вена — столица Австрии) представляют собой состояния мозга. Джон Сирл метко сформулировал эту идею в виде лозунга "Мозг рождает разум".

Но материализму приходится сталкиваться с двумя серьезными препятствиями.

Первым из них является проблема ^ свободной воли: как так может оказаться, что чисто физический разум, каждое преобразование в котором строго управляется законами физики, все еще сохраняет какую-то свободу выбора? Большинство философов рассматривают эту проблему как требующую тщательного переопределения наших наивных представлений о свободной воле, а не представляющую собой какое-либо покушение на материализм. Вторым препятствием является проблема, касающаяся общего вопроса о ^ сознании (а также связанных с ним, но не идентичных вопросам понимания и самосознания). В наиболее простой формулировке этот вопрос состоит в том, почему человек ощущает себя как имеющий определенные мыслительные состояния и вместе с тем не чувствует себя как имеющий какие-то другие физические состояния (например, не считает себя камнем).

Чтобы приступить к поиску ответа на подобные вопросы, мы должны найти способы вести речь о состояниях мозга на уровнях, более абстрактных, чем конкретные конфигурации всех атомов мозга определенного человека в конкретное время.

Например, когда я размышляю о столице Австрии, мой мозг подвергается бесчисленному количеству мельчайших изменений за время, прошедшее от одной пикосекунды до другой, но это не приводит к качественному изменению состояния мозга. Для того чтобы учесть возможные ситуации, необходимо ввести понятие типов состояния мозга, в рамках которого можно было бы судить, принадлежат ли два состояния мозга к одному и тому же или к разным типам. Различные ученые имеют несовпадающие взгляды на то, что подразумевается в данном случае под типом. Но почти все ученые считают, что если взять живой мозг и заменить в нем некоторые из атомов углерода новым множеством атомов углерода², то психическое состояние мозга не изменится.

Эта гипотеза вполне оправдана, поскольку в действительности в мозгу непрерывно происходит замена атомов в результате метаболических процессов, тем не менее такой процесс, по-видимому, не вызывает существенных психических расстройств.

Теперь рассмотрим конкретный вид психического состояния: пропозициональные позиции (впервые описанные в главе 10), которые также известны как [^] ментальные состояния. Таковыми являются состояния, подобные убежденности, уверенности, желанию, чувству страха и т.д., которые относятся к некоторому аспекту внешнего мира. Например, уверенность в том, что Вена — столица Австрии, — это убеждение, касающееся конкретного города и его статуса. Нас интересует вопрос, могут ли компьютеры иметь ментальные состояния, чтобы можно было понять, как охарактеризовать эти состояния. Например, можно утверждать, что психическое состояние, в котором я хочу гамбургер, отличается от состояния, в котором я хочу пиццу, поскольку гамбургер и пицца в реальном мире отличаются друг от друга. А если верно такое утверждение, то ментальные состояния имеют необходимую связь с относящимися к ним объектам во внешнем мире. С другой стороны, всего лишь за несколько абзацев перед этим было сформулировано утверждение, что психические состояния представляют собой состояния мозга, поэтому идентичность или неидент² Возможно, даже атомами другого изотопа углерода, как иногда бывает в экспериментах по сканированию мозга.

тичность психических состояний должна определяться полностью "внутри самой головы", без ссылок на реальный мир. Чтобы лучше изучить эту дилемму, обратимся к мысленному эксперименту, позволяющему отделить целенаправленные состояния от относящихся к ним внешних объектов.

Эксперимент "мозг в колбе" Допустим, что при желании мозг человека можно отделить от тела сразу после рождения и поместить в колбу, искусно спроектированную для этой цели. В этой колбе мозг получает питание и опору, а она позволяет ему расти и развиваться. Наряду с тем в мозг подаются электронные сигналы от компьютера, моделирующего полностью вымышленный мир, а моторные сигналы от мозга перехватываются и используются для модификации этой

имитации должным образом³. В таком случае мозг может иметь психическое состояние DyingFor{Me, Hamburger) (страстное желание получить гамбургер), даже несмотря на то, что у него нет тела, которое испытывало бы чувство голода, а также вкусовых рецепторов, чтобы ощутить вкус, к тому же в реальном для мозга (но фактически имитируемом) мире могло бы просто не оказаться гамбургера. Было бы это психическое состояние таким же, какое испытывает мозг в живом теле?

Один из способов разрешения этой дилеммы состоит в использовании гипотезы о том, что содержимое психических состояний можно интерпретировать с двух разных точек зрения. В подходе на основе [^] широкого анализа содержимого психические состояния интерпретируются с точки зрения всезнающего внешнего наблюдателя, имеющего доступ к информации обо всей ситуации, который способен замечать любые различия в мире. Поэтому при широком анализе содержимого чувства мозга, живущего в колбе, можно отличить от чувств "обычного" человека. А при [^] узком анализе содержимого учитывается только внутренняя субъективная точка зрения, и при таком подходе чувства, испытываемые тем и другим мозгом, остаются одинаковыми.

Уверенность в том, что гамбургер — желанная пища, имеет определенный характер связи с конкретным объектом, поскольку обязательно должен быть кто-то, обладающий уверенностью в таком свойстве гамбургера. Переходя к рассуждениям такого рода, мы вступаем в область познания [^] качества, или собственного опыта (в англоязычной литературе для обозначения этого понятия применяется термин "qualia", происходящий от латинского слова, которое переводится примерно как "именно такие"). Предположим, что в результате какого-то нарушения в нервных путях сетчатки и мозга неким лицом X воспринимается как красный тот цвет, который лицо Y воспринимает как зеленый, и наоборот. В таком случае, увидев один и тот же сигнал светофора, оба они действуют одинаково, но воспринимаемый ими опыт должен быть в определенной степени разным. Оба эти лица могут согласиться, что полученные ими данные восприятия говорят о том, что "свет на светофоре — красный", но сами эти восприятия остаются разными. Поэтому неясно, свидетельствует ли это о том, что они имеют одинаковые или разные психические состояния.

³ Описанная ситуация может быть знакома тем, кто смотрел фильм The Matrix (Матрица), вышедший на экраны в 1999 году.

Теперь перейдем еще к одному мысленному эксперименту, который относится к вопросу о том, могут ли иметь психические состояния физические объекты, отличные от нейронов человека.

Эксперимент с протезом мозга Мысленный эксперимент с протезом мозга был предложен в середине 1970-х Кларком Глаймором и описан в трудах Джона Сирла

[1376], но его чаще всего связывают с работой Ханса Моравека [1084]. Этот эксперимент заключается в следующем: предположим, что нейрофизиология достигла огромного уровня развития, на котором существует идеальное понимание взаимодействия входных и выходных сигналов и связей между всеми нейронами в мозгу человека. Предположим также, что существует возможность создавать микроскопические электронные устройства, имитирующие поведение нейрона, которые можно незаметно для человека подключать к его нервной ткани. Наконец, предположим, что некая чудесная хирургическая техника позволяет заменять отдельные нейроны соответствующими электронными устройствами, не нарушая работу мозга в целом. Эксперимент состоит в постепенной замене всех нейронов в голове человека электронными устройствами, а затем в обратном выполнении этого процесса для возврата испытуемого субъекта в его нормальное биологическое состояние.

Нас интересует как внешнее поведение, так и внутренний опыт этого субъекта во время операции и после нее. Согласно определению этого эксперимента, внешнее поведение субъекта должно оставаться неизменным по сравнению с тем, которое наблюдалось бы в том случае, если бы эта операция не выполнялась⁴. Итак, несмотря на то, что в присутствии или отсутствии сознания не так уж легко убедиться, будучи сторонним наблюдателем, сам субъект эксперимента должен по крайней мере иметь способность зарегистрировать любые изменения в своем восприятии собственного сознания. Очевидно, что возникает прямой конфликт интуитивных представлений о том, что может произойти. Моравек, будучи специалистом в области робототехники и приверженцем взглядов функционалистов, убежден в том, что сознание субъекта, подвергающегося эксперименту, останется незатронутым, а Сирл, философ и натуралист-биолог, столь же твердо убежден, что сознание у субъекта эксперимента постепенно исчезнет, о чем свидетельствует приведенная ниже цитата из его работы.

Вы обнаружите, к своему полному изумлению, что действительно теряете контроль над своим внешним поведением. Например, вы заметите, что при проверке врачами вашего зрения вам, допустим, скажут: "Мы держим перед вами объект красного цвета; пожалуйста, сообщите нам, что вы видите". Вы захотите крикнуть: "Я ничего не вижу. Я полностью ослеп", но услышите, как ваш голос говорит, полностью не подчиняясь вашему контролю: "Я вижу перед собой объект красного цвета..." Ваше сознание постепенно сужается и исчезает, тогда как внешне наблюдаемое поведение остается неизменным [1379].

Но существует возможность вести этот спор, опираясь не только на интуицию.

Во-первых, следует отметить, что внешнее поведение будет оставаться одинаковым в процессе того, как субъект постепенно теряет сознание, только в том случае, если

⁴ Можно также представить себе, что в эксперименте участвует идентичный

"контрольный" субъект, над которым якобы выполняется операция, но фактически она не проводится. Это позволяет сравнивать поведение двух субъектов.

воля субъекта исчезает мгновенно и полностью; в противном случае сужение сознания должно было бы отразиться на внешнем поведении; это означает, что испытуемый должен был бы закричать: "Помогите, я теряю сознание!" или нечто в этом роде. Такая гипотеза мгновенного исчезновения воли в результате постепенной замены одного за другим отдельных нейронов кажется маловероятной.

Во-вторых, рассмотрим, что произойдет, если мы будем задавать субъекту вопросы, касающиеся того, как он сам ощущает наличие у него сознания в тот период, когда у него не останется ни одного настоящего нейрона. Согласно условиям эксперимента, мы должны получать примерно такие ответы: "Я чувствую себя прекрасно."

Я должен также отметить, что немного удивлен, поскольку верил в истинность доводов Сирла". Еще один вариант состоит в том, что мы могли бы уколоть субъекта заостренной палочкой и услышать ответ: "Ой, больно". Теперь, если вернуться к обычной жизни, то скептик может возразить, что подобные выходные данные могут быть получены и от программ искусственного интеллекта как простые результаты принятых соглашений. Действительно, совсем не сложно предусмотреть, например, такое правило: "Если на датчике номер 12 появится сигнал с высокой интенсивностью, то выдать выходные данные «Ой, больно»", но весь смысл рассматриваемого эксперимента состоит в том, что мы продублировали функциональные свойства обычного человеческого мозга, поэтому предполагается, что электронный мозг не содержит таких структур, в которых реализованы подобные соглашения. Это означает, что нужно как-то объяснить, чем обусловлены проявления сознания, вырабатываемые электронным мозгом, которые основаны лишь на функциональных свойствах нейронов. И это объяснение должно также распространяться на настоящий мозг, который имеет такие же функциональные свойства. На наш взгляд, можно сделать только два приведенных ниже возможных вывода.

1. Причинные механизмы формирования сознания, которые вырабатывают выходные данные такого рода в обычном мозгу, все еще продолжают действовать в электронной версии мозга, поэтому последняя также обладает сознанием.
2. Осознаваемые психические события в обычном мозгу не имеют причинной связи с поведением, а поскольку они отсутствуют также в электронном мозгу, последний не обладает сознанием.

Хотя нельзя исключить вторую возможность, при данном подходе сознание сводится к тому, что философы называют [^] эпифеноменальной (выраженной в

качестве побочного явления) ролью — как будто что-то происходит, но не отбрасывает тени, которая должна была бы появиться в наблюдаемом мире. Кроме того, если сознание действительно эпифеноменально, то в мозгу должен находиться второй, бессознательный механизм, с помощью которого и формируется восклицание "Ой, больно", когда человека колют заостренной палочкой.

В-третьих, рассмотрим ситуацию, возникшую после того, как операция проделана в обратном направлении и субъект снова имеет обычный мозг. И в этом случае внешнее поведение субъекта должно быть, по определению, таким же, как если бы операция вовсе не проводилась. В частности, мы были бы вправе задать субъекту такие вопросы: "Что вы чувствовали во время операции? Помните, как вас укололи заостренной палочкой?" Субъект должен точно помнить фактический характер своего осознанного опыта, включая качественную сторону этого опыта, несмотря на тот факт, что, согласно Сирлу, такого опыта не должно быть.

Сирл мог бы возразить, что мы не определили эксперимент должным образом.

Если бы настоящие нейроны, скажем, прекращали действовать в том промежутке времени, когда они были извлечены, а затем снова помещены в мозг, то, безусловно, они не могли бы "запомнить" опыт, полученный в это время. Чтобы учесть это обстоятельство, необходимо обеспечить обновление состояния нейронов в соответствии с изменением внутреннего состояния искусственных нейронов, которыми они заменялись. Если бы в таком случае предполагалось наличие "нефункциональных" аспектов реальных нейронов, которые привели бы к поведению, функционально отличному от того, которое наблюдалось, пока искусственные нейроны были бы еще на месте, то налицо было бы простое приведение к абсурду, поскольку означало бы, что искусственные нейроны функционально не эквивалентны настоящим нейронам (одно из возможных возражений против этого довода приведено в упр. 26.3).

Патрисия Чарчленд [260] указала, что приведенные выше доводы, основанные на теории функционализма и применяемые на уровне нейронов, могут также использоваться на уровне любой более крупной функциональной единицы — группы нейронов, раздела мозга, доли, полушария или целого мозга. Это означает, что, согласившись с доводом, что эксперимент с протезом мозга демонстрирует наличие сознания у мозга, в котором нейроны заменены электронными компонентами, мы должны также согласиться, что сознание сохраняется, если весь мозг заменяется схемой, в которой входные данные отображаются на выходные с помощью огромной поисковой таблицы. Такое представление неприемлемо для многих людей (включая самого Тьюринга), интуиция которых подсказывает, что поисковые таблицы вряд ли могут иметь сознание или, по меньшей мере, что сознательный опыт, сформированный во время поиска в таблице, не сопоставим с опытом, сформированным в процессе работы системы, которая может быть описана

(даже в примитивном, вычислительном смысле) как манипулирование с убеждениями, результатами самоанализа, целями и тому подобными явлениями, которые формируются мозгом. Эти замечания свидетельствуют о том, что эксперимент с протезом мозга может быть эффективным средством, подкрепляющим нашу интуицию, только если в нем не предусматривается замена сразу всего мозга, но это и не означает, что в данном эксперименте может лишь рассматриваться замена одних атомов другими, как хочет нас заставить считать Сирл.

Китайская комната Последний мысленный эксперимент, который будет описан в данной главе, повидимому, является самым известным из всех. Идея этого эксперимента принадлежит Джону Сирлу [1376], описавшему гипотетическую систему, в отношении которой любому наблюдателю ясно, что она работает под управлением какой-то программы и успешно проходит тест Тьюринга, но также ясно (согласно Сирлу), что эта система не понимает смысла каких-либо из ее входных или выходных данных.

На основании этого Сирл делает вывод, что работа системы под управлением приемлемой программы (т.е. программы, вырабатывающей правильные выходные данные) не является достаточным условием для обладания разумом.

Система состоит из человека, который понимает только английский язык, снабжен книгой с правилами, написанной на английском языке, а в его распоряжении находятся разные стопки бумаг, причем некоторые из них пусты, а другие заполнены описаниями, не поддающимися расшифровке. (Таким образом, человек играет роль процессора компьютера, книга правил представляет собой программу, а стопки бумаг соответствуют запоминающему устройству.) Система находится в комнате с небольшим отверстием, выходящим наружу. Через отверстие появляются полоски бумаги с символами, не поддающимися расшифровке. Человек находит совпадающие с ними символы в книге правил и следует обнаруженным в ней инструкциям.

Инструкции могут предусматривать задания по написанию символов на новых полосках бумаги, поиску символов в стопках, переупорядочению стопок и т.д. В конечном итоге инструкции диктуют необходимость написания одного или нескольких символов на листе бумаги, который снова передается во внешний мир.

До сих пор все шло нормально. Но из внешнего мира мы видим систему, которая принимает входные данные в форме предложений на китайском языке и формирует ответы на китайском, которые внешне кажутся "интеллектуальными", как и беседа, мысленно представленная Тьюрингом⁵. После этого Сирл проводит следующие рассуждения: человек, сидящий в комнате, не понимает китайского (это дано). Книга правил и стопки бумаги, будучи просто листами бумаги, не понимают китайского.

Поэтому речь не может идти о каком-либо понимании китайского языка, с^
Поэтому, согласно Сирлу, эксплуатация даже подходящей программы не обязательно приводит к развитию понимания.

Как и Тьюринг, Сирл рассмотрел и попытался опровергнуть целый ряд ответов на его доводы. Некоторые комментаторы, включая Джона Маккарти и Роберта Виленского, выдвинули предложения, которые Сирл назвал системными ответами. Их возражение состоит в том, что человека, сидящего в комнате, безусловно, можно спросить, понимает ли он китайский язык, но это аналогично тому, как если бы процессор компьютера спросили, может ли он извлекать кубические корни. В обоих случаях ответ является отрицательным и в обоих случаях, согласно системному ответу, вся система обладает способностью, которая была предметом вопроса.

Безусловно, если задать системе с китайской комнатой вопрос на китайском языке, знает ли она китайский, ответ будет утвердительным (и сформулированным на живом китайском языке). Согласно корректному соглашению Тьюринга, этого должно быть достаточно. Ответ Сирла — это возврат к той идее, что понимание не заключено в мозгу человека, сидящего в китайской комнате, и не может быть заключено в стопках бумаги, поэтому не может быть никакого понимания. Далее Сирл указывает, что можно представить себе ситуацию, когда человек запоминает книгу правил и содержимое всех стопок бумаги, поэтому больше нет ни одного объекта, которому можно было бы приписать понимание, кроме самого человека; но и после этого, если ему будет задан вопрос (на английском языке), понимает ли он китайский, ответ будет отрицательным.

Теперь перейдем к реальному анализу этой проблемы. Переход от эксперимента с использованием стопок бумаги к эксперименту с запоминанием — это просто попытка сбить читателя с толку, поскольку обе формы представляют собой варианты физического воплощения работающей программы. Фактические утверждения, выдвинутые Сирлом, опираются на четыре приведенных ниже аксиомы [1378].

5 Тот факт, что стопки бумаги могут оказаться больше всей нашей планеты, а выработка ответов может занять миллионы лет, не имеет отношения к логической структуре данного эксперимента. Одной из целей обучения философии является выработка тщательно отточенного понимания того, какие возражения являются обоснованными и какие нет.

1. Компьютерные программы представляют собой формальные, синтаксические сущности.
2. Разум имеет мыслительное содержание, или семантику.
3. Синтаксиса как такового не достаточно для семантики.

4. Мозг порождает разум. На основании первых трех аксиом Сирл делает вывод, что программы не могут служить достаточным условием для появления разума. Иными словами, агент, в котором функционирует какая-то программа, может оказаться разумным, но он не обязательно становится разумным лишь в силу того, что в нем работает программа.

На основании четвертой аксиомы Сирл делает вывод: "Любая другая система, способная порождать разум, должна обладать причинной мощью (по меньшей мере), эквивалентной той, какой обладает мозг". На основании этого он делает вывод, что любой искусственный мозг должен воплощать в себе такую же причинную мощь, как и мозг, а не только работать под управлением конкретной программы, и что мозг человека не вырабатывает мыслительные феномены исключительно благодаря тому, что в нем функционирует какая-то программа.

Вывод о том, что применения программ недостаточно для создания разума, действительно следует из этих аксиом, если допускается их вольная интерпретация.

Но само обоснование вывода проведено неудовлетворительно — все, что смог доказать Сирл, состоит в том, что если явно отвергнуты принципы функционализма (как было сделано в его третьей аксиоме), то заключение, согласно которому объекты, отличные от мозга, порождают разум, становится необязательным. Это предположение вполне обосновано, поэтому вся дискуссия сводится к тому, может ли быть принята третья аксиома. Согласно Сирлу, весь смысл эксперимента с китайской комнатой состоит в предоставлении интуитивного обоснования для третьей аксиомы. Но реакция других исследователей показывает, что такие интуитивные представления близки по духу только тем, кто уже был склонен соглашаться с идеей, что программы, взятые в чистом виде, не способны вырабатывать истинное понимание.

Еще раз отметим, что цель эксперимента с китайской комнатой состоит в опровержении понятия сильного искусственного интеллекта — утверждения, что эксплуатация программы подходящего типа обязательно приводит к появлению разума.

Этот мысленный эксперимент проводится путем демонстрации внешне интеллектуальной системы, в которой функционирует программа подходящего типа, но в отношении этой системы, согласно Сирлу, можно явно показать, что она не обладает разумом. Для этого Сирл прибегает к интуиции, а не к доказательству; он как будто говорит нам: "достаточно взглянуть на эту комнату; разве в ней может быть разум?"

Но точно такой же довод можно привести и применительно к мозгу — достаточно взглянуть на этот конгломерат клеток (или атомов), работающих вслепую в

соответствии с законами биохимии (или физики); разве в нем может быть разум? Почему в куске мозга может быть разум, а в куске печени — нет?

Более того, Сирл, соглашаясь с тем, что материалы, отличные от нейронов, могут в принципе быть носителем разума, ослабляет свои доводы еще больше, по двум причинам: во-первых, нам приходится руководствоваться только интуицией Сирла (или своей собственной), чтобы доказать, что в китайской комнате отсутствует разум, и, во-вторых, даже если мы решим, что в этой комнате нет разума, такой вывод не позволит нам узнать что-либо о том, не будет ли программа, работающая в какойто другой физической среде (включая компьютер), иметь разум.

Сирл допускает логическую возможность того, что мозг действительно реализует программу искусственного интеллекта традиционного типа, но та же программа, работающая в машине неподходящего типа, не создает разум. Сирл отрицает то, будто он верит, что "машины не могут иметь разума", скорее он утверждает, что некоторые машины имеют разум, например люди — это биологические машины, обладающие разумом. Но он также оставляет нас в неведении относительно того, какого же типа машины подходят или не подходят под определение понятия разумных машин.

26.3. Этические и моральные последствия разработки искусственного интеллекта До сих пор в этой главе в основном рассматривался вопрос о том, может ли быть разработан искусственный интеллект, но необходимо также посвятить время анализу вопроса, должен ли он все же быть разработан. Если последствия создания технологии искусственного интеллекта с большей вероятностью будут отрицательными, чем положительными, то люди, работающие в этой области, несут моральную ответственность, обязывающую их направить свои поиски в другие области.

Непредвиденные отрицательные побочные эффекты стали следствием внедрения многих новых технологий: двигатели внутреннего сгорания послужили причиной загрязнения воздуха и повсеместного строительства дорог, даже в самых райских уголках; ядерные технологии стали причиной взрывов в Чернобыле и на острове Тримайл Айленд и создали угрозу глобального разрушения. Все ученые и инженеры сталкиваются с этическими соображениями, которые они должны учитывать, выполняя свою работу, выбирая проекты, которые должны или не должны быть реализованы, а также способы осуществления этих проектов. На эту тему была даже написана книга *Ethics of Computing* [103]. Но искусственный интеллект, по-видимому, становится источником некоторых невиданных ранее проблем, в том числе перечисленных ниже, кроме, скажем, строительства мостов, которые падают под собственным весом. • В результате автоматизации может увеличиться количество безработных. • Может уменьшиться (или увеличиться) количество свободного

времени, имеющегося в распоряжении людей. • Люди могут потерять чувство собственной уникальности. • Люди могут потерять некоторые из своих прав на личную жизнь. • Использование систем искусственного интеллекта может привести к тому, что люди станут более безответственными. • Успех искусственного интеллекта может стать началом конца человеческой расы.

Рассмотрим каждую из этих проблем по очереди. • В результате автоматизации может увеличиться количество безработных.

Современная индустриальная экономика стала полностью зависимой от применения компьютеров в целом и отдельных программ искусственного интеллекта в частности. Например, значительная часть экономики, особенно в

Соединенные Штатах, зависит от доступности потребительского кредита.

Проверка заявок на выпуск кредитных карт, выдача разрешений на осуществление платежей и раскрытие мошеннических сделок, а также другие операции теперь выполняются программами искусственного интеллекта.

Напрашивается вывод, будто из-за появления этих программ свои места потеряли тысячи служащих, но в действительности этих рабочих мест без применения программ искусственного интеллекта просто не было бы, поскольку в случае применения ручного труда стоимость этих операций была бы неприемлемой.

До сих пор автоматизация с помощью технологии искусственного интеллекта неизменно создавала больше рабочих мест, чем устраняла, к тому же приводила к появлению более интересных и высокооплачиваемых специальностей. Теперь, после того как канонической программой искусственного интеллекта стал "интеллектуальный агент¹", предназначенный для помощи человеку, потеря работы становится еще менее вероятным последствием внедрения искусственного интеллекта по сравнению с той эпохой, когда все усилия специалистов по искусственному интеллекту сосредоточивались на создании "экспертных систем", предназначенных для замены людей. • Может уменьшиться (или увеличиться) количество свободного времени, имеющегося в распоряжении людей. Алвин Тоффлер в своей книге *Future Shock* [1510] указал: "Рабочая неделя с начала столетия сократилась на 50%.

И никого не удивляет прогноз, что к 2000 году она будет сокращена еще наполовину". Артур К. Кларк [265] писал, что "люди в 2001 году могут столкнуться с будущим, заполненным необычайной скукой, когда главной проблемой в жизни станет принятие решения о том, какой из нескольких сотен телевизионных каналов выбрать для просмотра". Единственным из этих прогнозов, который сбывлся хоть в какой-то степени, стало количество телевизионных каналов [1453]. А вместо сокращения рабочего дня люди, занятые в отраслях промышленности,

характеризующихся интенсивным использованием знаний, стали чувствовать себя частью интегрированной компьютеризированной системы, которая работает 24 часа в сутки; чтобы успешно справляться со своими обязанностями, они вынуждены работать все больше и больше. В индустриальной экономике вознаграждения приблизительно пропорциональны затратами времени; увеличение продолжительности работы на 10% обычно приводит в среднем к увеличению доходов на 10%. А в информационной экономике, характеризующейся наличием широкополосной связи и упрощением тиражирования интеллектуальной собственности (которую Фрэнк и Кук [495] назвали "обществом, в котором победитель получает все"), самое большое вознаграждение приносит способность оказаться немного более успешным, чем конкурент; увеличение продолжительности работы на 10% может означать увеличение дохода на 100%. Поэтому каждый испытывает все возрастающий прессинг, который заставляет его работать все интенсивнее.

Искусственный интеллект способствует увеличению темпов внедрения технологических инноваций и поэтому вносит свой вклад в эту общую тенденцию, но искусственный интеллект обещает также предоставить нам возможность снять с себя часть нагрузки и позволить нашим автоматизированным агентам хоть какое-то время выполнять работу за нас.

- Люди могут потерять чувство собственной уникальности. В своей книге *Computer Power and Human Reason* [1566] Вейценбаум, автор программы Eliza, указал на некоторые потенциальные угрозы, с которыми сталкивается общество в связи с развитием искусственного интеллекта. Одним из самых важных доводов Вейценбаума является то, что в результате исследований в области искусственного интеллекта кажется уже не такой невероятной идея о том, что люди представляют собой автоматы, а эта идея приводит к потере самостоятельности или даже человечности. Но авторы настоящей книги хотят отметить, что эта идея существовала задолго до появления искусственного интеллекта и восходит по меньшей мере к тем временам, когда вышла книга *L'Homme Machine* [875]. Авторы также отмечают, что люди пережили и другие покушения на чувство их уникальности: Коперник, автор книги *De Revolutionibus Orbium Coelestium* [294], убрал Землю из центра солнечной системы, а Дарвин, автор книги *Descent of Man* [326], поместил вид *Homo sapiens* на тот же уровень, где находятся все другие виды живых существ. Поэтому даже в случае его широкого и успешного наступления искусственный интеллект станет не большей угрозой для моральных устоев общества XXI века, чем была дарвиновская теория эволюции для XIX века.
- Люди могут потерять некоторые из своих прав на личную жизнь. Вейценбаум также указал, что развитие технологии распознавания речи может привести к широкому распространению средств прослушивания телефонных разговоров и поэтому к

потере гражданских свобод. Он не предвидел, что когда-то в мире террористические угрозы станут настолько реальными, что изменят отношение людей к тому, с каким уровнем надзора они будут готовы согласиться, однако правильно понял, что искусственный интеллект обладает потенциалом к созданию средств надзора массового применения. Предсказание Вейценбаума вскоре может осуществиться: правительство США рассматривает вопрос о внедрении системы Echelon, которая "состоит из сети пунктов прослушивания, антенных полей и радарных станций; система опирается на поддержку компьютеров, в которых используется языковой перевод, распознавание речи и поиск по ключевым словам для автоматического просеивания трафика, идущего по телефону, электронной почте, факсу и телексу". Многие согласны с тем, что компьютеризация приводит к ущемлению прав на личную жизнь, — один из старших руководителей компании Sun Microsystems Скотт Макнили даже заявил: "У вас все равно нет никакой личной жизни. Забудьте о ней". Другие с этим не согласны; например, судья Луис Брандейс писал еще в 1890 году: "Право на личную жизнь является самым всеобъемлющим из всех прав... ведь это — право оставаться самим собой". • Использование систем искусственного интеллекта может привести к тому, что люди станут более безответственными. В той атмосфере постоянной готовности к судебным разбирательствам, которая доминирует в Соединенных Штатах, большую важность приобретают вопросы правовой ответственности.

Если терапевт принял на веру суждение медицинской экспертной системы в отб См. статью "Eavesdropping on Europe" (Применение средств подслушивания в Европе), Wired news, 9/30/1998, и процитированные в ней отчеты Европейского экономического сообщества.

ношении диагноза, то кто будет нести ответственность, если диагноз окажется неправильным? К счастью, теперь общепризнано, что нельзя рассматривать как пренебрежение служебными обязанностями выполнение терапевтом медицинских процедур, которые имеют высокую ожидаемую полезность, даже если фактические результаты оказались катастрофическими для пациента (отчасти такая смена взглядов обусловлена ростом влияния методов теории решений в медицине). Поэтому приведенный выше вопрос должен рассматриваться в такой формулировке: "Кто должен нести ответственность, если диагноз оказался неоправданным?" До сих пор суды исходили из того, что медицинские экспертные системы играют такую же роль, как медицинские учебники и справочники; терапевты обязаны понять ход рассуждений, лежащий в основе любого решения системы, и использовать свое собственное суждение для принятия решения о том, нужно ли следовать рекомендациям системы.

Поэтому при проектировании медицинских экспертных систем в виде интеллектуальных агентов действия этих систем следует рассматривать не как

непосредственно воздействующие на пациента, а как влияющие на поведение терапевта. А если экспертные системы когда-то будут надежно вырабатывать более точные диагнозы по сравнению с людьми, врачи могут стать юридически ответственными, если они не используют рекомендации экспертной системы. Такая предпосылка рассматривается в [528].

Приобретают также важное значение аналогичные вопросы, касающиеся использования интеллектуальных агентов в Internet. Например, достигнут определенный прогресс в части внедрения ограничений в интеллектуальные агенты, чтобы они не могли, допустим, повредить файлы других пользователей [1571]. Проблемы становятся еще более важными, когда речь идет о денежных сделках. Если финансовые операции выполняются интеллектуальным агентом "от чьего-то имени", то кто будет отвечать за причиненные убытки? Будет ли существовать такая возможность, чтобы интеллектуальный агент сам имел активы и участвовал в электронных торгах от своего имени? Создается впечатление, что такие вопросы до сих пор еще полностью не изучены. Насколько известно авторам данной книги, еще ни одной программе не был придан правовой статус как индивидуума, способного участвовать в финансовых операциях; в настоящее время такое решение, по-видимому, было бы неблагоразумным. Кроме того, программы еще не рассматриваются как "водители", когда речь идет о контроле за выполнением правил дорожного движения на реальных автомагистралях. По крайней мере, в Калифорнии не предусмотрено никаких юридических санкций, которые исключали бы возможность превышения автоматизированным транспортным средством скоростных пределов, хотя в случае аварии должен нести ответственность проектировщик механизма управления транспортным средством. Как и в случае технологии клонирования людей, законодателям еще предстоит включить новые разработки в правовое поле. • Успех искусственного интеллекта может стать началом конца человеческой расы. Почти любая технология, попадая в злонамеренные руки, обнаруживает потенциальные возможности для причинения вреда, но когда речь идет об искусственном интеллекте и робототехнике, возникает новая проблема, связан-

ная с тем, что эти злонамеренные руки могут принадлежать самой технологии.

Предупреждения о том, какую опасность несут роботы или роботизированные киборги-гуманоиды, вышедшие из-под контроля, стали сюжетом бесчисленных научно-фантастических произведений. К числу самых ранних примеров таких произведений относятся книга *Frankenstein, or the Modern Prometheus*¹ Мэри Шелли [1400] и пьеса R.U.R Карела Чапека (1921 год), в которых описано, как роботы завоевывают мир. В кинематографе этой теме посвящены фильм "The Terminator" (Терминатор), вышедший на экраны в 1984 году, в котором используются клише "о роботах, завоевывающих мир" и сюжет о путешествии во времени, и фильм "The

Matrix" (Матрица), вышедший в 1999 году, в котором объединены сюжеты "о роботах, завоевывающих мир" и "о мозге, растущем в колбе".

По-видимому, роботы являются главными героями такого большого количества художественных произведений о завоевании мира в основном из-за того, что они воплощают в себе неизвестное, точно так же, как ведьмы и приведения в сказках, которыми пугали людей в более ранние эпохи. Но действительно ли роботы создают более реальную угрозу, чем ведьмы и приведения? Если роботы правильно спроектированы как агенты, которые соблюдают интересы своего владельца, то они не создают таких угроз: роботы, развивающиеся на основе постоянного усовершенствования текущих проектов, будут служить своим хозяевам, а не бороться против них.

Люди иногда используют свой интеллект в агрессивных формах, поскольку они обладают некоторыми врожденными агрессивными тенденциями, обусловленными естественным отбором. Но машины, созданные людьми, не нуждаются в чертах врожденной агрессивности, если только сами люди не решат, что они должны быть таковыми. С другой стороны, возможно, что компьютеры добьются своего рода победы над людьми, успешно служа и становясь незаменимыми, так же как и автомобили, которые в определенном смысле завоевали промышленно развитый мир.

Рассмотрим один сценарий, заслуживающий дополнительного анализа. И. Дж. Гуд [576] писал в одном из своих произведений следующее.

Дадим определение сверхинтеллектуальной машине как способной намного превзойти во всех областях мыслительной деятельности любого человека, каким бы умным он не был.

А поскольку проектирование машин является одним из таких направлений мыслительной деятельности, то сверхинтеллектуальная машина сможет проектировать еще более интеллектуальные машины; это, безусловно, приведет к "взрыву интеллектуальности" и интеллект человека останется далеко позади. Таким образом, первое изобретение сверхинтеллектуальной машины станет последним изобретением, которое когда-либо сможет сделать человек, и то, если только машина будет достаточно любезна, чтобы сообщить человеку, как держать ее под контролем.

Этому "взрыву интеллектуальности" профессор математики и автор научнофантастических произведений Вернор Виндж присвоил другое название — ^ технологическое превосходство; он писал: "В течение тридцати лет люди получают технологические средства для создания сверхчеловеческого интеллекта.

Вскоре после этого эра людей закончится" [1542]. Гуд и Виндж (и многие другие) правильно отмечают, что в настоящее время кривая технологического прогресса 7 Чарльз Бэббидж в молодости испытал сильные впечатления, читая книгу о приключениях Франкенштейна.

растет экспоненциально (достаточно вспомнить закон Мура). Однако прогноз, что эта кривая будет и дальше подниматься вверх, следуя законам почти бесконечного роста, был бы слишком смелым. До сих пор любая технология развивалась по S-образной кривой, согласно которой экспоненциальный рост в конечном итоге сходится к нулю.

Виндж озабочен и обеспокоен грядущим технологическим превосходством, но другие специалисты в области компьютерных наук, занимающиеся прогнозами, радуются его наступлению. Ханс Моравек в своей книге *Robot: Mere Machine to Transcendent Mind* предсказывает, что роботы сравняются по интеллектуальности с человеком за 50 лет, после чего его превзойдут. В своей книге он пишет следующее.

Довольно скоро они станут способными вытеснить нас из жизни. Но я не очень встревожен такой возможностью, поскольку считаю, что будущие машины — это наше потомство, "порождение нашего разума", созданное по нашему образу и подобию; это мы, но в более развитой форме. Как и биологические дети предыдущих поколений, они воплотят в себе лучшие надежды человечества на долгосрочное будущее. Это побуждает нас предоставить им все возможное содействие, а затем отойти в сторону, после того, как мы больше не в состоянии будем делать что-то полезное [1085].

Рей Курцвейл в своей книге *The Age of Spiritual Machines* [872] предсказывает, что к 2099 году наметится "мощная тенденция к слиянию человеческого мышления с миром машинного интеллекта, который был изначально создан родом человеческим. Больше не будет какого-либо четкого различия между людьми и компьютерами". Возникло даже новое слово, ^ трансгуманизм, для обозначения активного социального движения, которое охватывает тех, кто готовится к такому будущему.

Достаточно сказать, что указанные вопросы становятся вызовом для большинства теоретиков морали, которые считают единственно возможным путем развития сохранение существования человека и самого человеческого рода.

Наконец, рассмотрим эту проблему с точки зрения робота. Если роботы обретут сознание, то трактовка их просто как "машин" (т.е. дальнейшее их принижение) может стать аморальной. Роботы сами должны также действовать морально — нам потребуется запрограммировать в них теорию, по которой они смогут судить, что хорошо и что плохо. Проблема прав и обязанностей роботов рассматривалась в произведениях авторов научной фантастики, начиная с Айзека Азимова [45]. В

широко известном фильме "АЛ." [1451] Спилберга основой сюжета является рассказ Брайена Олдисса об интеллектуальном роботе, в программу которого была вложена вера в то, что он — человек, поэтому он не мог понять, почему же его когда-то неизбежно покинет владелица-мать. И в самом рассказе, использованном Спилбергом, и в его фильме приведены доводы в пользу того, что должно быть развернуто движение за гражданские права роботов.

26.4. Резюме В данной главе рассматривались приведенные ниже темы. • Философы используют термин слабый искусственный интеллект для обозначения гипотезы о том, что машины могут обладать способностью действовать интеллектуально, и термин сильный искусственный интеллект — для обозначения

гипотезы, что такие машины можно рассматривать как действительно обладающие разумом (а не имитирующие разумную деятельность). • Алан Тьюринг отверг как некорректный вопрос: "Могут ли машины мыслить?" и заменил его поведенческим тестом. Он сумел предугадать многие возражения против самой возможности появления мыслящих машин. В настоящее время исследователи искусственного интеллекта почти не уделяют тесту Тьюринга внимания, поскольку предпочитают работать над повышением производительности своих систем в решении практических задачах, а не над совершенствованием их способности имитировать людей. • В настоящее время общепризнано, что психические состояния представляют собой состояния мозга. • Споры за и против сильного искусственного интеллекта еще не закончились.

Но лишь немногие из ведущих исследователей искусственного интеллекта считают, что итогом этих дебатов могут стать какие-либо существенные достижения. • Проблема сознания продолжает оставаться нерешенной загадкой. • Выявлено шесть потенциальных угроз обществу, создаваемых искусственным интеллектом и связанной с ним технологией. Авторы данной книги пришли к заключению, что некоторые из этих угроз либо являются маловероятными, либо ненамного отличаются по степени опасности от угроз, создаваемых другими, "неинтеллектуальными" технологиями. Лишь одна из этих угроз особо заслуживает дальнейшего анализа; она заключается в том, что с появлением сверхинтеллектуальных машин наступит такое будущее, которое весьма отличается от современности; это может нам не нравиться, но в данном вопросе у нас может не оказаться другого выбора. Указанные соображения неизбежно приводят к выводу, что мы должны тщательно взвешивать свои действия и в дальнейшем заняться анализом возможных последствий исследований искусственного интеллекта, от которых может зависеть будущее человеческой расы.

Библиографические и исторические заметки Природа разума всегда оставалась неизменной темой философских рассуждений от древних времен до настоящего времени. В своем произведении "Федон" Платон отдельно рассмотрел и отбросил

идею о том, что разум может быть "настройщиком" или образцом организации частей тела, т.е. ту точку зрения, которая близка к взглядам приверженцев функционализма в современной философии разума. Вместо этого он решил, что разум должен быть воплощен в бессмертной, нематериальной душе, отделимой от тела и состоящей из другой субстанции, т.е. встал на позиции дуализма. Аристотель различал несколько видов душ (обозначая их греческим словом "психе" — ψυχή) в живых существах, но некоторые из них он описывал в манере функционализма (дополнительные сведения о функционализме Аристотеля можно найти в [1151]).

Известным приверженцем дуалистических взглядов на человеческий разум был Декарт, но по иронии судьбы он оказал огромное историческое влияние на развитие

механицизма и материализма. Он явно рассматривал животных в качестве автоматов и предугадал предложенный Тьюрингом тест, написав в своей работе: "Нет ничего невероятного в том [что машина] может обладать способностью производить различные перестановки слов, чтобы дать достаточно осмысленный ответ на то, что сказано в ее присутствии, так же, как это способен сделать даже самый глупый из людей" [391]. Энергичная защита Декартом точки зрения на то, что животные являются автоматами, фактически позволила будущим философам скорее прийти к выводу о том, что люди также являются автоматами, даже несмотря на то, что сам он не сделал этого шага. В книге *L'Homme Machine* (Человек-машина) [875] Ламетри действительно приведено явное утверждение, что люди являются автоматами.

Приверженцы современной аналитической философии обычно признают материализм (часто в форме теории идентичности состояний мозга [39], [1215], согласно которой психические состояния идентичны состояниям мозга). Но в рамках материализма существуют серьезные разногласия по вопросам отношения к функционализму и применения машинной аналогии для человеческого разума, а также по вопросу о том, могут ли машины мыслить в буквальном понимании этого слова. На первых порах многие философы возражали против идей Тьюринга, изложенных в статье "Computing Machinery and Intelligence" [1520], например, Шривен [1374] пытался доказать, что бессмысленно даже говорить о том, что машины могут мыслить, на том основании, что в этом предположении искажается сам смысл данного слова. Но к 1963 году Шривен отказался от этих взглядов; см. дополнение к перепечатке его статьи [28]. Специалист в области компьютерных наук Эдсгер Дейкстра сказал, что "вопрос о том, может ли компьютер мыслить, не более интересен, чем вопрос о том, может ли подводная лодка плавать". А в [480] приведены доводы в пользу того, что тест Тьюринга не нужен для развития искусственного интеллекта.

Функционализм — это философия разума, которая зародилась под влиянием искусственного интеллекта наиболее естественным образом, поэтому критика функционализма часто принимает форму критики искусственного интеллекта (как в случае воззрений философа Сирла). Следуя классификации, используемой Блоком [138], мы можем различить несколько видов функционализма. Теория функциональной спецификации [923], [925] представляет собой одну из разновидностей теории идентичности состояний мозга, в которой выбираются состояния мозга, подлежащие идентификации с психическими состояниями на основе их функциональной роли. А теория идентичности функционального состояния [1246], [1248] более полно основана на машинной аналогии. В ней психические состояния идентифицируются не с физическими состояниями мозга, а с абстрактными вычислительными состояниями мозга, явно рассматриваемого как вычислительное устройство.

Предполагается, что эти абстрактные состояния не зависят от конкретной физической композиции мозга, а это заставляет думать, что теория идентичности функциональных состояний представляет собой одну из форм дуализма!

И теория идентичности состояний мозга, и различные формы функционализма подвергаются атакам со стороны философов, утверждающих, что в этих взглядах не учитывается качественный аспект психических состояний или "аспект их подобия" [1110]. С другой стороны, Сирл сосредоточивается не на этом вопросе, а на том, что функционализм якобы не позволяет учитывать целенаправленность [1376], [1377], [1379]. В [259] приведено опровержение критических взглядов обоих этих типов.

Отличием ^элиминирующего материализма [258], [1301] от всех других ведущих теорий в философии разума является то, что в нем не предпринимаются попытки обосновать правильность представлений "народной психологии" или обыденных представлений о разуме; вместо этого подобные взгляды отвергаются как ложные и предпринимается попытка заменить их чисто научной теорией разума. В принципе эта научная теория могла бы быть лучше развита в рамках классического искусственного интеллекта, но на практике приверженцы элиминирующего материализма склонны к проведению исследований в области неврологии и нейронных сетей [260] на том основании, что классический искусственный интеллект, особенно исследования в области "представления знаний", описанные в главе 10, как правило, исходят из истинности "народной психологии". Хотя точка зрения, основанная на "целенаправленной позиции" [387], может рассматриваться как соответствующая принципам функционализма, ее, возможно, следует вместо этого считать одной из форм элиминирующего материализма, поскольку предполагается, что принятие "целенаправленной позиции" не отражает каких-либо объективных свойств агента, по отношению к которым занята эта позиция. Следует также отметить такую возможность, что позиция элиминирующего материализма

будет принята в отношении одних аспектов мыслительной деятельности, тогда как в отношении других будет принят какой-то другой подход. Например, Деннет [388] выдвигает гораздо более строгие требования по устранению из сферы анализа (в рамках элиминирующего материализма) понятия качества, чем понятия целенаправленности.

Ссылки на литературу, содержащую основные критические замечания в адрес слабого искусственного интеллекта, в основном приведены в данной главе. Хотя в эпоху, наступившую после бума в области нейронных сетей, стало модно высмеивать символические подходы, не все философы критически относятся к достижениям GOFAI. Напротив, некоторые из них являются его горячими сторонниками и даже практиками. Зенон Пилишин [1250] утверждает, что процесс познания можно лучше всего понять с помощью вычислительной модели, не только в принципе, но и в ходе проведения современных исследований. Он специально занимался опровержением критических замечаний Дрейфуса в адрес вычислительной модели человеческого познания [1249]. Гильберт Харман [621], анализируя процесс пересмотра воззрений, провел аналогии с исследованиями искусственного интеллекта на базе системы поддержки истинности. Майкл Братман применил свою модель человеческой психологии "убеждение—желание—намерение" [176] к исследованиям искусственного интеллекта по планированию [177]. Крайний приверженец строгого искусственного интеллекта, Арон Сломан [1432, с. xiii], даже назвал "расистскими" взгляды Джозефа Вейценбаума [1566] на то, что гипотетические интеллектуальные машины не следует рассматривать как личности.

Философская литература по проблемам разума, мозга и близким к этому темам очень обширна; кроме того, эта литература часто является трудной для чтения теми, кто не обладает надлежащей подготовкой в области терминологии и используемых методов аргументирования. Исключительно авторитетным и очень полезным помощником в этом процессе может стать книга *Encyclopedia of Philosophy* (Энциклопедия философии) [431]. Более краткой и доступной книгой является *The Cambridge Dictionary of Philosophy* (Кембриджский словарь по философии) [48], но и в нем основные статьи (например, с описанием "философии разума") все еще превышают по объему десятки страниц. Вопросы философии разума, а также биологии и психологии разума

рассматриваются в книге *MIT Encyclopedia of Cognitive Science* [1599]. К числу общих сборников статей о философии разума, в которых представлены различные точки зрения на проблемы, связанные с искусственным интеллектом, включая функционализм, относятся *Materialism and the Mind-Body Problem* [1309] и *Readings in the Philosophy of Psychology*, том 1 [138]. Биро и Шахан представили сборник статей [131], посвященный всем доводам за и против функционализма. К антологиям

статей, в большей степени касающихся отношений между философией и искусственным интеллектом, относятся Minds and Machines [28], Philosophical Perspectives in Artificial Intelligence [1288], Mind Design [630] и The Philosophy of Artificial Intelligence [146].

Имеется также несколько общих введений в философский "вопрос об искусственном интеллекте" [145], [146], [293], [631]. Основным журналом, который публикует материалы философских и научных дебатов об искусственном интеллекте и неврологии, является The Behavioral and Brain Sciences (сокращенно BBS). Вопросы этики и ответственности в искусственном интеллекте рассматриваются в таких журналах, как Aland Society, Law, Computers and Artificial Intelligence и Artificial Intelligence and Law.

Упражнения 26.1. Пройдите по составленному Тьюрингом списку предполагаемых действий, на которые "не способны" машины, и укажите, какие из них удалось осуществить, какие осуществимы в принципе с помощью программ и какие все еще находятся под вопросом, поскольку для них требуются сознательные психические состояния.

26.2. Является ли опровержение довода с китайской комнатой убедительным доказательством того, что должным образом запрограммированные компьютеры имеют психические состояния? Обязательно ли принятие этого довода означает согласие с тем, что компьютеры не могут иметь психических состояний?

26.3. Пользуясь доводом с протезом мозга, важно предусмотреть способность восстановить мозг субъекта до нормального состояния, так, чтобы внешне он вел себя, будто над ним не проводилась какая-либо операция. Будет ли обоснованным возражение скептика о том, что для этого потребуется обновление нейрофизиологических свойств нейронов, которые относятся к сознательному опыту, в отличие от тех свойств, которые касаются функционального поведения нейронов?

26.4. Найдите и проанализируйте в популярном издании одну или несколько статей на ту тему, что создание искусственного интеллекта является невозможным.

26.5. Попытайтесь составить определения терминов "интеллект", "мышление" и "сознание". Проанализируйте некоторые возможные возражения против ваших определений.

26.6. Проанализируйте потенциальные угрозы обществу со стороны технологии искусственного интеллекта. Какие угрозы являются наиболее серьезными и как им можно противостоять? В каком соотношении они находятся с потенциальными выгодами?

26.7. Каковыми являются потенциальные угрозы со стороны технологии искусственного интеллекта в сравнении с угрозами со стороны других компьютерных технологий, а также со стороны ядерных, биои нанотехнологий?

26.8. Одни критики искусственного интеллекта утверждают, что его создать невозможно, а другие считают, что очень даже возможно и что сверхинтеллектуальные машины представляют собой угрозу. Какое из этих утверждений вы считаете наиболее вероятным? Будут ли противоречивыми взгляды тех, кто занимает одновременно обе позиции?

Глава 27. Настоящее и будущее искусственного интеллекта

Настоящее И БУДУЩЕЕ ИНТЕЛЛЕКТА В данной главе мы подводим итог тому, где мы находимся и куда движемся; это следует сделать, прежде чем приступить к дальнейшему изложению ее темы.

В части I предложен единый подход к проблематике искусственного интеллекта — как к проектированию рациональных агентов. В ней было показано, что сложность задачи проектирования зависит от того, какие акты восприятия и действия доступны для агента, каким целям должно удовлетворять поведение агента, а также от характера среды. Возможно применение целого ряда различных проектов агентов, начиная от простых рефлексных агентов и заканчивая агентами, основанными на знаниях, полностью способными к самостоятельному функционированию. Более того, компоненты этих проектов могут иметь целый ряд различных реализаций, таких как логические, вероятностные или "нейронные". А в главах, которые следуют за этой частью, представлены принципы, на основании которых действуют эти компоненты.

Как описано выше, в последнее время достигнуты поразительные успехи в научном понимании проблемы и в обеспечении технологических возможностей как с точки зрения разработки проектов, так и с точки зрения реализации компонентов агентов. В данной главе мы отвлечемся от деталей и попытаемся найти ответ на вопрос: <Ж* "Приведет ли весь этот прогресс к созданию интеллектуального агента общего назначения, способного функционировать в самых различных вариантах среды?"

В разделе 27.1 рассматриваются компоненты интеллектуального агента для определения того, что известно и чего еще недостает. В разделе 27.2 решается такая же задача применительно к общей архитектуре агента. В разделе 27.3 предпринимается попытка найти ответ на вопрос о том, является ли, прежде всего, правильной сама цель создания "проекта рационального агента" (ответ на данный вопрос должен быть таков: "Фактически дело обстоит иначе, но на данный момент эта цель являет-

ся вполне приемлемой"). Наконец, в разделе 27.4 показано, к каким последствиям приведет достижение нами успеха в своих начинаниях.

27.1. Компоненты агента В главе 2 представлены разнообразные проекты агентов и их компоненты. Но в настоящей главе, для того чтобы можно было сузить рамки обсуждения, будет рассматриваться проект агента, действующего с учетом полезности, который еще раз показан на рис. 27.1. Это— наиболее общий из рассматриваемых нами проектов агентов; в этой главе речь также пойдет о его дополнении средствами обучения, как показано на рис. 2.7.

(Как повлияют мои действия Что будет, если я выполню действие А (Полезность)- Какую пользу принесет мне это состояние Какое действие теперь выполнить Агент Исполнительные , механизмы с Рис. 27.1. Проект, основанный на модели агента, действующего с учетом полезности, который впервые представлен на рис. 2.6 • Взаимодействие со средой с помощью датчиков и исполнительных механизмов.

Этот аспект оставался очевидным для всех слабым пунктом на протяжении большей части истории развития искусственного интеллекта. Если не считать небольшого числа исключений, вызвавших всеобщее восхищение, системы искусственного интеллекта создавались таким образом, что людям приходилось вручную подавать в них входные данные и интерпретировать выходные, поскольку робототехнические системы, предназначенные для решения задач низкого уровня, на которые опирались бы высокоуровневые компоненты формирования рассуждений и планирования, в основном отсутствовали. Такая ситуация отчасти была обусловлена тем, что для обеспечения функционирования настоящих роботов даже в самой узкой области требовались существенные финансовые расходы и большие затраты труда проектировщиков. Такая ситуация быстро изменяется в последние годы в связи с появлением готовых программируемых роботов, таких как роботы с четырьмя опорными конечностями (см. рис. 25.4, б). Эти роботы, в свою очередь, созданы благодаря появлению небольших, недорогих телекамер CCD (Charge Coupled Device — прибор с за-

рядовой связью) с высоким разрешением, а также компактных, надежных электрических приводов. Технология MEMS (Micro-ElectroMechanical System — микроскопические электромеханические системы) позволила создать миниатюрные акселерометры и гироскопы, а в настоящее время в ее рамках создаются исполнительные механизмы, способные, например, приводить в действие искусственное летающее насекомое. (Существует также возможность объединять миллионы исполнительных механизмов MEMS для получения очень мощных макроскопических исполнительных механизмов.) Поэтому, что касается вариантов физической среды, то больше нет реальных причин, оправдывающих то положение, в котором находятся системы искусственного интеллекта. Кроме того, стала доступной полностью новая среда — Internet. • Слежение за состоянием мира. Это

— одна из основных способностей, которой должен обладать интеллектуальный агент. Для этого требуется и восприятие, и обновление внутренних представлений. В главе 7 описаны методы слежения за миром, представленные в форме пропозициональной логики; в главе 10 они расширены до логики первого порядка, а в главе 15 представлены алгоритмы фильтрации для слежения за неопределенными вариантами среды. Эти инструментальные средства фильтрации вступают в действие, когда приходится сталкиваться с реальными (поэтому далекими от идеала) результатами восприятия. Современные алгоритмы фильтрации и восприятия могут комбинироваться для успешного выполнения заданий по составлению сообщений в виде предикатов низкого уровня, таких как "на столе стоит чашка", но еще многое предстоит сделать, прежде чем с помощью этих алгоритмов можно будет составить отчет, например, о том, что "доктор Рассел пьет чай с доктором Норвигом". Еще одна проблема состоит в том, что алгоритмы приближенной фильтрации, хотя и могут действовать в весьма обширной среде, остаются по сути пропозициональными, поэтому, как и пропозициональная логика, не позволяют явно представлять объекты и отношения. В главе 14 описано, как можно применить в сочетании теорию вероятностей и логику первого порядка для решения этой задачи; можно рассчитывать на то, что применение этих идей для слежения за сложными вариантами среды со временем позволит добиться огромных преимуществ. Кстати, как только речь заходит об объектах в неопределенной среде, нам приходится сталкиваться с $\wedge$ неопределенностью идентичности, поскольку часто неизвестно, не потерян ли из виду тот объект, за которым мы начинали следить. Эта проблема в системах искусственного интеллекта, основанных на логике, почти всегда игнорировалась, поскольку в основном предполагалось, что результаты восприятия включают константные символы, которые однозначно обозначают те или иные объекты.

- Проектирование, оценка и выбор будущих способов действий.

При решении этой задачи требования к представлению основных знаний остаются такими же, как и при решении задачи слежения за миром; трудности состоят главным образом в том, что приходится сталкиваться с проявлениями действий (например, связанных с проведением беседы или совместного чаепития), которые в конечном итоге состоят из тысяч или миллионов примитивных шагов, выполняемых реальным агентом. Вообще говоря, люди осуществляют такое сложное поведение исключительно благодаря тому, что действуют в рамках

иерархической структуры поведенческих актов. В некоторых из алгоритмов планирования, приведенных в главе 12, используются иерархические представления и представления в логике первого порядка, позволяющие справляться с проблемами реальных масштабов; с другой стороны, в алгоритмах принятия решений в условиях неопределенности, приведенных в главе 17, по существу используются такие же идеи, как и в алгоритмах поиска с учетом состояния,

рассматриваемых в главе 3. В этой области необходимо выполнить еще очень большой объем работы, возможно, на основе новейших достижений в области иерархического обучения с подкреплением. • Полезность как способ выражения предпочтений. Вообще говоря, принцип, согласно которому рациональные решения должны быть основаны на максимизации ожидаемой полезности, является полностью общим и позволяет избежать многих проблем, связанных с подходами, основанными исключительно на достижении цели, таких как конфликтующие цели и ненадежные результаты. Однако до сих пор еще очень мало сделано в области создания реальных функций полезности. Достаточно представить себе, например, в какой сложной сети взаимодействующих предпочтений должен разбираться агент, действующий в качестве ассистента-делопроизводителя для чиновника.

Как оказалось, задача декомпозиции предпочтений по сложным состояниям, подобная тому, как осуществляется декомпозиция убеждений по сложным состояниям в байесовских сетях, является весьма трудноразрешимой. Одна из причин этого может состоять в том, что распределение предпочтений по состояниям фактически компилируется из предпочтений, распределенных по историям состояний, которые описываются с помощью функций вознаграждения (см. главу 17). Даже если функция вознаграждения является простой, соответствующая функция полезности может оказаться очень сложной. Это означает, что мы должны рассматривать задачу инженерии знаний для функций вознаграждения, которая должна стать способом информирования разрабатываемых агентов о том, какие к ним предъявляются требования, как очень серьезную. • Обучение. В главах 18—20 описано, как может быть сформулирована задача обучения агента в виде задачи определения с помощью индуктивного обучения (контролируемого, неконтролируемого или основанного на подкреплении) тех функций, которые лежат в основе различных компонентов агента.

Были разработаны очень мощные логические и статистические методы, позволяющие справляться с весьма значительными проблемами, часто достигающие или превосходящие возможности человека по идентификации предсказательных шаблонов, определенных в заданном словаре. С другой стороны, в области машинного обучения достигнуты лишь весьма небольшие успехи в решении важной проблемы формирования новых представлений на уровнях абстракции, более высоких по сравнению с входным словарем.

Например, как может автономный робот выработать полезные предикаты, такие как Office и Safe, если они не будут предоставлены ему разработчиком?

Аналогичные соображения распространяются и на проблему определения с помощью обучения способа поведения; например, участие в чаепитии

HavingACupOfTea — это важное действие высокого уровня, но как ввести его в библиотеку действий, которая первоначально содержит гораздо более

простые действия, такие как RaiseArm (Поднять руку) и Swallow (Сделать глоток)? Если мы не поймем специфику таких проблем, то столкнемся с утомительной задачей построения больших баз обыденных знаний вручную.

27.2. Архитектуры агентов Возникает резонный вопрос: "Какие архитектуры агентов, описанные в главе 2, должны использоваться в агентах?" Ответом является: "Все архитектуры!" Выше было показано, что рефлексные реакции требуются в тех ситуациях, в которых существенным является фактор времени, а с другой стороны, рассуждения, основанные на знаниях, позволяют агенту планировать наперед. Полноценный агент должен быть способным выполнять и то и другое с использованием ^ гибридной архитектуры.

Одним из важных свойств гибридных архитектур является то, что границы между различными компонентами, обеспечивающими принятие решений, не постоянны.

Например, в процессе компиляции декларативная информация, полученная на уровне формирования рассуждений, последовательно преобразуется во все более эффективные представления, что позволяет в конечном итоге достичь рефлексного уровня, как показано на рис. 27.2. (В этом состоит цель обучения на основе объяснения, как описано в главе 19.) Точно такую же структуру имеют такие архитектуры агентов, как Soar [880] и Theo [1063]. После решения каждой задачи с помощью явного формирования рассуждений эти агенты сохраняют обобщенную версию полученного решения для его использования в рефлексном компоненте. Менее изученной проблемой является проблема осуществления процесса, обратного указанному, — после изменения среды рефлекс, усвоенный в результате обучения, могут оказаться больше не подходящими, и агенту может потребоваться вернуться на уровень формирования рассуждений, для того чтобы выработать новые способы поведения.

Рассуждения на основе знаний и ! i Л Система Восприятия Система рефлексного уровня Действия Рис. 27.2. Компиляция служит для преобразования результатов принятия решений на основе рассуждений в более эффективные рефлексивные механизмы. Агентам могут также потребоваться способы, позволяющие управлять своими собственными процессами формирования рассуждений. Они должны быть способными прекратить размышления, когда потребуются действия, а также должны уметь использовать время, отведенное на рассуждения, чтобы выполнить наиболее продуктивные вычисления. Например, агент-водитель такси, который обнаружил впереди картину дорожного происшествия, должен решить за долю секунды, следует ли ему затормозить или объехать то место, где случилось происшествие. Кроме того,

данный агент должен также потратить лишь долю секунды на размышление о наиболее важных в этой ситуации вопросах, например, нет ли движения на полосах слева и справа и нет ли непосредственно сзади него большого грузовика, но не задумываться над тем, что резкий маневр увеличит износ и стирание шин автомобиля или что ему давно нужно было найти очередного пассажира. Исследование таких проблем осуществляется главным образом в рамках направления $\wedge$ искусственного интеллекта реального времени. По мере того как системы искусственного интеллекта проникают во все более сложные проблемные области, все решаемые задачи становятся задачами реального времени, поскольку агенту никогда больше не отводится достаточно времени для точного решения задачи принятия решений.

Очевидно, что становится насущной потребность в методах, которые позволяют действовать в более общих ситуациях принятия решений. В последние годы появились два перспективных метода. В первом из них предусматривается использование $\wedge$ алгоритмов с отсечением по времени [357], [682]. Алгоритмом с отсечением по времени называется алгоритм, качество выходных данных которого неизменно улучшается во времени, поэтому он всегда готов предоставить приемлемое решение, когда бы ни была прервана его работа. Такие алгоритмы действуют под управлением метауровневой процедуры принятия решений, которая оценивает, стоит ли выполнять дальнейшие вычисления. Простым примером алгоритма с отсечением по времени является поиск с итеративным углублением в задачах ведения игр. Могут также быть созданы более сложные системы, состоящие из многих таких алгоритмов, действующих вместе [1647]. Вторым методом являются $\wedge$ метарассуждения на основе теории решений [683], [687], [1332]. В этом методе применяется теория ценности информации (см. главу 16) для выбора вычислений. Ценность вычислений зависит и от их стоимости (с точки зрения того, что действие не проводится, пока они осуществляются) и от их преимуществ (измеряемых с учетом того, насколько повысилось качество решения). Методы формирования метарассуждений могут использоваться для проектирования лучших алгоритмов поиска и для обеспечения гарантий того, что алгоритмы будут обладать вневременным свойством. Безусловно, подход на основе метарассуждений является дорогостоящим, а методы компиляции могут применяться таким образом, чтобы издержки были малы по сравнению со стоимостями контролируемых вычислений.

Тем не менее метарассуждения представляют собой лишь один из аспектов общей $\wedge$ рефлексивной архитектуры, т.е. архитектуры, позволяющей формировать рассуждения о вычислительных сущностях и действиях, возникающих в самой архитектуре. Теоретическую основу для рефлексивных архитектур можно заложить, определив совместное пространство состояний, складывающееся из состояний среды и вычислительного состояния самого агента. Могут быть спроектированы

алгоритмы принятия решений и обучения, которые применяются к этому совместному пространству состояний и поэтому способствуют реализации и совершенствованию вычислительной деятельности агента. Мы надеемся, что в конечном итоге такие алгоритмы, предназначенные для решения узко конкретных задач, как альфа-бета поиск и обратный логический вывод, исчезнут из систем искусственного интеллекта и будут заменены общими методами, которые направляют вычисления агента в сторону эффективного формирования высококачественных решений.

27.3. Оценка правильности выбранного направления В предыдущем разделе были перечислены многие достижения и многие возможности для дальнейшего прогресса. Но в каком направлении идет все это развитие?

Дрейфус [415] проводит аналогию с попыткой достать до луны, взбираясь на дерево; в ходе этого наблюдается постоянный прогресс до тех пор, пока не будет достигнута вершина дерева. В этом разделе мы рассмотрим, напоминает ли текущий путь развития искусственного интеллекта подъем по стволу дерева или взлет ракеты.

В главе 1 было указано, что наша цель состоит в создании агентов, которые действуют рационально, но в той же главе было также указано следующее: ...задача достижения идеальной рациональности, при которой всегда выполняются правильные действия, не осуществима. Дело в том, что при этом предъявляются слишком высокие требования к вычислительным ресурсам. Но в основной части данной книги применяется рабочая гипотеза, согласно которой идеальная рациональность является хорошей отправной точкой для анализа.

Теперь настало время определить, в чем именно состоит цель искусственного интеллекта. Мы стремимся создавать агентов, но какой спецификацией следует при этом руководствоваться? Ниже описаны четыре возможных варианта. • ^ Идеальная рациональность. Идеально рациональный агент в каждое мгновение действует таким образом, чтобы максимизировать свою ожидаемую полезность с использованием информации, полученной им из среды. Но было показано, что вычисления, необходимые для достижения идеальной рациональности, в большинстве вариантов среды требуют слишком больших затрат времени, поэтому задача обеспечения идеальной рациональности не является реалистичной. • ^ Вычислительная рациональность. Это понятие рациональности использовалось нами неявно при проектировании логических агентов и агентов, основанных на принятии решений. Вычислительно рациональный агент в конечном итоге возвращает то, что рассматривалось как рациональный выбор в начале этапа формирования им рассуждений. Такое свойство может представлять интерес, только если система используется лишь в демонстрационных целях, а в большинстве вариантов среды правильный ответ теряет свою ценность, если он не был своевременным. На практике проектировщики систем искусственного интеллекта

вынуждены искать компромисс между требованиями по обеспечению качества решений и требованиями по уменьшению затрат времени на получение приемлемой общей производительности; к сожалению, теоретические основы вычислительной рациональности не позволяют предложить достаточно обоснованного способа выработки таких компромиссов. • ^ Ограниченная рациональность. Герберт Саймон [1415] отверг идею идеальной (или даже приближенно идеальной) рациональности и предложил использовать понятие ограниченной рациональности — описательную теорию принятия решений реальными агентами. Ниже приведена цитата из его работы.

Способность человеческого разума формулировать и решать сложные задачи слишком мала по сравнению с масштабами задач, для которых требуется искать решение, чтобы осуществлять объективно рациональное поведение в реальном мире, или хотя бы добиваться приемлемого приближения к такой объективной рациональности.

Саймон выдвинул предложение, что принцип ограниченной рациональности главным образом основан на принципе непротивительности (satisficing), т.е. на том, что проведение рассуждений следует осуществлять достаточно долго лишь для того, чтобы предложить "вполне приемлемый" ответ. За указанную выше работу Саймон получил Нобелевскую премию по экономике, а позднее выпустил книгу, в которой подробно осветил все свои идеи [1418]. По-видимому, понятие непротивительности может служить полезной моделью человеческого поведения во многих случаях. Но оно не является формальной спецификацией для интеллектуальных агентов, поскольку в теории Саймона не дано определение "вполне приемлемого" ответа. Кроме того, принцип непротивительности, по-видимому, является лишь одним из широкого спектра методов, используемых для осуществления действий в условиях ограниченных ресурсов. • ^ Ограниченная оптимальность (Bounded Optimality — BO). Ограниченно оптимальный агент действует настолько хорошо, насколько это возможно, с учетом его вычислительных ресурсов. Это означает, что ожидаемая полезность программы агента для ограниченного оптимального агента является по меньшей мере такой же высокой, как и ожидаемая полезность любой другой агентской программы, работающей на том же компьютере.

По-видимому, наилучшие перспективы создания мощного теоретического фундамента для искусственного интеллекта открывает только одна из этих четырех возможностей — ограниченная оптимальность. Преимущество связанного с ней подхода состоит в том, что он является осуществимым, — всегда можно найти по меньшей мере одну наилучшую программу, а таким свойством не обладает подход с идеальной рациональностью. Ограниченно оптимальные агенты действительно применимы в реальном мире, тогда как вычислительно рациональные агенты обычно неприменимы, а агенты, действующие по принципу непротивительности,

могут оказаться применимыми или нет, в зависимости от их собственных конструктивных особенностей.

Традиционным подходом в искусственном интеллекте было то, что нужно начинать с вычислительной рациональности, а затем вырабатывать компромиссы с учетом ресурсных ограничений. Если проблемы, связанные с применением ограничений, не столь существенны, то можно надеяться на создание окончательного проекта, аналогичного проекту ограниченно оптимального агента. Но, по мере того как ресурсные ограничения становятся все более важными (например, по мере усложнения среды), может оказаться так, что два проекта станут весьма несхожими. А в теории ограниченной оптимальности эти ограничения могут учитываться в рамках целостного подхода.

До сих пор объем знаний в области ограниченной оптимальности остается не таким уж значительным. Известно, что могут быть созданы ограниченно оптимальные программы для очень простых машин и для довольно лимитированных вариантов среды [445], [1330], но еще нет полного представления о том, какими должны быть программы ВО для больших компьютеров общего назначения, применяемых в сложных вариантах среды. Если теория ограниченной оптимальности будет носить конструктивный характер, то можно рассчитывать на получение проектов ограниченно оптимальных программ, которые не слишком сильно зависят от устройства используемого компьютера.

Научные исследования стали бы весьма затруднительными, если бы увеличение объема памяти гигабайтового компьютера на несколько килобайтов привело к существенному изменению программы ВО. Одним из способов обеспечения того, чтобы это не могло

случиться, может служить небольшое ослабление критериев ограниченной оптимальности. По аналогии с понятием асимптотической сложности (приложение А) можно определить понятие $\wedge$ асимптотической ограниченной оптимальности (Asymptotic Bounded Optimality— ABO), как описано ниже [1329]. Предположим, что программа Р является ограниченно оптимальной для компьютера М в классе вариантов среды Е, тогда как сложность вариантов среды в Е не ограничена. В таком случае программа Р' обладает свойством ABO для мв Е, если она может превзойти по производительности программу Р, работая на компьютере км, который в к раз быстрее (или крупнее) по сравнению с М.

За исключением предельных значений к было бы достаточно иметь программу, обладающую свойством ABO, для нетривиальной среды в нетривиальной архитектуре. Было бы мало смысла затрачивать невероятные усилия на поиск программ ВО, а не ABO, поскольку все равно размеры и скорость доступных компьютеров увеличиваются на постоянный коэффициент через фиксированные

промежутки времени, в связи с появлением каждого нового поколения этих устройств.

Можно рискнуть предположить, что программы ВО или АВО для мощных компьютеров, действующих в сложных вариантах среды, не обязательно должны иметь простую, изящную структуру. Выше уже было показано, что для искусственного интеллекта общего назначения требуются некоторые рефлексивные способности и некоторые способности к формированию рассуждений, целый ряд форм представления знаний и принятия решений, механизмы обучения и компиляции для всех этих форм, методы управления процессом формирования рассуждений и большой запас знаний в данной конкретной области. Ограниченно оптимальный агент должен адаптироваться к той среде, в которой он находится сам, с тем чтобы в конечном итоге его внутренняя организация соответствовала возможностям оптимизации, характерным для данной конкретной среды. Можно рассчитывать лишь на указанную возможность, а такой ход развития аналогичен пути, по которому развивались гоночные автомобили с ограничениями на мощность, пока наконец не были созданы чрезвычайно сложные, но весьма эффективные проекты. По мнению авторов, наука искусственного интеллекта, основанная на понятии ограниченной оптимальности, будет способствовать интенсивному исследованию процессов, позволяющих путем последовательных итераций создавать агентские программы с ограниченной оптимальностью и, возможно, меньше сосредоточиваться на анализе того, как именно устроены создаваемые при этом программы, пусть даже не такие изящные.

Подводя итог, можно отметить, что проведение разработки понятия ограниченной оптимальности было предложено в качестве формальной задачи для исследований по искусственному интеллекту, которая не только хорошо определена, но и осуществима.

Ограниченная оптимальность определяет оптимальные программы, но не оптимальные действия. А действия в конечном итоге вырабатываются программами и с помощью программ, которые полностью зависят от замысла проектировщика.

27.4. Перспективы развития искусственного интеллекта Дэвид Лодж в своем романе *Small World* [943] об академическом мире литературной критики описал сцену, в которой главный герой вызывает замешательство среди

группы выдающихся, но несогласных друг с другом теоретиков литературы, задав им следующий вопрос: "Что было бы, если бы вы оказались правы?" Ни один из теоретиков, по-видимому, еще не задумывался над этим вопросом раньше, поскольку ведение споров по поводу неопровержимых теорий — бессмысленное занятие.

Аналогичное замешательство можно вызвать, задав исследователям в области искусственного интеллекта вопрос: "Что было бы, если бы вам удалось достичь своей цели?" Ведь искусственный интеллект демонстрирует замечательные достижения, а интеллектуальные компьютеры, безусловно, более полезны, чем неинтеллектуальные компьютеры, так о чем же беспокоиться?

Как было указано в разделе 26.3, необходимо рассмотреть некоторые этические проблемы. Интеллектуальные компьютеры являются более мощными, но будет ли эта мощь использоваться во благо или во зло? Те, кто посвящают свою жизнь разработкам в области искусственного интеллекта, ответственны за то, чтобы влияние их работы было положительным. Широта этого влияния зависит от степени успеха искусственного интеллекта. Даже первые скромные успехи в области искусственного интеллекта повлияли на то, как осуществляются преподавание компьютерных наук [1459] и разработка программного обеспечения. Благодаря искусственному интеллекту удалось создать принципиально новые приложения, такие как системы распознавания речи, системы управления запасами, интеллектуальные системы наружного наблюдения, роботы и машины поиска.

Авторы считают, что достижение в искусственном интеллекте успехов среднего уровня окажет влияние на повседневную жизнь всех слоев населения во всем мире.

До сих пор такого рода всепроникающее воздействие на общество смогли оказать лишь компьютеризированные сети связи, такие как сеть сотовой телефонной связи и Internet, а искусственный интеллект оставался в стороне. Вполне можно представить себе, что действительно полезные персональные ассистенты для офиса или дома окажут большое положительное воздействие на повышение качества повседневной жизни, хотя они в краткосрочной перспективе и могут вызвать некоторые экономические неурядицы. Кроме того, технологические возможности, открывающиеся на этом уровне, могут быть также применены для создания автономного оружия, появление которого многие считают нежелательным.

Наконец, кажется вполне вероятным, что крупномасштабный успех в создании искусственного интеллекта (появление интеллекта на уровне человека и превосходящего его) повлияет на существование большинства представителей рода человеческого. Изменится сам характер нашей работы и развлечений, так же как и наши представления об интеллекте, сознании и будущей судьбе человечества. На этом уровне системы искусственного интеллекта могут создать более непосредственную угрозу самоопределению, свободе и даже выживанию людей. По этим причинам нельзя рассматривать исследования в области искусственного интеллекта в отрыве от их этических последствий.

Каким мы видим будущее? Авторы научно-фантастических романов, повидимому, чаще публикуют пессимистические, а не оптимистические сценарии грядущего,

возможно, потому, что это позволяет сочинять более увлекательные сюжеты. Но создается впечатление, что искусственный интеллект пока развивается по такому же принципу, как и другие революционные технологии (типографское дело, инженерное оборудование, воздухоплавание, телефония и т.д.), отрицательные последствия внедрения которых перевешиваются положительными результатами.

В заключение следует отметить, что за свою короткую историю искусственный интеллект добился существенного прогресса, но последнее утверждение из эссе Алана Тьюринга *Computing Machinery and Intelligence* продолжает оставаться неоспоримым и в наши дни.

Мы способны заглянуть вперед лишь на очень короткое расстояние, но все равно можем увидеть, как много еще предстоит сделать.